Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 1)

问题 1

题目

你最近创建了一个新的Google Cloud项目。在测试可以从Cloud Shell提交Vertex AI Pipeline作业后，你想使用Vertex AI Workbench用户管理的笔记本实例从该实例运行代码。你创建了实例并运行了代码，但这次作业因权限不足错误而失败。你应该怎么做？

You recently created a new Google Cloud project. After testing that you can submit a Vertex AI Pipeline job from the Cloud Shell, you want to use a Vertex AI Workbench user-managed notebook instance to run your code from that instance. You created the instance and ran the code but this time the job fails with an insufficient permissions error. What should you do?

选项

A. 确保你创建的Workbench实例与你将使用的Vertex AI Pipelines资源位于同一区域。

Ensure that the Workbench instance that you created is in the same region of the Vertex AI Pipelines resources you will use.

B. 确保Vertex AI Workbench实例与你将使用的Vertex AI Pipeline资源位于同一子网络上。

Ensure that the Vertex AI Workbench instance is on the same subnetwork of the Vertex AI Pipeline resources that you will use.

C. 确保Vertex AI Workbench实例被分配了身份和访问管理(IAM) Vertex AI User角色。

Ensure that the Vertex AI Workbench instance is assigned the Identity and Access Management (IAM) Vertex AI User role.

D. 确保Vertex AI Workbench实例被分配了身份和访问管理(IAM) Notebooks Runner角色。

Ensure that the Vertex AI Workbench instance is assigned the Identity and Access Management (IAM) Notebooks Runner role.

正确答案：C. Ensure that the Vertex AI Workbench instance is assigned the Identity and Access Management (IAM) Vertex AI User role.

解析： 这是一个典型的IAM权限问题。当您从Cloud Shell运行代码时，它使用的是您的用户凭证，这些凭证可能具有足够的权限。但是，当从Vertex AI Workbench实例运行时，代码使用的是附加到该实例的服务账号，而该账号似乎缺少与Vertex AI Pipelines交互所需的权限。

错误明确提到了"insufficient permissions"（权限不足），这指向了IAM问题。Vertex AI User角色包含提交和管理Vertex AI Pipeline作业所需的必要权限。

选项A和B涉及网络和区域配置，而非权限问题。选项D提到的Notebooks Runner角色更多是关于执行笔记本代码，而不是访问Vertex AI Pipeline服务。

问题 2

题目

你在一家半导体制造公司工作。你需要创建一个实时应用程序来自动化质量控制流程。在装配线末端，会实时拍摄每个半导体的高清图像。这些照片会上传到Cloud Storage存储桶，同时上传表格数据，包括每个半导体的批次号、序列号、尺寸和重量。你需要配置模型训练和服务，同时最大化模型准确性。你应该怎么做？

You work for a semiconductor manufacturing company. You need to create a real-time application that automates the quality control process. High-definition images of each semiconductor are taken at the end of the assembly line in real time. The photos are uploaded to a Cloud Storage bucket along with tabular data that includes each semiconductor's batch number, serial number, dimensions, and weight. You need to configure model training and serving while maximizing model accuracy. What should you do?

选项

A. 使用Vertex AI数据标注服务标注图像，并训练AutoML图像分类模型。部署模型，并配置Pub/Sub在图像被分类为失败类时发布消息。

Use Vertex AI Data Labeling Service to label the images, and train an AutoML image classification model. Deploy the model, and configure Pub/Sub to publish a message when an image is categorized into the failing class.

B. 使用Vertex AI数据标注服务标注图像，并训练AutoML图像分类模型。安排每日批量预测作业，在作业完成时发布Pub/Sub消息。

Use Vertex AI Data Labeling Service to label the images, and train an AutoML image classification model. Schedule a daily batch prediction job that publishes a Pub/Sub message when the job completes.

C. 将图像转换为嵌入表示。将此数据导入BigQuery，并训练BigQuery ML K-means聚类模型，设置两个聚类。部署模型并配置Pub/Sub，在半导体数据被分类到失败聚类时发布消息。

Convert the images into an embedding representation. Import this data into BigQuery, and train a BigQuery ML K-means clustering model with two clusters. Deploy the model and configure Pub/Sub to publish a message when a semiconductor's data is categorized into the failing cluster.

D. 将表格数据导入BigQuery，使用Vertex AI数据标注服务标注数据并训练AutoML表格分类模型。部署模型，并配置Pub/Sub在半导体数据被分类为失败类时发布消息。

Import the tabular data into BigQuery, use Vertex AI Data Labeling Service to label the data and train an AutoML tabular classification model. Deploy the model, and configure Pub/Sub to publish a message when a semiconductor's data is categorized into the failing class.

正确答案：A. Use Vertex AI Data Labeling Service to label the images, and train an AutoML image classification model. Deploy the model, and configure Pub/Sub to publish a message when an image is categorized into the failing class.

解析： 这个场景需要实时质量控制，基于高清图像和表格数据来识别有缺陷的半导体。

选项A使用图像数据（关键的质量控制视觉信息），实现实时预测和即时通知，使用AutoML提供高准确性，并且符合实时应用的需求。

选项B使用每日批量预测，不是实时的，无法满足生产线上的实时质量控制需求，会导致生产过程中的延迟。

选项C使用K-means聚类是无监督学习，可能不如有监督方法准确，嵌入表示会丢失部分图像信息，可能无法像AutoML那样最大化模型准确性。

选项D忽略了图像数据，而图像对于质量控制至关重要，仅使用表格元数据，可能无法检测到视觉缺陷。维度和重量等数据可能无法反映所有质量问题。

问题 3

题目

你在一家快速增长的社交媒体公司工作。你的团队在本地CPU集群上构建TensorFlow推荐模型。数据包含数十亿历史用户事件和10万个分类特征。你注意到随着数据增加，模型训练时间也在增加。你计划将模型迁移到Google Cloud。你想使用最可扩展的方法，同时最小化训练时间。你应该怎么做？

You work for a rapidly growing social media company. Your team builds TensorFlow recommender models in an on-premises CPU cluster. The data contains billions of historical user events and 100,000 categorical features. You notice that as the data increases, the model training time increases. You plan to move the models to Google Cloud. You want to use the most scalable approach that also minimizes training time. What should you do?

选项

A. 使用带有TPUv3 Pod切片的TPU虚拟机部署训练作业，并使用TPUEmbeading API。

Deploy the training jobs by using TPU VMs with TPUv3 Pod slices, and use the TPUEmbeading API

B. 在带有CPU的自动扩展Google Kubernetes Engine集群中部署训练作业。

Deploy the training jobs in an autoscaling Google Kubernetes Engine cluster with CPUs

C. 使用BigQuery ML部署矩阵分解模型训练作业。

Deploy a matrix factorization model training job by using BigQuery ML

D. 使用带有A100 GPU的Compute Engine实例部署训练作业，并使用tf.nn.embedding_lookup API。

Deploy the training jobs by using Compute Engine instances with A100 GPUs, and use the tf.nn.embedding_lookup API

正确答案：A. Deploy the training jobs by using TPU VMs with TPUv3 Pod slices, and use the TPUEmbeading API

解析： 对于具有10万个分类特征和数十亿用户事件的推荐系统，嵌入表会非常大。这正是TPU发挥优势的场景，特别是使用TPUEmbedding API，它专为大规模嵌入操作而优化。

TPU是专为机器学习工作负载设计的专用硬件加速器。TPUEmbedding API专为处理大规模嵌入操作而设计，这对于有大量分类特征的推荐模型至关重要。TPU Pod切片允许在多个TPU芯片上进行分布式训练。TPU在大规模嵌入查找操作方面表现出色，这是推荐系统的核心操作。

选项B使用常规CPU可能面临与当前本地CPU集群类似的限制，不能从根本上解决大型嵌入表的计算瓶颈。

选项C的BigQuery ML提供简单的模型训练，但对模型复杂性和定制化有限制。矩阵分解是比深度学习推荐模型更简单的方法，可能无法支持现有TensorFlow模型的全部复杂性。

选项D的A100 GPU对通用ML工作负载很强大，但对于特别大的嵌入操作，它们可能不如TPU高效。这种方法比CPU快，但可能不如TPU优化。

问题 4

题目

你正在使用Vertex AI Pipelines、Vertex AI Training、Vertex AI Experiments和Vertex AI Endpoints训练和部署表格数据回归模型的更新版本。模型部署在Vertex AI端点中，你的用户通过使用Vertex AI端点调用模型。你希望在特征数据分布发生显著变化时收到电子邮件，以便重新触发训练管道并部署模型的更新版本。你应该怎么做？

You are training and deploying updated versions of a regression model with tabular data by using Vertex AI Pipelines, Vertex AI Training, Vertex AI Experiments, and Vertex AI Endpoints. The model is deployed in a Vertex AI endpoint, and your users call the model by using the Vertex AI endpoint. You want to receive an email when the feature data distribution changes significantly, so you can retrigger the training pipeline and deploy an updated version of your model. What should you do?

选项

A. 使用Vertex AI模型监控。在端点上启用预测漂移监控，并指定通知电子邮件。

Use Vertex AI Model Monitoring. Enable prediction drift monitoring on the endpoint, and specify a notification email.

B. 在Cloud Logging中，使用Vertex AI端点中的日志创建基于日志的警报。配置Cloud Logging在触发警报时发送电子邮件。

In Cloud Logging, create a logs-based alert using the logs in the Vertex AI endpoint. Configure Cloud Logging to send an email when the alert is triggered.

C. 在Cloud Monitoring中创建基于日志的指标和指标阈值警报。配置Cloud Monitoring在触发警报时发送电子邮件。

In Cloud Monitoring create a logs-based metric and a threshold alert for the metric. Configure Cloud Monitoring to send an email when the alert is triggered.

D. 将端点的容器日志导出到BigQuery。创建Cloud Function运行SQL查询来分析导出的日志并发送电子邮件。使用Cloud Scheduler触发Cloud Function。

Export the container logs of the endpoint to BigQuery. Create a Cloud Function to run a SQL query over the exported logs and send an email. Use Cloud Scheduler to trigger the Cloud Function.

正确答案：A. Use Vertex AI Model Monitoring. Enable prediction drift monitoring on the endpoint, and specify a notification email.

解析： Vertex AI Model Monitoring是专门设计用来监控ML模型的数据漂移的。它可以监控输入特征分布的变化（feature skew/drift），支持配置电子邮件通知，这是Vertex AI的内置功能，专为此场景设计，不需要额外的自定义开发或基础架构组件。

选项B的Cloud Logging捕获日志但不专门分析数据漂移，从普通日志中检测特征分布变化非常困难，不提供统计分析功能来比较特征分布，这是一个通用的日志监控解决方案，不针对ML模型的特征分布。

选项C与选项B类似，但基于指标，需要自定义指标定义和阈值设置，不专门用于ML特征漂移检测，会缺少正确漂移检测所需的更深入的统计分析。

选项D是一个复杂的自定义解决方案，涉及多个组件，需要编写自定义分析代码进行漂移检测，维护成本高且容易出错，SQL查询可能不是执行特征分布统计分析的最佳方式。

问题 5

题目

你已经训练了一个计划在Vertex AI上部署用于在线预测的XGBoost模型。你现在正在将模型上传到Vertex AI模型注册表，并且需要配置解释方法，该方法将以最小延迟返回在线预测请求。你还希望在模型的特征归因随时间发生有意义变化时收到警报。你应该怎么做？

You have trained an XGBoost model that you plan to deploy on Vertex AI for online prediction. You are now uploading your model to Vertex AI Model Registry, and you need to configure the explanation method that will serve online prediction requests to be returned with minimal latency. You also want to be alerted when feature attributions of the model meaningfully change over time. What should you do?

选项

A. 1. 指定采样Shapley作为解释方法，路径计数为5。 2. 将模型部署到Vertex AI端点。 3. 创建使用预测漂移作为监控目标的模型监控作业。

1. Specify sampled Shapley as the explanation method with a path count of 5.
2. Deploy the model to Vertex AI Endpoints.
3. Create a Model Monitoring job that uses prediction drift as the monitoring objective.

B. 1. 指定集成梯度作为解释方法，路径计数为5。 2. 将模型部署到Vertex AI端点。 3. 创建使用预测漂移作为监控目标的模型监控作业。

1. Specify Integrated Gradients as the explanation method with a path count of 5.
2. Deploy the model to Vertex AI Endpoints.
3. Create a Model Monitoring job that uses prediction drift as the monitoring objective.

C. 1. 指定采样Shapley作为解释方法，路径计数为50。 2. 将模型部署到Vertex AI端点。 3. 创建使用训练-服务偏差作为监控目标的模型监控作业。

1. Specify sampled Shapley as the explanation method with a path count of 50.
2. Deploy the model to Vertex AI Endpoints.
3. Create a Model Monitoring job that uses training-serving skew as the monitoring objective.

D. 1. 指定集成梯度作为解释方法，路径计数为50。 2. 将模型部署到Vertex AI端点。 3. 创建使用训练-服务偏差作为监控目标的模型监控作业。

1. Specify Integrated Gradients as the explanation method with a path count of 50.
2. Deploy the model to Vertex AI Endpoints.
3. Create a Model Monitoring job that uses training-serving skew as the monitoring objective.

正确答案：A. 1. Specify sampled Shapley as the explanation method with a path count of 5. 2. Deploy the model to Vertex AI Endpoints. 3. Create a Model Monitoring job that uses prediction drift as the monitoring objective.

解析： 由于您使用的是XGBoost树模型，Sampled Shapley比Integrated Gradients更高效。为了最小化延迟，应选择较低的路径计数(5)。要监控特征归因的变化，预测漂移监控比训练-服务偏差更适合。

解释方法比较：

- Sampled Shapley：适用于树模型(如XGBoost)，计算效率高
- Integrated Gradients：更适合神经网络，对树模型计算开销大

路径计数(path count)比较：

- 路径计数=5：采样更少路径，计算更快，延迟更低
- 路径计数=50：采样更多路径，解释更准确但计算更慢

监控目标比较：

- 预测漂移(prediction drift)：监控模型输出和特征分布随时间的变化
- 训练-服务偏差(training-serving skew)：监控训练数据与服务数据之间的差异

问题 6

题目

你在一家游戏创业公司工作，该公司在Cloud Storage中有几TB的结构化数据。这些数据包括游戏时间数据、用户元数据和游戏元数据。你想构建一个向用户推荐新游戏的模型，该模型需要最少的编码工作。你应该怎么做？

You work at a gaming startup that has several terabytes of structured data in Cloud Storage. This data includes gameplay time data, user metadata, and game metadata. You want to build a model that recommends new games to users that requires the least amount of coding. What should you do?

选项

A. 将数据加载到BigQuery中。使用BigQuery ML训练自编码器模型。

Load the data in BigQuery. Use BigQuery ML to train an Autoencoder model.

B. 将数据加载到BigQuery中。使用BigQuery ML训练矩阵分解模型。

Load the data in BigQuery. Use BigQuery ML to train a matrix factorization model.

C. 将数据读取到Vertex AI Workbench笔记本中。使用TensorFlow训练双塔模型。

Read data to a Vertex AI Workbench notebook. Use TensorFlow to train a two-tower model.

D. 将数据读取到Vertex AI Workbench笔记本中。使用TensorFlow训练矩阵分解模型。

Read data to a Vertex AI Workbench notebook. Use TensorFlow to train a matrix factorization model.

正确答案：B. Load the data in BigQuery. Use BigQuery ML to train a matrix factorization model.

解析： 这个问题的关键是找到构建游戏推荐模型所需编码最少的方法。

BigQuery ML支持使用简单的SQL语句创建和训练模型。矩阵分解是推荐系统的标准方法，特别适合用户-物品交互数据。BigQuery ML专门提供了用于推荐的矩阵分解模型，只需几行SQL代码就能创建和训练模型，可以直接处理TB级数据而无需复杂的数据工程。

选项A的Autoencoder模型通常用于降维和异常检测，虽然可以用于推荐系统，但这不是它的主要用途，对于推荐任务，配置和优化Autoencoder需要更多的专业知识。

选项C和D需要编写数据加载代码，需要使用TensorFlow实现模型，编码需求比BigQuery ML选项高。

例如，使用BigQuery ML创建矩阵分解推荐模型只需类似这样的SQL：

```
CREATE MODEL `project.dataset.game_recommender`
OPTIONS(model_type='matrix_factorization',
        user_col='user_id',
        item_col='game_id',
        rating_col='play_time',
        l2_reg=0.2,
        num_factors=20)
AS SELECT user_id, game_id, play_time
FROM `project.dataset.gameplay_data`
```

问题 7

题目

你在一家大型银行工作，该银行通过在美国和新加坡运行的托管在Google Cloud上的应用程序为客户提供服务。你开发了一个PyTorch模型来将交易分类为潜在欺诈或非欺诈。该模型是一个三层感知器，使用数值和分类特征作为输入，哈希处理在模型内进行。你已将模型部署到us-central1区域的nl-highcpu-16机器上，预测实时提供。模型当前的中位响应延迟为40毫秒。你想减少延迟，特别是在新加坡，那里的一些客户正经历最长的延迟。你应该怎么做？

You work for a large bank that serves customers through an application hosted in Google Cloud that is running in the US and Singapore. You have developed a PyTorch model to classify transactions as potentially fraudulent or not. The model is a three-layer perceptron that uses both numerical and categorical features as input, and hashing happens within the model. You deployed the model to the us-central1 region on nl-highcpu-16 machines, and predictions are served in real time. The model's current median response latency is 40 ms. You want to reduce latency, especially in Singapore, where some customers are experiencing the longest delays. What should you do?

选项

A. 为用于在线推理的机器附加NVIDIA T4 GPU。

Attach an NVIDIA T4 GPU to the machines being used for online inference.

B. 将用于在线推理的机器更改为nl-highcpu-32。

Change the machines being used for online inference to nl-highcpu-32.

C. 在us-central1和asia-southeast1区域将模型部署到Vertex AI私有端点，并允许应用程序选择适当的端点。

Deploy the model to Vertex AI private endpoints in the us-central1 and asia-southeast1 regions, and allow the application to choose the appropriate endpoint.

D. 在asia-southeast1区域创建另一个Vertex AI端点，并允许应用程序选择适当的端点。

Create another Vertex AI endpoint in the asia-southeast1 region, and allow the application to choose the appropriate endpoint.

正确答案：D. Create another Vertex AI endpoint in the asia-southeast1 region, and allow the application to choose the appropriate endpoint.

解析： 这个问题考察的是如何减少跨地域部署的机器学习模型的延迟问题，特别是针对远距离用户。

在新加坡附近区域(asia-southeast1)部署额外的端点，应用程序可以将新加坡用户的请求路由到地理位置更近的端点，显著减少网络传输延迟。这比单纯增加计算资源(选项A和B)或使用更复杂的私有端点(选项C)更能解决实际问题。

对于简单的三层感知器模型，GPU加速或增加CPU核心可能带来的性能提升有限。当前40ms的延迟对于计算部分已经相当不错，瓶颈可能在网络传输。

问题 8

题目

你需要在小型数据集上训练XGBoost模型。你的训练代码需要自定义依赖项。你想最小化训练作业的启动时间。你应该如何设置Vertex AI自定义训练作业？

You need to train an XGBoost model on a small dataset. Your training code requires custom dependencies. You want to minimize the startup time of your training job. How should you set up your Vertex AI custom training job?

选项

A. 将数据存储在Cloud Storage存储桶中，并创建带有训练应用程序的自定义容器。在训练应用程序中，从Cloud Storage读取数据并训练模型。

Store the data in a Cloud Storage bucket, and create a custom container with your training application. In your training application, read the data from Cloud Storage and train the model.

B. 使用XGBoost预构建的自定义容器。创建包含数据并在运行时安装依赖项的Python源代码分发包。在训练应用程序中，将数据加载到pandas DataFrame中并训练模型。

Use the XGBoost prebuilt custom container. Create a Python source distribution that includes the data and installs the dependencies at runtime. In your training application, load the data into a pandas DataFrame and train the model.

C. 创建包含数据的自定义容器。在训练应用程序中，将数据加载到pandas DataFrame中并训练模型。

Create a custom container that includes the data. In your training application, load the data into a pandas DataFrame and train the model.

D. 将数据存储在Cloud Storage存储桶中，并使用XGBoost预构建的自定义容器运行训练应用程序。创建在运行时安装依赖项的Python源代码分发包。在训练应用程序中，从Cloud Storage读取数据并训练模型。

Store the data in a Cloud Storage bucket, and use the XGBoost prebuilt custom container to run your training application. Create a Python source distribution that installs the dependencies at runtime. In your training application, read the data from Cloud Storage and train the model.

正确答案：C. Create a custom container that includes the data. In your training application, load the data into a pandas DataFrame and train the model.

解析： 这道题要求在Vertex AI上设置XGBoost模型训练任务，重点是最小化启动时间。

创建包含数据的自定义容器，所有内容（代码、依赖、数据）都预先打包在容器中，运行时无需额外安装步骤。对于小数据集，将其包含在容器中不会显著增加容器大小，避免了运行时从Cloud Storage下载数据和安装依赖的时间。

这种方法虽然前期准备时间较长（构建容器），但一旦设置好，实际训练作业的启动时间会最短，因为一切都已准备就绪。

创建自定义容器需要相当长的时间，但这个过程只需要执行一次。关键是在训练作业启动时最小化启动时间，而不是整个准备过程的时间。

问题 9

题目

你正在创建一个使用不同Google Cloud服务进行数据处理、模型训练和模型部署的ML流水线。你已经为每个单独的任务开发了代码，并且预计会有高频率的新文件。现在你需要在这些任务之上创建一个编排层。你只希望在数据集中的Cloud Storage存储桶中存在新文件时才运行此编排流水线。你还希望最小化计算节点成本。你应该怎么做？

You are creating an ML pipeline for data processing, model training, and model deployment that uses different Google Cloud services. You have developed code for each individual task, and you expect a high frequency of new files. You now need to create an orchestration layer on top of these tasks. You only want this orchestration pipeline to run if new files are present in your dataset in a Cloud Storage bucket. You also want to minimize the compute node costs. What should you do?

选项

A. 在Vertex AI Pipelines中创建一个流水线。配置第一步来比较存储桶内容与上次运行流水线时的内容。使用调度器API定期运行流水线。

Create a pipeline in Vertex AI Pipelines. Configure the first step to compare the contents of the bucket to the last time the pipeline was run. Use the scheduler API to run the pipeline periodically.

B. 创建一个使用Cloud Storage触发器的Cloud Function，部署Cloud Composer有向无环图(DAG)。

Create a Cloud Function that uses a Cloud Storage trigger and deploys a Cloud Composer directed acyclic graph (DAG).

C. 在Vertex AI Pipelines中创建一个流水线。创建一个使用Cloud Storage触发器的Cloud Function，部署该流水线。

Create a pipeline in Vertex AI Pipelines. Create a Cloud Function that uses a Cloud Storage trigger and deploys the pipeline.

D. 部署带有GCSObjectUpdateSensor类的Cloud Composer有向无环图(DAG)，该类检测何时向Cloud Storage存储桶添加新文件。

Deploy a Cloud Composer directed acyclic graph (DAG) with a GCSObjectUpdateSensor class that detects when a new file is added to the Cloud Storage bucket.

正确答案：C. Create a pipeline in Vertex AI Pipelines. Create a Cloud Function that uses a Cloud Storage trigger and deploys the pipeline.

解析： 在所有选项中，C最能满足最小化计算节点成本的要求，因为：

1. 使用无服务器Cloud Function，只有在触发时才产生成本
2. Vertex AI Pipeline只在有新文件时才会部署和运行
3. 完全事件驱动，没有持续运行的计算资源
4. 能有效处理高频率的新文件情况

选项A使用定期轮询方式检查新文件，即使没有新文件，也会定期启动计算资源运行管道的第一步，不是事件驱动的，会产生不必要的计算成本。

选项B会部署整个Cloud Composer环境(基于Airflow)，Cloud Composer需要持续运行的集群，即使没有工作负载也会产生计算成本，对于仅需要在新文件到达时运行的场景，这是过度设计。

选项D使用Cloud Composer(Airflow)持续运行检测新文件，需要持续运行的计算资源来支持传感器检测，即使没有工作负载，基础Airflow集群也会产生持续计算成本。

问题 10

题目

你正在使用Kubeflow Pipelines开发基于PyTorch的端到端MLOps流水线。该流水线从BigQuery读取数据，处理数据，进行特征工程、模型训练、模型评估，并将模型作为二进制文件部署到Cloud Storage。你正在为特征工程和模型训练步骤的多个不同版本编写代码，并在Vertex AI Pipelines中运行每个新版本。每次流水线运行需要超过一小时才能完成。你想加快流水线执行以减少开发时间，并且你想避免额外成本。你应该怎么做？

You are using Kubeflow Pipelines to develop an end-to-end PyTorch-based MLOps pipeline. The pipeline reads data from BigQuery, processes the data, conducts feature engineering, model training, model evaluation, and deploys the model as a binary file to Cloud Storage. You are writing code for several different versions of the feature engineering and model training steps, and running each new version in Vertex AI Pipelines. Each pipeline run is taking over an hour to complete. You want to speed up the pipeline execution to reduce your development time, and you want to avoid additional costs. What should you do?

选项

A. 注释掉你当前未更新的流水线部分。

Comment out the part of the pipeline that you are not currently updating.

B. 在Kubeflow流水线的所有步骤中启用缓存。

Enable caching in all the steps of the Kubeflow pipeline.

C. 将特征工程委托给BigQuery，并从流水线中移除它。

Delegate feature engineering to BigQuery and remove it from the pipeline.

D. 为模型训练步骤添加GPU。

Add a GPU to the model training step.

正确答案：B. Enable caching in all the steps of the Kubeflow pipeline.

解析： Kubeflow的缓存机制是为迭代开发场景设计的，能够在维持端到端完整性的同时大幅减少开发周期。

启用缓存的优点：

- 如果步骤的输入没有变化，直接使用缓存的结果而不重新计算
- 只有修改过的步骤和受影响的下游步骤需要重新运行
- 保持了端到端流水线的完整性
- 不需要额外计算资源，仅使用少量存储空间
- 特别适合迭代开发场景

选项A注释掉部分管道会打破端到端测试的完整性，可能导致集成问题，需要频繁修改代码来添加/删除注释，容易引入错误或遗漏关键依赖。

选项C将特征工程委托给BigQuery是架构变更，不是简单的优化，需要重写代码，可能产生额外的BigQuery处理费用，不解决模型训练优化问题。

选项D添加GPU会显著增加成本，明确违反了"避免额外成本"的要求。

虽然技术上来说缓存确实需要一些存储资源，但在成本核算上这被认为是微不足道的，尤其与节省的计算资源和开发时间相比。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 2)

问题 11

题目

你在一家最近在西班牙开始运营的跨国组织工作。你组织内的团队需要处理各种西班牙文档，如商业、法律和财务文档。你想使用机器学习帮助你的组织快速获得准确的翻译，并且付出最少的努力。你的组织不需要特定领域的术语或行话。你应该怎么做？

You work for a multinational organization that has recently begun operations in Spain. Teams within your organization will need to work with various Spanish documents, such as business, legal, and financial documents. You want to use machine learning to help your organization get accurate translations quickly and with the least effort. Your organization does not require domain-specific terms or jargon. What should you do?

选项

A. 创建Vertex AI Workbench笔记本实例。在笔记本中，从文档中提取句子，并训练自定义AutoML文本模型。

Create a Vertex AI Workbench notebook instance. In the notebook, extract sentences from the documents, and train a custom AutoML text model.

B. 使用Google Translate将1000个短语从西班牙语翻译成英语。使用这些翻译对，训练自定义AutoML Translation模型。

Use Google Translate to translate 1,000 phrases from Spanish to English. Using these translated pairs, train a custom AutoML Translation model.

C. 使用Cloud Translation API的Document Translation功能翻译文档。

Use the Document Translation feature of the Cloud Translation API to translate the documents.

D. 创建Vertex AI Workbench笔记本实例。在笔记本中，将西班牙文档转换为纯文本，并创建自定义TensorFlow seq2seq翻译模型。

Create a Vertex AI Workbench notebook instance. In the notebook, convert the Spanish documents into plain text, and create a custom TensorFlow seq2seq translation model.

正确答案：C. Use the Document Translation feature of the Cloud Translation API to translate the documents.

解析： 使用Cloud Translation API的Document Translation功能是唯一满足"准确、快速、最少工作量"要求的选项。Document Translation专为处理格式化文档而设计，能保留文档布局，这对商业和法律文档尤为重要。当不需要处理特定领域术语时，使用Google已经训练好的强大翻译模型是最明智的选择。

选项A和D需要大量的开发工作和训练数据，与"最少工作量"的要求不符。选项B需要手动创建翻译数据集并训练模型，但在不需要领域特定术语的情况下，这是不必要的工作。

问题 12

题目

你有一个每周在Vertex AI上运行的自定义作业。该作业使用专有的ML工作流实现，生成数据集、模型和自定义构件，并将它们发送到Cloud Storage存储桶。创建了许多不同版本的数据集和模型。由于合规要求，你的公司需要跟踪哪个模型用于做出特定预测，并需要访问每个模型的构件。你应该如何配置工作流以满足这些要求？

You have a custom job that runs on Vertex AI on a weekly basis. The job is implemented using a proprietary ML workflow that produces the datasets, models, and custom artifacts, and sends them to a Cloud Storage bucket. Many different versions of the datasets and models were created. Due to compliance requirements, your company needs to track which model was used for making a particular prediction, and needs access to the artifacts for each model. How should you configure your workflows to meet these requirements?

选项

A. 在自定义作业中使用Vertex AI Metadata API为每个模型创建上下文、执行和构件，并使用事件将它们链接在一起。

Use the Vertex AI Metadata API inside the custom job to create context, execution, and artifacts for each model, and use events to link them together.

B. 创建Vertex AI实验，并在自定义作业内启用自动日志记录。

Create a Vertex AI experiment, and enable autologging inside the custom job.

C. 配置TensorFlow Extended (TFX) ML Metadata数据库，并使用ML Metadata API。

Configure a TensorFlow Extended (TFX) ML Metadata database, and use the ML Metadata API.

D. 在Vertex AI Model Registry中注册每个模型，并使用模型标签存储相关的数据集和模型信息。

Register each model in Vertex AI Model Registry, and use model labels to store the related dataset and model information.

正确答案：A. Use the Vertex AI Metadata API inside the custom job to create context, execution, and artifacts for each model, and use events to link them together.

解析： Vertex AI Metadata API专为满足ML合规性要求而设计，能够记录完整的数据和模型谱系，跟踪哪个模型用于特定预测，维护所有相关构件的访问权限，并建立模型、数据集和其他构件之间的关系。

选项B的Vertex AI实验主要用于比较不同训练运行，自动记录专注于捕获指标和参数，不提供用于合规性的完整谱系跟踪。

选项C需要设置和管理单独的数据库，与Vertex AI生态系统分离，与已在Vertex AI上运行的作业不协调，需要额外的集成工作。

选项D的Model Registry主要用于模型版本控制和部署，标签是简单的键值对，难以表达复杂的谱系关系，不提供详细的构件跟踪。

问题 13

题目

你最近使用神经网络开发了一个用于图像分类的自定义模型。你需要自动识别学习率、层数和核大小的值。为此，你计划并行运行多个作业，以确定优化性能的参数。你希望最小化自定义代码开发和基础设施管理。你应该怎么做？

You have recently developed a custom model for image classification by using a neural network. You need to automatically identify the values for learning rate, number of layers, and kernel size. To do this, you plan to run multiple jobs in parallel to identify the parameters that optimize performance. You want to minimize custom code development and infrastructure management. What should you do?

选项

A. 训练AutoML图像分类模型。

Train an AutoML image classification model.

B. 创建使用Vertex AI Vizier SDK进行参数优化的自定义训练作业。

Create a custom training job that uses the Vertex AI Vizier SDK for parameter optimization.

C. 创建Vertex AI超参数调优作业。

Create a Vertex AI hyperparameter tuning job.

D. 创建并行运行不同模型训练作业的Vertex AI流水线。

Create a Vertex AI pipeline that runs different model training jobs in parallel.

正确答案：C. Create a Vertex AI hyperparameter tuning job.

解析： Vertex AI超参数调优是专为此类任务设计的服务，自动处理并行作业编排和执行，内置智能搜索算法，提高参数优化效率，只需要最少的代码修改和配置，不需要管理任何基础设施，能够直接优化题目中提到的所有参数（学习率、层数、核大小）。

选项A的AutoML会替换掉已经开发的自定义模型，不允许优化特定的神经网络参数。

选项B的Vertex AI Vizier SDK需要编写自定义代码来集成，需要更多的开发工作，不符合"最小化自定义代码开发"的要求。

选项D需要设计和实现完整的管道逻辑，需要编写代码来生成参数组合、安排作业和评估结果，不符合"最小化自定义代码开发"的要求。

问题 14

题目

你在一个维护基于云的通信平台的组织工作，该平台将传统聊天、语音和视频会议集成到一个平台中。音频录音存储在Cloud Storage中。所有录音都有8 kHz采样率，且长度超过一分钟。你需要在平台中实现一个新功能，将语音通话录音自动转录为文本，用于未来的应用，如通话摘要和情感分析。根据Google推荐的最佳实践，你应该如何实现语音通话转录功能？

You work at an organization that maintains a cloud-based communication platform that integrates conventional chat, voice, and video conferencing into one platform. The audio recordings are stored in Cloud Storage. All recordings have an 8 kHz sample rate and are more than one minute long. You need to implement a new feature in the platform that will automatically transcribe voice call recordings into a text for future applications, such as call summarization and sentiment analysis. How should you implement the voice call transcription feature following Google-recommended best practices?

选项

A. 使用原始音频采样率，并使用Speech-to-Text API的同步识别转录音频。

Use the original audio sampling rate, and transcribe the audio by using the Speech-to-Text API with synchronous recognition.

B. 使用原始音频采样率，并使用Speech-to-Text API的异步识别转录音频。

Use the original audio sampling rate, and transcribe the audio by using the Speech-to-Text API with asynchronous recognition.

C. 将音频录音上采样到16 kHz，并使用Speech-to-Text API的同步识别转录音频。

Upsample the audio recordings to 16 kHz, and transcribe the audio by using the Speech-to-Text API with synchronous recognition.

D. 将音频录音上采样到16 kHz，并使用Speech-to-Text API的异步识别转录音频。

Upsample the audio recordings to 16 kHz, and transcribe the audio by using the Speech-to-Text API with asynchronous recognition.

正确答案：B. Use the original audio sampling rate, and transcribe the audio by using the Speech-to-Text API with asynchronous recognition.

解析： 根据Google Speech-to-Text API文档，对于超过1分钟的音频文件，必须使用异步识别。同时，对于已有的8kHz采样率的录音（特别是电话类音频），Google明确建议不要上采样到16kHz，而是保持原始采样率。

文档明确指出："If your audio data has already been recorded at an existing sample rate other than 16000 Hz, do not resample your audio to 16000 Hz. Most legacy telephony audio, for example, use sample rates of 8000 Hz, which may give less accurate results. If you must use such audio, provide the audio to the Speech API at its native sample rate."

同步识别限制为最多1分钟的音频，而题目中提到录音"more than one minute long"，因此必须使用异步识别。

问题 15

题目

你在一家最近决定将ML和数据工作负载迁移到Google Cloud的大型组织工作。数据工程团队已将结构化数据以Avro格式导出到Cloud Storage存储桶中。你需要提出一个工作流，该工作流执行分析、创建特征，并托管ML模型用于在线预测的特征。你应该如何配置流水线？

You work at a large organization that recently decided to move their ML and data workloads to Google Cloud. The data engineering team has exported the structured data to a Cloud Storage bucket in Avro format. You need to propose a workflow that performs analytics, creates features, and hosts the features that your ML models use for online prediction. How should you configure the pipeline?

选项

A. 将Avro文件摄入Cloud Spanner进行分析。使用Dataflow流水线创建特征，并将它们存储在Vertex AI Feature Store中用于在线预测。

Ingest the Avro files into Cloud Spanner to perform analytics. Use a Dataflow pipeline to create the features, and store them in Vertex AI Feature Store for online prediction.

B. 将Avro文件摄入BigQuery进行分析。使用Dataflow流水线创建特征，并将它们存储在Vertex AI Feature Store中用于在线预测。

Ingest the Avro files into BigQuery to perform analytics. Use a Dataflow pipeline to create the features, and store them in Vertex AI Feature Store for online prediction.

C. 将Avro文件摄入Cloud Spanner进行分析。使用Dataflow流水线创建特征，并将它们存储在BigQuery中用于在线预测。

Ingest the Avro files into Cloud Spanner to perform analytics. Use a Dataflow pipeline to create the features, and store them in BigQuery for online prediction.

D. 将Avro文件摄入BigQuery进行分析。使用BigQuery SQL创建特征，并将它们存储在单独的BigQuery表中用于在线预测。

Ingest the Avro files into BigQuery to perform analytics. Use BigQuery SQL to create features and store them in a separate BigQuery table for online prediction.

正确答案：B. Ingest the Avro files into BigQuery to perform analytics. Use a Dataflow pipeline to create the features, and store them in Vertex AI Feature Store for online prediction.

解析： 在这个场景中，需要设置一个完整的ML数据流水线，包括数据分析、特征创建和特征服务。

选项B是最佳解决方案，因为：

- BigQuery是专为大规模数据分析设计的，天然支持Avro格式
- BigQuery非常适合复杂查询和分析工作负载
- Dataflow适合复杂的特征转换和工程
- Vertex AI Feature Store专为低延迟特征服务设计，非常适合在线预测

选项A使用Cloud Spanner进行分析，这是不合适的。Cloud Spanner是高一致性的事务型关系数据库，主要用于OLTP工作负载，不是为大规模分析设计的，成本高且不适合此用例。

选项C使用Cloud Spanner进行分析（同样不合适），并将特征存储在BigQuery中用于在线预测。BigQuery不适合低延迟在线预测，它是为批处理设计的，无法满足毫秒级响应的需求。

选项D虽然使用BigQuery进行分析是合适的，但将特征存储在BigQuery表中用于在线预测是不合适的。BigQuery不适合低延迟服务场景，而Vertex AI Feature Store专为此目的设计。

问题 16

题目

你最近训练了一个计划部署在Vertex AI上的scikit-learn模型。该模型将支持在线和批量预测。你需要预处理模型推理的输入数据。你希望打包模型以便部署，同时最小化额外代码。你应该怎么做？

You have recently trained a scikit-learn model that you plan to deploy on Vertex AI. This model will support both online and batch prediction. You need to preprocess input data for model inference. You want to package the model for deployment while minimizing additional code. What should you do?

选项

A. 1. 使用预构建的scikit-learn预测容器将模型上传到Vertex AI Model Registry。 2. 将模型部署到Vertex AI Endpoints，并创建使用instanceConfig.instanceType设置转换输入数据的Vertex AI批量预测作业。

1. Upload your model to the Vertex AI Model Registry by using a prebuilt scikit-ieam prediction container.
2. Deploy your model to Vertex AI Endpoints, and create a Vertex AI batch prediction job that uses the instanceConfig.instanceType setting to transform your input data.

B. 1. 将模型包装在自定义预测例程(CPR)中，并从CPR本地模型构建容器镜像。 2. 将scikit-learn模型容器上传到Vertex AI Model Registry。 3. 将模型部署到Vertex AI Endpoints，并创建Vertex AI批量预测作业。

1. Wrap your model in a custom prediction routine (CPR). and build a container image from the CPR local model.
2. Upload your scikit learn model container to Vertex AI Model Registry.
3. Deploy your model to Vertex AI Endpoints, and create a Vertex AI batch prediction job

C. 1. 为scikit-learn模型创建自定义容器。 2. 为模型定义自定义服务函数。 3. 将模型和自定义容器上传到Vertex AI Model Registry。 4. 将模型部署到Vertex AI Endpoints，并创建Vertex AI批量预测作业。

1. Create a custom container for your scikit learn model.
2. Define a custom serving function for your model.
3. Upload your model and custom container to Vertex AI Model Registry.
4. Deploy your model to Vertex AI Endpoints, and create a Vertex AI batch prediction job.

D. 1. 为scikit-learn模型创建自定义容器。 2. 将模型和自定义容器上传到Vertex AI Model Registry。 3. 将模型部署到Vertex AI Endpoints，并创建使用instanceConfig.instanceType设置转换输入数据的Vertex AI批量预测作业。

1. Create a custom container for your scikit learn model.
2. Upload your model and custom container to Vertex AI Model Registry.
3. Deploy your model to Vertex AI Endpoints, and create a Vertex AI batch prediction job that uses the instanceConfig.instanceType setting to transform your input data.

正确答案：B. 1. Wrap your model in a custom prediction routine (CPR). and build a container image from the CPR local model. 2. Upload your scikit learn model container to Vertex AI Model Registry. 3. Deploy your model to Vertex AI Endpoints, and create a Vertex AI batch prediction job

解析： 自定义预测例程(CPR)专门设计用于处理模型部署时的预处理和后处理需求。它提供了一个结构化的方式来添加数据转换逻辑，而不需要大量自定义代码。CPR允许您定义预处理步骤，同时重用scikit-learn模型的核心功能。

CPR同时支持在线和批量预测场景，保持处理逻辑一致性。处理逻辑只需定义一次，就可用于两种预测模式。

相比于选项C和D中创建完全自定义容器，CPR提供了一个更轻量级的解决方案。CPR只需要您编写预处理逻辑，而不是整个服务基础设施。

选项A的instanceConfig.instanceType设置确实可以进行一些基本转换，但对于复杂的预处理逻辑可能不够灵活。

问题 17

题目

你正在向正在提供流量的生产Vertex AI端点部署模型的新版本。你计划将所有用户流量定向到新模型。你需要以最小干扰应用程序的方式部署模型。你应该怎么做？

You are deploying a new version of a model to a production Vertex AI endpoint that is serving traffic. You plan to direct all user traffic to the new model. You need to deploy the model with minimal disruption to your application. What should you do?

选项

A. 1. 创建新端点 2. 创建新模型。将其设置为默认版本。将模型上传到Vertex AI Model Registry 3. 将新模型部署到新端点 4. 更新Cloud DNS指向新端点

1. Create a new endpoint
2. Create a new model. Set it as the default version. Upload the model to Vertex AI Model Registry
3. Deploy the new model to the new endpoint
4. Update Cloud DNS to point to the new endpoint

B. 1. 创建新端点 2. 创建新模型。将parentModel参数设置为当前部署模型的模型ID，并将其设置为默认版本。将模型上传到Vertex AI Model Registry 3. 将新模型部署到新端点，并将新模型设置为100%的流量。

1. Create a new endpoint
2. Create a new model. Set the parentModel parameter to the model ID of the currently deployed model and set it as the default version. Upload the model to Vertex AI Model Registry
3. Deploy the new model to the new endpoint, and set the new model to 100% of the traffic.

C. 1. 创建新模型。将parentModel参数设置为当前部署模型的模型ID。将模型上传到Vertex AI Model Registry。 2. 将新模型部署到现有端点，并将新模型设置为100%的流量

1. Create a new model. Set the parentModel parameter to the model ID of the currently deployed model. Upload the model to Vertex AI Model Registry.
2. Deploy the new model to the existing endpoint, and set the new model to 100% of the traffic

D. 1. 创建新模型。将其设置为默认版本。将模型上传到Vertex AI Model Registry 2. 将新模型部署到现有端点

1. Create a new model. Set it as the default version. Upload the model to Vertex AI Model Registry
2. Deploy the new model to the existing endpoint

正确答案：C. 1. Create a new model. Set the parentModel parameter to the model ID of the currently deployed model. Upload the model to Vertex AI Model Registry. 2. Deploy the new model to the existing endpoint, and set the new model to 100% of the traffic

解析： 在已有的Vertex AI生产端点上部署新模型版本时，保持端点稳定是最小化应用干扰的关键。

选项C使用现有端点，客户端无需更改配置。parentModel参数建立与当前模型的关系，便于版本管理和回滚。通过在同一端点上控制新旧模型版本的流量比例，可以支持平滑过渡和监控新版本性能。整个流程操作简单，步骤最少。

选项A和B需要创建新端点，这会导致客户端配置更改，增加了中断风险。选项D没有明确控制流量分配机制，新模型作为默认版本可能导致流量突然切换。

选项C的方法在实际生产环境中最常用，它允许在最小化风险的情况下部署新模型，同时提供监控和回滚机制。

问题 18

题目

你正在使用大型数据集训练ML模型。你使用TPU来加速训练过程。你注意到训练过程比预期花费更长时间。你发现TPU没有达到其全部能力。你应该怎么做？

You are training an ML model on a large dataset. You are using a TPU to accelerate the training process. You notice that the training process is taking longer than expected. You discover that the TPU is not reaching its full capacity. What should you do?

选项

A. 增加学习率

Increase the learning rate

B. 增加训练轮次(epochs)

Increase the number of epochs

C. 降低学习率

Decrease the learning rate

D. 增加批量大小(batch size)

Increase the batch size

正确答案：D. Increase the batch size

解析： TPU的设计原理与常规GPU或CPU有显著不同。它具有特殊的矩阵乘法单元(MXU)，这些单元针对大规模并行计算进行了优化。当批量大小较小时，这些计算单元无法充分利用，导致处理效率低下。

增加批量大小是充分利用TPU计算能力的最直接方法。较大的批量允许TPU同时处理更多数据，减少空闲时间，提高计算效率。这是TPU优化中最基本也是最有效的方法之一。

其他选项（增加/减少学习率或增加训练轮次）不会直接解决TPU利用率问题，它们主要影响模型收敛性能，而非硬件利用率。

问题 19

题目

你在一家零售公司工作。你在Vertex AI中有一个托管的表格数据集，其中包含来自三个不同商店的销售数据。该数据集包括几个特征，如商店名称和销售时间戳。你想使用这些数据训练一个模型，为即将开业的新商店做销售预测。你需要将数据拆分为训练集、验证集和测试集。你应该使用什么方法来拆分数据？

You work for a retail company. You have a managed tabular dataset in Vertex AI that contains sales data from three different stores. The dataset includes several features, such as store name and sale timestamp. You want to use the data to train a model that makes sales predictions for a new store that will open soon. You need to split the data between the training, validation, and test sets. What approach should you use to split the data?

选项

A. 使用Vertex AI手动拆分，使用商店名称特征为每个集合分配一个商店

Use Vertex AI manual split, using the store name feature to assign one store for each set

B. 使用Vertex AI默认数据拆分

Use Vertex AI default data split

C. 使用Vertex AI时间顺序拆分，并指定销售时间戳特征作为时间变量

Use Vertex AI chronological split, and specify the sales timestamp feature as the time variable

D. 使用Vertex AI随机拆分，将70%的行分配给训练集，10%分配给验证集，20%分配给测试集

Use Vertex AI random split, assigning 70% of the rows to the training set, 10% to the validation set, and 20% to the test set

正确答案：C. Use Vertex AI chronological split, and specify the sales timestamp feature as the time variable

解析： 销售预测本质上是时间序列预测问题，因此保持时间连续性非常重要。使用时间序列分割能避免数据泄露（防止模型训练时"看到"未来数据），并且反映实际使用场景（用历史数据预测未来）。

选项A（按商店名称手动分割）会严重限制训练数据量，无法学习不同商店间的共同模式，对新商店的泛化能力可能很差。

选项B（默认分割）通常是简单随机分割，忽略了数据的时间性质，可能导致信息泄露。

选项D（随机分割）打破了时间连续性，可能造成数据泄露，不符合销售预测的实际使用场景。

使用时间序列分割(选项C)能让模型学习到时间相关的销售模式，这对于预测新商店的销售至关重要。时间模式（如节假日销售高峰、周末效应等）很可能在新商店也会出现。

问题 20

题目

你开发了一个预测客户流失的BigQuery ML模型，并将该模型部署到Vertex AI Endpoints。你希望在模型特征值发生变化时使用最少的额外代码自动重训练模型。你还希望最小化模型重训练的次数以降低训练成本。你应该怎么做？

You have developed a BigQuery ML model that predicts customer churn, and deployed the model to Vertex AI Endpoints. You want to automate the retraining of your model by using minimal additional code when model feature values change. You also want to minimize the number of times that your model is retrained to reduce training costs. What should you do?

选项

A. 1. 在Vertex AI Endpoints上启用请求-响应日志记录 2. 安排TensorFlow Data Validation作业监控预测漂移 3. 如果分布之间存在显著差距，则执行模型重训练

1 Enable request-response logging on Vertex AI Endpoints 2. Schedule a TensorFlow Data Validation job to monitor prediction drift 3. Execute model retraining if there is significant distance between the distributions

B. 1. 在Vertex AI Endpoints上启用请求-响应日志记录 2. 安排TensorFlow Data Validation作业监控训练/服务偏差 3. 如果分布之间存在显著差距，则执行模型重训练

1. Enable request-response logging on Vertex AI Endpoints

2. Schedule a TensorFlow Data Validation job to monitor training/serving skew
3. Execute model retraining if there is significant distance between the distributions

C. 1. 创建配置为监控预测漂移的Vertex AI Model Monitoring作业 2. 配置警报监控，在检测到监控警报时向Pub/Sub队列发布消息 3. 使用Cloud Function监控Pub/Sub队列，并在BigQuery中触发重训练

1. Create a Vertex AI Model Monitoring job configured to monitor prediction drift
2. Configure alert monitoring to publish a message to a Pub/Sub queue when a monitoring alert is detected
3. Use a Cloud Function to monitor the Pub/Sub queue, and trigger retraining in BigQuery

D. 1. 创建配置为监控训练/服务偏差的Vertex AI Model Monitoring作业 2. 配置警报监控，在检测到监控警报时向Pub/Sub队列发布消息 3. 使用Cloud Function监控Pub/Sub队列，并在BigQuery中触发重训练

1. Create a Vertex AI Model Monitoring job configured to monitor training/serving skew
2. Configure alert monitoring to publish a message to a Pub/Sub queue when a monitoring alert is detected
3. Use a Cloud Function to monitor the Pub/Sub queue, and trigger retraining in BigQuery

正确答案：D. 1. Create a Vertex AI Model Monitoring job configured to monitor training/serving skew 2. Configure alert monitoring to publish a message to a Pub/Sub queue when a monitoring alert is detected 3. Use a Cloud Function to monitor the Pub/Sub queue, and trigger retraining in BigQuery

解析： 训练/服务偏差(training/serving skew)是检测特征值变化的最直接指标。这种监控方法直接比较训练数据中特征的分布与当前服务中看到的特征分布，当特征实际发生变化时才触发重训练，从而最小化重训练次数。

相比之下，预测漂移(prediction drift)监控的是预测结果(输出)的变化，这可能由多种因素引起，不一定是特征值变化。

使用Vertex AI Model Monitoring的内置功能，代码量最少，不需要自定义监控逻辑。结合无服务器组件(Pub/Sub、Cloud Functions)构建事件驱动架构，减少了维护负担。

选项A和B都需要自定义TensorFlow Data Validation代码，不符合"最小额外代码"的要求。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 3)

问题 21

题目

你的任务是将原型代码部署到生产环境。特征工程代码是用PySpark编写的，运行在Dataproc Serverless上。模型训练是使用Vertex AI自定义训练作业执行的。这两个步骤没有连接，目前在特征工程步骤完成后必须手动运行模型训练。你需要创建一个可扩展且可维护的生产流程，该流程能够端到端运行并跟踪步骤之间的连接。你应该怎么做？

You have been tasked with deploying prototype code to production. The feature engineering code is in PySpark and runs on Dataproc Serverless. The model training is executed by using a Vertex AI custom training job. The two steps are not connected, and the model training must currently be run manually after the

feature engineering step finishes. You need to create a scalable and maintainable production process that runs end-to-end and tracks the connections between steps. What should you do?

选项

A. 创建Vertex AI Workbench笔记本。使用笔记本提交Dataproc Serverless特征工程作业。使用同一笔记本提交自定义模型训练作业。按顺序运行笔记本单元以将步骤端到端连接起来。

Create a Vertex AI Workbench notebook. Use the notebook to submit the Dataproc Serverless feature engineering job. Use the same notebook to submit the custom model training job. Run the notebook cells sequentially to tie the steps together end-to-end.

B. 创建Vertex AI Workbench笔记本。在笔记本中初始化Apache Spark上下文并运行PySpark特征工程代码。使用同一笔记本在TensorFlow中运行自定义模型训练作业。按顺序运行笔记本单元以将步骤端到端连接起来。

Create a Vertex AI Workbench notebook. Initiate an Apache Spark context in the notebook and run the PySpark feature engineering code. Use the same notebook to run the custom model training job in TensorFlow. Run the notebook cells sequentially to tie the steps together end-to-end.

C. 使用Kubeflow pipelines SDK编写指定两个组件的代码：

- 第一个是启动特征工程作业的Dataproc Serverless组件
- 第二个是包装在create_custom_training_job_from_component实用工具中的自定义组件，用于启动自定义模型训练作业 创建Vertex AI Pipelines作业来链接并运行这两个组件

Use the Kubeflow pipelines SDK to write code that specifies two components:

- The first is a Dataproc Serverless component that launches the feature engineering job
- The second is a custom component wrapped in the create_custom_training_job_from_component utility that launches the custom model training job Create a Vertex AI Pipelines job to link and run both components

D. 使用Kubeflow pipelines SDK编写指定两个组件的代码：

- 第一个组件初始化Apache Spark上下文，运行PySpark特征工程代码
- 第二个组件运行TensorFlow自定义模型训练代码 创建Vertex AI Pipelines作业来链接并运行这两个组件

Use the Kubeflow pipelines SDK to write code that specifies two components

- The first component initiates an Apache Spark context that runs the PySpark feature engineering code
- The second component runs the TensorFlow custom model training code Create a Vertex AI Pipelines job to link and run both components.

正确答案：C. Use the Kubeflow pipelines SDK to write code that specifies two components: - The first is a Dataproc Serverless component that launches the feature engineering job - The second is a custom component wrapped in the create_custom_training_job_from_component utility that launches the custom model training job. Create a Vertex AI Pipelines job to link and run both components

解析： 选项C是将原型代码转换为可扩展、可维护生产流程的最佳方式，因为它：

1. 合理利用现有基础设施：使用现有的Dataproc Serverless特征工程和Vertex AI自定义训练作业，无需重写现有代码

2. 使用专业工具组合：每个组件使用专为其任务设计的服务
3. 自动化生产工作流：完全端到端自动化，无需手动干预
4. 跟踪步骤连接：Vertex AI Pipelines自动跟踪步骤之间的关系和依赖
5. 提供监控和错误处理：内置日志记录、监控和错误处理机制

选项A和B使用笔记本不适合生产环境，缺乏错误处理和自动化特性。选项D尝试在管道内运行Spark而非利用现有Dataproc Serverless，增加了复杂性。

问题 22

题目

你最近将scikit-learn模型部署到Vertex AI端点。你现在正在使用实时生产流量测试该模型。在监控端点时，你发现全天的请求量是预期的两倍。你希望端点能够在未来需求增加时高效扩展，以防止用户体验高延迟。你应该怎么做？

You recently deployed a scikit-learn model to a Vertex AI endpoint. You are now testing the model on live production traffic. While monitoring the endpoint, you discover twice as many requests per hour than expected throughout the day. You want the endpoint to efficiently scale when the demand increases in the future to prevent users from experiencing high latency. What should you do?

选项

A. 将两个模型部署到同一端点，并在它们之间均匀分配请求

Deploy two models to the same endpoint, and distribute requests among them evenly

B. 根据预期的基线流量配置适当的minReplicaCount值

Configure an appropriate minReplicaCount value based on expected baseline traffic

C. 在autoscailingMetricSpecs配置中将目标利用率百分比设置为更高的值

Set the target utilization percentage in the autoscailngMetricSpecs configuration to a higher value

D. 将模型的机器类型更改为使用GPU的类型

Change the model's machine type to one that utilizes GPUs

正确答案：B. Configure an appropriate minReplicaCount value based on expected baseline traffic

解析： 配置合适的minReplicaCount（最小副本数）是应对流量激增的最佳选择，因为：

1. 它确保端点始终有足够的副本来处理观察到的基线流量（预期的两倍）
2. 通过保持足够的最小副本数，避免了冷启动延迟
3. 只需调整配置参数，无需构建新系统
4. 为Vertex AI的自动扩展功能提供良好的起点

选项A只是静态分流，不能根据需求动态扩展。选项C提高目标利用率会推迟扩展触发，可能增加延迟风险。选项D的GPU对scikit-learn模型帮助有限，成本增加显著。

minReplicaCount控制始终运行的最小副本数，确保有足够容量应对基本负载，是一种平衡成本和性能的方法。

问题 23

题目

你在一家银行工作。你有一个由银行供应商提供的自定义表格ML模型。由于训练数据的敏感性，无法获取训练数据。该模型被打包为Vertex AI Model服务容器，它接受字符串作为每个预测实例的输入。在每个字符串中，特征值由逗号分隔。你希望将此模型部署到生产环境进行在线预测，并以最少的工作量监控特征分布随时间的变化。你应该怎么做？

You work at a bank. You have a custom tabular ML model that was provided by the bank's vendor. The training data is not available due to its sensitivity. The model is packaged as a Vertex AI Model serving container, which accepts a string as input for each prediction instance. In each string, the feature values are separated by commas. You want to deploy this model to production for online predictions and monitor the feature distribution over time with minimal effort. What should you do?

选项

A. 1. 将模型上传到Vertex AI Model Registry，并将模型部署到Vertex AI端点 2. 创建以特征漂移检测为监控目标的Vertex AI Model Monitoring作业，并提供实例模式

1. Upload the model to Vertex AI Model Registry, and deploy the model to a Vertex AI endpoint
2. Create a Vertex AI Model Monitoring job with feature drift detection as the monitoring objective, and provide an instance schema

B. 1. 将模型上传到Vertex AI Model Registry，并将模型部署到Vertex AI端点 2. 创建以特征偏差检测为监控目标的Vertex AI Model Monitoring作业，并提供实例模式

1. Upload the model to Vertex AI Model Registry, and deploy the model to a Vertex AI endpoint
2. Create a Vertex AI Model Monitoring job with feature skew detection as the monitoring objective, and provide an instance schema

C. 1. 重构服务容器以接受键值对作为输入格式 2. 将模型上传到Vertex AI Model Registry，并将模型部署到Vertex AI端点 3. 创建以特征漂移检测为监控目标的Vertex AI Model Monitoring作业

1. Refactor the serving container to accept key-value pairs as input format
2. Upload the model to Vertex AI Model Registry, and deploy the model to a Vertex AI endpoint
3. Create a Vertex AI Model Monitoring job with feature drift detection as the monitoring objective.

D. 1. 重构服务容器以接受键值对作为输入格式 2. 将模型上传到Vertex AI Model Registry，并将模型部署到Vertex AI端点 3. 创建以特征偏差检测为监控目标的Vertex AI Model Monitoring作业

1. Refactor the serving container to accept key-value pairs as input format
2. Upload the model to Vertex AI Model Registry, and deploy the model to a Vertex AI endpoint
3. Create a Vertex AI Model Monitoring job with feature skew detection as the monitoring objective

正确答案：A. 1. Upload the model to Vertex AI Model Registry, and deploy the model to a Vertex AI endpoint 2. Create a Vertex AI Model Monitoring job with feature drift detection as the monitoring objective, and provide an instance schema

解析： 选项A是最佳解决方案，因为：

1. 不需要修改供应商提供的容器，保持最小工作量
2. 使用特征漂移检测比较不同时间点的生产数据，不需要原始训练数据
3. 通过提供实例模式(schema)解释逗号分隔的输入格式
4. 能够有效监控特征分布随时间的变化

特征漂移和特征偏差的关键区别是：

- 特征漂移(Feature drift)比较不同时间点的生产数据，监控分布随时间变化
- 特征偏差(Feature skew)比较生产数据与训练数据的分布差异

由于训练数据不可用，特征偏差检测不适用于此场景。选项C和D需要重构容器，增加工作量和风险。

问题 24

题目

你正在Google Cloud中实现批量推理ML流水线。该模型是使用TensorFlow开发的，并以SavedModel格式存储在Cloud Storage中。你需要将模型应用于存储在BigQuery表中的包含10 TB数据的历史数据集。你应该如何执行推理？

You are implementing a batch inference ML pipeline in Google Cloud. The model was developed using TensorFlow and is stored in SavedModel format in Cloud Storage. You need to apply the model to a historical dataset containing 10 TB of data that is stored in a BigQuery table. How should you perform the inference?

选项

A. 将历史数据以Avro格式导出到Cloud Storage。配置Vertex AI批量预测作业为导出的数据生成预测

Export the historical data to Cloud Storage in Avro format. Configure a Vertex AI batch prediction job to generate predictions for the exported data

B. 使用BigQuery ML中的CREATE MODEL语句导入TensorFlow模型。将历史数据应用于TensorFlow模型

Import the TensorFlow model by using the CREATE MODEL statement in BigQuery ML. Apply the historical data to the TensorFlow model

C. 将历史数据以CSV格式导出到Cloud Storage。配置Vertex AI批量预测作业为导出的数据生成预测

Export the historical data to Cloud Storage in CSV format. Configure a Vertex AI batch prediction job to generate predictions for the exported data

D. 配置Vertex AI批量预测作业将模型应用于BigQuery中的历史数据

Configure a Vertex AI batch prediction job to apply the model to the historical data in BigQuery

正确答案：B. Import the TensorFlow model by using the CREATE MODEL statement in BigQuery ML. Apply the historical data to the TensorFlow model

解析： 对于10TB的大型数据集，将模型移动到数据要比将数据移动到模型高效得多。BigQuery ML可以直接导入TensorFlow SavedModel并用于推理，使整个过程在单一系统中完成。

选项A和C需要将10TB数据从BigQuery移动到Cloud Storage，这需要时间和资源，增加了复杂性和潜在的成本。选项D暗示Vertex AI批量预测可以直接从BigQuery表读取数据，这不是标准支持的功能。

使用BigQuery ML导入模型的方法简单高效：

```
CREATE MODEL `my_dataset.my_model`
OPTIONS(MODEL_TYPE='TENSORFLOW',
        MODEL_PATH='gs://my-bucket/model')
AS SELECT * FROM `my_dataset.historical_data_table`;
```

问题 25

题目

你最近将模型部署到Vertex AI端点。你的数据经常发生漂移，因此你已启用请求-响应日志记录并创建了Vertex AI Model Monitoring作业。你已观察到你的模型接收的流量比预期的高。你需要降低模型监控成本，同时继续快速检测漂移。你应该怎么做？

You recently deployed a model to a Vertex AI endpoint. Your data drifts frequently, so you have enabled request-response logging and created a Vertex AI Model Monitoring job. You have observed that your model is receiving higher traffic than expected. You need to reduce the model monitoring cost while continuing to quickly detect drift. What should you do?

选项

A. 用使用TensorFlow Data Validation (TFDV)的DataFlow流水线替换监控作业

Replace the monitoring job with a DataFlow pipeline that uses TensorFlow Data Validation (TFDV)

B. 用自定义SQL脚本替换监控作业，以计算BigQuery中特征和预测的统计数据

Replace the monitoring job with a custom SQL script to calculate statistics on the features and predictions in BigQuery

C. 减少监控作业的RandomSampleConfig中的sample_rate参数

Decrease the sample_rate parameter in the RandomSampleConfig of the monitoring job

D. 增加监控作业的ScheduleConfig中的monitor_interval参数

Increase the monitor_interval parameter in the ScheduleConfig of the monitoring job

正确答案：C. Decrease the sample_rate parameter in the RandomSampleConfig of the monitoring job

解析： 减少采样率(sample_rate)是降低监控成本同时保持快速检测漂移能力的最佳方法。这种方法：

1. 直接减少处理的请求量，降低成本
2. 维持相同的监控频率，不影响漂移检测速度
3. 只是分析较小的随机样本，仍能代表整体流量模式
4. 无需更改现有设置，简单调整参数
5. 继续使用Vertex AI的专业监控功能

选项A和B需要构建和维护自定义解决方案，增加开发工作量。选项D延长监控间隔会延迟漂移检测，违背"继续快速检测漂移"的要求。

关键区别：

- 选项C(调整采样率)影响的是"多少"数据被分析
- 选项D(调整间隔)影响的是"多久"进行一次分析

问题 26

题目

你在一家零售公司工作。你创建了一个Vertex AI预测模型，该模型生成月度商品销售预测。你想快速创建一份报告，帮助解释模型如何计算预测。你有一个月的最新实际销售数据，这些数据未包含在训练数据集中。你应该如何为报告生成数据？

You work for a retail company. You have created a Vertex AI forecast model that produces monthly item sales predictions. You want to quickly create a report that will help to explain how the model calculates the predictions. You have one month of recent actual sales data that was not included in the training dataset. How should you generate data for your report?

选项

A. 使用实际销售数据创建批量预测作业。在报告中比较预测与实际情况。

Create a batch prediction job by using the actual sales data. Compare the predictions to the actuals in the report.

B. 使用实际销售数据创建批量预测作业，并配置作业设置以生成特征归因。在报告中比较结果。

Create a batch prediction job by using the actual sales data, and configure the job settings to generate feature attributions. Compare the results in the report.

C. 使用实际销售数据生成反事实示例。使用实际销售数据和反事实示例创建批量预测作业。在报告中比较结果。

Generate counterfactual examples by using the actual sales data. Create a batch prediction job using the actual sales data and the counterfactual examples. Compare the results in the report.

D. 使用与原始模型相同的训练数据集训练另一个模型，并排除一些列。使用实际销售数据创建一个使用新模型的批量预测作业和另一个使用原始模型的批量预测作业。在报告中比较两组预测。

Train another model by using the same training dataset as the original, and exclude some columns. Using the actual sales data create one batch prediction job by using the new model and another one with the original model. Compare the two sets of predictions in the report.

正确答案：B. Create a batch prediction job by using the actual sales data, and configure the job settings to generate feature attributions. Compare the results in the report.

解析： 特征归因(feature attributions)直接解释了各输入特征对预测结果的贡献程度，这正是理解"模型如何计算预测"的关键。

选项B是最佳选择，因为：

1. 特征归因清晰展示每个特征对预测的影响程度

2. Vertex AI批量预测直接支持生成特征归因，只需配置相关参数
3. 无需额外训练、不需要构建新系统
4. 同时提供预测结果和解释信息
5. 最符合"快速创建报告"的要求

选项A只显示预测准确性，不解释决策过程。选项C和D需要额外工作，不符合"快速"要求。

问题 27

题目

你创建了一个包含两个步骤的Vertex AI流水线。第一步预处理10 TB数据，大约需要1小时完成，并将结果保存在Cloud Storage存储桶中。第二步使用处理后的数据训练模型。你需要更新模型的代码以允许测试不同的算法。你希望减少流水线执行时间和成本，同时尽量减少流水线变更。你应该怎么做？

You have created a Vertex AI pipeline that includes two steps. The first step preprocesses 10 TB data completes in about 1 hour, and saves the result in a Cloud Storage bucket. The second step uses the processed data to train a model. You need to update the model's code to allow you to test different algorithms. You want to reduce pipeline execution time and cost while also minimizing pipeline changes. What should you do?

选项

A. 添加一个流水线参数和一个额外的流水线步骤。根据参数值，流水线步骤执行或跳过数据预处理，并开始模型训练。

Add a pipeline parameter and an additional pipeline step. Depending on the parameter value, the pipeline step conducts or skips data preprocessing, and starts model training.

B. 创建一个没有预处理步骤的新流水线，并为模型训练硬编码预处理后的Cloud Storage文件位置。

Create another pipeline without the preprocessing step, and hardcode the preprocessed Cloud Storage file location for model training.

C. 为数据预处理步骤配置来自计算优化机器系列的具有更多CPU和RAM的机器。

Configure a machine with more CPU and RAM from the compute-optimized machine family for the data preprocessing step.

D. 为流水线作业启用缓存，并为模型训练步骤禁用缓存。

Enable caching for the pipeline job, and disable caching for the model training step.

正确答案：D. Enable caching for the pipeline job, and disable caching for the model training step.

解析： 启用缓存同时禁用模型训练步骤的缓存是最优解，因为：

1. 缓存预处理步骤的结果，避免重复处理相同的10TB数据
2. 只有模型训练步骤（需要测试不同算法的部分）会重新运行
3. 最小化管道变更，只需配置缓存设置
4. 显著减少执行时间（避免每次都花1小时在预处理上）
5. 减少计算资源成本

选项A需要添加新参数和步骤，管道变更较大，增加管理复杂性，不是最优的自动化解决方案。

选项B创建全新管道，变更大，需要维护两个管道，增加管理负担，硬编码位置缺乏灵活性。

选项C虽然会加速预处理，但每次运行仍需重新处理数据，更强大的机器会增加成本，与目标相悖，不解决反复运行相同预处理步骤的根本问题。

问题 28

题目

你在一家食品产品公司工作。你公司的历史销售数据存储在BigQuery中。你需要使用Vertex AI的自定义训练服务来训练多个TensorFlow模型，这些模型从BigQuery读取数据并预测未来销售。你计划实现一个数据预处理算法，在开始试验模型之前对大量特征进行最小-最大缩放和分桶。你希望最小化预处理时间、成本和开发工作量。你应该如何配置这个工作流？

You work at a food product company. Your company's historical sales data is stored in BigQuery.You need to use Vertex AI's custom training service to train multiple TensorFlow models that read the data from BigQuery and predict future sales. You plan to implement a data preprocessing algorithm that performs min-max scaling and bucketing on a large number of features before you start experimenting with the models. You want to minimize preprocessing time, cost, and development effort. How should you configure this workflow?

选项

A. 将转换写入使用spark-bigquery-connector的Spark中，并使用Dataproc预处理数据。

Write the transformations into Spark that uses the spark-bigquery-connector, and use Dataproc to preprocess the data.

B. 编写SQL查询在BigQuery中原地转换数据。

Write SQL queries to transform the data in-place in BigQuery.

C. 在TensorFlow模型中添加转换作为预处理层。

Add the transformations as a preprocessing layer in the TensorFlow models.

D. 创建使用BigQueryIO连接器的Dataflow流水线，摄取数据，处理数据，并将其写回BigQuery。

Create a Dataflow pipeline that uses the BigQueryIO connector to ingest the data, process it, and write it back to BigQuery.

正确答案：B. Write SQL queries to transform the data in-place in BigQuery.

解析： 使用BigQuery SQL进行数据预处理是这个场景中最高效的方法：

1. 无需移动数据（避免数据传输成本和时间）
2. BigQuery针对分析查询和转换进行了优化，处理速度快
3. 开发工作量最小（只需编写SQL）
4. SQL可以轻松处理min-max缩放和分桶操作

选项A需要设置和管理Dataproc集群，需要编写和维护Spark代码，开发工作量大，数据需要从BigQuery移出处理。

选项C会导致每个模型都重复相同的预处理步骤，在模型训练/调优过程中重复处理同样的数据，造成计算资源浪费。

选项D需要编写和维护Apache Beam流水线代码，开发工作量大，数据需要从BigQuery移出处理，然后再写回，增加复杂性。

问题 29

题目

你在一家有严格数据治理要求的银行工作。你最近实现了一个自定义模型来检测欺诈交易。你希望你的训练代码通过使用托管在你项目网络中的API端点下载内部数据。你需要以最安全的方式访问数据，同时减轻数据泄露的风险。你应该怎么做？

You work for a bank with strict data governance requirements. You recently implemented a custom model to detect fraudulent transactions. You want your training code to download internal data by using an API endpoint hosted in your project's network. You need the data to be accessed in the most secure way, while mitigating the risk of data exfiltration. What should you do?

选项

A. 为对等连接启用VPC Service Controls，并将Vertex AI添加到服务边界。

Enable VPC Service Controls for peerings, and add Vertex AI to a service perimeter.

B. 创建Cloud Run端点作为数据的代理。使用身份和访问管理(IAM)身份验证来保护从训练作业到端点的访问。

Create a Cloud Run endpoint as a proxy to the data. Use Identity and Access Management (IAM) authentication to secure access to the endpoint from the training job.

C. 配置Vertex AI的VPC对等互连，并指定训练作业的网络。

Configure VPC Peering with Vertex AI, and specify the network of the training job.

D. 在调用训练作业之前将数据下载到Cloud Storage存储桶。

Download the data to a Cloud Storage bucket before calling the training job.

正确答案：A. Enable VPC Service Controls for peerings, and add Vertex AI to a service perimeter.

解析： 在严格数据治理场景下，VPC Service Controls是防止数据泄露的主要安全控制，特别适合银行等高度监管的环境。

选项A为银行的API端点部署了最强的安全保障，因为：

1. VPC Service Controls创建围绕Google Cloud资源的安全边界
2. 允许Vertex AI安全地访问边界内的资源同时防止数据外流
3. 服务边界提供了额外的安全层，防止未授权的数据移动
4. 这是为满足金融机构严格合规性要求而设计的解决方案

选项B需要额外部署和维护Cloud Run服务，并且仅依赖IAM进行安全控制，缺乏防范数据泄露的具体机制。选项C只提供基本的网络连接，而选项D创建敏感数据的额外副本，增加了风险。

问题 30

题目

你最近在Vertex AI Pipelines中部署了一个流水线，该流水线训练模型并将其推送到Vertex AI端点以服务实时流量。你需要继续实验和迭代你的流水线以提高模型性能。你计划使用Cloud Build进行CI/CD。你希望快速轻松地将新流水线部署到生产环境，并希望最小化新流水线实现在生产环境中出现问题的可能性。你应该怎么做？

You recently deployed a pipeline in Vertex AI Pipelines that trains and pushes a model to a Vertex AI endpoint to serve real-time traffic. You need to continue experimenting and iterating on your pipeline to improve model performance. You plan to use Cloud Build for CI/CD You want to quickly and easily deploy new pipelines into production, and you want to minimize the chance that the new pipeline implementations will break in production. What should you do?

选项

A. 设置一个CI/CD流水线，构建和测试源代码。如果测试成功，使用Google Cloud控制台将构建的容器上传到Artifact Registry并将编译后的流水线上传到Vertex AI Pipelines。

Set up a CI/CD pipeline that builds and tests your source code. If the tests are successful, use the Google Cloud console to upload the built container to Artifact Registry and upload the compiled pipeline to Vertex AI Pipelines.

B. 设置一个CI/CD流水线，构建源代码，然后将构建的构件部署到预生产环境。在预生产环境中运行单元测试。如果测试成功，将流水线部署到生产环境。

Set up a CI/CD pipeline that builds your source code and then deploys built artifacts into a pre-production environment. Run unit tests in the pre-production environment. If the tests are successful deploy the pipeline to production.

C. 设置一个CI/CD流水线，构建和测试源代码，然后将构建的构件部署到预生产环境。在预生产环境中成功运行流水线后，将流水线部署到生产环境。

Set up a CI/CD pipeline that builds and tests your source code and then deploys built artifacts into a pre-production environment. After a successful pipeline run in the pre-production environment, deploy the pipeline to production.

D. 设置一个CI/CD流水线，构建和测试源代码，然后将构建的构件部署到预生产环境。在预生产环境中成功运行流水线后，重新构建源代码并将构件部署到生产环境。

Set up a CI/CD pipeline that builds and tests your source code and then deploys built artifacts into a pre-production environment. After a successful pipeline run in the pre-production environment, rebuild the source code and deploy the artifacts to production.

正确答案：C. Set up a CI/CD pipeline that builds and tests your source code and then deploys built artifacts into a pre-production environment. After a successful pipeline run in the pre-production environment, deploy the pipeline to production.

解析： 选项C提供了端到端的自动化流程，确保从构建到预生产测试再到生产部署的完整性：

1. 包含源代码构建和测试（通过单元测试验证代码的正确性）

2. 先部署到预生产环境（验证集成和环境兼容性）
3. 在预生产环境中运行完整管道验证（确保管道在类似生产的环境中运行良好）
4. 测试整个工作流，不仅是单元测试
5. 使用经过验证的相同构件部署到生产环境（确保生产环境使用的正是测试过的相同构件）

选项A需要手动使用控制台上传构件，增加人为错误风险，自动化程度低。选项B只进行单元测试，无法捕获集成问题或管道执行特定问题。选项D添加了不必要的重建步骤，这可能导致预生产和生产环境使用不同构件，增加风险。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 4)

问题 31

题目

你正在使用XGBoost在Python中训练一个将用于在线服务的模型。你的模型预测服务将被在GKE集群上运行的Golang实现的后端服务调用。你的模型需要预处理和后处理步骤。你需要实现处理步骤，使它们在服务时运行。你希望最小化代码更改和基础设施维护，并尽快将模型部署到生产环境。你应该怎么做？

You are using XGBoost to train a model in Python that will be used for online serving. Your model prediction service will be called by a backend service implemented in Golang running on a Google Kubernetes Engine (GKE) cluster. Your model requires pre and postprocessing steps. You need to implement the processing steps so that they run at serving time. You want to minimize code changes and infrastructure maintenance, and deploy your model into production as quickly as possible. What should you do?

选项

A. 使用FastAPI实现HTTP服务器。创建运行你的HTTP服务器的Docker镜像，并将其部署在你组织的GKE集群上。

Use FastAPI to implement an HTTP server. Create a Docker image that runs your HTTP server, and deploy it on your organization's GKE cluster.

B. 使用FastAPI实现HTTP服务器。创建运行你的HTTP服务器的Docker镜像，将镜像上传到Vertex AI Model Registry并部署到Vertex AI端点。

Use FastAPI to implement an HTTP server. Create a Docker image that runs your HTTP server, Upload the image to Vertex AI Model Registry and deploy it to a Vertex AI endpoint.

C. 使用Predictor接口实现自定义预测例程。构建自定义容器，将容器上传到Vertex AI Model Registry并部署到Vertex AI端点。

Use the Predictor interface to implement a custom prediction routine. Build the custom container, upload the container to Vertex AI Model Registry and deploy it to a Vertex AI endpoint.

D. 在将训练好的模型导入Vertex AI时使用XGBoost预构建的服务容器。将模型部署到Vertex AI端点。与后端工程师合作，在Golang中实现预处理和后处理步骤。

Use the XGBoost prebuilt serving container when importing the trained model into Vertex AI. Deploy the model to a Vertex AI endpoint. Work with the backend engineers to implement the pre- and postprocessing steps in the Golang.

正确答案：C. Use the Predictor interface to implement a custom prediction routine. Build the custom container, upload the container to Vertex AI Model Registry and deploy it to a Vertex AI endpoint.

解析： Predictor接口提供了一种集成预处理和后处理步骤的简洁方式，同时使用Vertex AI端点托管模型：

1. 自定义预测例程专为添加预处理和后处理设计
2. 与Python模型训练代码保持技术一致性
3. Vertex AI处理所有基础设施管理
4. 无需在两个系统之间协调预处理/后处理

选项A和B需要编写完整的HTTP服务器，增加代码复杂性，而选项A还需要处理GKE集群的部署和管理。选项D要求把预处理和后处理步骤用不同语言（Golang）实现，增加了维护复杂性和跨团队协作成本。

问题 32

题目

你在一家银行工作。你的银行计划部署一个scikit-learn模型来分析新贷款产品的财务风险。该模型使用多个参数进行训练，使用pickle保存到磁盘，并经过了广泛测试。在最终代码审查中，你的安全团队提出了模型在生产环境中使用不安全的担忧。你应该怎么做？

You work for a bank. Your bank plans to deploy a scikit-learn model to analyze financial risk in a new loan product. The model was trained with multiple parameters, was saved to disk using pickle, and has been tested extensively. During the final code review, your security team has raised concerns that the model is not secure for use in production. What should you do?

选项

A. 使用模型无关的LIME包生成单个预测的解释。

Use the model-agnostic LIME package to generate explanations of individual predictions.

B. 将模型存储在具有受限访问权限的安全Cloud Storage存储桶中。

Store the model in a secure Cloud Storage bucket with restricted access.

C. 使用TensorFlow Decision Forests重新训练模型，并以SavedModel格式保存。

Retrain the model by using TensorFlow Decision Forests, and save it in the SavedModel format.

D. 为模型实现CI/CD测试以确保持续性能。

Implement CI/CD testing for the model to ensure continued performance.

正确答案：C. Retrain the model by using TensorFlow Decision Forests, and save it in the SavedModel format.

解析： 安全团队关注的主要问题很可能是Python的pickle格式固有的安全风险。pickle在反序列化时可以执行任意代码，这在生产环境中是一个严重的安全漏洞，特别是在银行这样的高安全性要求场景中。

选项C通过使用TensorFlow Decision Forests（支持决策树模型，与scikit-learn功能类似）并保存为SavedModel格式解决了这个问题。SavedModel是一种安全的、受支持的序列化格式，不存在pickle的安全问题。

选项A只关注模型解释性，不解决安全问题。选项B仅限制对不安全文件的访问，但不解决底层安全漏洞。选项D的CI/CD测试可能保证性能，但不会解决pickle格式的安全问题。

问题 33

题目

你的团队有一个部署到Vertex AI端点的模型。你创建了一个由Cloud Function触发的Vertex AI流水线，该流水线自动化了模型训练过程。你需要优先保持模型最新，但也要最小化重训练成本。你应该如何配置重训练？

Your team has a model deployed to a Vertex AI endpoint. You have created a Vertex AI pipeline that automates the model training process and is triggered by a Cloud Function. You need to prioritize keeping the model up-to-date, but also minimize retraining costs. How should you configure retraining?

选项

A. 配置Pub/Sub在有足够新数据可用时调用Cloud Function

Configure Pub/Sub to call the Cloud Function when a sufficient amount of new data becomes available

B. 配置一个Cloud Scheduler作业，以适合你团队预算的预定频率调用Cloud Function

Configure a Cloud Scheduler job that calls the Cloud Function at a predetermined frequency that fits your team's budget

C. 在Vertex AI端点上启用模型监控。配置Pub/Sub在检测到异常时调用Cloud Function

Enable model monitoring on the Vertex AI endpoint. Configure Pub/Sub to call the Cloud Function when anomalies are detected

D. 在Vertex AI端点上启用模型监控。配置Pub/Sub在检测到特征漂移时调用Cloud Function

Enable model monitoring on the Vertex AI endpoint. Configure Pub/Sub to call the Cloud Function when feature drift is detected

正确答案：D. Enable model monitoring on the Vertex AI endpoint. Configure Pub/Sub to call the Cloud Function when feature drift is detected

解析： 这个问题要求在保持模型最新状态和最小化重训练成本之间找到最佳平衡点。

选项D是最优解，因为：

1. 特征漂移(Feature drift)监控能够检测输入数据分布的变化，这是模型性能可能下降的直接指标
2. 只有在数据特征实际发生显著变化时才触发重训练，避免了不必要的训练成本
3. 这是一种基于数据变化的智能触发机制，而不是盲目地基于时间或数据量
4. 使用Pub/Sub和Cloud Function提供了高效的事件驱动架构

相比之下，其他选项存在以下问题：

- 选项A基于数据量触发，可能导致频繁重训练，即使模型性能没有下降
- 选项B使用固定时间表，与实际模型需求无关，可能导致不必要的训练或模型过时
- 选项C监控模型异常，虽然也是反应式的，但不如特征漂移直接针对问题根源

在ML生产环境中，特征漂移是重训练决策的关键指标，因为它直接反映了训练数据与生产数据之间的差异。

问题 34

题目

你的公司在本地数据库中存储了大量打给客户呼叫中心的电话通话音频文件。每个音频文件都是wav格式，长度约为5分钟。你需要分析这些音频文件以了解客户情绪。你计划使用Speech-to-Text API。你希望使用最高效的方法。你应该怎么做？

Your company stores a large number of audio files of phone calls made to your customer call center in an on-premises database. Each audio file is in wav format and is approximately 5 minutes long. You need to analyze these audio files for customer sentiment. You plan to use the Speech-to-Text API You want to use the most efficient approach. What should you do?

选项

A. 1. 将音频文件上传到Cloud Storage 2. 调用speech:longrunningrecognize API端点生成转录 3. 调用AutoML情感分析模型的predict方法分析转录

1. Upload the audio files to Cloud Storage
2. Call the speech:longrunningrecognize API endpoint to generate transcriptions
3. Call the predict method of an AutoML sentiment analysis model to analyze the transcriptions.

B. 1. 将音频文件上传到Cloud Storage 2. 调用speech:longrunningrecognize API端点生成转录 3. 创建一个Cloud Function，使用analyzeSentiment方法调用Natural Language API

1. Upload the audio files to Cloud Storage.
2. Call the speech:longrunningrecognize API endpoint to generate transcriptions
3. Create a Cloud Function that calls the Natural Language API by using the analyzeSentiment method

C. 1. 在Python中迭代本地文件 2. 使用Speech-to-Text Python库创建speech.RecognitionAudio对象，并将内容设置为音频文件数据 3. 调用speech:recognize API端点生成转录 4. 调用AutoML情感分析模型的predict方法分析转录

1. Iterate over your local files in Python
2. Use the Speech-to-Text Python library to create a speech.RecognitionAudio object, and set the content to the audio file data
3. Call the speech:recognize API endpoint to generate transcriptions
4. Call the predict method of an AutoML sentiment analysis model to analyze the transcriptions.

D. 1. 在Python中迭代本地文件 2. 使用Speech-to-Text Python库创建speech.RecognitionAudio对象，并将内容设置为音频文件数据 3. 调用speech:longrunningrecognize API端点生成转录 4. 使用analyzeSentiment方法调用Natural Language API

1. Iterate over your local files in Python

2. Use the Speech-to-Text Python Library to create a speech.RecognitionAudio object and set the content to the audio file data
3. Call the speech:longrunningrecognize API endpoint to generate transcriptions.
4. Call the Natural Language API by using the analyzeSentiment method

正确答案：B. 1. Upload the audio files to Cloud Storage. 2. Call the speech:longrunningrecognize API endpoint to generate transcriptions 3. Create a Cloud Function that calls the Natural Language API by using the analyzeSentiment method

解析： 这个问题要求找出处理大量5分钟长的音频文件最高效的方式。选项B是最优解，原因如下：

1. **文件存储策略**：将音频文件从本地数据库上传到Cloud Storage是处理大量音频文件的最佳实践，这允许Speech-to-Text API直接从存储桶读取，避免了带宽和内存限制问题。

2. **API选择**：

    - 对于5分钟长的音频文件，`speech:longrunningrecognize`是正确的API选择，它专为处理长音频设计
    - Natural Language API的`analyzeSentiment`方法是一种托管服务，不需要自己训练和维护模型，对于情感分析任务提供了即用即得的高效解决方案

3. **基础设施选择**：使用Cloud Functions为情感分析创建无服务器组件，提供了自动扩展能力，能高效处理变化的工作负载

与其他选项相比：

- 选项A使用AutoML模型进行情感分析，这需要额外的训练和维护，对于标准情感分析任务可能过于复杂
- 选项C使用`speech:recognize`，这不适合5分钟长的音频（该API更适合短音频），并且它从本地直接处理文件
- 选项D尝试直接从本地文件创建RecognitionAudio对象，这对于处理大量5分钟长音频文件的效率低下

问题 35

题目

你在一家社交媒体公司工作。你想为iOS移动应用程序创建一个无代码图像分类模型，用于识别时尚配饰。你在Cloud Storage中有一个标记数据集。你需要配置一个训练工作流，以最小化成本并以尽可能低的延迟提供预测。你应该怎么做？

You work for a social media company. You want to create a no-code image classification model for an iOS mobile application to identify fashion accessories. You have a labeled dataset in Cloud Storage. You need to configure a training workflow that minimizes cost and serves predictions with the lowest possible latency. What should you do?

选项

A. 使用AutoML训练模型，并在Vertex AI Model Registry中注册模型。配置你的移动应用程序在预测期间发送批量请求。

Train the model by using AutoML, and register the model in Vertex AI Model Registry. Configure your mobile application to send batch requests during prediction.

B. 使用AutoML Edge训练模型，并将其导出为Core ML模型。配置你的移动应用程序直接使用.mlmodel文件。

Train the model by using AutoML Edge, and export it as a Core ML model. Configure your mobile application to use the .mlmodel file directly.

C. 使用AutoML Edge训练模型，并将模型导出为TFLite模型。配置你的移动应用程序直接使用.tflite文件。

Train the model by using AutoML Edge, and export the model as a TFLite model. Configure your mobile application to use the .tflite file directly.

D. 使用AutoML训练模型，并将模型作为Vertex AI端点公开。配置你的移动应用程序在预测期间调用端点。

Train the model by using AutoML, and expose the model as a Vertex AI endpoint. Configure your mobile application to invoke the endpoint during prediction.

正确答案：B. Train the model by using AutoML Edge, and export it as a Core ML model. Configure your mobile application to use the .mlmodel file directly.

解析： 这个问题要求在成本和延迟两个关键指标上进行优化，用于iOS应用的图像分类模型。选项B是最优解，原因如下：

1. **最低可能的延迟**：
    - 在设备上本地运行模型（边缘计算）消除了网络请求延迟
    - Core ML是Apple专为iOS设备优化的机器学习框架，能充分利用设备的神经网络处理单元(NPU)和GPU
    - 边缘推理不依赖网络连接，即使在弱网络或离线环境也能正常工作
2. **最小化成本**：
    - 模型部署到用户设备后，不需要为每次预测付费
    - 不需要维护云端推理服务器，减少了基础设施成本
    - AutoML Edge专为生成高效、小型模型而设计
3. **iOS平台的最佳匹配**：
    - Core ML是iOS的原生机器学习格式，具有与iOS系统和硬件最佳的集成性
    - .mlmodel文件可以直接嵌入到iOS应用中，部署流程简单

相比其他选项：

- 选项A和D都需要从移动设备向云服务器发送请求，增加了延迟和依赖
- 选项C使用TFLite格式，虽然也是边缘部署，但在iOS设备上的性能优化不如Core ML

问题 36

题目

你在一家零售公司工作。你被要求开发一个模型来预测客户是否会在特定日期购买产品。你的团队处理了公司的销售数据，并创建了一个包含以下行的表格： • Customer_id • Product_id • Date • Days_since_last_purchase（以天为单位） • Average_purchase_frequency（以1/天为单位） • Purchase（二元类，如果客户在Date购买了产品）

你需要解释你的模型对每个单独预测的结果。你应该怎么做？

You work for a retail company. You have been asked to develop a model to predict whether a customer will purchase a product on a given day. Your team has processed the company's sales data, and created a table with the following rows: • Customer_id • Product_id • Date • Days_since_last_purchase (measured in days) • Average_purchase_frequency (measured in 1/days) • Purchase (binary class, if customer purchased product on the Date)

You need to interpret your model's results for each individual prediction. What should you do?

选项

A. 创建BigQuery表。使用BigQuery ML构建提升树分类器。检查树的分区规则，以了解每个预测如何通过树流动。

Create a BigQuery table. Use BigQuery ML to build a boosted tree classifier. Inspect the partition rules of the trees to understand how each prediction flows through the trees.

B. 创建Vertex AI表格数据集。训练AutoML模型来预测客户购买。将模型部署到Vertex AI端点并启用特征归因。使用"explain"方法获取每个单独预测的特征归因值。

Create a Vertex AI tabular dataset. Train an AutoML model to predict customer purchases. Deploy the model to a Vertex AI endpoint and enable feature attributions. Use the "explain" method to get feature attribution values for each individual prediction.

C. 创建BigQuery表。使用BigQuery ML构建逻辑回归分类模型。使用模型系数的值来解释特征重要性，值越高表示重要性越高。

Create a BigQuery table. Use BigQuery ML to build a logistic regression classification model. Use the values of the coefficients of the model to interpret the feature importance, with higher values corresponding to more importance

D. 创建Vertex AI表格数据集。训练AutoML模型来预测客户购买。将模型部署到Vertex AI端点。在每次预测时，启用L1正则化以检测非信息特征。

Create a Vertex AI tabular dataset. Train an AutoML model to predict customer purchases. Deploy the model to a Vertex AI endpoint. At each prediction, enable L1 regularization to detect non-informative features.

正确答案：B. Create a Vertex AI tabular dataset. Train an AutoML model to predict customer purchases. Deploy the model to a Vertex AI endpoint and enable feature attributions. Use the "explain" method to get feature attribution values for each individual prediction.

解析： 题目要求为每个单独的预测提供解释，这本质上是一个"模型可解释性"问题，特别是在单个预测实例层面。

选项B是最佳解决方案，因为：

1. **个体级别的解释**：Vertex AI的feature attributions功能专为解释单个预测而设计，能针对每次预测提供具体的特征贡献值
2. **方法适配性**：`explain`方法会返回每个特征对特定预测结果的贡献度，使业务人员能够理解为什么某个特定顾客被预测为会购买或不会购买
3. **可视化能力**：Vertex AI的特征归因可以生成直观的图表，显示每个特征的相对重要性

4. **灵活性**：适用于复杂的黑盒模型，即使是AutoML生成的复杂模型也能提供可解释性

相比之下，其他选项存在以下问题：

选项A使用决策树检查分区规则，虽然决策树本身较为可解释，但对于提升树模型，很难清晰解释单个预测的完整路径。

选项C中，逻辑回归系数提供的是全局特征重要性，不能解释单个预测实例的特征贡献。

选项D错误地将L1正则化描述为预测时的操作，而实际上L1正则化是训练过程中用于特征选择的技术。

问题 37

题目

你为一家在零售店收银区捕捉实时视频画面的公司工作。你需要使用实时视频画面构建一个模型，在接近实时的情况下检测等待服务的客户数量。你希望快速实施解决方案并尽量减少工作量。你应该如何构建模型？

You work for a company that captures live video footage of checkout areas in their retail stores. You need to use the live video footage to build a model to detect the number of customers waiting for service in near real time. You want to implement a solution quickly and with minimal effort. How should you build the model?

选项

A. 使用Vertex AI Vision占用分析模型。

Use the Vertex AI Vision Occupancy Analytics model.

B. 使用Vertex AI Vision人员/车辆检测器模型。

Use the Vertex AI Vision Person/vehicle detector model.

C. 使用Vertex AutoML在标注数据集上训练AutoML对象检测模型。

Train an AutoML object detection model on an annotated dataset by using Vertex AutoML.

D. 使用Vertex AutoML在标注数据集上训练Seq2Seq+对象检测模型。

Train a Seq2Seq+ object detection model on an annotated dataset by using Vertex AutoML.

正确答案：A. Use the Vertex AI Vision Occupancy Analytics model.

解析： 这个问题强调了两个关键需求：1) 需要"快速实施"解决方案，2) 需要"最小化工作量"。基于这些要求，选项A明显是最佳选择。

Vertex AI Vision Occupancy Analytics模型是一个预训练模型，专门设计用于分析视频中的空间占用情况和人员计数。这个模型具有以下优势：

1. **即用即得的解决方案**：这是一个已经训练好的模型，可以直接使用，无需额外的训练过程
2. **专为人员计数设计**：该模型专门用于分析空间中的人流量和占用情况，与检测排队顾客数量的需求完全吻合
3. **实时处理能力**：支持近实时视频分析，满足题目中的"near real time"要求
4. **最小化工作量**：直接应用预训练模型，无需收集、标注数据或调整模型参数

与其他选项相比：

- 选项B的Person/vehicle detector模型虽然也是预训练模型，但它主要功能是识别图像中人和车辆的存在，而不是专门用于计数或分析排队情况
- 选项C和D都需要创建标注数据集并训练自定义模型，这会显著增加实施时间和所需工作量

问题 38

题目

你在一家大型银行公司担任分析师。你正在开发一个强大且可扩展的ML流水线，用于训练多个回归和分类模型。你对该流水线的主要关注点是模型可解释性。你希望尽快将流水线投入生产。你应该怎么做？

You work as an analyst at a large banking firm. You are developing a robust scalable ML pipeline to train several regression and classification models. Your primary focus for the pipeline is model interpretability. You want to productionize the pipeline as quickly as possible. What should you do?

选项

A. 通过Vertex AI Pipelines使用Wide & Deep的表格工作流程，联合训练宽线性模型和深度神经网络

Use Tabular Workflow for Wide & Deep through Vertex AI Pipelines to jointly train wide linear models and deep neural networks

B. 使用Google Kubernetes Engine为基于XGBoost的模型构建自定义训练流水线

Use Google Kubernetes Engine to build a custom training pipeline for XGBoost-based models

C. 通过Vertex AI Pipelines使用TabNet的表格工作流程来训练基于注意力的模型

Use Tabular Workflow for TabNet through Vertex AI Pipelines to train attention-based models

D. 使用Cloud Composer为自定义深度学习模型构建训练流水线

Use Cloud Composer to build the training pipelines for custom deep learning-based models

正确答案：C. Use Tabular Workflow for TabNet through Vertex AI Pipelines to train attention-based models

解析：这个问题要求建立一个关注模型可解释性且能快速投入生产的ML流水线。选项C是最佳选择，原因如下：

1. **模型可解释性**：
   - TabNet是一种基于注意力机制的神经网络架构，专为表格数据设计
   - 它能提供实例级别的特征归因，明确显示每个特征对每个预测的影响
   - TabNet提供了Deep Learning的性能同时保持了传统ML方法的可解释性
   - 它的实例级和特征级解释机制非常适合银行业需要解释决策的监管要求
2. **快速投入生产**：
   - Vertex AI Pipelines提供了完全托管的环境，减少了基础设施管理负担
   - Tabular Workflow是预构建的流水线模板，无需从头编写代码
   - 这种方法提供了端到端的解决方案，从数据处理到训练再到部署

与其他选项相比：

- 选项A的Wide & Deep模型虽然结合了线性模型的可解释性和深度网络的表现力，但它的可解释性主要来自"Wide"部分，而"Deep"部分仍然是黑盒
- 选项B需要在GKE上构建和管理自定义流水线，不符合"尽快投入生产"的要求
- 选项D使用Cloud Composer不仅需要处理Airflow工作流配置，还需要面对深度学习模型的可解释性挑战

问题 39

题目

你在TensorFlow中开发了一个用于翻译文本的Transformer模型。你的训练数据包括Cloud Storage存储桶中的数百万文档。你计划使用分布式训练来减少训练时间。你需要配置训练作业，同时最小化修改代码和管理集群配置所需的工作量。你应该怎么做？

You developed a Transformer model in TensorFlow to translate text. Your training data includes millions of documents in a Cloud Storage bucket. You plan to use distributed training to reduce training time. You need to configure the training job while minimizing the effort required to modify code and to manage the cluster's configuration. What should you do?

选项

A. 为第二个工作池创建带有GPU加速器的Vertex AI自定义训练作业。使用tf.distribute.MultiWorkerMirroredStrategy进行分发。

Create a Vertex AI custom training job with GPU accelerators for the second worker pool. Use tf.distribute.MultiWorkerMirroredStrategy for distribution.

B. 创建带有Reduction Server的Vertex AI自定义分布式训练作业。为第一和第二池使用N1高内存机器类型实例，为第三工作池使用N1高CPU机器类型实例。

Create a Vertex AI custom distributed training job with Reduction Server. Use N1 high-memory machine type instances for the first and second pools, and use N1 high-CPU machine type instances for the third worker pool.

C. 创建使用Cloud TPU VM的训练作业。使用tf.distribute.TPUStrategy进行分发。

Create a training job that uses Cloud TPU VMs. Use tf.distribute.TPUStrategy for distribution.

D. 创建带有A2 GPU机器类型实例的单工作池的Vertex AI自定义训练作业。使用tf.distribute.MirroredStrategy进行分发。

Create a Vertex AI custom training job with a single worker pool of A2 GPU machine type instances. Use tf.distribute.MirroredStrategy for distribution.

正确答案：C. Create a training job that uses Cloud TPU VMs. Use tf.distribute.TPUStrategy for distribution.

解析： 这个问题要求为Transformer模型选择最佳的分布式训练配置，同时最小化代码修改和集群管理负担。

选项C使用Cloud TPU VM和TPUStrategy是最佳选择，原因如下：

1. **代码修改最少**：TPUStrategy是TensorFlow中专为TPU优化的高级分布式策略，通常只需少量代码修改

2. **最小化集群管理**：Cloud TPU VM是一种托管解决方案，Google自动处理底层硬件管理和扩展
3. **性能最优**：TPU专为大规模机器学习工作负载（特别是Transformer模型）设计，提供了卓越的性能
4. **最佳的硬件-软件匹配**：TPU与TensorFlow深度集成，为Transformer等大型模型提供最佳训练效率

相比之下：

- 选项A需要手动配置多个工作池，增加了管理复杂性
- 选项B需要设置和维护Reduction Server及三个不同的工作池，显著增加了管理负担
- 选项D仅使用单个工作池，可能无法充分利用分布式训练的优势

对于大型Transformer模型和数百万文档的训练数据集，TPU提供了最佳的性能和成本效益比。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 5)

问题 41

题目

你在一家酒店工作，有一个数据集包含客户的书面评论，这些评论是从纸质客户反馈表格中扫描的，以PDF文件形式存储。每个表格都有相同的布局。你需要从每个表格上的客户评论中快速预测整体满意度分数。你应该如何完成这项任务？

You work for a hotel and have a dataset that contains customers' written comments scanned from paper-based customer feedback forms, which are stored as PDF files. Every form has the same layout. You need to quickly predict an overall satisfaction score from the customer comments on each form. How should you accomplish this task?

选项

A. 使用Vision API从每个PDF文件解析文本。使用Natural Language API的analyzeSentiment功能推断整体满意度分数。

Use the Vision API to parse the text from each PDF file. Use the Natural Language API analyzeSentiment feature to infer overall satisfaction scores.

B. 使用Vision API从每个PDF文件解析文本。使用Natural Language API的analyzeEntitySentiment功能推断整体满意度分数。

Use the Vision API to parse the text from each PDF file. Use the Natural Language API analyzeEntitySentiment feature to infer overall satisfaction scores.

C. 训练Document AI自定义提取器来解析每个PDF文件评论部分的文本。使用Natural Language API的analyzeSentiment功能推断整体满意度分数。

Uptrain a Document AI custom extractor to parse the text in the comments section of each PDF file. Use the Natural Language API analyzeSentiment feature to infer overall satisfaction scores.

D. 训练Document AI自定义提取器来解析每个PDF文件评论部分的文本。使用Natural Language API的analyzeEntitySentiment功能推断整体满意度分数。

Uptrain a Document AI custom extractor to parse the text in the comments section of each PDF file. Use the Natural Language API analyzeEntitySentiment feature to infer overall satisfaction scores.

正确答案：C. Uptrain a Document AI custom extractor to parse the text in the comments section of each PDF file. Use the Natural Language API analyzeSentiment feature to infer overall satisfaction scores.

解析： 这个问题涉及从结构一致的酒店反馈表单中提取顾客评论并预测整体满意度，需要考虑两个关键步骤：1) 文本提取和2) 情感分析。

Document AI是比Vision API更优选择，因为:

- 专为结构化文档设计，能识别并解析表单布局
- 题目明确指出"每个表单具有相同布局"，Document AI可以训练为只提取表单中的评论部分
- 相比之下，Vision API是更通用的OCR工具，会提取所有文本，需要额外处理才能获取评论内容

对于情感分析部分，analyzeSentiment比analyzeEntitySentiment更适合，因为:

- analyzeSentiment提供整个文本的整体情感分数，这正是预测"整体满意度分数"所需的
- analyzeEntitySentiment会识别文本中的特定实体（如"房间"、"服务"等）并分别分析每个实体的情感
- 题目要求的是"整体满意度分数"，而不是针对具体方面的细化分析

问题 42

题目

你在一家初创公司工作，该公司有多个数据科学工作负载。你的计算基础设施目前在本地，数据科学工作负载原生于PySpark。你的团队计划将数据科学工作负载迁移到Google Cloud。你需要构建一个概念验证，将一个数据科学作业迁移到Google Cloud。你想提出一个需要最小成本和工作量的迁移过程。你应该首先做什么？

You work for a startup that has multiple data science workloads. Your compute infrastructure is currently on-premises, and the data science workloads are native to PySpark. Your team plans to migrate their data science workloads to Google Cloud. You need to build a proof of concept to migrate one data science job to Google Cloud. You want to propose a migration process that requires minimal cost and effort. What should you do first?

选项

A. 创建一个n2-standard-4虚拟机实例，并在其上安装Java、Scala和Apache Spark依赖项。

Create a n2-standard-4 VM instance and install Java, Scala, and Apache Spark dependencies on it.

B. 创建一个具有基本节点池配置的Google Kubernetes Engine集群，在其上安装Java、Scala和Apache Spark依赖项。

Create a Google Kubernetes Engine cluster with a basic node pool configuration, install Java, Scala, and Apache Spark dependencies on it.

C. 创建一个标准(1个主节点，3个工作节点)Dataproc集群，并在其上运行Vertex AI Workbench笔记本实例。

Create a Standard (1 master, 3 workers) Dataproc cluster, and run a Vertex AI Workbench notebook instance on it.

D. 创建一个实例类型为n2-standard-4的Vertex AI Workbench笔记本。

Create a Vertex AI Workbench notebook with instance type n2-standard-4.

正确答案：D. Create a Vertex AI Workbench notebook with instance type n2-standard-4.

解析： 这个问题的关键在于"最小成本和工作量"（minimal cost and effort）进行PySpark工作负载的迁移概念验证。

选项D是最佳选择，原因如下：

1. **最小化初始设置工作**：
    - Vertex AI Workbench笔记本预安装了PySpark和常用数据科学库
    - 无需手动安装Java、Scala或Spark依赖项
    - 可以直接开始编写和执行PySpark代码
2. **成本效益**：
    - 单个n2-standard-4实例比完整的Spark集群成本低得多
    - 对于概念验证阶段，不需要高性能计算集群
3. **与数据科学工作流程的兼容性**：
    - 笔记本界面是数据科学家熟悉的工作环境
    - 支持交互式开发和实验，非常适合概念验证阶段

相比之下，其他选项需要更多的设置和配置工作：

- 选项A需要手动安装和配置所有Spark依赖项，增加了工作量
- 选项B涉及Kubernetes，对于简单的概念验证来说过于复杂
- 选项C的Dataproc集群对于初始概念验证来说资源过剩且成本较高

问题 43

题目

你在一家银行工作。你被要求开发一个支持贷款申请决策的ML模型。你需要确定在工作流中包含哪些Vertex AI服务。你想跟踪模型的训练参数和每个训练轮次的指标。你计划比较每个版本模型的性能，根据你选择的指标确定最佳模型。你应该使用哪些Vertex AI服务？

You work for a bank. You have been asked to develop an ML model that will support loan application decisions. You need to determine which Vertex AI services to include in the workflow. You want to track the model's training parameters and the metrics per training epoch. You plan to compare the performance of each version of the model to determine the best model based on your chosen metrics. Which Vertex AI services should you use?

选项

A. Vertex ML Metadata、Vertex AI Feature Store和Vertex AI Vizier

Vertex ML Metadata, Vertex AI Feature Store, and Vertex AI Vizier

B. Vertex AI Pipelines、Vertex AI Experiments和Vertex AI Vizier

Vertex AI Pipelines, Vertex AI Experiments, and Vertex AI Vizier

C. Vertex ML Metadata、Vertex AI Experiments和Vertex AI TensorBoard

Vertex ML Metadata, Vertex AI Experiments, and Vertex AI TensorBoard

D. Vertex AI Pipelines、Vertex AI Feature Store和Vertex AI TensorBoard

Vertex AI Pipelines, Vertex AI Feature Store, and Vertex AI TensorBoard

正确答案：C. Vertex ML Metadata, Vertex AI Experiments, and Vertex AI TensorBoard

解析： 这个问题要求选择适合银行贷款决策模型开发的Vertex AI服务组合，特别强调需要跟踪训练参数、每轮训练指标以及比较不同版本模型性能。

选项C提供了最理想的服务组合，原因如下：

1. **Vertex ML Metadata**：
   - 提供了全面的元数据跟踪功能，记录模型的训练参数、数据集和执行情况
   - 支持模型谱系追踪，对于银行这类受监管行业尤为重要
   - 有助于理解模型版本之间的差异和变化
2. **Vertex AI Experiments**：
   - 专门设计用于组织、跟踪和比较机器学习实验
   - 允许创建不同的实验运行，并基于选定指标进行比较，直接满足"比较每个版本模型的性能"的需求
   - 提供可视化工具来比较不同模型版本的关键指标，帮助选择最佳模型
3. **Vertex AI TensorBoard**：
   - 提供了详细的训练过程可视化，是跟踪"每个训练周期指标"的理想工具
   - 支持实时监控训练进度，查看损失函数、准确率等指标随时间的变化
   - 提供模型权重、梯度和激活函数的可视化，有助于深入理解模型行为

相比之下，其他选项中的服务组合不能完全满足需求：

- Feature Store（选项A和D）主要用于特征管理和服务，不直接支持训练参数跟踪或模型比较
- Vizier（选项A和B）专注于超参数调优，而非全面的实验跟踪和比较

问题 44

题目

你在一家汽车保险公司工作。你正在准备一个概念验证ML应用程序，该应用程序使用受损车辆的图像来推断受损部件。你的团队已经从公司数据库中的损坏索赔文件中整理了一组带注释的图像。与每个图像相关的注释包括每个已识别受损部件的边界框和部件名称。你有足够的预算在Google Cloud上训练模型。你需要快速创建一个初始模型。你应该怎么做？

You work for an auto insurance company. You are preparing a proof-of-concept ML application that uses images of damaged vehicles to infer damaged parts. Your team has assembled a set of annotated images

from damage claim documents in the company's database. The annotations associated with each image consist of a bounding box for each identified damaged part and the part name. You have been given a sufficient budget to train models on Google Cloud. You need to quickly create an initial model. What should you do?

选项

A. 从TensorFlow Hub下载一个预训练的对象检测模型。使用带注释的图像数据在Vertex AI Workbench中微调模型。

Download a pre-trained object detection model from TensorFlow Hub. Fine-tune the model in Vertex AI Workbench by using the annotated image data.

B. 在AutoML中使用带注释的图像数据训练对象检测模型。

Train an object detection model in AutoML by using the annotated image data.

C. 在Vertex AI Pipelines中创建一个流水线，配置AutoMLTrainingJobRunOp组件，使用带注释的图像数据训练自定义对象检测模型。

Create a pipeline in Vertex AI Pipelines and configure the AutoMLTrainingJobRunOp component to train a custom object detection model by using the annotated image data.

D. 在Vertex AI自定义训练中使用带注释的图像数据训练对象检测模型。

Train an object detection model in Vertex AI custom training by using the annotated image data.

正确答案：B. Train an object detection model in AutoML by using the annotated image data.

解析： 这个问题的核心要求是为汽车保险公司"快速创建一个初始模型"，用于识别受损车辆图像中的受损部件。

选项B是最佳选择，原因如下：

1. **速度和效率**：
    - AutoML提供了无代码解决方案，可以最快速地从已标注数据到工作模型
    - 整个过程只需上传数据并配置几个基本参数，无需编写复杂代码
    - 特别适合"快速创建初始模型"的要求
2. **适合概念验证阶段**：
    - 概念验证阶段目标是快速验证可行性，而非构建最优模型
    - AutoML能以最小努力提供足够好的结果来验证概念
3. **充分利用已有标注数据**：
    - 题目明确指出已有带边界框和部件名称的标注数据，这正好符合AutoML对象检测的输入格式
    - AutoML可以直接使用这些标注，无需额外处理

相比之下，其他选项需要更多时间和专业知识：

- 选项A需要选择适当的预训练模型，编写微调代码，并管理训练过程

- 选项C引入了不必要的复杂性，使用Vertex AI Pipelines对于简单的概念验证来说过于繁琐
- 选项D需要从头编写自定义训练代码，这是最灵活但也是最耗时的方法

问题 45

题目

你正在分析存储在Cloud Storage中的医疗保健组织的客户数据。数据包含个人身份信息(PII)。你需要进行数据探索和预处理，同时确保敏感字段的安全和隐私。你应该怎么做？

You are analyzing customer data for a healthcare organization that is stored in Cloud Storage. The data contains personally identifiable information (PII). You need to perform data exploration and preprocessing while ensuring the security and privacy of sensitive fields. What should you do?

选项

A. 在执行数据探索和预处理之前，使用Cloud Data Loss Prevention (DLP) API去标识PII。

Use the Cloud Data Loss Prevention (DLP) API to de-identify the PII before performing data exploration and preprocessing.

B. 使用客户管理的加密密钥(CMEK)对静态PII数据进行加密，并在数据探索和预处理期间解密PII数据。

Use customer-managed encryption keys (CMEK) to encrypt the PII data at rest, and decrypt the PII data during data exploration and preprocessing.

C. 使用VPC Service Controls安全边界内的虚拟机进行数据探索和预处理。

Use a VM inside a VPC Service Controls security perimeter to perform data exploration and preprocessing.

D. 使用Google管理的加密密钥对静态PII数据进行加密，并在数据探索和预处理期间解密PII数据。

Use Google-managed encryption keys to encrypt the PII data at rest, and decrypt the PII data during data exploration and preprocessing.

正确答案：A. Use the Cloud Data Loss Prevention (DLP) API to de-identify the PII before performing data exploration and preprocessing.

解析： 这个问题涉及医疗健康数据的处理，这类数据通常受到严格的隐私法规保护。关键要求是在进行数据探索和预处理的同时确保敏感字段的安全性和隐私性。

选项A是最佳选择，原因如下：

1. **数据本身的保护**：
    - Cloud DLP API专门设计用于识别、分类和去识别化（de-identify）敏感数据
    - 去识别化过程会将PII转换为假名、令牌或掩码值，使分析人员无法看到实际的敏感信息
    - 这种方法保留了数据的分析价值和结构，同时移除了隐私风险
2. **符合医疗数据处理最佳实践**：
    - 医疗数据处理通常要求"最小必要"原则，即只使用完成特定任务所需的最少敏感信息
    - DLP提供了多种去识别化技术（如K-匿名化、L-多样性等），适合不同的分析需求

3. **平衡分析需求和隐私保护**：
    - 去识别化后的数据仍然可以用于大多数数据探索和预处理任务
    - 如果确实需要原始数据进行特定分析，DLP还提供了重新识别功能，但可以严格控制此类访问

与其他选项相比：

- 选项B和D（使用加密密钥）主要保护的是静态存储和传输中的数据，但一旦解密用于分析，敏感PII就会完全暴露
- 选项C（VPC Service Controls）提供的是网络级别的隔离，不会改变数据本身，分析人员仍能看到原始PII数据

问题 46

题目

你正在构建一个预测性维护模型，以预先检测桥梁部件缺陷。你计划使用桥梁的高清图像作为模型输入。你需要向相关利益方解释模型的输出，以便他们采取适当的行动。你应该如何构建模型？

You are building a predictive maintenance model to preemptively detect part defects in bridges. You plan to use high definition images of the bridges as model inputs. You need to explain the output of the model to the relevant stakeholders so they can take appropriate action. How should you build the model?

选项

A. 使用scikit-learn构建基于树的模型，并使用SHAP值解释模型输出。

Use scikit-learn to build a tree-based model, and use SHAP values to explain the model output.

B. 使用scikit-learn构建基于树的模型，并使用部分依赖图(PDP)解释模型输出。

Use scikit-learn to build a tree-based model, and use partial dependence plots (PDP) to explain the model output.

C. 使用TensorFlow创建基于深度学习的模型，并使用集成梯度(Integrated Gradients)解释模型输出。

Use TensorFlow to create a deep learning-based model, and use Integrated Gradients to explain the model output.

D. 使用TensorFlow创建基于深度学习的模型，并使用采样Shapley方法解释模型输出。

Use TensorFlow to create a deep learning-based model, and use the sampled Shapley method to explain the model output.

正确答案：C. Use TensorFlow to create a deep learning-based model, and use Integrated Gradients to explain the model output.

解析： 这个问题涉及使用高清桥梁图像建立预测性维护模型，同时需要向相关利益方解释模型输出。

选项C是最佳方案，原因如下：

1. **模型与输入数据的匹配度**：

- 题目明确指出使用"高清图像"作为模型输入
- 深度学习模型，特别是卷积神经网络(CNN)，是处理图像数据的标准方法
- TensorFlow提供了丰富的图像处理架构，非常适合从复杂图像中检测细微缺陷

2. **解释方法的适用性**：

- Integrated Gradients是专为解释深度学习图像模型而设计的技术
- 它能够生成"归因图"，直观地显示图像中哪些区域对预测结果贡献最大
- 这种可视化解释方式极其适合桥梁缺陷检测，因为它可以直接在图像上高亮显示潜在问题区域
- 工程师和决策者可以查看这些高亮区域，直接判断需要检查的具体位置

3. **实际应用价值**：

- 在桥梁维护场景中，能够精确定位可能存在缺陷的位置至关重要
- Integrated Gradients提供的像素级解释正好满足这一需求

相比之下，其他选项存在明显缺陷：

- 选项A和B使用scikit-learn的树模型，这类模型不适合直接处理原始图像数据
- 选项D使用深度学习模型是正确的，但Sampled Shapley方法对高维图像数据计算成本极高，且不如Integrated Gradients那样为视觉解释专门优化

问题 47

题目

你在一家医院工作，该医院希望优化手术安排方式。你需要创建一个模型，使用已安排手术数量与使用床位之间的关系。你想预测每天基于已安排手术需要多少床位。你有一年的医院数据，按365行组织。

数据包括每天的以下变量：• 安排的手术数量 • 占用的床位数 • 日期

你想最大化模型开发和测试的速度。你应该怎么做？

You work for a hospital that wants to optimize how it schedules operations. You need to create a model that uses the relationship between the number of surgeries scheduled and beds used. You want to predict how many beds will be needed for patients each day in advance based on the scheduled surgeries. You have one year of data for the hospital organized in 365 rows.

The data includes the following variables for each day: • Number of scheduled surgeries • Number of beds occupied • Date

You want to maximize the speed of model development and testing. What should you do?

选项

A. 创建一个BigQuery表。使用BigQuery ML构建回归模型，将床位数作为目标变量，将已安排手术数量和日期特征（如星期几）作为预测变量。

Create a BigQuery table. Use BigQuery ML to build a regression model, with number of beds as the target variable, and number of scheduled surgeries and date features (such as day of week) as the predictors.

B. 创建一个BigQuery表。使用BigQuery ML构建ARIMA模型，将床位数作为目标变量，将日期作为时间变量。

Create a BigQuery table. Use BigQuery ML to build an ARIMA model, with number of beds as the target variable, and date as the time variable.

C. 创建一个Vertex AI表格数据集。训练一个AutoML回归模型，将床位数作为目标变量，将已安排小手术数量和日期特征（如星期几）作为预测变量。

Create a Vertex AI tabular dataset. Train an AutoML regression model, with number of beds as the target variable, and number of scheduled minor surgeries and date features (such as day of the week) as the predictors.

D. 创建一个Vertex AI表格数据集。训练一个Vertex AI AutoML预测模型，将床位数作为目标变量，将已安排手术数量作为协变量，将日期作为时间变量。

Create a Vertex AI tabular dataset. Train a Vertex AI AutoML Forecasting model, with number of beds as the target variable, number of scheduled surgeries as a covariate and date as the time variable.

正确答案：D. Create a Vertex AI tabular dataset. Train a Vertex AI AutoML Forecasting model, with number of beds as the target variable, number of scheduled surgeries as a covariate and date as the time variable.

解析： 这个问题要求预测医院每天需要的床位数量，这本质上是一个时间序列预测问题，而不仅仅是简单的回归分析。

选项D是最佳方案，原因如下：

1. **问题本质是时间序列预测**：
    - 医院床位预测本质上是一个时间序列预测问题，强调了时间维度的重要性
    - Vertex AI AutoML Forecasting专为此类预测任务设计
    - 自动处理时间特征提取、模型选择和参数调优，减少了手动工作
2. **数据协变量的最佳利用**：
    - 选项D明确将"已排期手术数量"作为协变量纳入预测模型
    - 这正确地建模了手术排期如何影响未来床位需求的因果关系
    - 医院情况通常有周期性模式（如周末与工作日差异），时间序列模型能自动捕捉这些模式
3. **开发效率的整体考量**：
    - 虽然数据只有365行，但AutoML Forecasting能有效处理小规模时间序列数据
    - 自动化特征工程和模型选择减少了总体开发时间
    - 专门的预测模型通常比通用回归模型更适合处理固有的时间结构

相比之下，其他选项存在以下问题：

- 选项A使用简单回归模型，无法充分捕捉时间序列数据的时间依赖性
- 选项B的ARIMA模型没有将关键预测变量"手术数量"作为协变量
- 选项C错误地指定了"小手术数量"而非题目中的"手术数量"

问题 48

题目

你最近在TensorFlow中开发了一个wide and deep模型。你使用SQL脚本生成训练数据集，该脚本在BigQuery中预处理原始数据，对数据进行实例级转换。你需要创建一个训练流水线，每周重新训练模型。训练好的模型将用于生成每日推荐。你想最小化模型开发和训练时间。你应该如何开发训练流水线？

You recently developed a wide and deep model in TensorFlow. You generated training datasets using a SQL script that preprocessed raw data in BigQuery by performing instance-level transformations of the data. You need to create a training pipeline to retrain the model on a weekly basis. The trained model will be used to generate daily recommendations. You want to minimize model development and training time. How should you develop the training pipeline?

选项

A. 使用Kubeflow Pipelines SDK实现流水线。使用BigQueryJobOp组件运行预处理脚本，使用CustomTrainingJobOp组件启动Vertex AI训练作业。

Use the Kubeflow Pipelines SDK to implement the pipeline. Use the BigQueryJobOp component to run the preprocessing script and the CustomTrainingJobOp component to launch a Vertex AI training job.

B. 使用Kubeflow Pipelines SDK实现流水线。使用DataflowPythonJobOp组件预处理数据，使用CustomTrainingJobOp组件启动Vertex AI训练作业。

Use the Kubeflow Pipelines SDK to implement the pipeline. Use the DataflowPythonJobOp component to preprocess the data and the CustomTrainingJobOp component to launch a Vertex AI training job.

C. 使用TensorFlow Extended SDK实现流水线。使用带有BigQuery执行器的ExampleGen组件摄取数据，使用Transform组件预处理数据，使用Trainer组件启动Vertex AI训练作业。

Use the TensorFlow Extended SDK to implement the pipeline Use the ExampleGen component with the BigQuery executor to ingest the data the Transform component to preprocess the data, and the Trainer component to launch a Vertex AI training job.

D. 使用TensorFlow Extended SDK实现流水线。将预处理步骤实现为模型input_fn的一部分。使用带有BigQuery执行器的ExampleGen组件摄取数据，使用Trainer组件启动Vertex AI训练作业。

Use the TensorFlow Extended SDK to implement the pipeline Implement the preprocessing steps as part of the input_fn of the model. Use the ExampleGen component with the BigQuery executor to ingest the data and the Trainer component to launch a Vertex AI training job.

正确答案：A. Use the Kubeflow Pipelines SDK to implement the pipeline. Use the BigQueryJobOp component to run the preprocessing script and the CustomTrainingJobOp component to launch a Vertex AI training job.

解析：这道题目要求为TensorFlow wide and deep模型创建训练流水线，关键要求是"最小化模型开发和训练时间"。已有的工作流包括使用SQL脚本在BigQuery中预处理数据。

选项A是最佳选择，原因如下：

1. **复用现有资产**：
    - 题目明确提到已经有SQL脚本用于预处理数据
    - BigQueryJobOp组件允许直接执行这些现有SQL脚本，不需要重写预处理逻辑
    - 复用现有代码大幅减少开发时间，符合"最小化模型开发时间"的要求

2. **技术选择适当**：
    - Kubeflow Pipelines提供了简洁的方式连接BigQuery和Vertex AI训练作业
    - CustomTrainingJobOp支持在Vertex AI上运行现有的TensorFlow模型训练代码
    - 这种组合避免了任何主要的代码重构工作
3. **处理流程优化**：
    - BigQuery处理大规模数据效率高，适合SQL预处理
    - 直接从BigQuery到训练作业的流程最小化了数据传输开销
    - 整个流程无需额外中间处理，减少了总训练时间

相比之下，其他选项存在以下问题：

- 选项B需要将SQL脚本重写为Python代码，增加了不必要的开发工作
- 选项C要求使用Transform组件重新实现预处理逻辑，而不是利用现有的SQL脚本
- 选项D将预处理集成到模型的input_fn中，这会影响训练效率，因为每次训练时都需要重新执行相同的预处理逻辑

问题 49

题目

你正在使用大型数据集为你的公司训练自定义语言模型。你计划在Vertex AI上使用Reduction Server策略。你需要配置分布式训练作业的工作池。你应该怎么做？

You are training a custom language model for your company using a large dataset. You plan to use the Reduction Server strategy on Vertex AI. You need to configure the worker pools of the distributed training job. What should you do?

选项

A. 将前两个工作池的机器配置为具有GPU，并使用包含你的训练代码的容器镜像。将第三个工作池配置为具有GPU，并使用reductionserver容器镜像。

Configure the machines of the first two worker pools to have GPUs, and to use a container image where your training code runs. Configure the third worker pool to have GPUs, and use the reductionserver container image.

B. 将前两个工作池的机器配置为具有GPU，并使用包含你的训练代码的容器镜像。将第三个工作池配置为使用不带加速器的reductionserver容器镜像，并选择优先考虑带宽的机器类型。

Configure the machines of the first two worker pools to have GPUs and to use a container image where your training code runs. Configure the third worker pool to use the reductionserver container image without accelerators, and choose a machine type that prioritizes bandwidth.

C. 将前两个工作池的机器配置为具有TPU，并使用包含你的训练代码的容器镜像。将第三个工作池配置为不带加速器，并使用不带加速器的reductionserver容器镜像，并选择优先考虑带宽的机器类型。

Configure the machines of the first two worker pools to have TPUs and to use a container image where your training code runs. Configure the third worker pool without accelerators, and use the reductionserver

container image without accelerators, and choose a machine type that prioritizes bandwidth.

D. 将前两个工作池的机器配置为具有TPU，并使用包含你的训练代码的容器镜像。将第三个工作池配置为具有TPU，并使用reductionserver容器镜像。

Configure the machines of the first two pools to have TPUs, and to use a container image where your training code runs. Configure the third pool to have TPUs, and use the reductionserver container image.

正确答案：B. Configure the machines of the first two worker pools to have GPUs and to use a container image where your training code runs. Configure the third worker pool to use the reductionserver container image without accelerators, and choose a machine type that prioritizes bandwidth.

解析： 这个问题考察对Vertex AI上Reduction Server分布式训练策略的理解，尤其是如何正确配置不同工作池的资源和角色。

选项B是最佳配置，原因如下：

1. **合理的加速器分配**：
    - 第一和第二工作池负责实际的模型训练计算，因此配置GPU是合适的，能够加速语言模型的矩阵运算
    - 第三工作池（Reduction Server）主要负责梯度聚合和通信，这是带宽密集型而非计算密集型的任务，不需要GPU加速器
    - 为Reduction Server添加GPU会浪费计算资源而不会显著提高性能
2. **针对Reduction Server的优化选择**：
    - 将Reduction Server配置为优先考虑带宽的机器类型是正确的，因为它的主要瓶颈是网络通信
    - 选择高带宽、无加速器的机器类型为这种通信密集型角色提供了最佳成本效益比
3. **容器镜像分配适当**：
    - 工作池使用包含训练代码的容器镜像，确保它们能执行模型训练
    - Reduction Server使用专用的reductionserver容器镜像，这是专为梯度聚合功能设计的

相比之下，其他选项存在以下问题：

- 选项A为Reduction Server配置了GPU，这是不必要的资源浪费
- 选项C和D使用TPU而非GPU，虽然对某些语言模型有效，但题目没有指定这种需求，且TPU通常比同等GPU更贵
- 选项D还为Reduction Server添加了TPU，这比为其添加GPU更加浪费资源

问题 50

题目

你已经使用在批处理Dataflow流水线中预处理的数据训练了一个模型。你的用例需要实时推理。你希望确保训练和服务之间一致地应用数据预处理逻辑。你应该怎么做？

You have trained a model by using data that was preprocessed in a batch Dataflow pipeline. Your use case requires real-time inference. You want to ensure that the data preprocessing logic is applied consistently between training and serving. What should you do?

选项

A. 执行数据验证，确保流水线的输入数据与端点的输入数据格式相同。

Perform data validation to ensure that the input data to the pipeline is the same format as the input data to the endpoint.

B. 重构批处理数据流水线中的转换代码，使其可以在流水线外使用。在端点中使用相同的代码。

Refactor the transformation code in the batch data pipeline so that it can be used outside of the pipeline. Use the same code in the endpoint.

C. 重构批处理数据流水线中的转换代码，使其可以在流水线外使用。与端点的最终用户共享此代码。

Refactor the transformation code in the batch data pipeline so that it can be used outside of the pipeline. Share this code with the end users of the endpoint.

D. 使用时间窗口批处理实时请求，然后使用Dataflow流水线预处理批处理请求。将预处理后的请求发送到端点。

Batch the real-time requests by using a time window and then use the Dataflow pipeline to preprocess the batched requests. Send the preprocessed requests to the endpoint.

正确答案：B. Refactor the transformation code in the batch data pipeline so that it can be used outside of the pipeline. Use the same code in the endpoint.

解析： 这个问题关注的是训练和推理之间的数据处理一致性，尤其是如何将批处理环境中的预处理逻辑应用到实时推理环境中。

选项B是最佳解决方案，原因如下：

1. **代码一致性保证**：
    - 通过重构批处理管道中的转换代码，使其可在管道外使用，确保了完全相同的处理逻辑
    - 在端点（推理服务）中使用这同一份代码，保证了训练和推理阶段数据处理的一致性
    - 这种方法避免了"训练-推理偏差"(training-serving skew)，即因处理逻辑不一致导致的模型性能下降
2. **满足实时需求**：
    - 重构后的代码可以嵌入到推理服务中，实现对单个请求的实时处理
    - 不引入额外的服务延迟，符合"实时推理"的要求
    - 每个请求到达时可立即应用相同的预处理步骤
3. **工程实践最佳**：
    - 这种方法遵循了ML工程的最佳实践：封装和重用数据转换逻辑
    - 便于维护，当预处理逻辑需要更新时，只需修改一处代码

相比之下，其他选项存在以下问题：

- 选项A仅验证输入数据格式，但不确保应用相同的转换逻辑
- 选项C将预处理责任转移给终端用户，这很可能导致实现不一致

- 选项D试图通过时间窗口批处理请求，这会引入显著延迟，与"实时推理"的要求相矛盾

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 6)

问题 51

题目

你需要开发一个用于在线预测的自定义TensorFlow模型。训练数据存储在BigQuery中。你需要对模型训练和服务的数据应用实例级数据转换。你希望在模型训练和服务时使用相同的预处理例程。你应该如何配置预处理例程？

You need to develop a custom TensorFlow model that will be used for online predictions. The training data is stored in BigQuery. You need to apply instance-level data transformations to the data for model training and serving. You want to use the same preprocessing routine during model training and serving. How should you configure the preprocessing routine?

选项

A. 创建一个BigQuery脚本来预处理数据，并将结果写入另一个BigQuery表。

Create a BigQuery script to preprocess the data, and write the result to another BigQuery table.

B. 在Vertex AI Pipelines中创建一个流水线，使用自定义预处理组件从BigQuery读取数据并进行预处理。

Create a pipeline in Vertex AI Pipelines to read the data from BigQuery and preprocess it using a custom preprocessing component.

C. 创建一个从BigQuery读取和转换数据的预处理函数。创建一个Vertex AI自定义预测例程，在服务时调用预处理函数。

Create a preprocessing function that reads and transforms the data from BigQuery. Create a Vertex AI custom prediction routine that calls the preprocessing function at serving time.

D. 创建一个Apache Beam流水线，使用TensorFlow Transform和Dataflow从BigQuery读取数据并进行预处理。

Create an Apache Beam pipeline to read the data from BigQuery and preprocess it by using TensorFlow Transform and Dataflow.

正确答案：D. Create an Apache Beam pipeline to read the data from BigQuery and preprocess it by using TensorFlow Transform and Dataflow.

解析：这个问题的核心是要确保模型训练和服务（在线预测）时使用完全相同的数据预处理逻辑。TensorFlow Transform (tf.Transform)是处理这种训练-服务一致性问题的专业工具，主要优势在于：

1. **专为解决训练-服务偏差而设计**：
    - tf.Transform能创建一个包含预处理逻辑的图，可以被导出为SavedModel格式，与模型一起部署
    - 这确保了训练和服务时使用完全相同的转换逻辑

2. **处理复杂的预处理场景**：
    - tf.Transform不仅处理简单的实例级转换，还能处理需要全局统计的复杂转换
    - 对于需要计算均值、标准差、分位数等统计量的转换(如标准化、分箱)，tf.Transform能确保训练和预测使用相同的统计值
3. **大规模数据处理能力**：
    - Apache Beam和Dataflow提供了处理BigQuery中大规模数据的强大能力
    - 这种分布式处理方式比单个预处理函数更适合处理实际生产环境中的大数据集

其他选项存在的问题：

- 选项A只处理训练数据，没有解决服务时的预处理问题
- 选项B同样没有解决服务时如何应用相同的预处理步骤
- 选项C虽然在预测时调用预处理函数，但对于依赖训练数据统计的转换，难以保证完全一致性

问题 52

题目

你正在Google Cloud上预训练一个大型语言模型。这个模型在训练循环中包含自定义TensorFlow操作。模型训练将使用大批量，你预计训练将持续数周。你需要配置一个训练架构，同时最小化训练时间和计算成本。你应该怎么做？

You are pre-training a large language model on Google Cloud. This model includes custom TensorFlow operations in the training loop. Model training will use a large batch size, and you expect training to take several weeks. You need to configure a training architecture that minimizes both training time and compute costs. What should you do?

选项

A. 使用tf.distribute.MultiWorkerMirroredStrategy实现8个a2-megagpu-16g机器的工作节点。

Implement 8 workers of a2-megagpu-16g machines by using tf.distribute.MultiWorkerMirroredStrategy.

B. 使用tf.distribute.TPUStrategy实现带有-accelerator-type=v4-128的TPU Pod切片。

Implement a TPU Pod slice with -accelerator-type=v4-128 by using tf.distribute.TPUStrategy.

C. 使用tf.distribute.MirroredStrategy实现16个c2d-highcpu-32机器的工作节点。

Implement 16 workers of c2d-highcpu-32 machines by using tf.distribute.MirroredStrategy.

D. 使用tf.distribute.MultiWorkerMirroredStrategy实现16个a2-highgpu-8g机器的工作节点。

Implement 16 workers of a2-highgpu-8g machines by using tf.distribute.MultiWorkerMirroredStrategy.

正确答案：B. Implement a TPU Pod slice with -accelerator-type=v4-128 by using tf.distribute.TPUStrategy.

解析： 这个问题要求为大型语言模型预训练配置训练架构，需要同时最小化训练时间和计算成本。

TPU Pod是最佳选择，原因如下：

1. **TPU的性能优势**：
    - TPU v4是Google专为大规模机器学习工作负载设计的加速器，特别适合大型语言模型
    - 对于大批量训练，TPU的矩阵乘法单元(MXU)和高带宽内存(HBM)提供了显著优势
    - TPU Pod提供了强大的计算能力和超高的内存带宽，可以显著减少训练时间
2. **成本效益平衡**：
    - 虽然TPU的小时费率较高，但由于训练速度大幅提升，总训练时间大幅缩短
    - 对于需要几周训练的大型模型，减少训练时间对总成本影响巨大
    - TPU的能耗效率也高于GPU，进一步降低了运营成本
3. **适合大型语言模型的架构**：
    - TPU的设计特别优化了大型Transformer架构（大型语言模型的基础）
    - v4-128表示一个拥有128个TPU核心的Pod切片，提供了大量的并行计算能力
    - TPUStrategy已经针对这种架构进行了优化，简化了分布式训练的实现

相比之下，其他选项如CPU机器或不同GPU配置，对于大型语言模型预训练的性能和成本效益都不如TPU Pod。

问题 53

题目

你正在使用包含数十亿图像及其各自说明的数据集构建TensorFlow文本到图像生成模型。你想创建一个低维护、自动化的工作流，该工作流从Cloud Storage存储桶读取数据、收集统计信息、将数据集分割为训练/验证/测试数据集、执行数据转换、使用训练/验证数据集训练模型，并使用测试数据集验证模型。你应该怎么做？

You are building a TensorFlow text-to-image generative model by using a dataset that contains billions of images with their respective captions. You want to create a low maintenance, automated workflow that reads the data from a Cloud Storage bucket collects statistics, splits the dataset into training/validation/test datasets performs data transformations trains the model using the training/validation datasets, and validates the model by using the test dataset. What should you do?

选项

A. 使用Apache Airflow SDK创建多个使用Dataflow和Vertex AI服务的操作符。在Cloud Composer上部署该工作流。

Use the Apache Airflow SDK to create multiple operators that use Dataflow and Vertex AI services. Deploy the workflow on Cloud Composer.

B. 使用MLFlow SDK并将其部署在Google Kubernetes Engine集群上。创建多个使用Dataflow和Vertex AI服务的组件。

Use the MLFlow SDK and deploy it on a Google Kubernetes Engine cluster. Create multiple components that use Dataflow and Vertex AI services.

C. 使用Kubeflow Pipelines (KFP) SDK创建多个使用Dataflow和Vertex AI服务的组件。在Vertex AI Pipelines上部署该工作流。

Use the Kubeflow Pipelines (KFP) SDK to create multiple components that use Dataflow and Vertex AI services. Deploy the workflow on Vertex AI Pipelines.

D. 使用TensorFlow Extended (TFX) SDK创建多个使用Dataflow和Vertex AI服务的组件。在Vertex AI Pipelines上部署该工作流。

Use the TensorFlow Extended (TFX) SDK to create multiple components that use Dataflow and Vertex AI services. Deploy the workflow on Vertex AI Pipelines.

正确答案：D. Use the TensorFlow Extended (TFX) SDK to create multiple components that use Dataflow and Vertex AI services. Deploy the workflow on Vertex AI Pipelines.

解析： 这个问题要求创建一个自动化的、低维护的工作流来训练一个文本到图像的生成模型，需要处理包含数十亿图像的数据集并执行多个处理步骤。

TFX是最佳选择，原因如下：

1. **TFX与TensorFlow的专业集成**：
    - TensorFlow Extended (TFX)专为TensorFlow模型的端到端ML流水线设计
    - 题目明确指定要构建"TensorFlow文本到图像生成模型"，TFX提供了与TensorFlow的原生集成
    - TFX特别适合大规模数据和复杂模型架构，非常适合处理"数十亿图像"的数据集
2. **内置的ML专用组件**：
    - TFX提供了专门用于题目中提到的各个步骤的组件：
        - ExampleGen：从Cloud Storage读取数据
        - StatisticsGen：收集数据统计信息
        - SchemaGen：基于统计信息推断数据模式
        - ExampleValidator：验证数据质量
        - Transform：执行数据转换
        - Trainer：训练模型
        - Evaluator：使用测试数据集验证模型
    - 这些组件已针对ML工作流进行了优化，减少了自定义代码的需求
3. **低维护性**：
    - 部署在Vertex AI Pipelines上意味着不需要管理基础设施
    - TFX管道提供自动化工具来监控和管理ML工作流
    - 预构建的组件减少了维护自定义代码的需求

其他选项如Apache Airflow、MLFlow或Kubeflow Pipelines虽然也可用于构建工作流，但不如TFX为TensorFlow模型提供的针对性优化和专用组件。

问题 54

题目

你正在使用Vertex AI Pipelines开发一个ML流水线。你希望你的流水线将XGBoost模型的新版本上传到Vertex AI Model Registry并将其部署到Vertex AI Endpoints进行在线推理。你想使用最简单的方法。你应该怎么做？

You are developing an ML pipeline using Vertex AI Pipelines. You want your pipeline to upload a new version of the XGBoost model to Vertex AI Model Registry and deploy it to Vertex AI Endpoints for online inference. You want to use the simplest approach. What should you do?

选项

A. 在基于vertex-ai/prediction/xgboost-cpu镜像的自定义组件中使用Vertex AI REST API

Use the Vertex AI REST API within a custom component based on a vertex-ai/prediction/xgboost-cpu image

B. 使用Vertex AI ModelEvaluationOp组件评估模型

Use the Vertex AI ModelEvaluationOp component to evaluate the model

C. 在基于python:3.10镜像的自定义组件中使用Vertex AI SDK for Python

Use the Vertex AI SDK for Python within a custom component based on a python:3.10 image

D. 将Vertex AI ModelUploadOp和ModelDeployOp组件链接在一起

Chain the Vertex AI ModelUploadOp and ModelDeployOp components together

正确答案：D. Chain the Vertex AI ModelUploadOp and ModelDeployOp components together

解析： 这个问题要求使用Vertex AI Pipelines将XGBoost模型上传到Model Registry并部署到Endpoints，关键要求是采用"最简单的方法"。

直接链接预构建组件是最简单的方法，原因如下：

1. **使用专用预构建组件**：
    - ModelUploadOp和ModelDeployOp是Vertex AI Pipelines提供的专用组件，专门设计用于模型上传和部署
    - 这些组件封装了所有必要的逻辑，避免了编写自定义代码的复杂性
    - 直接使用这些组件意味着无需处理底层API细节
2. **简洁的实现方式**：
    - 只需将两个组件链接在一起即可完成整个工作流程
    - 实现代码通常仅需几行：

```
model_upload_op = ModelUploadOp(
    model=model,
    display_name='xgboost-model'
)
model_deploy_op = ModelDeployOp(
    model=model_upload_op.outputs['model'],
    endpoint_name='prediction-endpoint'
)
```

3. **最符合"最简单方法"的要求**：

- 最少的代码量
- 最少的配置工作
- 最少的自定义逻辑
- 最少的维护负担

相比之下，其他选项如使用REST API、自定义组件或ModelEvaluationOp都引入了不必要的复杂性。

问题 55

题目

你为一家在线零售商工作。你的公司有几千种短生命周期产品。你的公司在BigQuery中存储了五年的销售数据。你被要求构建一个模型，为每种产品进行月度销售预测。你想使用一个能够快速实施且工作量最小的解决方案。你应该怎么做？

You work for an online retailer. Your company has a few thousand short lifecycle products. Your company has five years of sales data stored in BigQuery. You have been asked to build a model that will make monthly sales predictions for each product. You want to use a solution that can be implemented quickly with minimal effort. What should you do?

选项

A. 在Vertex AI Training上使用Prophet构建自定义模型。

Use Prophet on Vertex AI Training to build a custom model.

B. 使用Vertex AI Forecast构建基于神经网络的模型。

Use Vertex AI Forecast to build a NN-based model.

C. 使用BigQuery ML构建统计ARIMA_PLUS模型。

Use BigQuery ML to build a statistical ARIMA_PLUS model.

D. 在Vertex AI Training上使用TensorFlow构建自定义模型。

Use TensorFlow on Vertex AI Training to build a custom model.

正确答案：C. Use BigQuery ML to build a statistical ARIMA_PLUS model.

解析： 这个问题要求为一家在线零售商构建产品销售预测模型，关键要求是"快速实施，最小工作量"。数据已经存储在BigQuery中。

BigQuery ML是最直接的解决方案，原因如下：

1. **数据就地处理的优势**：
   - 数据已经存在于BigQuery中，使用BigQuery ML无需移动数据
   - 这消除了数据提取、转换和加载(ETL)的工作，显著减少实施时间
   - 数据留在原处减少了数据安全和治理的复杂性
2. **ARIMA_PLUS模型的适用性**：

- ARIMA_PLUS是专门为时间序列预测设计的，非常适合月度销售预测
- 它能自动处理季节性模式，这对零售销售预测至关重要
- 对于"短生命周期产品"，ARIMA_PLUS可以快速适应数据模式变化

3. **实施简便性**：

- BigQuery ML使用SQL语法，大多数数据分析师都已熟悉
- 创建模型可以通过几行SQL代码完成
- 不需要设置复杂的训练基础架构

4. **可扩展性**：

- BigQuery可以轻松处理数千个产品的预测，适合题目中"几千种短生命周期产品"的规模
- 每个产品的预测可以并行处理，提高效率

相比之下，其他选项如使用Prophet、自定义TensorFlow模型或Vertex AI Forecast都需要更多的开发工作和专业知识。

问题 56

题目

你正在创建一个模型训练流水线，用于从基于文本的产品评论中预测情感分数。你希望控制模型参数的调优方式，并且在训练后将模型部署到端点。你将使用Vertex AI Pipelines运行该流水线。你需要决定使用哪些Google Cloud流水线组件。你应该选择哪些组件？

You are creating a model training pipeline to predict sentiment scores from text-based product reviews. You want to have control over how the model parameters are tuned, and you will deploy the model to an endpoint after it has been trained. You will use Vertex AI Pipelines to run the pipeline. You need to decide which Google Cloud pipeline components to use. What components should you choose?

选项

A. TabularDatasetCreateOp、CustomTrainingJobOp和EndpointCreateOp

TabularDatasetCreateOp, CustomTrainingJobOp, and EndpointCreateOp

B. TextDatasetCreateOp、AutoMLTextTrainingOp和EndpointCreateOp

TextDatasetCreateOp, AutoMLTextTrainingOp, and EndpointCreateOp

C. TabularDatasetCreateOp、AutoMLTextTrainingOp和ModelDeployOp

TabularDatasetCreateOp. AutoMLTextTrainingOp, and ModelDeployOp

D. TextDatasetCreateOp、CustomTrainingJobOp和ModelDeployOp

TextDatasetCreateOp, CustomTrainingJobOp, and ModelDeployOp

正确答案：D. TextDatasetCreateOp, CustomTrainingJobOp, and ModelDeployOp

解析： 这个问题要求为文本产品评论的情感分析创建模型训练流水线，需要控制模型参数调优，并在训练后部署模型。

正确的组件组合应该考虑：

1. **TextDatasetCreateOp**：
    - 专门用于创建文本数据集，非常适合处理"文本型产品评论"数据
    - 处理文本数据的特殊性质，如可变长度和非结构化特性
    - 比TabularDatasetCreateOp更适合处理纯文本数据
2. **CustomTrainingJobOp**：
    - 允许运行自定义训练代码，满足"要控制模型参数调优方式"的要求
    - 提供对模型架构、损失函数、优化器和超参数的完全控制
    - 比AutoMLTrainingOp提供更多的自定义能力
3. **ModelDeployOp**：
    - 专门用于将训练好的模型部署到Vertex AI端点
    - 比EndpointCreateOp更直接地处理模型部署的全过程
    - 处理了模型部署的所有细节，包括资源分配、版本控制等

其他组件组合如使用TabularDatasetCreateOp处理文本数据，或使用AutoMLTextTrainingOp但需要控制参数调优，都与问题要求不符。

问题 57

题目

你的团队经常创建新的ML模型并运行实验。你的团队将代码推送到托管在Cloud Source Repositories上的单个仓库。你想创建一个持续集成流水线，当代码有任何修改时自动重新训练模型。设置CI流水线的第一步应该是什么？

Your team frequently creates new ML models and runs experiments. Your team pushes code to a single repository hosted on Cloud Source Repositories. You want to create a continuous integration pipeline that automatically retrains the models whenever there is any modification of the code. What should be your first step to set up the CI pipeline?

选项

A. 配置一个事件设置为"Pull Request"的Cloud Build触发器

Configure a Cloud Build trigger with the event set as "Pull Request"

B. 配置一个事件设置为"Push to a branch"的Cloud Build触发器

Configure a Cloud Build trigger with the event set as "Push to a branch"

C. 配置一个Cloud Function，每当代码发生变化时构建仓库

Configure a Cloud Function that builds the repository each time there is a code change

D. 配置一个Cloud Function，每当创建新分支时构建仓库

Configure a Cloud Function that builds the repository each time a new branch is created

正确答案：B. Configure a Cloud Build trigger with the event set as "Push to a branch"

解析： 这个问题要求创建一个持续集成(CI)管道，在代码有任何修改时自动重新训练模型。设置此CI管道的第一步是选择合适的触发机制。

选项B是最佳选择，原因如下：

1. **事件触发匹配需求**：
    - "Push to a branch"触发器会在每次代码推送到分支时激活
    - 这完全符合"每当代码有任何修改时"的要求
    - 所有代码变更都必然通过推送(push)到仓库来完成
2. **Cloud Build的专业性**：
    - Cloud Build是Google Cloud上专门用于CI/CD的服务
    - 它与Cloud Source Repositories有原生集成
    - 为ML模型的自动化训练提供了稳定、可扩展的执行环境

其他选项存在明显问题：

- 选项A（"Pull Request"触发器）只会在创建或更新拉取请求时触发，而不是针对每次代码修改
- 选项C和D使用Cloud Functions，增加了不必要的复杂性，且无法直接监听代码仓库变更

问题 58

题目

你构建了一个自定义模型，该模型在做出预测之前会执行几个内存密集型预处理任务。你将模型部署到Vertex AI端点，并验证在合理的时间内收到了结果。在将用户流量路由到该端点后，你发现当接收到多个请求时，该端点没有按预期自动扩展。你应该怎么做？

You have built a custom model that performs several memory-intensive preprocessing tasks before it makes a prediction. You deployed the model to a Vertex AI endpoint, and validated that results were received in a reasonable amount of time. After routing user traffic to the endpoint, you discover that the endpoint does not autoscale as expected when receiving multiple requests. What should you do?

选项

A. 使用具有更多内存的机器类型

Use a machine type with more memory

B. 减少每台机器的工作节点数量

Decrease the number of workers per machine

C. 在自动扩展配置中增加CPU利用率目标

Increase the CPU utilization target in the autoscaling configurations.

D. 在自动扩展配置中减少CPU利用率目标

Decrease the CPU utilization target in the autoscaling configurations

正确答案：D. Decrease the CPU utilization target in the autoscaling configurations

解析： 这个问题描述了一个内存密集型预处理任务的模型部署在Vertex AI端点上，单一请求表现良好，但多请求情况下没有按预期自动扩展。

选项D是最佳解决方案，原因如下：

1. **自动扩展机制理解**：
    - Vertex AI端点默认使用CPU利用率作为自动扩展的主要指标
    - 当CPU利用率超过目标阈值时，系统会自动添加新实例
    - 当CPU利用率低于目标阈值时，系统会减少实例数量
2. **内存密集型操作的特殊考虑**：
    - 内存密集型操作可能导致内存成为瓶颈，而不是CPU
    - 在此情况下，实例可能在CPU利用率达到自动扩展阈值之前，就因内存压力而性能下降
3. **降低CPU利用率目标的好处**：
    - 降低CPU利用率目标会使自动扩展更积极地响应负载增加
    - 系统会在CPU利用率较低时就开始扩展，不等到实例过载
    - 这可以防止在内存密集型工作负载中，因为等待CPU利用率达到较高阈值而导致的扩展延迟

其他选项不能有效解决自动扩展问题，例如增加单机内存虽然可能提高单实例性能，但不解决扩展问题本身。

问题 59

题目

你的公司管理着一个电子商务网站。你开发了一个ML模型，根据用户购物车中当前的商品，在近实时中向用户推荐额外产品。工作流程将包括以下过程：

1. 网站将发送带有相关数据的Pub/Sub消息，然后从Pub/Sub接收带有预测的消息
2. 预测将存储在BigQuery中
3. 模型将存储在Cloud Storage存储桶中，并将频繁更新

你希望最小化预测延迟和更新模型所需的工作量。你应该如何重新配置架构？

Your company manages an ecommerce website. You developed an ML model that recommends additional products to users in near real time based on items currently in the user's cart. The workflow will include the following processes:

1. The website will send a Pub/Sub message with the relevant data and then receive a message with the prediction from Pub/Sub
2. Predictions will be stored in BigQuery
3. The model will be stored in a Cloud Storage bucket and will be updated frequently

You want to minimize prediction latency and the effort required to update the model. How should you reconfigure the architecture?

选项

A. 编写一个将模型加载到内存中进行预测的Cloud Function。配置该函数在消息发送到Pub/Sub时触发。

Write a Cloud Function that loads the model into memory for prediction. Configure the function to be triggered when messages are sent to Pub/Sub.

B. 在Vertex AI Pipelines中创建一个执行预处理、预测和后处理的流水线。配置该流水线在消息发送到Pub/Sub时由Cloud Function触发。

Create a pipeline in Vertex AI Pipelines that performs preprocessing, prediction, and postprocessing. Configure the pipeline to be triggered by a Cloud Function when messages are sent to Pub/Sub.

C. 将模型公开为Vertex AI端点。在Dataflow作业中编写一个自定义DoFn，调用该端点进行预测。

Expose the model as a Vertex AI endpoint. Write a custom DoFn in a Dataflow job that calls the endpoint for prediction.

D. 在Dataflow作业中使用带有WatchFilePattern的RunInference API，该作业包装模型并提供预测。

Use the RunInference API with WatchFilePattern in a Dataflow job that wraps around the model and serves predictions.

正确答案：D. Use the RunInference API with WatchFilePattern in a Dataflow job that wraps around the model and serves predictions.

解析： 这个问题涉及构建一个近实时产品推荐系统，关键要求是"最小化预测延迟"和"最小化更新模型所需的工作量"。

选项D是最佳选择，原因如下：

1. **RunInference API的性能优势**：
    - RunInference API是Dataflow提供的专门用于高性能机器学习推理的接口
    - 它经过优化，可以高效处理流式推理请求，减少延迟
    - Dataflow可以根据负载自动扩展，确保即使在高流量情况下也能保持低延迟
2. **WatchFilePattern解决频繁模型更新问题**：
    - WatchFilePattern功能允许Dataflow作业自动监控Cloud Storage中的模型文件变化
    - 当新模型版本上传到存储桶时，Dataflow会自动加载新模型，无需重启作业或手动干预
    - 这完美解决了"模型将被频繁更新"且"最小化更新模型所需的工作量"的要求
3. **高效数据流处理**：
    - Dataflow的流处理能力可以无缝处理Pub/Sub消息
    - 同时向BigQuery写入预测结果
    - 整体架构保持了数据流的连续性，减少了系统组件间的切换开销

相比之下，其他选项如Cloud Functions可能存在冷启动延迟，Vertex AI Pipelines更适合批处理而非实时推理，Vertex AI端点的更新需要重新部署。

问题 60

题目

你正在与你的团队合作开发一个模型原型。你需要为你的团队成员创建一个Vertex AI Workbench环境，并限制项目中其他员工的访问。你应该怎么做？

You are collaborating on a model prototype with your team. You need to create a Vertex AI Workbench environment for the members of your team and also limit access to other employees in your project. What should you do?

选项

A. 1. 创建一个新的服务账号并授予其Notebook Viewer角色 2. 在该服务账号上向每个团队成员授予Service Account User角色 3. 向每个团队成员授予Vertex AI User角色 4. 提供一个使用新服务账号的Vertex AI Workbench用户管理的笔记本实例

1. Create a new service account and grant it the Notebook Viewer role
2. Grant the Service Account User role to each team member on the service account
3. Grant the Vertex AI User role to each team member
4. Provision a Vertex AI Workbench user-managed notebook instance that uses the new service account

B. 1. 向默认Compute Engine服务账号授予Vertex AI User角色 2. 在默认Compute Engine服务账号上向每个团队成员授予Service Account User角色 3. 提供一个使用默认Compute Engine服务账号的Vertex AI Workbench用户管理的笔记本实例

1. Grant the Vertex AI User role to the default Compute Engine service account
2. Grant the Service Account User role to each team member on the default Compute Engine service account
3. Provision a Vertex AI Workbench user-managed notebook instance that uses the default Compute Engine service account.

C. 1. 创建一个新的服务账号并授予其Vertex AI User角色 2. 在该服务账号上向每个团队成员授予Service Account User角色 3. 向每个团队成员授予Notebook Viewer角色 4. 提供一个使用新服务账号的Vertex AI Workbench用户管理的笔记本实例

1. Create a new service account and grant it the Vertex AI User role
2. Grant the Service Account User role to each team member on the service account
3. Grant the Notebook Viewer role to each team member.
4. Provision a Vertex AI Workbench user-managed notebook instance that uses the new service account

D. 1. 向主要团队成员授予Vertex AI User角色 2. 向其他团队成员授予Notebook Viewer角色 3. 提供一个使用主要用户账号的Vertex AI Workbench用户管理的笔记本实例

1. Grant the Vertex AI User role to the primary team member
2. Grant the Notebook Viewer role to the other team members
3. Provision a Vertex AI Workbench user-managed notebook instance that uses the primary user's account

正确答案：C. 1. Create a new service account and grant it the Vertex AI User role 2. Grant the Service Account User role to each team member on the service account 3. Grant the Notebook Viewer role to each

team member. 4. Provision a Vertex AI Workbench user-managed notebook instance that uses the new service account

解析：这个问题要求为团队创建一个Vertex AI Workbench环境，同时限制项目中其他员工的访问。这涉及到身份管理、服务账号配置和适当的权限分配。

选项C是最佳解决方案，原因如下：

1. **创建专用服务账号的安全性**：
    - 创建新的服务账号（而不是使用默认账号）允许精确控制访问权限
    - 这种方法遵循"最小权限原则"，只授予必要的权限
    - 服务账号专门用于此Workbench实例，实现了团队工作与其他项目活动的隔离
2. **权限分配的合理性**：
    - 向服务账号授予Vertex AI User角色，使其能够与Vertex AI资源交互
    - 向团队成员授予Service Account User角色，允许他们以该服务账号身份操作
    - 向团队成员授予Notebook Viewer角色，确保他们可以访问和使用笔记本
3. **架构的可扩展性**：
    - 通过服务账号中介进行访问控制，便于未来调整团队成员（添加或移除）
    - 统一的权限模型使管理更加简单
    - 不依赖于特定用户账号，避免了人员变动带来的风险

相比之下，其他选项要么使用默认服务账号（权限过大），要么创建不对称的权限模型（只有主要成员拥有完全权限），不符合协作需求。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 7)

问题 61

题目

你在一家领先的医疗保健公司工作，为各种用例开发最先进的算法。你拥有带有自定义标签的非结构化文本数据。你需要提取并使用这些标签对各种医疗短语进行分类。你应该怎么做？

You work at a leading healthcare firm developing state-of-the-art algorithms for various use cases. You have unstructured textual data with custom labels. You need to extract and classify various medical phrases with these labels. What should you do?

选项

A. 使用Healthcare Natural Language API提取医疗实体

Use the Healthcare Natural Language API to extract medical entities

B. 使用基于BERT的模型微调医疗实体提取模型

Use a BERT-based model to fine-tune a medical entity extraction model

C. 使用AutoML Entity Extraction训练医疗实体提取模型

Use AutoML Entity Extraction to train a medical entity extraction model

D. 使用TensorFlow构建自定义医疗实体提取模型

Use TensorFlow to build a custom medical entity extraction model

正确答案：C. Use AutoML Entity Extraction to train a medical entity extraction model

解析： 这个问题涉及医疗文本数据中提取和分类带有自定义标签的医疗短语。关键要素是处理"非结构化文本数据"和"自定义标签"。

选项C是最佳解决方案，原因如下：

1. **支持自定义标签训练**：
    - AutoML Entity Extraction专门设计用于从文本中提取自定义实体
    - 它允许用户上传带有自定义标签的训练数据，而不局限于预定义的实体类型
    - 这完全符合题目中"自定义标签"的关键要求
2. **无需深厚的ML专业知识**：
    - AutoML提供了低代码/无代码的方法来训练复杂的实体提取模型
    - 这使得医疗领域专家可以专注于标签定义和数据质量，而不是模型架构设计
    - 简化了从开发到部署的整个流程
3. **针对实体提取优化**：
    - AutoML Entity Extraction的底层技术已针对文本实体提取任务进行了优化
    - 它可以有效处理医疗术语和专业表达，前提是有足够的标记样本
    - 能够识别上下文相关的实体提及，这对医疗文本尤为重要

相比之下，其他选项存在以下缺点：

选项A（Healthcare Natural Language API）虽然专为医疗领域设计，但主要针对预定义的医疗实体类型（如药物、疾病、手术等）。它不支持使用自定义标签进行训练，因此不满足题目的核心要求。

选项B（BERT模型微调）技术上可行，但需要更多的ML专业知识和开发工作。虽然它可能提供最高的性能上限，但对于企业级解决方案来说，实施和维护成本较高。

选项D（使用TensorFlow构建自定义模型）提供了最大的灵活性，但也需要最多的开发资源和ML专业知识。这是最复杂的方法，需要处理从特征工程到模型部署的所有方面。

问题 62

题目

你使用Vertex AI开发了一个自定义模型，用于预测应用程序的用户流失率。你正在使用Vertex AI模型监控进行偏差检测。存储在BigQuery中的训练数据包含两组特征 - 人口统计学和行为特征。你后来发现，在每组特征上

单独训练的两个模型比原始模型表现更好。你需要配置一个新的模型监控流水线，将流量分配给这两个模型。你希望对每个模型使用相同的预测采样率和监控频率。你还希望最小化管理工作量。你应该怎么做？

You developed a custom model by using Vertex AI to predict your application's user churn rate. You are using Vertex AI Model Monitoring for skew detection. The training data stored in BigQuery contains two sets of features - demographic and behavioral. You later discover that two separate models trained on each set perform better than the original model. You need to configure a new model monitoring pipeline that splits traffic among the two models. You want to use the same prediction-sampling-rate and monitoring-frequency for each model. You also want to minimize management effort. What should you do?

选项

A. 保持训练数据集不变。将模型部署到两个单独的端点，并提交两个Vertex AI模型监控作业，适当选择特征阈值参数。

Keep the training dataset as is. Deploy the models to two separate endpoints, and submit two Vertex AI Model Monitoring jobs with appropriately selected feature-thresholds parameters.

B. 保持训练数据集不变。将两个模型部署到同一端点，并提交一个Vertex AI模型监控作业，使用考虑模型ID和特征选择的monitoring-config-from-file参数。

Keep the training dataset as is. Deploy both models to the same endpoint and submit a Vertex AI Model Monitoring job with a monitoring-config-from-file parameter that accounts for the model IDs and feature selections.

C. 根据人口统计和行为特征将训练数据集分成两个表。将模型部署到两个单独的端点，并提交两个Vertex AI模型监控作业。

Separate the training dataset into two tables based on demographic and behavioral features. Deploy the models to two separate endpoints, and submit two Vertex AI Model Monitoring jobs.

D. 根据人口统计和行为特征将训练数据集分成两个表。将两个模型部署到同一端点，并提交一个考虑模型ID和训练数据集的monitoring-config-from-file参数的Vertex AI模型监控作业。

Separate the training dataset into two tables based on demographic and behavioral features. Deploy both models to the same endpoint, and submit a Vertex AI Model Monitoring job with a monitoring-config-from-file parameter that accounts for the model IDs and training datasets.

正确答案：B. Keep the training dataset as is. Deploy both models to the same endpoint and submit a Vertex AI Model Monitoring job with a monitoring-config-from-file parameter that accounts for the model IDs and feature selections.

解析：这个问题要求对两个分开的模型（一个基于人口统计学特征，一个基于行为特征）配置模型监控，同时满足流量拆分、使用相同采样率和监控频率，并最小化管理工作量。

选项B是最佳解决方案，原因如下：

1. **数据管理最简化**：
    - 保持训练数据集原样，不需要额外创建和维护分离的表
    - 这消除了数据复制和同步的需求，减少了存储和管理开销
    - 原始数据集已包含所有需要的特征，无需重组

2. **端点部署策略**：
    - 将两个模型部署到同一端点简化了管理
    - 单一端点可以自动处理流量分配，减少了基础设施管理负担
3. **配置文件的强大功能**：
    - monitoring-config-from-file参数可以精确指定每个模型应该监控哪些特征子集
    - 即使使用同一训练数据源，配置文件能够区分每个模型的监控焦点
    - 可以为两个模型设置相同的采样率和监控频率
4. **真正最小化管理工作量**：
    - 不需要分离和维护额外的数据表
    - 单一端点和单一监控作业减少了操作开销
    - 所有配置集中在一个文件中，便于审查和修改

相比之下，其他选项如管理两个单独的端点和监控作业(选项A和C)增加了管理复杂性，不符合"最小化管理工作量"的要求。

问题 63

题目

你在一家总部位于加拿大的制药公司工作。你的团队开发了一个BigQuery ML模型，用于预测加拿大下个月的流感感染数量。天气数据每周发布一次，而流感感染统计数据每月发布一次。你需要配置一个模型重训练策略，以最小化成本。你应该怎么做？

You work for a pharmaceutical company based in Canada. Your team developed a BigQuery ML model to predict the number of flu infections for the next month in Canada. Weather data is published weekly, and flu infection statistics are published monthly. You need to configure a model retraining policy that minimizes cost. What should you do?

选项

A. 每周下载天气和流感数据。配置Cloud Scheduler每周执行Vertex AI流水线来重新训练模型。

Download the weather and flu data each week. Configure Cloud Scheduler to execute a Vertex AI pipeline to retrain the model weekly.

B. 每月下载天气和流感数据。配置Cloud Scheduler每月执行Vertex AI流水线来重新训练模型。

Download the weather and flu data each month. Configure Cloud Scheduler to execute a Vertex AI pipeline to retrain the model monthly.

C. 每周下载天气和流感数据。配置Cloud Scheduler每月执行Vertex AI流水线来重新训练模型。

Download the weather and flu data each week. Configure Cloud Scheduler to execute a Vertex AI pipeline to retrain the model every month.

D. 每周下载天气数据，每月下载流感数据。将模型部署到具有特征漂移监控功能的Vertex AI端点，并在检测到监控警报时重新训练模型。

Download the weather data each week, and download the flu data each month. Deploy the model to a Vertex AI endpoint with feature drift monitoring, and retrain the model if a monitoring alert is detected.

正确答案：D. Download the weather data each week, and download the flu data each month. Deploy the model to a Vertex AI endpoint with feature drift monitoring, and retrain the model if a monitoring alert is detected.

解析： 这个问题要求为预测加拿大流感感染数量的BigQuery ML模型配置重训练策略，关键要求是"最小化成本"。考虑到天气数据每周更新一次，而流感统计数据每月更新一次，需要找到经济高效的解决方案。

选项D是最佳选择，原因如下：

1. **数据获取频率的优化**：
    - 天气数据每周下载一次，与其发布频率一致
    - 流感数据每月下载一次，也与其发布频率一致
    - 这种方法避免了不必要的数据传输和存储成本，不会频繁下载未更新的数据
2. **按需重训练的成本效益**：
    - 使用特征漂移监控代替固定时间表的重训练策略
    - 只有在检测到实际的数据分布变化时才触发模型重训练
    - 这种反应式方法避免了周期性重训练的计算成本，特别是当新数据与现有训练数据相似时
3. **充分利用云服务特性**：
    - Vertex AI的特征漂移监控功能专为这种场景设计
    - 自动化监控减少了人工干预和分析的需要
    - 结合BigQuery ML和Vertex AI的优势，形成完整的ML操作流程

相比之下，其他选项存在明显的成本效率问题：

- 选项A每周重训练模型，但流感数据每月才更新一次，这意味着大多数时间是在用相同的流感数据进行不必要的重训练
- 选项B虽然每月重训练，但没有利用每周更新的天气数据，可能降低预测准确性
- 选项C每周下载所有数据但每月重训练，在下载流感数据方面浪费资源（因为它每月才更新一次）

问题 64

题目

你正在构建一个MLOps平台，以自动化公司的ML实验和模型重训练。你需要组织数十个流水线的工件。你应该如何存储流水线的工件？

You are building a MLOps platform to automate your company's ML experiments and model retraining. You need to organize the artifacts for dozens of pipelines. How should you store the pipelines' artifacts?

选项

A. 将参数存储在Cloud SQL中，将模型源代码和二进制文件存储在GitHub中。

Store parameters in Cloud SQL, and store the models' source code and binaries in GitHub.

B. 将参数存储在Cloud SQL中，将模型源代码存储在GitHub中，将模型二进制文件存储在Cloud Storage中。

Store parameters in Cloud SQL, store the models' source code in GitHub, and store the models' binaries in Cloud Storage.

C. 将参数存储在Vertex ML Metadata中，将模型源代码存储在GitHub中，将模型二进制文件存储在Cloud Storage中。

Store parameters in Vertex ML Metadata, store the models' source code in GitHub, and store the models' binaries in Cloud Storage.

D. 将参数存储在Vertex ML Metadata中，将模型源代码和二进制文件存储在GitHub中。

Store parameters in Vertex ML Metadata and store the models' source code and binaries in GitHub.

正确答案：C. Store parameters in Vertex ML Metadata, store the models' source code in GitHub, and store the models' binaries in Cloud Storage.

解析： 这个问题要求为MLOps平台组织数十个流水线的工件(artifacts)，需要考虑不同类型工件的最佳存储位置。

选项C是最佳解决方案，原因如下：

1. **Vertex ML Metadata用于参数存储**：
    - Vertex ML Metadata专为ML工作流元数据设计，提供了专门的参数跟踪功能
    - 它能够与Vertex AI流水线无缝集成，自动捕获实验参数和指标
    - 相比关系型数据库，它提供了更丰富的元数据查询和分析能力，特别适合ML实验
    - 支持参数的谱系跟踪(lineage tracking)，对于复制实验和满足合规要求很重要
2. **GitHub用于源代码版本控制**：
    - GitHub是存储和管理源代码的行业标准
    - 提供版本控制、代码审查、分支管理等关键功能
    - 支持CI/CD集成，便于自动化测试和部署
    - 适用于文本类型的资源，如Python脚本、配置文件等
3. **Cloud Storage用于模型二进制文件**：
    - Cloud Storage最适合存储大型二进制文件，如训练好的模型
    - 提供高性能访问和扩展性，可处理任意大小的模型
    - 与Vertex AI服务紧密集成，方便部署模型到端点
    - 提供版本控制、生命周期管理和成本优化功能

相比之下，其他选项存在以下问题：

选项A和B使用Cloud SQL存储参数，这不如专门为ML元数据设计的Vertex ML Metadata更适合，特别是当需要跟踪复杂的实验历史和模型谱系时。

选项A和D将模型二进制文件存储在GitHub中，这不是最佳实践：

- GitHub主要设计用于源代码版本控制，不适合存储大型二进制文件
- 将大型模型文件存储在GitHub中会导致仓库膨胀，降低克隆和操作效率

- GitHub对仓库大小有限制，可能无法满足存储多个大型模型的需求

问题 65

题目

你在一家电信公司工作。你正在构建一个模型，预测哪些客户可能无法支付下一期电话账单。该模型的目的是主动为面临风险的客户提供服务折扣和账单截止日期延期等帮助。数据存储在BigQuery中，可用于模型训练的预测特征包括：

- Customer_id（客户ID）
- Age（年龄）
- Salary（薪资，以当地货币计量）
- Sex（性别）
- Average bill value（平均账单金额，以当地货币计量）
- Number of phone calls in the last month（上月通话次数，整数）
- Average duration of phone calls（平均通话时长，以分钟计）

你需要调查并减轻针对弱势群体的潜在偏见，同时保持模型的准确性。

你应该怎么做？

You work for a telecommunications company. You're building a model to predict which customers may fail to pay their next phone bill. The purpose of this model is to proactively offer at-risk customers assistance such as service discounts and bill deadline extensions. The data is stored in BigQuery and the predictive features that are available for model training include:

- Customer_id
- Age
- Salary (measured in local currency)
- Sex
- Average bill value (measured in local currency)
- Number of phone calls in the last month (integer)
- Average duration of phone calls (measured in minutes)

You need to investigate and mitigate potential bias against disadvantaged groups, while preserving model accuracy.

What should you do?

选项

A. 确定敏感特征与其他特征之间是否存在有意义的相关性。训练BigQuery ML提升树分类模型，并排除敏感特征和任何有意义相关的特征。

Determine whether there is a meaningful correlation between the sensitive features and the other features. Train a BigQuery ML boosted trees classification model and exclude the sensitive features and any meaningfully correlated features.

B. 使用所有特征训练BigQuery ML提升树分类模型。使用ML.GLOBAL_EXPLAIN方法计算模型每个特征的全局归因值。如果任何敏感特征的特征重要性值超过阈值，丢弃该模型并在不使用该特征的情况下重新训练。

Train a BigQuery ML boosted trees classification model with all features. Use the ML.GLOBAL_EXPLAIN method to calculate the global attribution values for each feature of the model. If the feature importance value for any of the sensitive features exceeds a threshold, discard the model and tram without this feature.

C. 使用所有特征训练BigQuery ML提升树分类模型。使用ML.EXPLAIN_PREDICT方法计算测试集中每个客户的每个特征的归因值。如果对于任何个别客户，任何特征的重要性值超过预定义阈值，丢弃该模型并重新训练模型，不使用该特征。

Train a BigQuery ML boosted trees classification model with all features. Use the ML.EXPLAIN_PREDICT method to calculate the attribution values for each feature for each customer in a test set. If for any individual customer, the importance value for any feature exceeds a predefined threshold, discard the model and train the model again without this feature.

D. 定义一个公平性指标，表示在敏感特征上的准确性。使用所有特征训练BigQuery ML提升树分类模型。使用训练好的模型对测试集进行预测。将数据与敏感特征重新连接，并计算公平性指标以调查其是否满足你的要求。

Define a fairness metric that is represented by accuracy across the sensitive features. Train a BigQuery ML boosted trees classification model with all features. Use the trained model to make predictions on a test set. Join the data back with the sensitive features, and calculate a fairness metric to investigate whether it meets your requirements.

正确答案：D. Define a fairness metric that is represented by accuracy across the sensitive features. Train a BigQuery ML boosted trees classification model with all features. Use the trained model to make predictions on a test set. Join the data back with the sensitive features, and calculate a fairness metric to investigate whether it meets your requirements.

解析： 这个问题涉及在构建电信账单违约预测模型时，如何识别和减轻潜在的偏见，同时保持模型的准确性。题目中的特征包含了敏感属性（年龄、性别和薪资），这些特征可能导致对某些群体的歧视。

选项D是最佳方案，原因如下：

1. **直接衡量公平性**：
    - 通过定义一个明确的公平性指标（例如不同敏感特征组的准确率差异），直接测量模型结果的公平性
    - 这种方法评估的是真正重要的结果公平性，而不仅仅是模型结构或特征使用
    - 允许根据业务需求和法规要求定制公平性标准
2. **保留预测能力**：
    - 使用所有可用特征训练模型，最大化预测准确性
    - 不预先排除任何特征，避免因特征缺失导致的性能下降
    - 在测量公平性之后，可以根据结果决定是否需要进一步的干预
3. **分析灵活性**：
    - 通过将预测结果与敏感特征重新关联，可以进行多角度的公平性分析
    - 可以评估多种公平性指标，如不同群体间的错误率平衡性、机会平等性等
    - 支持更复杂的公平性分析，例如交叉群体比较

其他选项存在的问题：

- 选项A通过删除敏感特征及其相关特征，可能过度限制模型的预测能力
- 选项B使用全局特征重要性来评估偏见，但全局指标可能掩盖对特定子群体的不公平影响
- 选项C基于单个预测的特征重要性来筛选模型，这种方法过于严格，且不直接针对群体层面的公平性

问题 66

题目

你最近训练了一个XGBoost模型，计划将其部署到生产环境用于在线推理。在向模型二进制文件发送预测请求之前，你需要执行一个简单的数据预处理步骤。该步骤公开了一个REST API，接受你内部VPC服务控制中的请求并返回预测。你希望配置这个预处理步骤，同时最小化成本和工作量。你应该怎么做？

You recently trained a XGBoost model that you plan to deploy to production for online inference. Before sending a predict request to your model's binary, you need to perform a simple data preprocessing step. This step exposes a REST API that accepts requests in your internal VPC Service Controls and returns predictions. You want to configure this preprocessing step while minimizing cost and effort. What should you do?

选项

A. 将腌制(pickled)模型存储在Cloud Storage中。构建基于Flask的应用程序，将应用程序打包到自定义容器镜像中，并将模型部署到Vertex AI端点。

Store a pickled model in Cloud Storage. Build a Flask-based app, package the app in a custom container image, and deploy the model to Vertex AI Endpoints.

B. 构建基于Flask的应用程序，将应用程序和腌制模型打包到自定义容器镜像中，并将模型部署到Vertex AI端点。

Build a Flask-based app, package the app and a pickled model in a custom container image, and deploy the model to Vertex AI Endpoints.

C. 基于Vertex AI SDK的XGBoost Predictor构建自定义预测器类，将其和腌制模型打包到基于Vertex内置镜像的自定义容器镜像中，并将模型部署到Vertex AI端点。

Build a custom predictor class based on XGBoost Predictor from the Vertex AI SDK, package it and a pickled model in a custom container image based on a Vertex built-in image, and deploy the model to Vertex AI Endpoints.

D. 基于Vertex AI SDK的XGBoost Predictor构建自定义预测器类，将处理程序打包到基于Vertex内置容器镜像的自定义容器镜像中。将腌制模型存储在Cloud Storage中，并将模型部署到Vertex AI端点。

Build a custom predictor class based on XGBoost Predictor from the Vertex AI SDK, and package the handler in a custom container image based on a Vertex built-in container image. Store a pickled model in Cloud Storage, and deploy the model to Vertex AI Endpoints.

正确答案：D. Build a custom predictor class based on XGBoost Predictor from the Vertex AI SDK, and package the handler in a custom container image based on a Vertex built-in container image. Store a pickled model in Cloud Storage, and deploy the model to Vertex AI Endpoints.

解析： 这个问题涉及配置XGBoost模型的部署和预处理步骤，关键要求是"最小化成本和工作量"。

选项D是最佳解决方案，原因如下：

1. **模型和代码的分离带来更高灵活性**：
    - 将模型存储在Cloud Storage而非容器内，使模型更新变得更简单
    - 无需重建和重新部署容器就能更新模型，大幅减少持续维护的工作量
    - 这种分离符合关注点分离原则，是软件工程的最佳实践
2. **利用Vertex AI专用组件**：
    - 基于Vertex AI SDK的XGBoost Predictor构建自定义预测器类，减少了开发工作量
    - 使用Vertex内置镜像作为基础，进一步简化了容器构建过程
    - 这种方法利用了Google专门为机器学习推理优化的组件
3. **资源优化和成本效益**：
    - 容器镜像不包含模型文件，体积更小，部署更快，存储成本更低
    - 同一个容器可用于多个模型版本，只需指向不同的Cloud Storage路径
    - 长期来看，这种架构减少了维护复杂性和更新成本
4. **版本管理更简便**：
    - 模型版本控制变得更加直观和独立，可利用Cloud Storage的版本控制功能
    - 容器代码和模型可以分别维护各自的版本线，降低整体复杂性

其他选项存在的问题：

- 选项A和B需要从头构建Flask应用，这增加了开发工作量
- 选项C将模型和预测器封装在同一个容器中，虽然简化了初始部署，但长期维护更复杂

问题 67

题目

你在一家银行工作。你需要开发一个信用风险模型来支持贷款申请决策。你决定使用TensorFlow中的神经网络实现该模型。由于监管要求，你需要能够根据模型的特征解释其预测。当模型部署后，你还希望随时间监控模型的性能。你决定使用Vertex AI进行模型开发和部署。你应该怎么做？

You work at a bank. You need to develop a credit risk model to support loan application decisions. You decide to implement the model by using a neural network in TensorFlow. Due to regulatory requirements, you need to be able to explain the model's predictions based on its features. When the model is deployed, you also want to monitor the model's performance over time. You decided to use Vertex AI for both model development and deployment. What should you do?

选项

A. 使用Vertex Explainable AI的采样Shapley方法，并启用Vertex AI模型监控以检查特征分布漂移。

Use Vertex Explainable AI with the sampled Shapley method, and enable Vertex AI Model Monitoring to check for feature distribution drift.

B. 使用Vertex Explainable AI的采样Shapley方法，并启用Vertex AI模型监控以检查特征分布偏差。

Use Vertex Explainable AI with the sampled Shapley method, and enable Vertex AI Model Monitoring to check for feature distribution skew.

C. 使用Vertex Explainable AI的XRAI方法，并启用Vertex AI模型监控以检查特征分布漂移。

Use Vertex Explainable AI with the XRAI method, and enable Vertex AI Model Monitoring to check for feature distribution drift.

D. 使用Vertex Explainable AI的XRAI方法，并启用Vertex AI模型监控以检查特征分布偏差。

Use Vertex Explainable AI with the XRAI method, and enable Vertex AI Model Monitoring to check for feature distribution skew.

正确答案：A. Use Vertex Explainable AI with the sampled Shapley method, and enable Vertex AI Model Monitoring to check for feature distribution drift.

解析： 这个问题要求为银行的信贷风险模型选择适当的解释方法和监控策略，以满足监管要求和长期性能监控。

选项A是最佳解决方案，原因如下：

1. **Sampled Shapley方法的适用性**：
    - Sampled Shapley方法特别适合于表格数据和结构化特征，这正是银行信贷风险模型典型的数据类型
    - 该方法基于博弈论，计算每个特征对预测结果的贡献，能够为每个贷款决策提供清晰的特征重要性解释
    - 它能够处理数值和分类特征，适合包含多种输入（如收入、信用历史、就业状况等）的信贷模型
    - 对于监管合规，Shapley值提供了数学上严谨的解释，满足"解释模型预测"的要求
2. **特征分布漂移(drift)监控的重要性**：
    - 分布漂移监控会比较生产环境中随时间推移的数据分布变化
    - 这对信贷模型至关重要，因为经济条件、客户行为和市场趋势会随时间变化
    - 识别漂移有助于及时更新模型，确保其在新环境下仍然准确可靠
    - 这满足了"监控模型随时间推移的性能"的需求

相比之下，其他选项存在以下问题：

- 选项B监控"特征分布偏斜(skew)"而非"漂移(drift)"是不合适的。偏斜通常指训练数据与服务数据之间的静态差异，不能有效监控模型随时间推移的性能变化。
- 选项C和D使用XRAI方法，这主要适用于图像模型的解释，不适合银行信贷风险评估的结构化表格数据。

问题 68

题目

你正在调查你的一个模型产生的错误分类错误的根本原因。你使用Vertex AI Pipelines训练和部署了该模型。流水线从BigQuery读取数据，在Cloud Storage中创建TFRecord格式的数据副本，在Vertex AI Training上使用该

副本训练模型，并将模型部署到Vertex AI端点。你已经确定了出现错误分类的特定模型版本，现在需要找回该模型训练所用的数据。你应该如何找到该数据副本？

You are investigating the root cause of a misclassification error made by one of your models. You used Vertex AI Pipelines to train and deploy the model. The pipeline reads data from BigQuery. creates a copy of the data in Cloud Storage in TFRecord format, trains the model in Vertex AI Training on that copy, and deploys the model to a Vertex AI endpoint. You have identified the specific version of that model that misclassified, and you need to recover the data this model was trained on. How should you find that copy of the data?

选项

A. 使用Vertex AI Feature Store。修改流水线以使用特征存储，并确保所有训练数据都存储在其中。在特征存储中搜索用于训练的数据。

Use Vertex AI Feature Store. Modify the pipeline to use the feature store, and ensure that all training data is stored in it. Search the feature store for the data used for the training.

B. 使用Vertex AI Metadata的血统功能找到模型工件。确定模型的版本并识别创建数据副本的步骤，然后在元数据中搜索其位置。

Use the lineage feature of Vertex AI Metadata to find the model artifact. Determine the version of the model and identify the step that creates the data copy and search in the metadata for its location.

C. 使用Vertex AI端点中的日志功能确定模型部署的时间戳。找到该时间戳的流水线运行。识别创建数据副本的步骤，并在日志中搜索其位置。

Use the logging features in the Vertex AI endpoint to determine the timestamp of the model's deployment. Find the pipeline run at that timestamp. Identify the step that creates the data copy, and search in the logs for its location.

D. 找到与模型训练对应的Vertex AI Training中的作业ID。在该作业的日志中搜索用于训练的数据。

Find the job ID in Vertex AI Training corresponding to the training for the model. Search in the logs of that job for the data used for the training.

正确答案：B. Use the lineage feature of Vertex AI Metadata to find the model artifact. Determine the version of the model and identify the step that creates the data copy and search in the metadata for its location.

解析： 这个问题要求找出导致模型错误分类的原始训练数据。由于模型是通过Vertex AI Pipelines训练和部署的，我们需要找到一种方法来追踪该模型版本使用的确切训练数据。

选项B是最佳解决方案，原因如下：

1. **利用专门设计的血统跟踪功能**：
    - Vertex AI Metadata的血统（lineage）功能专门设计用于跟踪ML工件之间的关系
    - 它保存了模型、数据和管道执行之间的精确连接
    - 这种关系是显式存储的，不依赖于时间戳匹配或日志分析等不可靠方法
2. **直接的工作流程**：
    - 从已知的模型工件开始，可以直接向后追溯到创建该模型的确切训练数据

- 整个过程是确定性的，不依赖于日志保留策略或时间相关性
- 可以精确识别用于训练特定模型版本的数据副本的确切位置

3. **完整的元数据捕获**：

- Vertex AI Pipelines自动在Vertex AI Metadata中存储每个组件和工件的信息
- 这包括数据副本的位置、模型训练参数和部署细节
- 即使在很长时间后，这些关系仍然可以被追踪，不受日志轮换或存储限制的影响

相比之下，其他选项存在以下问题：

- 选项A要求修改现有管道，这是一个面向未来的解决方案，不适用于已经训练和部署的模型
- 选项C依赖于时间戳匹配和日志分析，这是一种间接且不可靠的方法
- 选项D也依赖于日志分析，而日志可能不包含数据路径或可能已被清除

问题 69

题目

你正在使用跨越多个Google Cloud项目的数据在Vertex AI上训练模型。你需要查找、跟踪和比较不同版本模型的性能。你应该在ML工作流中包含哪些Google Cloud服务？

You are training models in Vertex AI by using data that spans across multiple Google Cloud projects. You need to find, track, and compare the performance of the different versions of your models. Which Google Cloud services should you include in your ML workflow?

选项

A. Dataplex、Vertex AI Feature Store和Vertex AI TensorBoard

Dataplex, Vertex AI Feature Store, and Vertex AI TensorBoard

B. Vertex AI Pipelines、Vertex AI Feature Store和Vertex AI Experiments

Vertex AI Pipelines, Vertex AI Feature Store, and Vertex AI Experiments

C. Dataplex、Vertex AI Experiments和Vertex AI ML Metadata

Dataplex, Vertex AI Experiments, and Vertex AI ML Metadata

D. Vertex AI Pipelines、Vertex AI Experiments和Vertex AI Metadata

Vertex AI Pipelines, Vertex AI Experiments, and Vertex AI Metadata

正确答案：D. Vertex AI Pipelines, Vertex AI Experiments, and Vertex AI Metadata

解析： 这个问题要求选择合适的Google Cloud服务组合，以便在跨越多个Google Cloud项目的数据上训练模型时，能够寻找、跟踪和比较不同版本模型的性能。

选项D是最佳解决方案，原因如下：

1. **Vertex AI Pipelines的跨项目编排能力**：

- Vertex AI Pipelines允许创建和运行端到端的ML工作流

- 可以编排跨项目的数据访问、模型训练和评估
- 提供可重复、可版本化的工作流定义，确保模型训练过程的一致性
- 支持参数化运行，便于在不同数据集上执行相同的训练流程

2. **Vertex AI Experiments的实验跟踪功能**：

- 专门设计用于组织、跟踪和比较多个模型训练运行
- 允许记录超参数、指标和工件，捕获完整的实验细节
- 提供可视化工具来比较不同实验的性能指标
- 这直接满足了"比较不同版本模型性能"的需求

3. **Vertex AI Metadata的模型谱系管理**：

- 自动捕获模型训练过程中的元数据和谱系信息
- 记录模型与其训练数据、参数和环境之间的关系
- 支持跨项目查询和跟踪模型工件
- 使您能够轻松找到和识别所有项目中的模型版本

这三个服务协同工作形成完整的ML模型管理解决方案：Pipelines自动化和标准化训练过程，Experiments跟踪和比较结果，Metadata维护所有工件之间的关系。

相比之下，其他选项存在以下问题：

- 选项A和B包含Feature Store，它专注于特征管理而非模型比较
- 选项A包含TensorBoard，它主要用于单个训练运行的可视化，不适合跨项目模型管理
- 选项C包含Dataplex，它更适合数据湖管理而非ML模型生命周期管理

问题 70

题目

你为一家制造公司工作。你需要训练一个自定义图像分类模型，以在装配线末端检测产品缺陷。虽然你的模型表现良好，但你的保留集中的一些图像始终被高置信度地错误标记。你想使用Vertex AI来理解你模型的结果。你应该怎么做？

You work for a manufacturing company. You need to train a custom image classification model to detect product defects at the end of an assembly line. Although your model is performing well, some images in your holdout set are consistently mislabeled with high confidence. You want to use Vertex AI to understand your model's results. What should you do?

选项

A. 使用Integrated Gradients配置基于特征的解释。将可视化类型设置为PIXELS，并将clip_percent_upperbound设置为95。

Configure feature-based explanations by using Integrated Gradients. Set visualization type to PIXELS, and set clip_percent_upperbound to 95.

B. 使用Vertex AI Matching Engine创建索引。使用错误标记的图像查询索引。

Create an index by using Vertex AI Matching Engine. Query the index with your mislabeled images.

C. 使用XRAI配置基于特征的解释。将可视化类型设置为OUTLINES，并将极性设置为正。

Configure feature-based explanations by using XRAI. Set visualization type to OUTLINES, and set polarity to positive.

D. 配置基于示例的解释。指定用于潜在空间表示的嵌入输出层。

Configure example-based explanations. Specify the embedding output layer to be used for the latent space representation.

正确答案：A. Configure feature-based explanations by using Integrated Gradients. Set visualization type to PIXELS, and set clip_percent_upperbound to 95.

解析： 这个问题涉及理解为什么图像分类模型会以高置信度错误分类某些图像。我们需要找到一种方法来可视化模型的决策过程，以便识别导致错误分类的图像区域或特征。

选项A是最佳解决方案，原因如下：

1. **Integrated Gradients的适用性**：
    - Integrated Gradients是Vertex AI支持的标准特征归因方法
    - 它非常适合于理解图像分类决策，特别是对于高置信度的错误分类
    - 它可以精确显示哪些像素对特定分类决策贡献最大
2. **PIXELS可视化类型的准确性**：
    - PIXELS是Vertex AI中图像解释的有效可视化类型选项
    - 它为每个像素提供归因值，有助于精确定位导致错误分类的区域
    - 对于制造业缺陷检测特别有用，因为需要精确定位问题区域
3. **clip_percent_upperbound参数的作用**：
    - 设置为95的clip_percent_upperbound确保只显示最重要的归因值
    - 这减少了视觉噪音，突出显示最关键的像素区域
    - 对于制造业缺陷检测特别有用，因为它聚焦于最显著的特征

相比之下，其他选项存在以下问题：

选项C提到的"OUTLINES"可视化类型在Vertex AI中不是标准选项，虽然XRAI方法对图像确实很友好，但这个参数配置不准确。

选项B使用Matching Engine不直接解释模型决策过程，它主要用于相似性搜索，不能帮助理解为什么特定图像被错误分类。

选项D的基于示例的解释方法显示的是哪些训练示例对预测影响最大，虽然有用，但对于理解图像中的具体问题区域帮助有限。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 8)

问题 71

题目

你正在使用Keras和TensorFlow开发欺诈检测模型。客户交易记录存储在BigQuery的大型表中。你需要在使用这些记录训练模型之前，以经济高效和高效的方式对其进行预处理。训练好的模型将用于在BigQuery中执行批量推理。你应该如何实现预处理工作流？

You are using Keras and TensorFlow to develop a fraud detection model. Records of customer transactions are stored in a large table in BigQuery. You need to preprocess these records in a cost-effective and efficient way before you use them to train the model. The trained model will be used to perform batch inference in BigQuery. How should you implement the preprocessing workflow?

选项

A. 使用Apache Spark实现预处理流水线，并在Dataproc上运行该流水线。将预处理后的数据作为CSV文件保存在Cloud Storage存储桶中。

Implement a preprocessing pipeline by using Apache Spark, and run the pipeline on Dataproc. Save the preprocessed data as CSV files in a Cloud Storage bucket.

B. 将数据加载到pandas DataFrame中。使用pandas转换实现预处理步骤，并直接在DataFrame上训练模型。

Load the data into a pandas DataFrame. Implement the preprocessing steps using pandas transformations, and train the model directly on the DataFrame.

C. 在BigQuery中使用SQL执行预处理。使用TensorFlow中的BigQueryClient直接从BigQuery读取数据。

Perform preprocessing in BigQuery by using SQL. Use the BigQueryClient in TensorFlow to read the data directly from BigQuery.

D. 使用Apache Beam实现预处理流水线，并在Dataflow上运行该流水线。将预处理后的数据作为CSV文件保存在Cloud Storage存储桶中。

Implement a preprocessing pipeline by using Apache Beam, and run the pipeline on Dataflow. Save the preprocessed data as CSV files in a Cloud Storage bucket.

正确答案：C. Perform preprocessing in BigQuery by using SQL. Use the BigQueryClient in TensorFlow to read the data directly from BigQuery.

解析： 这个问题要求为存储在BigQuery大型表中的客户交易记录实现一个成本效益高且高效的预处理工作流，用于训练欺诈检测模型，且最终模型将用于在BigQuery中执行批量推理。

选项C是最佳解决方案，原因如下：

1. **数据留在原处，最小化数据移动**：
    - 直接在BigQuery中执行预处理，避免了数据提取和加载的开销
    - 数据移动通常是云计算环境中最昂贵和最耗时的操作之一
    - 由于数据已经在BigQuery中，并且最终推理也将在BigQuery中进行，保持数据在同一平台内是最有效的
2. **利用BigQuery的强大处理能力**：

- BigQuery是一个高度可扩展的分析引擎，能够处理TB或PB级数据
- SQL预处理操作在BigQuery中高度优化，可以并行处理大型数据集
- 无需管理额外的计算资源，降低了操作复杂性

3. **与TensorFlow的直接集成**：

- TensorFlow提供了BigQueryClient，允许直接从BigQuery读取数据
- 这种集成支持高效的数据流，无需中间存储步骤
- 可以通过设置适当的批处理大小来控制内存使用

4. **端到端流程的一致性**：

- 由于模型将用于在BigQuery中进行批量推理，保持一致的环境减少了潜在的兼容性问题
- 整个过程中使用相同的数据格式和转换逻辑，降低了出错风险

相比之下，其他选项存在明显的效率和成本问题：

选项A和D将数据从BigQuery导出到Cloud Storage，这不仅增加了数据传输成本，还引入了额外的处理步骤和存储需求。当需要进行批量推理时，还需要将数据重新加载回BigQuery。

选项B试图将整个"大型表"加载到pandas DataFrame中，这对于大规模数据集来说是不可行的，会导致内存不足错误。pandas主要设计用于在单机上处理适量的数据。

问题 72

题目

你需要使用TensorFlow训练图像分类模型。你的数据集位于Cloud Storage目录中，包含数百万张带标签的图像。在训练模型之前，你需要准备数据。你希望数据预处理和模型训练工作流尽可能高效、可扩展且维护成本低。你应该怎么做？

You need to use TensorFlow to train an image classification model. Your dataset is located in a Cloud Storage directory and contains millions of labeled images. Before training the model, you need to prepare the data. You want the data preprocessing and model training workflow to be as efficient, scalable, and low maintenance as possible. What should you do?

选项

A. 1. 创建Dataflow作业，在Cloud Storage目录中创建分片TFRecord文件。 2. 在训练脚本中引用tf.data.TFRecordDataset。 3. 使用带有V100 GPU的Vertex AI Training训练模型。

1. Create a Dataflow job that creates sharded TFRecord files in a Cloud Storage directory.
2. Reference tf.data.TFRecordDataset in the training script.
3. Train the model by using Vertex AI Training with a V100 GPU.

B. 1. 创建Dataflow作业，将图像移动到多个Cloud Storage目录中，每个目录根据相应的标签命名。 2. 在训练脚本中引用tfds.folder_dataset:ImageFolder。 3. 使用带有V100 GPU的Vertex AI Training训练模型。

1. Create a Dataflow job that moves the images into multiple Cloud Storage directories, where each directory is named according to the corresponding label
2. Reference tfds.folder_dataset:ImageFolder in the training script.

3. Train the model by using Vertex AI Training with a V100 GPU.

C. 1. 创建使用n1-standard-64 V100 GPU Vertex AI Workbench实例的Jupyter笔记本。 2. 编写Python脚本，在实例内的目录中创建分片TFRecord文件。 3. 在训练脚本中引用tf.data.TFRecordDataset。 4. 使用Workbench实例训练模型。

1. Create a Jupyter notebook that uses an nt-standard-64 V100 GPU Vertex AI Workbench instance.
2. Write a Python script that creates sharded TFRecord files in a directory inside the instance.
3. Reference tf.data.TFRecordDataset in the training script.
4. Train the model by using the Workbench instance.

D. 1. 创建使用n1-standard-64 V100 GPU Vertex AI Workbench实例的Jupyter笔记本。 2. 编写Python脚本，将图像复制到多个Cloud Storage目录中，每个目录根据相应的标签命名。 3. 在训练脚本中引用tfds.foladr_dataset.ImageFolder。 4. 使用Workbench实例训练模型。

1. Create a Jupyter notebook that uses an n1-standard-64, V100 GPU Vertex AI Workbench instance.
2. Write a Python script that copies the images into multiple Cloud Storage directories, where each. directory is named according to the corresponding label.
3. Reference tfds.foladr_dataset.ImageFolder in the training script.
4. Train the model by using the Workbench instance.

正确答案：A. 1. Create a Dataflow job that creates sharded TFRecord files in a Cloud Storage directory. 2. Reference tf.data.TFRecordDataset in the training script. 3. Train the model by using Vertex AI Training with a V100 GPU.

解析： 这个问题要求为包含数百万张标记图像的数据集创建一个高效、可扩展且低维护的数据预处理和模型训练工作流程。

选项A是最佳解决方案，原因如下：

1. **数据预处理的高效扩展**：
    - Dataflow是Google Cloud的全托管、无服务器数据处理服务，可自动扩展以处理大规模数据
    - 对于"数百万张图像"的数据集，Dataflow可以并行处理，显著加快预处理速度
    - 生成分片TFRecord文件是一种经过验证的预处理大规模图像数据集的最佳实践
2. **TFRecord格式的性能优势**：
    - TFRecord是TensorFlow的优化文件格式，专为高吞吐量I/O而设计
    - 它支持压缩、并行读取，并减少了磁盘寻址开销
    - 分片(sharded)的TFRecord文件可进一步提高训练期间的数据加载效率
    - 这种格式特别适合处理图像等大型二进制数据
3. **整体架构的低维护性**：
    - 整个工作流程使用全托管服务(Dataflow和Vertex AI Training)
    - 数据存储在Cloud Storage中，无需管理存储基础设施
    - 简洁的数据处理管道易于监控和维护
    - Vertex AI Training自动处理训练资源的配置和扩缩
4. **工作流程的连贯性**：

- 从预处理到训练形成了清晰的数据流
- tf.data.TFRecordDataset提供高效的数据加载API，与预处理步骤生成的文件格式完美匹配

相比之下，其他选项存在以下问题：

选项B使用基于文件夹的数据组织方式，虽然直观但对于数百万图像效率较低；读取大量小文件比读取优化的TFRecord文件慢得多。

选项C和D使用单个Vertex AI Workbench实例进行数据预处理，对于数百万图像的处理缺乏可扩展性，且使用单个实例存储临时数据可能导致存储空间不足。

问题 73

题目

你正在构建自定义图像分类模型，并计划使用Vertex AI Pipelines实现端到端训练。你的数据集由需要在用于训练模型之前进行预处理的图像组成。预处理步骤包括调整图像大小、转换为灰度和提取特征。你已经为预处理任务实现了一些Python函数。你应该在管道中使用哪些组件？

You are building a custom image classification model and plan to use Vertex AI Pipelines to implement the end-to-end training. Your dataset consists of images that need to be preprocessed before they can be used to train the model. The preprocessing steps include resizing the images, converting them to grayscale, and extracting features. You have already implemented some Python functions for the preprocessing tasks. Which components should you use in your pipeline?

选项

A. DataprocSparkBatchOp和CustomTrainingJobOp

DataprocSparkBatchOp and CustomTrainingJobOp

B. DataflowPythonJobOp、WaitGcpResourcesOp和CustomTrainingJobOp

DataflowPythonJobOp, WaitGcpResourcesOp, and CustomTrainingJobOp

C. dsl.ParallelFor、dsl.component和CustomTrainingJobOp

dsl.ParallelFor, dsl.component, and CustomTrainingJobOp

D. ImageDatasetImportDataOp、dsl.component和AutoMLImageTrainingJobRunOp

ImageDatasetImportDataOp, dsl.component, and AutoMLImageTrainingJobRunOp

正确答案：B. DataflowPythonJobOp, WaitGcpResourcesOp, and CustomTrainingJobOp

解析： 这个问题要求为图像分类模型的端到端训练选择适当的Vertex AI Pipelines组件，涉及预处理已有Python函数。

选项B是最佳解决方案，原因如下：

1. **DataflowPythonJobOp的强大数据处理能力**：
   - Dataflow是一个全托管的分布式处理服务，专为大规模数据处理设计

- 对于图像预处理这类计算密集型任务，Dataflow提供了自动扩缩能力
- 已实现的Python预处理函数可以通过Apache Beam Python SDK轻松集成到Dataflow中
- Dataflow比简单的组件级并行处理更适合处理大量图像，提供更好的容错性和资源优化

2. **WaitGcpResourcesOp的关键协调作用**：

   - 确保Dataflow预处理作业完全完成后才开始模型训练
   - 防止训练使用不完整的预处理数据，这对管道的可靠性至关重要
   - 提供明确的依赖关系管理，使管道执行更加稳健

3. **CustomTrainingJobOp的灵活训练支持**：

   - 适合运行自定义图像分类模型训练
   - 可以根据需求配置特定的计算资源
   - 提供对训练过程的完全控制

其他选项存在以下问题：

- 选项A (DataprocSparkBatchOp)对于简单的图像预处理任务过于复杂和重量级
- 选项C (dsl.ParallelFor)在Vertex AI Pipelines中有并行度上限，缺乏Dataflow的自动扩缩能力
- 选项D使用AutoMLImageTrainingJobRunOp，但题目明确指定了"自定义"图像分类模型，而非AutoML模型

问题 74

题目

你在一家使用BigQuery ML构建的回归模型预测产品销售的零售公司工作。该模型正被用于提供在线预测。最近你开发了一个使用不同架构（自定义模型）的新版本模型。初步分析表明两个模型都表现良好。你想将新版本的模型部署到生产环境并在未来两个月内监控其性能。你需要最小化对现有和未来模型用户的影响。你应该如何部署模型？

You work for a retail company that is using a regression model built with BigQuery ML to predict product sales. This model is being used to serve online predictions. Recently you developed a new version of the model that uses a different architecture (custom model). Initial analysis revealed that both models are performing as expected. You want to deploy the new version of the model to production and monitor the performance over the next two months. You need to minimize the impact to the existing and future model users. How should you deploy the model?

选项

A. 将新模型作为现有模型的不同版本导入到相同的Vertex AI Model Registry中。将新模型部署到与现有模型相同的Vertex AI端点，并使用流量分割将95%的生产流量路由到BigQuery ML模型，5%的生产流量路由到新模型。

Import the new model to the same Vertex AI Model Registry as a different version of the existing model. Deploy the new model to the same Vertex AI endpoint as the existing model, and use traffic splitting to route 95% of production traffic to the BigQuery ML model and 5% of production traffic to the new model.

B. 将新模型导入到与现有模型相同的Vertex AI Model Registry中。将模型部署到一个Vertex AI端点。将95%的生产流量路由到BigQuery ML模型，5%的生产流量路由到新模型。

Import the new model to the same Vertex AI Model Registry as the existing model. Deploy the models to one Vertex AI endpoint. Route 95% of production traffic to the BigQuery ML model and 5% of production traffic to the new model.

C. 将新模型导入到与现有模型相同的Vertex AI Model Registry中。将每个模型部署到单独的Vertex AI端点。

Import the new model to the same Vertex AI Model Registry as the existing model. Deploy each model to a separate Vertex AI endpoint.

D. 将新模型部署到单独的Vertex AI端点。创建一个Cloud Run服务，根据输入特征值将预测请求路由到相应的端点。

Deploy the new model to a separate Vertex AI endpoint. Create a Cloud Run service that routes the prediction requests to the corresponding endpoints based on the input feature values.

正确答案：A. Import the new model to the same Vertex AI Model Registry as a different version of the existing model. Deploy the new model to the same Vertex AI endpoint as the existing model, and use traffic splitting to route 95% of production traffic to the BigQuery ML model and 5% of production traffic to the new model.

解析： 这个问题涉及在零售公司环境中安全部署新版本预测模型的最佳策略，关键要求是"最小化对现有和未来模型用户的影响"，同时需要监控新模型在未来两个月的性能。

选项A是最佳解决方案，原因如下：

1. **版本控制的正确实施**：
    - 将新模型作为现有模型的不同版本导入到同一个Model Registry中
    - 这种方法维护了清晰的模型谱系，便于版本跟踪和回滚
    - 将新模型视为既有模型的演进版本，而非完全不同的模型，符合连续迭代的最佳实践
2. **无缝端点过渡**：
    - 使用相同的端点意味着现有客户端代码无需任何修改
    - 客户端API调用保持不变，透明地获取预测结果
    - 这完全满足"最小化影响"的需求，客户无需感知后端模型的变化
3. **控制风险的流量分配**：
    - 95%/5%的流量分割是典型的金丝雀部署(canary deployment)策略
    - 只有5%的流量路由到新模型，限制了潜在问题的影响范围
    - 同时提供足够的真实世界数据来评估新模型在生产环境中的性能
4. **便于性能监控和比较**：
    - 相同端点内的流量分割便于直接比较两个模型在相同条件下的性能
    - 两个月的监控期提供足够的数据来做出明智的长期决策
    - 根据监控结果，可以逐步调整流量分配比例，平稳过渡到新模型

相比之下，其他选项存在以下问题：

选项B描述不够明确，没有指定新模型应作为现有模型的不同版本。

选项C和D将模型部署到不同端点，这要求客户端应用更改调用代码以使用新端点，增加了实施复杂性并影响用户体验。

问题 75

题目

你正在使用Vertex AI和TensorFlow开发自定义图像分类模型。你需要使模型的决策和决策依据对公司的利益相关者可理解。你还希望探索结果以识别任何问题或潜在偏见。你应该怎么做？

You are using Vertex AI and TensorFlow to develop a custom image classification model. You need the model's decisions and the rationale to be understandable to your company's stakeholders. You also want to explore the results to identify any issues or potential biases. What should you do?

选项

A. 1. 使用TensorFlow生成并可视化特征和统计数据。 2. 与标准模型评估指标一起分析结果。

1. Use TensorFlow to generate and visualize features and statistics.
2. Analyze the results together with the standard model evaluation metrics.

B. 1. 使用TensorFlow Profiler可视化模型执行情况。 2. 分析不正确预测与执行瓶颈之间的关系。

1. Use TensorFlow Profiler to visualize the model execution.
2. Analyze the relationship between incorrect predictions and execution bottlenecks.

C. 1. 使用Vertex Explainable AI生成基于示例的解释。 2. 将整个数据集中的样本输入结果与标准模型评估指标一起可视化。

1. Use Vertex Explainable AI to generate example-based explanations.
2. Visualize the results of sample inputs from the entire dataset together with the standard model evaluation metrics.

D. 1. 使用Vertex Explainable AI生成特征归因。将特征归因聚合到整个数据集。 2. 与标准模型评估指标一起分析聚合结果。

1. Use Vertex Explainable AI to generate feature attributions. Aggregate feature attributions over the entire dataset.
2. Analyze the aggregation result together with the standard model evaluation metrics.

正确答案：D. 1. Use Vertex Explainable AI to generate feature attributions. Aggregate feature attributions over the entire dataset. 2. Analyze the aggregation result together with the standard model evaluation metrics.

解析： 这个问题要求在开发图像分类模型时，满足两个关键需求：1) 使模型决策和决策依据对企业利益相关者可理解；2) 探索结果以识别潜在问题和偏见。

选项D是最佳解决方案，原因如下：

1. **特征归因的可解释性**：
    - Vertex Explainable AI的特征归因功能可以明确显示图像中哪些区域对模型的决策产生了最大影响

- 对于图像模型，这通常表现为热力图或显著性地图，直观地突出显示了重要区域
- 这种可视化形式非常适合向非技术利益相关者解释模型决策，因为它们直观且易于理解

2. **全数据集归因聚合的全局视角**：

- 将特征归因聚合到整个数据集能够揭示模型决策的系统性模式
- 这有助于识别模型可能一贯关注的不相关特征，如背景元素而非主体对象
- 聚合分析可以发现特定人口统计或子组的潜在偏见

3. **与标准评估指标结合的全面分析**：

- 将特征归因分析与准确率、精确率、召回率等标准指标结合，提供更全面的模型性能视图
- 这种方法可以解释为什么模型在某些类别或子组上表现不佳
- 帮助识别需要改进的具体领域，而不仅仅是报告整体性能统计数据

其他选项不能同时满足这两个关键需求，要么不够直观易懂，要么无法有效识别系统性偏见。

问题 76

题目

你在一家大型零售商工作，你需要构建一个预测客户流失的模型。公司拥有历史客户数据集，包括客户人口统计信息、购买历史和网站活动。你需要在BigQuery ML中创建模型并全面评估其性能。你应该怎么做？

You work for a large retailer, and you need to build a model to predict customer chum. The company has a dataset of historical customer data, including customer demographics purchase history, and website activity. You need to create the model in BigQuery ML and thoroughly evaluate its performance. What should you do?

选项

A. 在BigQuery ML中创建线性回归模型，并将模型注册到Vertex AI Model Registry。在Vertex AI中评估模型性能。

Create a linear regression model in BigQuery ML, and register the model in Vertex AI Model Registry. Evaluate the model performance in Vertex AI.

B. 在BigQuery ML中创建逻辑回归模型，并将模型注册到Vertex AI Model Registry。在Vertex AI中评估模型性能。

Create a logistic regression model in BigQuery ML and register the model in Vertex AI Model Registry. Evaluate the model performance in Vertex AI.

C. 在BigQuery ML中创建线性回归模型。使用ML.EVALUATE函数评估模型性能。

Create a linear regression model in BigQuery ML. Use the ML.EVALUATE function to evaluate the model performance.

D. 在BigQuery ML中创建逻辑回归模型。使用ML.CONFUSION_MATRIX函数评估模型性能。

Create a logistic regression model in BigQuery ML. Use the ML.CONFUSION_MATRIX function to evaluate the model performance.

正确答案：B. Create a logistic regression model in BigQuery ML and register the model in Vertex AI Model Registry. Evaluate the model performance in Vertex AI.

解析： 这个问题要求为零售商构建客户流失(churn)预测模型，并对模型性能进行全面评估。

选项B是最佳解决方案，原因如下：

1. **选择正确的模型类型**：
    - 客户流失预测本质上是一个二元分类问题（客户会流失或不会流失）
    - 逻辑回归(logistic regression)是处理二元分类问题的标准算法
    - 它能够基于各种输入特征预测客户流失的概率
    - 相比之下，线性回归适用于预测连续值而非分类问题
2. **利用Vertex AI的高级评估能力**：
    - 题目明确要求"全面评估性能"(thoroughly evaluate its performance)
    - Vertex AI提供比BigQuery ML内置评估功能更强大、更全面的评估工具
    - 它支持更复杂的模型评估指标、可视化和监控功能
    - 可以执行更深入的分析，如模型偏差检测、特征重要性分析和敏感性分析
3. **模型注册和管理的优势**：
    - 将模型注册到Vertex AI Model Registry提供更好的模型生命周期管理
    - 支持模型版本控制、标记和元数据管理
    - 便于在将来部署模型到生产环境并持续监控
    - 对于大型零售商这样的企业环境特别重要

其他选项要么使用了不适合分类问题的线性回归模型，要么没有利用Vertex AI的高级评估功能进行全面评估。

问题 77

题目

你正在开发一个模型，用于识别从车辆仪表盘拍摄的视频中提取的图像中的交通标志。你有一个包含10万张图像的数据集，这些图像被裁剪为仅显示十种不同交通标志中的一种。这些图像已经相应地标记用于模型训练，并存储在Cloud Storage存储桶中。你需要能够在每次训练运行期间调整模型。你应该如何训练模型？

You are developing a model to identify traffic signs in images extracted from videos taken from the dashboard of a vehicle. You have a dataset of 100,000 images that were cropped to show one out of ten different traffic signs. The images have been labeled accordingly for model training, and are stored in a Cloud Storage bucket. You need to be able to tune the model during each training run. How should you train the model?

选项

A. 使用Vertex AI AutoML训练对象检测模型。

Train a model for object detection by using Vertex AI AutoML.

B. 使用Vertex AI AutoML训练图像分类模型。

Train a model for image classification by using Vertex AI AutoML.

C. 开发对象检测的模型训练代码，并使用Vertex AI自定义训练训练模型。

Develop the model training code for object detection, and train a model by using Vertex AI custom training.

D. 开发图像分类的模型训练代码，并使用Vertex AI自定义训练训练模型。

Develop the model training code for image classification, and train a model by using Vertex AI custom training.

正确答案：D. Develop the model training code for image classification, and train a model by using Vertex AI custom training.

解析： 这个问题要求训练一个模型来识别从车辆仪表盘拍摄的视频中提取的交通标志图像，关键要求是能够"在每次训练运行期间调整模型"。

选项D是最佳解决方案，原因如下：

1. **正确的问题类型**：
    - 题目明确指出图像已经被裁剪以显示十种不同交通标志中的一种
    - 这些图像已经被相应地标记用于模型训练
    - 这明显是一个图像分类问题，而非对象检测问题
    - 图像分类任务是将整个图像分类到预定义的类别中，这正是我们需要的
2. **满足模型调优的需求**：
    - 题目强调"需要能够在每次训练运行期间调整模型"
    - Vertex AI的自定义训练提供了对训练过程的完全控制
    - 可以编写自定义训练代码，实现特定的超参数调优逻辑
    - 可以实现早停(early stopping)、学习率调度等高级调优技术
    - 可以根据性能指标动态调整模型架构或训练策略

其他选项要么使用了错误的模型类型(对象检测而非图像分类)，要么使用AutoML无法满足灵活调优的需求。

问题 78

题目

你已经将scikit-learn模型部署到使用自定义模型服务器的Vertex AI端点。你启用了自动扩展；然而，部署的模型无法扩展超过一个副本，这导致了请求被丢弃。你注意到即使在高负载期间，CPU利用率仍然保持较低。你应该怎么做？

You have deployed a scikit-team model to a Vertex AI endpoint using a custom model server. You enabled autoscaling: however, the deployed model fails to scale beyond one replica, which led to dropped requests. You notice that CPU utilization remains low even during periods of high load. What should you do?

选项

A. 为预测节点附加GPU

Attach a GPU to the prediction nodes

B. 增加模型服务器中的工作线程数量

Increase the number of workers in your model server

C. 根据预期需求安排节点的扩展

Schedule scaling of the nodes to match expected demand

D. 在DeployedModel配置中增加minReplicaCount

Increase the minReplicaCount in your DeployedModel configuration

正确答案：B. Increase the number of workers in your model server

解析： 这个问题涉及Vertex AI端点上部署的scikit-learn模型无法正常扩展的故障排除。根据题目描述，尽管启用了自动扩缩功能，但模型无法扩展超过一个副本，导致请求丢失。更重要的线索是，即使在高负载期间，CPU利用率仍然保持较低水平。

选项B是最佳解决方案，原因如下：

1. **识别真正的瓶颈**：
    - 低CPU利用率表明计算资源并非瓶颈
    - 当CPU未被充分利用但仍然无法处理所有请求时，这通常表明存在并发处理能力的限制
    - 自定义模型服务器中的工作线程(workers)数量直接决定了可以并行处理的请求数量
    - 增加工作线程可以在单个副本内提高并发能力
2. **自动扩缩的工作原理**：
    - Vertex AI的自动扩缩通常基于CPU利用率等指标来决定是否添加更多副本
    - 如果CPU利用率保持较低，自动扩缩系统认为现有资源足够，不会触发扩展
    - 即使请求在队列中堆积或被丢弃，系统也不会创建新副本
3. **解决应用层而非基础设施层的问题**：
    - 这个解决方案针对的是应用架构问题，而不是资源配置问题
    - 它可以在不增加计算资源的情况下提高吞吐量
    - 允许单个副本更充分地利用现有CPU资源

其他选项要么增加不必要的资源（GPU），要么没有解决根本问题（调度扩缩或增加最小副本数）。

问题 79

题目

你在一家宠物食品公司工作，该公司管理着一个在线论坛。客户在论坛上上传宠物照片与他人分享。每天大约上传20张照片。你希望自动且近实时地检测每张上传的照片是否有动物。你希望优先考虑时间并最小化应用程序开发和部署的成本。你应该怎么做？

You work for a pet food company that manages an online forum. Customers upload photos of their pets on the forum to share with others. About 20 photos are uploaded daily. You want to automatically and in near real time detect whether each uploaded photo has an animal. You want to prioritize time and minimize cost of your application development and deployment. What should you do?

选项

A. 将用户提交的图像发送到Cloud Vision API。使用对象定位识别图像中的所有对象，并将结果与动物列表进行比较。

Send user-submitted images to the Cloud Vision API. Use object localization to identify all objects in the image and compare the results against a list of animals.

B. 从TensorFlow Hub下载预训练的对象检测模型。将模型部署到Vertex AI端点。将新的用户提交图像发送到模型端点，以分类每张照片是否有动物。

Download an object detection model from TensorFlow Hub. Deploy the model to a Vertex AI endpoint. Send new user-submitted images to the model endpoint to classify whether each photo has an animal.

C. 手动标记先前提交的图像，在任何动物周围画上边界框。使用Vertex AI构建AutoML对象检测模型。将模型部署到Vertex AI端点。将新的用户提交图像发送到你的模型端点，以检测每张照片是否有动物。

Manually label previously submitted images with bounding boxes around any animals. Build an AutoML object detection model by using Vertex AI. Deploy the model to a Vertex AI endpoint Send new user-submitted images to your model endpoint to detect whether each photo has an animal.

D. 手动标记先前提交的图像是否有动物。在Vertex AI上创建图像数据集。使用Vertex AutoML训练分类模型以区分这两个类别。将模型部署到Vertex AI端点。将新的用户提交图像发送到你的模型端点，以分类每张照片是否有动物。

Manually label previously submitted images as having animals or not. Create an image dataset on Vertex AI. Train a classification model by using Vertex AutoML to distinguish the two classes. Deploy the model to a Vertex AI endpoint. Send new user-submitted images to your model endpoint to classify whether each photo has an animal.

正确答案：A. Send user-submitted images to the Cloud Vision API. Use object localization to identify all objects in the image and compare the results against a list of animals.

解析： 这个问题关注的是为宠物食品公司的在线论坛开发一个近实时检测上传照片中是否有动物的系统，关键要求是"优先考虑时间和最小化应用程序开发和部署成本"，且每天上传量较小（约20张照片）。

选项A是最佳解决方案，原因如下：

1. **开发时间最短**：
    - Cloud Vision API是一个现成的服务，只需要简单的API集成
    - 无需训练模型或配置复杂的基础设施
    - 可以在几小时内完成开发和部署，而其他选项可能需要数天或数周
2. **成本效益最高**：
    - 对于每天仅20张图片的低容量场景，按需付费的API是最经济的选择
    - 无需支付持续运行的端点成本或训练费用
    - Cloud Vision API的定价模型对低容量使用场景非常友好
3. **功能完全满足需求**：
    - 对象定位(object localization)功能可以识别图像中的各种对象，包括各类动物
    - API返回的对象类别可以轻松与动物列表进行比较

- 准确率高，已在大量真实世界图像上进行了训练

4. **近实时处理能力**：

- Cloud Vision API通常在毫秒到秒级别内返回结果
- 完全满足"近实时"检测的要求
- 无需担心扩展或资源配置问题

其他选项涉及更复杂的开发过程（自定义模型训练或部署），不符合最小化时间和成本的要求。

问题 80

题目

你在一家创建在线多人游戏的移动游戏初创公司工作。最近，你的公司观察到游戏中作弊的玩家增加，导致收入损失和用户体验不佳。你构建了一个二元分类模型，用于确定玩家在完成游戏会话后是否作弊，然后向其他下游系统发送消息以禁止作弊的玩家。你的模型在测试期间表现良好，现在你需要将模型部署到生产环境。你希望你的服务解决方案在完成游戏会话后立即提供分类结果，以避免进一步的收入损失。你应该怎么做？

You work at a mobile gaming startup that creates online multiplayer games. Recently, your company observed an increase in players cheating in the games, leading to a loss of revenue and a poor user experience You built a binary classification model to determine whether a player cheated after a completed game session, and then send a message to other downstream systems to ban the player that cheated. Your model has performed well during testing, and you now need to deploy the model to production. You want your serving solution to provide immediate classifications after a completed game session to avoid further loss of revenue. What should you do?

选项

A. 将模型导入到Vertex AI Model Registry。使用Vertex批量预测服务运行批量推理作业。

Import the model into Vertex AI Model Registry. Use the Vertex Batch Prediction service to run batch inference jobs.

B. 将模型文件保存在Cloud Storage存储桶中。创建一个Cloud Function来读取模型文件并在Cloud Function上进行在线推理请求。

Save the model files in a Cloud Storage bucket. Create a Cloud Function to read the model files and make online inference requests on the Cloud Function.

C. 将模型文件保存在虚拟机上。每次有预测请求时加载模型文件，并在虚拟机上运行推理作业。

Save the model files in a VM. Load the model files each time there is a prediction request, and run an inference job on the VM

D. 将模型导入到Vertex AI Model Registry。创建托管该模型的Vertex AI端点，并进行在线推理请求。

Import the model into Vertex AI Model Registry. Create a Vertex AI endpoint that hosts the model, and make online inference requests.

正确答案：D. Import the model into Vertex AI Model Registry. Create a Vertex AI endpoint that hosts the model, and make online inference requests.

解析： 这个问题涉及为移动游戏公司部署一个作弊检测模型，关键需求是在游戏会话结束后"立即"提供分类结果，以避免进一步的收入损失。

选项D是最佳解决方案，原因如下：

1. **实时预测能力**：
    - Vertex AI端点专为在线推理(online inference)设计，能够提供毫秒级响应
    - 完美满足"立即分类"的核心需求
    - 可以在游戏会话结束后立即触发作弊检测，并迅速采取行动
2. **性能和可靠性**：
    - 模型在端点上预加载并常驻内存，消除了每次请求加载模型的延迟
    - 提供高可用性服务，确保关键业务功能不中断
    - 内置的自动扩缩功能可应对玩家流量波动
3. **完整的MLOps支持**：
    - Vertex AI Model Registry提供版本控制和模型管理
    - 支持模型监控和指标跟踪，可以持续监控模型在生产环境中的性能
    - 便于未来模型更新和A/B测试
4. **与下游系统集成**：
    - 可以设置预测后的回调或事件触发，无缝连接到禁止作弊玩家的下游系统
    - 提供标准化的API接口，便于游戏服务器集成

其他选项或者无法提供即时响应（批量预测），或者存在性能问题（每次请求加载模型），不符合核心需求。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 9)

问题 81

题目

你创建了一个自动化自定义模型训练的Vertex AI流水线。你想添加一个流水线组件，使你的团队在运行不同的执行并以可视化和编程方式比较指标时能够最轻松地协作。你应该怎么做？

You have created a Vertex AI pipeline that automates custom model training. You want to add a pipeline component that enables your team to most easily collaborate when running different executions and comparing metrics both visually and programmatically. What should you do?

选项

A. 向Vertex AI流水线添加一个将指标记录到BigQuery表的组件。查询该表以比较流水线的不同执行情况。将BigQuery连接到Looker Studio以可视化指标。

Add a component to the Vertex AI pipeline that logs metrics to a BigQuery table. Query the table to compare different executions of the pipeline. Connect BigQuery to Looker Studio to visualize metrics.

B. 向Vertex AI流水线添加一个将指标记录到BigQuery表的组件。将表加载到pandas DataFrame中以比较流水线的不同执行情况。使用Matplotlib可视化指标。

Add a component to the Vertex AI pipeline that logs metrics to a BigQuery table. Load the table into a pandas DataFrame to compare different executions of the pipeline. Use Matplotlib to visualize metrics.

C. 向Vertex AI流水线添加一个将指标记录到Vertex ML Metadata的组件。使用Vertex AI Experiments比较流水线的不同执行情况。使用Vertex AI TensorBoard可视化指标。

Add a component to the Vertex AI pipeline that logs metrics to Vertex ML Metadata. Use Vertex AI Experiments to compare different executions of the pipeline. Use Vertex AI TensorBoard to visualize metrics.

D. 向Vertex AI流水线添加一个将指标记录到Vertex ML Metadata的组件。将Vertex ML Metadata加载到pandas DataFrame中以比较流水线的不同执行情况。使用Matplotlib可视化指标。

Add a component to the Vertex AI pipeline that logs metrics to Vertex ML Metadata. Load the Vertex ML Metadata into a pandas DataFrame to compare different executions of the pipeline. Use Matplotlib to visualize metrics.

正确答案：C. Add a component to the Vertex AI pipeline that logs metrics to Vertex ML Metadata. Use Vertex AI Experiments to compare different executions of the pipeline. Use Vertex AI TensorBoard to visualize metrics.

解析： 这个问题要求选择一个能够让团队"最容易协作"的方案，以便运行不同的执行并以可视化和编程方式比较指标。

选项C是最佳解决方案，原因如下：

1. **专为ML协作设计的工具组合**：
    - Vertex ML Metadata、Vertex AI Experiments和Vertex AI TensorBoard是一套紧密集成的工具
    - 这些工具专为机器学习实验跟踪、比较和可视化而设计
    - 提供了完整的实验生命周期管理，从指标记录到比较和可视化
2. **简化的协作体验**：
    - Vertex AI Experiments提供了直观的用户界面，允许团队成员轻松查看和比较不同的执行结果
    - 实验结果可以通过Web界面共享，无需团队成员编写代码即可访问关键信息
    - 支持对实验进行注释和标记，便于团队沟通和知识共享
3. **强大的可视化能力**：
    - Vertex AI TensorBoard是TensorFlow官方可视化工具的集成版本，专为展示ML指标设计
    - 提供了丰富的可视化选项，如学习曲线、分布图、直方图等
    - 支持实时更新，团队成员可以同时查看训练进展
4. **编程访问能力**：
    - 虽然提供了友好的UI，但所有数据也可以通过API以编程方式访问

- 可以使用Python SDK查询和分析Vertex ML Metadata中的指标
- 支持高级分析和自定义报告的生成

相比之下，其他选项要么增加了不必要的数据移动步骤，要么使用工具组合不够集成和专业化，无法提供同样流畅的协作体验。

问题 82

题目

你的团队正在训练大量使用不同算法、参数和数据集的ML模型。一些模型在Vertex AI流水线中训练，一些在Vertex AI Workbench笔记本实例上训练。你的团队想要比较这两种服务上模型的性能。你希望最小化存储参数和指标所需的工作量。你应该怎么做？

Your team is training a large number of ML models that use different algorithms, parameters, and datasets. Some models are trained in Vertex AI Pipelines, and some are trained on Vertex AI Workbench notebook instances. Your team wants to compare the performance of the models across both services. You want to minimize the effort required to store the parameters and metrics. What should you do?

选项

A. 为所有在流水线和笔记本中运行的模型实施额外步骤，将参数和指标导出到BigQuery。

Implement an additional step for all the models running in pipelines and notebooks to export parameters and metrics to BigQuery.

B. 创建一个Vertex AI实验。将所有流水线作为实验运行提交。对于在笔记本上训练的模型，使用Vertex AI SDK记录参数和指标。

Create a Vertex AI experiment. Submit all the pipelines as experiment runs. For models trained on notebooks log parameters and metrics by using the Vertex AI SDK.

C. 在Vertex AI流水线中实现所有模型。创建一个Vertex AI实验，并将所有流水线运行与该实验关联。

Implement all models in Vertex AI Pipelines Create a Vertex AI experiment, and associate all pipeline runs with that experiment.

D. 使用Vertex AI Metadata API将所有模型参数和指标存储为模型元数据。

Store all model parameters and metrics as model metadata by using the Vertex AI Metadata API.

正确答案：B. Create a Vertex AI experiment. Submit all the pipelines as experiment runs. For models trained on notebooks log parameters and metrics by using the Vertex AI SDK.

解析： 这个问题要求为训练在不同服务上（Vertex AI Pipelines和Vertex AI Workbench笔记本）的多个ML模型找到一种比较性能的方法，关键要求是"最小化存储参数和指标所需的工作量"。

选项B是最佳解决方案，原因如下：

1. **最小化实施工作量**：
   - 无需更改现有的训练工作流程，模型可以继续在当前环境中训练
   - 不需要将所有模型迁移到单一平台，避免了重新实现代码的工作

- 为两种训练方法提供了简单统一的接口，而无需建立复杂的自定义数据管道

2. **利用专门设计的功能**：

   - Vertex AI实验是专为跟踪、比较和管理ML实验而设计的
   - 对于管道训练的模型，可以将管道运行直接与实验关联
   - 对于笔记本训练的模型，可以使用Vertex AI SDK轻松记录参数和指标

3. **统一的实验跟踪体验**：

   - 所有模型数据，无论来源于哪个训练平台，都存储在同一个实验中
   - 提供了一致的接口来查询和比较所有模型的性能
   - 内置可视化和比较工具，无需额外开发

4. **与Google Cloud生态系统的无缝集成**：

   - 作为Vertex AI的核心功能，实验与其他服务紧密集成
   - 不需要设置和维护额外的基础设施（如BigQuery表）
   - 支持自动化和程序化访问，便于进一步分析

其他选项存在额外工作量或系统复杂性的问题，不符合"最小化工作量"的核心要求。

问题 83

题目

你在一个使用TensorFlow框架构建最先进深度学习模型的团队工作。你的团队每周运行多个ML实验，这使得跟踪实验运行变得困难。你希望采用一种简单的方法，在最小化任何额外代码的同时，有效地跟踪、可视化和调试Google Cloud上的ML实验运行。你应该如何进行？

You work on a team that builds state-of-the-art deep learning models by using the TensorFlow framework. Your team runs multiple ML experiments each week, which makes it difficult to track the experiment runs. You want a simple approach to effectively track, visualize, and debug ML experiment runs on Google Cloud while minimizing any overhead code. How should you proceed?

选项

A. 设置Vertex AI Experiments来跟踪指标和参数。配置Vertex AI TensorBoard进行可视化。

Set up Vertex AI Experiments to track metrics and parameters. Configure Vertex AI TensorBoard for visualization.

B. 设置Cloud Function将指标文件写入和保存到Cloud Storage存储桶。配置Google Cloud VM在本地托管TensorBoard进行可视化。

Set up a Cloud Function to write and save metrics files to a Cloud Storage bucket. Configure a Google Cloud VM to host TensorBoard locally for visualization.

C. 设置Vertex AI Workbench笔记本实例。使用该实例将指标数据保存在Cloud Storage存储桶中，并在本地托管TensorBoard进行可视化。

Set up a Vertex AI Workbench notebook instance. Use the instance to save metrics data in a Cloud Storage bucket and to host TensorBoard locally for visualization.

D. 设置Cloud Function将指标文件写入和保存到BigQuery表。配置Google Cloud VM在本地托管TensorBoard进行可视化。

Set up a Cloud Function to write and save metrics files to a BigQuery table. Configure a Google Cloud VM to host TensorBoard locally for visualization.

正确答案：A. Set up Vertex AI Experiments to track metrics and parameters. Configure Vertex AI TensorBoard for visualization.

解析： 这个问题关注的是为TensorFlow深度学习实验提供一个简单的跟踪、可视化和调试方法，关键要求是"最小化任何开销代码"。

选项A是最佳解决方案，原因如下：

1. **专为机器学习实验设计的托管服务**：
    - Vertex AI Experiments是专门为跟踪ML实验而设计的服务
    - 它提供了预构建的功能来记录、组织和查询实验参数和指标
    - 无需编写自定义代码来实现实验跟踪逻辑，完全符合"最小化开销代码"的要求
2. **与TensorFlow的原生集成**：
    - Vertex AI TensorBoard是Google Cloud上的托管版TensorBoard
    - TensorBoard是TensorFlow生态系统的官方可视化工具
    - 它与TensorFlow无缝集成，团队无需修改现有工作流程即可获得强大的可视化能力
3. **零基础设施维护**：
    - 两个组件都是完全托管的服务，不需要设置或维护基础设施
    - 无需管理VM、存储或计算资源
    - 自动扩展以适应团队的多个实验，无需手动干预
4. **全面的可视化和调试功能**：
    - Vertex AI TensorBoard提供了丰富的可视化选项，如学习曲线、模型图、权重分布等
    - 支持实时监控实验进展
    - 提供了强大的调试工具，如模型图分析、计算图可视化等

其他选项要么需要设置和维护额外的基础设施，要么需要编写自定义代码，增加了不必要的复杂性和开销。

问题 84

题目

你在一家纺织制造公司工作。你的公司有数百台机器，每台机器都有许多传感器。你的团队使用传感器数据构建了数百个检测机器异常的ML模型。模型每天重新训练，你需要以成本效益高的方式部署这些模型。模型必须24/7不间断运行并进行亚毫秒级预测。你应该怎么做？

Your work for a textile manufacturing company. Your company has hundreds of machines, and each machine has many sensors. Your team used the sensory data to build hundreds of ML models that detect machine anomalies. Models are retrained daily, and you need to deploy these models in a cost-effective way. The models must operate 24/7 without downtime and make sub millisecond predictions. What should you do?

选项

A. 部署Dataflow批处理管道和Vertex AI预测端点。

Deploy a Dataflow batch pipeline and a Vertex AI Prediction endpoint.

B. 部署带有RunInference API的Dataflow批处理管道，并使用模型刷新。

Deploy a Dataflow batch pipeline with the RunInference API, and use model refresh.

C. 部署Dataflow流处理管道和具有自动扩缩功能的Vertex AI预测端点。

Deploy a Dataflow streaming pipeline and a Vertex AI Prediction endpoint with autoscaling.

D. 部署带有RunInference API的Dataflow流处理管道，并使用自动模型刷新。

Deploy a Dataflow streaming pipeline with the RunInference API, and use automatic model refresh.

正确答案：D. Deploy a Dataflow streaming pipeline with the RunInference API, and use automatic model refresh.

解析： 这个问题涉及为纺织制造公司部署大量异常检测模型的最佳策略，关键要求包括成本效益、不间断运行、亚毫秒级预测，以及每日重新训练模型。

选项D是最佳解决方案，原因如下：

1. **实时流处理适合持续监控**：
    - Dataflow流处理管道能够实时处理来自数百台机器的传感器数据流
    - 这种持续处理模式对于机器异常检测至关重要，因为需要立即识别潜在问题
    - 流处理比批处理更适合24/7不间断的监控场景
2. **RunInference API的成本效益**：
    - RunInference API允许直接在Dataflow管道中运行模型推理
    - 与为每个模型维护单独的预测端点相比，这种方法显著降低了成本
    - 对于需要部署"数百个ML模型"的情况，这种内联推理特别具有成本优势
    - 避免了每个模型的端点维护和API调用开销
3. **自动模型刷新确保无缝更新**：
    - 自动模型刷新功能允许在不中断服务的情况下更新模型
    - 对于"每日重新训练"的模型尤为重要
    - 确保始终使用最新训练的模型进行预测，而不会导致服务中断
4. **低延迟性能**：
    - 此架构能够实现"亚毫秒级预测"的要求

- 通过在流处理管道中直接进行推理，最小化了网络延迟
- Dataflow的分布式处理能力可以有效处理来自数百台机器的大量传感器数据

其他选项要么使用批处理不适合24/7监控，要么使用单独的预测端点不够成本效益，无法满足所有关键需求。

问题 85

题目

你正在开发一个ML模型，该模型根据位置、状况、型号类型、颜色和引擎/电池效率等数据预测二手汽车的成本。数据每晚更新。汽车经销商将使用该模型确定适当的汽车价格。你创建了一个Vertex AI流水线，该流水线读取数据，将数据分成训练/评估/测试集，执行特征工程，使用训练数据集训练模型，并使用评估数据集验证模型。你需要配置一个最小化成本的重训练工作流程。你应该怎么做？

You are developing an ML model that predicts the cost of used automobiles based on data such as location, condition, model type, color, and engine/battery efficiency. The data is updated every night. Car dealerships will use the model to determine appropriate car prices. You created a Vertex AI pipeline that reads the data splits the data into training/evaluation/test sets performs feature engineering trains the model by using the training dataset and validates the model by using the evaluation dataset. You need to configure a retraining workflow that minimizes cost. What should you do?

选项

A. 比较当前运行的训练和评估损失。如果损失相似，则将模型部署到Vertex AI端点。配置cron作业每晚重新部署流水线。

Compare the training and evaluation losses of the current run. If the losses are similar, deploy the model to a Vertex AI endpoint. Configure a cron job to redeploy the pipeline every night.

B. 比较当前运行的训练和评估损失。如果损失相似，则将模型部署到具有训练/服务偏差阈值模型监控的Vertex AI端点。当模型监控阈值触发时，重新部署流水线。

Compare the training and evaluation losses of the current run. If the losses are similar, deploy the model to a Vertex AI endpoint with training/serving skew threshold model monitoring. When the model monitoring threshold is triggered redeploy the pipeline.

C. 将结果与先前运行的评估结果进行比较。如果性能提高，则将模型部署到Vertex AI端点。配置cron作业每晚重新部署流水线。

Compare the results to the evaluation results from a previous run. If the performance improved deploy the model to a Vertex AI endpoint. Configure a cron job to redeploy the pipeline every night.

D. 将结果与先前运行的评估结果进行比较。如果性能提高，则将模型部署到具有训练/服务偏差阈值模型监控的Vertex AI端点。当模型监控阈值触发时，重新部署流水线。

Compare the results to the evaluation results from a previous run. If the performance improved deploy the model to a Vertex AI endpoint with training/serving skew threshold model monitoring. When the model monitoring threshold is triggered redeploy the pipeline.

正确答案：D. Compare the results to the evaluation results from a previous run. If the performance improved deploy the model to a Vertex AI endpoint with training/serving skew threshold model monitoring. When the

model monitoring threshold is triggered redeploy the pipeline.

解析： 这个问题关注的是为二手车价格预测模型配置一个"最小化成本"的重训练工作流程。关键信息是数据每晚更新，但我们需要确定最具成本效益的重训练策略。

选项D是最佳解决方案，原因如下：

1. **选择性部署新模型**：
    - 将当前评估结果与先前运行的结果比较
    - 只有在性能提高时才部署新模型
    - 避免了部署性能没有改进的模型，节省了部署和服务成本
    - 这种方法确保了只有真正更好的模型才会投入使用
2. **按需重训练**：
    - 使用训练/服务偏差阈值模型监控来检测数据分布变化
    - 只有在检测到明显的数据偏差时才触发重新训练
    - 避免了不必要的定期重训练，显著降低了计算成本
    - 即使数据每晚更新，但并非每次更新都会导致数据分布发生足够大的变化
3. **双重优化机制**：
    - 结合了"只部署更好的模型"和"只在需要时重训练"两种成本优化策略
    - 这种双重过滤确保了计算和服务资源的最高效利用
    - 适应了数据变化的实际速度，而不是假设的更新频率
4. **自动化监控**：
    - Vertex AI的模型监控提供了自动检测数据偏差的能力
    - 无需人工干预即可触发重训练，降低了操作成本
    - 确保模型在数据变化时仍然保持准确性

其他选项要么使用定时重训练而不考虑实际需求，要么比较训练和评估损失而非模型性能改进，无法实现最优的成本效益。

问题 86

题目

你最近使用BigQuery ML训练了一个AutoML回归模型。你与团队分享了结果并获得了积极反馈。你需要尽快将模型部署用于在线预测。你应该怎么做？

You recently used BigQuery ML to train an AutoML regression model. You shared results with your team and received positive feedback. You need to deploy your model for online prediction as quickly as possible. What should you do?

选项

A. 使用BigQuery ML重新训练模型，并指定Vertex AI作为模型注册表。从Vertex AI模型注册表将模型部署到Vertex AI端点。

Retrain the model by using BigQuery ML, and specify Vertex AI as the model registry. Deploy the model from Vertex AI Model Registry to a Vertex AI endpoint.

B. 使用Vertex AI重新训练模型。从Vertex AI模型注册表将模型部署到Vertex AI端点。

Retrain the model by using Vertex AI. Deploy the model from Vertex AI Model Registry to a Vertex AI endpoint.

C. 使用BigQuery ML修改模型，并指定Vertex AI作为模型注册表。从Vertex AI模型注册表将模型部署到Vertex AI端点。

Alter the model by using BigQuery ML, and specify Vertex AI as the model registry. Deploy the model from Vertex AI Model Registry to a Vertex AI endpoint.

D. 将模型从BigQuery ML导出到Cloud Storage。将模型导入Vertex AI模型注册表。将模型部署到Vertex AI端点。

Export the model from BigQuery ML to Cloud Storage. Import the model into Vertex AI Model Registry. Deploy the model to a Vertex AI endpoint.

正确答案：D. Export the model from BigQuery ML to Cloud Storage. Import the model into Vertex AI Model Registry. Deploy the model to a Vertex AI endpoint.

解析： 这个问题要求将一个已经训练好并获得团队积极反馈的BigQuery ML AutoML回归模型"尽快"部署用于在线预测。关键点是找到最快的部署路径，避免不必要的步骤。

选项D是最佳解决方案，原因如下：

1. **利用现有的模型**：
    - 题目明确表示已经训练了一个模型并获得积极反馈
    - 选项D直接使用这个现有模型，而不是重新训练
    - 这避免了耗时的重新训练过程，是最快的方法
2. **标准化的导出-导入流程**：
    - 这是BigQuery ML模型部署到Vertex AI的标准流程
    - BigQuery ML提供了内置功能将模型导出到Cloud Storage
    - Vertex AI可以直接从Cloud Storage导入模型到其Model Registry
    - 这个过程是直接的、文档完善的，实施风险最低
3. **最少的步骤**：
    - 导出、导入和部署是将BigQuery ML模型部署到Vertex AI端点所需的最少步骤
    - 没有引入任何额外的、不必要的操作
    - 整个流程可以通过少量命令或API调用完成
4. **保留模型性能**：
    - 直接使用已验证的模型确保了部署的模型与团队评审的完全一致
    - 不会引入任何可能影响性能的变化
    - 维持了已获得积极反馈的预测能力

其他选项都包含不必要的重新训练或修改步骤，违背了"尽快部署"的要求。

问题 87

题目

你使用本地数据构建了一个基于深度学习的图像分类模型。你想使用Vertex AI将模型部署到生产环境。由于安全考虑，你不能将数据移动到云端。你意识到输入数据分布可能随时间变化。你需要检测生产中的模型性能变化。你应该怎么做？

You built a deep learning-based image classification model by using on-premises data. You want to use Vertex AI to deploy the model to production. Due to security concerns, you cannot move your data to the cloud. You are aware that the input data distribution might change over time. You need to detect model performance changes in production. What should you do?

选项

A. 使用Vertex Explainable AI进行模型可解释性。配置基于特征的解释。

Use Vertex Explainable AI for model explainability. Configure feature-based explanations.

B. 使用Vertex Explainable AI进行模型可解释性。配置基于示例的解释。

Use Vertex Explainable AI for model explainability. Configure example-based explanations.

C. 创建Vertex AI模型监控作业。为你的模型启用训练-服务偏斜检测。

Create a Vertex AI Model Monitoring job. Enable training-serving skew detection for your model.

D. 创建Vertex AI模型监控作业。为你的模型启用特征归因偏斜和漂移检测。

Create a Vertex AI Model Monitoring job. Enable feature attribution skew and drift detection for your model.

正确答案：D. Create a Vertex AI Model Monitoring job. Enable feature attribution skew and drift detection for your model.

解析： 这个问题涉及在不能将数据移至云端的安全限制下，为部署在Vertex AI上的图像分类模型配置性能监控，特别是要检测"输入数据分布随时间变化"导致的模型性能变化。

选项D是最佳解决方案，原因如下：

1. **适合无训练数据场景**：
    - 特征归因漂移检测不需要访问原始训练数据
    - 它可以仅基于生产环境中的推理请求进行监控
    - 这完全符合"不能将数据移至云端"的安全限制
2. **专为检测数据分布变化设计**：
    - 漂移检测专门用于监控数据分布随时间的变化
    - 当新的预测请求的特征分布与基准期间不同时，会触发警报
    - 这直接解决了"输入数据分布可能随时间变化"的挑战

3. **特征归因监控的深度洞察**：
    - 除了监测输入分布的变化，此选项还监测特征归因的变化
    - 特征归因跟踪哪些特征对模型决策的贡献有变化
    - 这提供了更深层次的性能监控，不仅知道性能变化了，还能了解为什么变化
4. **无需额外数据迁移**：
    - 此方法直接在生产环境中工作，只分析进入模型的推理请求
    - 不需要将任何历史数据移至云端
    - 整个监控过程在模型已部署的Vertex AI环境内完成

其他选项要么关注可解释性而非性能监控，要么需要访问训练数据统计信息，不符合题目的安全限制。

问题 88

题目

你训练了一个模型，将其与自定义Docker容器一起打包用于服务，并将其部署到Vertex AI模型注册表。当你提交批量预测作业时，它失败并显示此错误："模型服务器从未准备就绪。请验证你的模型文件或容器配置是否有效。"日志中没有其他错误。你应该怎么做？

You trained a model packaged it with a custom Docker container for serving, and deployed it to Vertex AI Model Registry. When you submit a batch prediction job, it fails with this error: "Error model server never became ready. Please validate that your model file or container configuration are valid." There are no additional errors in the logs. What should you do?

选项

A. 向你的应用程序添加日志配置，以将日志发送到Cloud Logging。

Add a logging configuration to your application to emit logs to Cloud Logging.

B. 将模型配置中的HTTP端口更改为默认值8080。

Change the HTTP port in your model's configuration to the default value of 8080.

C. 将模型配置中的healthRoute值更改为/healthcheck。

Change the healthRoute value in your model's configuration to /healthcheck.

D. 在本地拉取Docker镜像，并使用docker run命令在本地启动它。使用docker logs命令探索错误日志。

Pull the Docker image locally, and use the docker run command to launch it locally. Use the docker logs command to explore the error logs.

正确答案：D. Pull the Docker image locally, and use the docker run command to launch it locally. Use the docker logs command to explore the error logs

解析： 这个问题涉及一个在Vertex AI批量预测作业中失败的自定义Docker容器模型，关键错误信息是"模型服务器从未准备就绪"，而且没有其他错误日志。我们需要确定最有效的故障排除方法。

选项D是最佳解决方案，原因如下：

1. **直接访问完整日志**：
    - 在Vertex AI上，某些容器内部日志可能不会完全暴露到Cloud Logging
    - 本地运行容器可以捕获所有stdout和stderr输出
    - `docker logs`命令提供了对容器启动和运行过程中生成的所有日志的完整访问
    - 这可以揭示在云环境中可能被过滤或截断的错误消息
2. **模拟实际环境进行测试**：
    - 本地运行容器创建了一个可控的测试环境
    - 可以验证容器本身是否正确构建并能够启动
    - 可以检查模型服务器是否正确响应预测请求
    - 可以测试健康检查端点是否正常工作
3. **交互式故障排除**：
    - 本地环境允许交互式排除故障
    - 可以尝试不同的命令、环境变量或配置
    - 可以检查容器内的文件系统和进程
    - 可以直接观察模型服务器的启动过程
4. **系统性的诊断方法**：
    - 这种方法遵循故障排除的基本原则：首先确定根本原因
    - 在尝试特定修复之前确认问题的准确本质
    - 避免了基于猜测的试错方法
    - 提供了解决问题的系统性路径

其他选项在不了解根本原因的情况下进行具体更改，这是基于猜测的解决方案，可能解决不了真正的问题。

问题 89

题目

你正在开发一个ML模型来识别公司产品的图像。你可以访问Cloud Storage存储桶中的超过一百万张图像。你计划使用Vertex AI Training尝试不同的TensorFlow模型。你需要在训练期间大规模读取图像，同时最小化数据I/O瓶颈。你应该怎么做？

You are developing an ML model to identify your company's products in images. You have access to over one million images in a Cloud Storage bucket. You plan to experiment with different TensorFlow models by using Vertex AI Training. You need to read images at scale during training while minimizing data I/O bottlenecks. What should you do?

选项

A. 使用Cloud Storage FUSE将图像直接加载到Vertex AI计算节点中。使用tf.data.Dataset.from_tensor_slices函数读取图像。

Load the images directly into the Vertex AI compute nodes by using Cloud Storage FUSE. Read the images by using the tf.data.Dataset.from_tensor_slices function.

B. 从你的图像数据创建Vertex AI托管数据集。使用AIP_TRAINING_DATA_URI环境变量访问图像，并使用tf.data.Dataset.list_files函数读取图像。

Create a Vertex AI managed dataset from your image data. Access the AIP_TRAINING_DATA_URI environment variable to read the images by using the tf.data.Dataset.list_files function.

C. 将图像转换为TFRecords并存储在Cloud Storage存储桶中。使用tf.data.TFRecordDataset函数读取TFRecords。

Convert the images to TFRecords and store them in a Cloud Storage bucket. Read the TFRecords by using the tf.data.TFRecordDataset function.

D. 将图像的URL存储在CSV文件中。使用tf.data.experimental.CsvDataset函数读取该文件。

Store the URLs of the images in a CSV file. Read the file by using the tf.data.experimental.CsvDataset function.

正确答案：C. Convert the images to TFRecords and store them in a Cloud Storage bucket. Read the TFRecords by using the tf.data.TFRecordDataset function.

解析： 这个问题要求在使用超过一百万张图像进行模型训练时，找到一种最小化数据I/O瓶颈的方法。关键点是处理大规模图像数据的效率问题。

选项C是最佳解决方案，原因如下：

1. **TFRecord格式的I/O优化**：
    - TFRecord是TensorFlow的优化二进制文件格式，专为高效数据读取而设计
    - 它允许将多个图像打包到单个文件中，大幅减少I/O操作的次数
    - 对于"超过一百万张图像"的大规模数据集，减少单独文件读取操作至关重要
    - 支持顺序读取多个样本，提高数据吞吐量
2. **高效的批处理和预取**：
    - tf.data.TFRecordDataset与TensorFlow的数据管道优化无缝集成
    - 支持高效的批处理、预取和并行处理操作
    - 允许训练过程在处理当前批次的同时预取下一批次数据
    - 这种流水线机制最大限度地减少了GPU的空闲时间
3. **压缩和存储效率**：
    - TFRecord支持数据压缩，减少存储和传输数据所需的带宽
    - 提供了更高效的数据布局，适合云存储环境的顺序访问模式
    - 可以将相关特征（如图像和标签）存储在一起，减少散乱的访问模式
4. **行业最佳实践**：
    - 这是TensorFlow处理大规模图像数据集的推荐方法
    - 在Vertex AI训练环境中表现良好，经过优化以处理来自Cloud Storage的TFRecord文件
    - 专为解决机器学习训练中的I/O瓶颈问题而设计

其他选项都需要单独读取每个图像文件或通过间接方式访问，无法避免大量小型I/O操作带来的瓶颈。

问题 90

题目

你在一家电子商务创业公司工作。你需要创建一个客户流失预测模型。你公司最近的销售记录存储在BigQuery表中。你想了解你的初始模型是如何做出预测的。你还希望尽可能快地迭代模型，同时最小化成本。你应该如何构建你的第一个模型？

You work at an ecommerce startup. You need to create a customer churn prediction model. Your company's recent sales records are stored in a BigQuery table. You want to understand how your initial model is making predictions. You also want to iterate on the model as quickly as possible while minimizing cost. How should you build your first model?

选项

A. 将数据导出到Cloud Storage存储桶。将数据加载到Vertex AI Workbench上的pandas DataFrame中，并使用scikit-learn训练逻辑回归模型。

Export the data to a Cloud Storage bucket. Load the data into a pandas DataFrame on Vertex AI Workbench and train a logistic regression model with scikit-learn.

B. 使用TensorFlow BigQueryClient创建tf.data.Dataset。在TensorFlow中实现深度神经网络。

Create a tf.data.Dataset by using the TensorFlow BigQueryClient. Implement a deep neural network in TensorFlow.

C. 在BigQuery中准备数据并将数据与Vertex AI数据集关联。创建AutoMLTabularTrainingJob来训练分类模型。

Prepare the data in BigQuery and associate the data with a Vertex AI dataset. Create an AutoMLTabularTrainingJob to train a classification model.

D. 将数据导出到Cloud Storage存储桶。创建tf.data.Dataset从Cloud Storage读取数据。在TensorFlow中实现深度神经网络。

Export the data to a Cloud Storage bucket. Create a tf.data.Dataset to read the data from Cloud Storage. Implement a deep neural network in TensorFlow.

正确答案：C. Prepare the data in BigQuery and associate the data with a Vertex AI dataset. Create an AutoMLTabularTrainingJob to train a classification model.

解析： 这个问题要求为电子商务创业公司创建一个客户流失预测模型，关键需求是理解模型如何做出预测，能够快速迭代，同时最小化成本。

选项C是最佳解决方案，原因如下：

1. **理解模型预测的深度洞察**：
    - Vertex AI AutoML提供了内置且全面的模型可解释性工具
    - 提供自动的特征重要性分析和预测解释，比手动实现解释更全面
    - 通过直观的图形化界面展示结果，使业务团队成员也能理解模型决策过程
    - 包括全局和局部解释，帮助理解整体模型行为和个别预测

2. **真正的快速迭代**：
    - 虽然单次训练时间可能较长，但从数据到可用模型的端到端时间更短
    - 无需编写数据转换、特征工程和模型评估代码
    - 自动尝试多种算法和参数组合，相当于并行进行多次实验
    - 训练完成后立即可以部署和使用，无需额外的工程工作
3. **综合成本效益**：
    - 考虑到开发人员时间和专业知识需求，AutoML可能更具成本效益
    - 避免了需要数据科学专家手动调优模型的成本
    - 减少了从测试到生产的工程工作
    - 为初创公司提供了"立即可用"的解决方案，加速上市时间
4. **适合初创公司场景**：
    - 提供了一站式解决方案，从数据到部署模型
    - 无需构建和维护复杂的ML基础设施
    - 允许初创公司快速获得高质量模型，而无需招聘专门的ML团队
    - 简化了从实验到生产的路径

其他选项要么需要更多专业知识和开发时间（TensorFlow DNN模型），要么无法提供同样全面的解释能力和自动化程度，不适合快速验证和迭代的需求。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 10)

问题 91

题目

你正在开发一个基于表格数据的新XGBoost分类模型的训练流水线。数据存储在BigQuery表中。你需要完成以下步骤：

1. 随机将数据分成训练和评估数据集，比例为65/35
2. 进行特征工程
3. 获取评估数据集的指标
4. 比较在不同流水线执行中训练的模型

你应该如何执行这些步骤？

You are developing a training pipeline for a new XGBoost classification model based on tabular data. The data is stored in a BigQuery table. You need to complete the following steps:

1. Randomly split the data into training and evaluation datasets in a 65/35 ratio
2. Conduct feature engineering
3. Obtain metrics for the evaluation dataset
4. Compare models trained in different pipeline executions

How should you execute these steps?

选项

A. 1. 使用Vertex AI Pipelines，添加一个组件来将数据分成训练和评估集，并添加另一个组件进行特征工程。 2. 在训练组件中启用指标自动记录。 3. 在Vertex AI Experiments中比较流水线运行。

1. Using Vertex AI Pipelines, add a component to divide the data into training and evaluation sets, and add another component for feature engineering.
2. Enable autologging of metrics in the training component.
3. Compare pipeline runs in Vertex AI Experiments.

B. 1. 使用Vertex AI Pipelines，添加一个组件来将数据分成训练和评估集，并添加另一个组件进行特征工程。 2. 在训练组件中启用指标自动记录。 3. 使用Vertex ML Metadata中的工件血统比较模型。

1. Using Vertex AI Pipelines, add a component to divide the data into training and evaluation sets, and add another component for feature engineering.
2. Enable autologging of metrics in the training component.
3. Compare models using the artifacts' lineage in Vertex ML Metadata.

C. 1. 在BigQuery ML中，使用CREATE MODEL语句，指定BOOSTED_TREE_CLASSIFIER作为模型类型，并使用BigQuery处理数据分割。 2. 使用SQL视图应用特征工程并使用该视图中的数据训练模型。 3. 使用带有ML.TRAINING_INFO语句的SQL查询比较模型的评估指标。

1. In BigQuery ML, use the CREATE MODEL statement with BOOSTED_TREE_CLASSIFIER as the model type and use BigQuery to handle the data splits.
2. Use a SQL view to apply feature engineering and train the model using the data in that view.
3. Compare the evaluation metrics of the models by using a SQL query with the ML.TRAINING_INFO statement.

D. 1. 在BigQuery ML中，使用CREATE MODEL语句，指定BOOSTED_TREE_CLASSIFIER作为模型类型，并使用BigQuery处理数据分割。 2. 使用ML TRANSFORM指定特征工程转换并使用表中的数据训练模型。 3. 使用带有ML.TRAINING_INFO语句的SQL查询比较模型的评估指标。

1. In BigQuery ML, use the CREATE MODEL statement with BOOSTED_TREE_CLASSIFIER as the model type and use BigQuery to handle the data splits.
2. Use ML TRANSFORM to specify the feature engineering transformations and tram the model using the data in the table.
3. Compare the evaluation metrics of the models by using a SQL query with the ML.TRAINING_INFO statement.

正确答案：A. Using Vertex AI Pipelines, add a component to divide the data into training and evaluation sets, and add another component for feature engineering. Enable autologging of metrics in the training component. Compare pipeline runs in Vertex AI Experiments.

解析： 这个问题要求选择最适合执行指定步骤的方案。

选项A是最佳解决方案，原因如下：

1. **完整流水线集成**：
    - Vertex AI Pipelines提供了一个完整的框架来编排所有需要的步骤
    - 可以轻松创建用于数据分割和特征工程的专用组件

    - 流水线组件化设计使得流程可重复、可维护

2. **自动指标记录**：

    - 训练组件中的指标自动记录功能确保评估数据集的所有指标都被捕获
    - 这些指标可以直接用于模型性能评估
    - 无需编写额外代码来捕获和存储这些指标

3. **Vertex AI Experiments的强大比较功能**：

    - Vertex AI Experiments专为比较不同ML实验运行而设计
    - 提供直观的可视化界面来比较不同流水线执行中训练的模型
    - 支持比较超参数、指标、模型性能等
    - 这正是满足第4步要求的理想工具

相比之下，其他选项存在以下问题：

- 选项B使用Vertex ML Metadata的工件血统，它更适合追踪数据和模型之间的关系，而不是专门针对比较不同运行的模型性能
- 选项C和D使用BigQuery ML和SQL查询，虽然可以完成任务，但对于比较不同运行的模型，Vertex AI Experiments提供了更丰富、更直观的比较功能

问题 92

题目

你在一家向全球数千家企业销售公司电子产品的公司工作。你的公司将历史客户数据存储在BigQuery中。你需要构建一个模型，预测客户在未来三年的终身价值。你想使用最简单的方法来构建模型，并且你想要访问可视化工具。你应该怎么做？

You work for a company that sells corporate electronic products to thousands of businesses worldwide. Your company stores historical customer data in BigQuery. You need to build a model that predicts customer lifetime value over the next three years. You want to use the simplest approach to build the model and you want to have access to visualization tools. What should you do?

选项

A. 创建Vertex AI Workbench笔记本进行探索性数据分析。使用IPython魔术命令创建包含输入特征的新BigQuery表。使用BigQuery控制台运行CREATE MODEL语句。通过使用ML.EVALUATE和ML.PREDICT语句验证结果。

Create a Vertex AI Workbench notebook to perform exploratory data analysis. Use IPython magics to create a new BigQuery table with input features. Use the BigQuery console to run the CREATE MODEL statement. Validate the results by using the ML.EVALUATE and ML.PREDICT statements.

B. 从BigQuery控制台运行CREATE MODEL语句创建AutoML模型。通过使用ML.EVALUATE和ML.PREDICT语句验证结果。

Run the CREATE MODEL statement from the BigQuery console to create an AutoML model. Validate the results by using the ML.EVALUATE and ML.PREDICT statements.

C. 创建Vertex AI Workbench笔记本进行探索性数据分析并创建输入特征。将特征保存为Cloud Storage中的CSV文件。将CSV文件导入为新的BigQuery表。使用BigQuery控制台运行CREATE MODEL语句。通过使用ML.EVALUATE和ML.PREDICT语句验证结果。

Create a Vertex AI Workbench notebook to perform exploratory data analysis and create input features. Save the features as a CSV file in Cloud Storage. Import the CSV file as a new BigQuery table. Use the BigQuery console to run the CREATE MODEL statement. Validate the results by using the ML.EVALUATE and ML.PREDICT statements.

D. 创建Vertex AI Workbench笔记本进行探索性数据分析。使用IPython魔术命令创建包含输入特征的新BigQuery表，创建模型，并通过使用CREATE MODEL、ML.EVALUATE和ML.PREDICT语句验证结果。

Create a Vertex AI Workbench notebook to perform exploratory data analysis. Use IPython magics to create a new BigQuery table with input features, create the model, and validate the results by using the CREATE MODEL, ML.EVALUATE, and ML.PREDICT statements.

正确答案：B. Run the CREATE MODEL statement from the BigQuery console to create an AutoML model. Validate the results by using the ML.EVALUATE and ML.PREDICT statements.

解析： 这个问题要求为预测客户终身价值构建模型，关键要求是"最简单的方法"和"访问可视化工具"。

选项B是最佳解决方案，原因如下：

1. **最简单的端到端方法**：
    - 利用数据已在BigQuery中的优势
    - 直接在BigQuery中运行CREATE MODEL语句创建AutoML模型
    - 不需要切换到不同的工具或环境
    - 无需导出/导入数据
    - 最少的步骤和代码
2. **内置可视化能力**：
    - BigQuery控制台提供查询结果的基本可视化
    - BigQuery与Looker Studio有原生集成，可创建丰富的可视化报表
    - ML.EVALUATE结果可以直接在BigQuery界面中可视化
    - 可以使用SQL查询模型结果并利用BigQuery的图表功能
3. **AutoML的优势**：
    - 自动处理特征选择和工程
    - 自动调整超参数
    - 不需要深入的ML专业知识
    - 对于预测任务(如客户终身价值)提供良好的性能

其他选项引入了不必要的复杂性：

- 选项A和D需要设置Vertex AI Workbench环境和使用IPython魔术命令
- 选项C包含多个额外步骤：创建笔记本、导出CSV、导入BigQuery
- 这些额外步骤违背了"最简单的方法"的要求

BigQuery ML提供了一个一站式环境，结合了数据存储、模型训练和可视化能力，使其成为满足所有要求的最简单解决方案。

问题 93

题目

你最近训练了一个XGBoost模型，计划将其作为HTTP微服务对内部使用进行暴露。部署后，你预计会有少量的传入请求。你希望以最小的工作量和延迟将模型投入生产。你应该怎么做？

You recently trained an XGBoost model on tabular data. You plan to expose the model for internal use as an HTTP microservice. After deployment, you expect a small number of incoming requests. You want to productionize the model with the least amount of effort and latency. What should you do?

选项

A. 使用CREATE MODEL和BOOSTED_TREE_REGRESSOR语句将模型部署到BigQuery ML，并从微服务调用BigQuery API。

Deploy the model to BigQuery ML by using CREATE MODEL with the BOOSTED_TREE_REGRESSOR statement, and invoke the BigQuery API from the microservice.

B. 构建基于Flask的应用程序。将应用程序打包在Vertex AI的自定义容器中，并将其部署到Vertex AI端点。

Build a Flask-based app. Package the app in a custom container on Vertex AI, and deploy it to Vertex AI Endpoints.

C. 构建基于Flask的应用程序。将应用程序打包在Docker镜像中，并将其部署到自动驾驶模式的Google Kubernetes Engine。

Build a Flask-based app. Package the app in a Docker image, and deploy it to Google Kubernetes Engine in Autopilot mode.

D. 使用预构建的XGBoost Vertex容器创建模型，并将其部署到Vertex AI端点。

Use a prebuilt XGBoost Vertex container to create a model, and deploy it to Vertex AI Endpoints.

正确答案：D. Use a prebuilt XGBoost Vertex container to create a model, and deploy it to Vertex AI Endpoints.

解析： 这个问题涉及如何以最小的工作量和延迟将XGBoost模型部署为内部HTTP微服务。关键需求是"最小的工作量和延迟"以及"预计少量请求"。

选项D是最佳解决方案，原因如下：

1. **最小工作量**：
    - 使用预构建的XGBoost Vertex容器意味着不需要编写自定义服务代码
    - 不需要创建Flask应用程序或处理Docker容器化过程
    - Vertex AI提供了专门针对XGBoost模型优化的容器
2. **低延迟服务**：

    - Vertex AI端点专为低延迟在线预测设计
    - 预构建容器已针对性能进行了优化
    - 为模型服务提供了可靠的基础设施，无需管理

3. **适合内部微服务**：

    - 易于集成到内部系统中
    - 提供标准的HTTP接口
    - 适合预期的"少量请求"场景

相比之下，其他选项存在以下问题：

- 选项A需要重新训练模型，并且通过BigQuery API进行预测可能会增加延迟
- 选项B要求构建自定义Flask应用和容器，增加了开发工作量
- 选项C同样需要Flask开发工作，还需要设置GKE环境，即使是自动驾驶模式也比Vertex AI端点更复杂

通过使用预构建容器和Vertex AI端点，可以获得工作量和延迟的最佳平衡，特别适合小规模的内部服务需求。

问题 94

题目

你在一家在线杂货店工作。你最近开发了一个自定义ML模型，当用户访问网站时推荐一个食谱。你选择在Vertex AI端点上的机器类型，通过使用模型可以服务的每秒查询数(QPS)来优化成本，并将其部署在具有8个vCPU且没有加速器的单台机器上。

即将到来的假期季节，你预计在此期间的流量将是典型日常流量的四倍。你需要确保模型能够有效地扩展以满足增加的需求。你应该怎么做？

You work for an online grocery store. You recently developed a custom ML model that recommends a recipe when a user arrives at the website. You chose the machine type on the Vertex AI endpoint to optimize costs by using the queries per second (QPS) that the model can serve, and you deployed it on a single machine with 8 vCPUs and no accelerators.

A holiday season is approaching and you anticipate four times more traffic during this time than the typical daily traffic. You need to ensure that the model can scale efficiently to the increased demand. What should you do?

选项

A. 1. 维持端点上相同的机器类型。 2. 设置监控作业和CPU使用率警报。 3. 如果你收到警报，将计算节点添加到端点。

1. Maintain the same machine type on the endpoint.
2. Set up a monitoring job and an alert for CPU usage.
3. If you receive an alert, add a compute node to the endpoint.

B. 1. 将端点上的机器类型更改为具有32个vCPU的类型。 2. 设置监控作业和CPU使用率警报。 3. 如果你收到警报，根据需要进一步扩展vCPU。

1. Change the machine type on the endpoint to have 32 vCPUs.

2. Set up a monitoring job and an alert for CPU usage.
3. If you receive an alert, scale the vCPUs further as needed.

C. 1. 维持端点上相同的机器类型。配置端点启用基于vCPU使用率的自动扩缩。 2. 设置监控作业和CPU使用率警报。 3. 如果你收到警报，调查原因。

1. Maintain the same machine type on the endpoint Configure the endpoint to enable autoscaling based on vCPU usage.
2. Set up a monitoring job and an alert for CPU usage.
3. If you receive an alert, investigate the cause.

D. 1. 将端点上的机器类型更改为具有GPU的类型。配置端点启用基于GPU使用率的自动扩缩。 2. 设置监控作业和GPU使用率警报。 3. 如果你收到警报，调查原因。

1. Change the machine type on the endpoint to have a GPU. Configure the endpoint to enable autoscaling based on the GPU usage.
2. Set up a monitoring job and an alert for GPU usage.
3. If you receive an alert, investigate the cause.

正确答案：C. Maintain the same machine type on the endpoint Configure the endpoint to enable autoscaling based on vCPU usage. Set up a monitoring job and an alert for CPU usage. If you receive an alert, investigate the cause.

解析： 这个问题要求为即将面临流量激增的在线推荐系统选择最佳的扩展策略。关键需求是有效地扩展以处理预计增加的需求（典型流量的4倍）。

选项C是最佳解决方案，原因如下：

1. **保留优化的机器类型**：
    - 保持已经过成本优化的现有机器类型（8个vCPU）
    - 避免了过度调整导致的不必要成本
    - 利用已知能够高效处理当前负载的配置
2. **启用自动扩缩**：
    - 基于vCPU使用率的自动扩缩是处理可变负载的最佳方法
    - 能够在需要时自动添加更多计算节点
    - 当流量减少时自动缩减，避免不必要的资源浪费
    - 无需人工干预即可适应流量变化
3. **监控与预警机制**：
    - 设置监控和警报提供额外的安全保障
    - 如果自动扩缩不能完全解决问题，警报会提醒团队调查
    - 跟踪系统性能，确保用户体验保持良好

相比之下，其他选项存在以下问题：

- 选项A需要手动响应警报并添加节点，不够自动化，响应可能不够及时
- 选项B预先扩大机器类型到32个vCPU，即使在假期到来前可能不需要这么多资源，这会导致资源浪费

- 选项D引入了GPU，这对于推荐模型可能不必要，增加了不必要的成本，且更改了硬件架构，可能需要额外的模型调整

问题 95

题目

你在一家向世界各地发运科学产品的国际制造组织工作。这些产品的说明手册需要翻译成15种不同的语言。你组织的领导团队希望开始使用机器学习来降低人工翻译的成本并提高翻译速度。你需要实施一个可扩展的解决方案，最大化准确性并最小化运营开销。你还希望包括一个评估和修复错误翻译的流程。你应该怎么做？

You work for an international manufacturing organization that ships scientific products all over the world. Instruction manuals for these products need to be translated to 15 different languages. Your organization's leadership team wants to start using machine learning to reduce the cost of manual human translations and increase translation speed. You need to implement a scalable solution that maximizes accuracy and minimizes operational overhead. You also want to include a process to evaluate and fix incorrect translations. What should you do?

选项

A. 使用Cloud Function触发器创建工作流。配置一个Cloud Function，在文档上传到输入Cloud Storage存储桶时触发。配置另一个使用Cloud Translation API翻译文档的Cloud Function，并将翻译保存到输出Cloud Storage存储桶。使用人工审阅者评估不正确的翻译。

Create a workflow using Cloud Function triggers. Configure a Cloud Function that is triggered when documents are uploaded to an input Cloud Storage bucket. Configure another Cloud Function that translates the documents using the Cloud Translation API, and saves the translations to an output Cloud Storage bucket. Use human reviewers to evaluate the incorrect translations.

B. 创建一个Vertex AI流水线，处理文档，启动AutoML Translation训练作业，评估翻译并将模型部署到具有自动扩缩和模型监控的Vertex AI端点。当训练和实时数据之间存在预定义的偏差时，使用最新数据重新触发流水线。

Create a Vertex AI pipeline that processes the documents launches, an AutoML Translation training job, evaluates the translations and deploys the model to a Vertex AI endpoint with autoscaling and model monitoring. When there is a predetermined skew between training and live data, re-trigger the pipeline with the latest data.

C. 使用AutoML Translation训练模型。配置Translation Hub项目，并使用训练好的模型翻译文档。使用人工审阅者评估不正确的翻译。

Use AutoML Translation to train a model. Configure a Translation Hub project, and use the trained model to translate the documents. Use human reviewers to evaluate the incorrect translations.

D. 使用Vertex AI自定义训练作业，使用你的数据微调最先进的开源预训练模型。将模型部署到具有自动扩缩和模型监控的Vertex AI端点。当训练和实时数据之间存在预定义的偏差时，配置触发器运行另一个使用最新数据的训练作业。

Use Vertex AI custom training jobs to fine-tune a state-of-the-art open source pretrained model with your data. Deploy the model to a Vertex AI endpoint with autoscaling and model monitoring. When there is a

predetermined skew between the training and live data, configure a trigger to run another training job with the latest data.

正确答案：C. Use AutoML Translation to train a model. Configure a Translation Hub project, and use the trained model to translate the documents. Use human reviewers to evaluate the incorrect translations.

解析： 这个问题涉及为科学产品翻译说明手册的方案选择，关键要求是可扩展性、最大化准确性、最小化运营开销，并包含错误翻译评估机制。

选项C是最佳解决方案，原因如下：

1. **Translation Hub的专业优势**：
    - Translation Hub是专为企业翻译工作流设计的专用服务
    - 提供用户友好的界面管理多语言翻译项目
    - 内置审核工作流，便于人工检查和修正错误翻译
    - 专为文档翻译优化，非常适合产品说明手册
2. **AutoML Translation的自定义能力**：
    - 允许使用组织特定的科学和技术术语进行训练
    - 可以针对15种不同语言分别优化
    - 提供比通用翻译API更高的准确性
    - 特别适合专业领域（如科学产品）的翻译
3. **最低的运营开销**：
    - 完全托管的服务无需管理基础设施
    - 直观的用户界面减少了操作复杂性
    - 避免了复杂流水线和监控系统的管理负担
    - 适合非技术团队使用，如翻译和文档专家
4. **人工审核整合**：
    - 提供明确的流程来识别和修复错误翻译
    - 结合了机器翻译的速度和人工审核的质量
    - 支持不断学习和改进翻译质量

相比之下，其他选项存在以下问题：

- 选项A使用Cloud Functions手动构建翻译流程，缺乏专业翻译功能和管理界面
- 选项B构建复杂的Vertex AI流水线，增加了不必要的操作复杂性
- 选项D使用自定义训练任务微调开源模型，需要深厚的ML专业知识和复杂的运维

问题 96

题目

你是一家零售公司的员工。你的任务是建立一个模型，确定每个客户流失的概率。你需要预测结果具有可解释性，以便结果可用于开发针对有风险客户的营销活动。你应该怎么做？

You work for a retail company. You have been tasked with building a model to determine the probability of churn for each customer. You need the predictions to be interpretable so the results can be used to develop marketing campaigns that target at-risk customers. What should you do?

选项

A. 在Vertex AI Workbench笔记本实例中构建随机森林回归模型。配置模型在训练后生成特征重要性。

Build a random forest regression model in a Vertex AI Workbench notebook instance. Configure the model to generate feature importances after the model is trained.

B. 构建AutoML表格回归模型。配置模型在进行预测时生成解释。

Build an AutoML tabular regression model. Configure the model to generate explanations when it makes predictions.

C. 使用Vertex AI自定义训练构建自定义TensorFlow神经网络。配置模型在进行预测时生成解释。

Build a custom TensorFlow neural network by using Vertex AI custom training. Configure the model to generate explanations when it makes predictions.

D. 在Vertex AI Workbench笔记本实例中构建随机森林分类模型。配置模型在训练后生成特征重要性。

Build a random forest classification model in a Vertex AI Workbench notebook instance. Configure the model to generate feature importances after the model is trained.

正确答案：D. Build a random forest classification model in a Vertex AI Workbench notebook instance. Configure the model to generate feature importances after the model is trained.

解析： 这个问题关注客户流失预测模型的可解释性要求。关键是需要构建一个能够提供"可解释预测"的模型，以支持针对性营销活动的开发。

选项D是最佳解决方案，原因如下：

1. **正确的模型类型**：
    - 客户流失是一个二元分类问题（客户会流失或不会流失）
    - 分类模型比回归模型更适合预测客户流失的概率
    - 随机森林分类器能够输出概率值，正好满足需求
2. **内在可解释性**：
    - 随机森林是一种"白盒"模型，比神经网络等"黑盒"模型更具可解释性
    - 特征重要性可以直接从随机森林模型中提取
    - 这些特征重要性直观地展示了哪些因素最影响客户流失决策
3. **营销活动价值**：
    - 了解推动客户流失的关键特征可以直接指导营销策略
    - 例如，如果"最后购买时间"是重要特征，可以针对长时间未购买的客户发送促销
    - 特征重要性提供了可操作的见解，而不仅仅是预测结果

相比之下，其他选项存在以下问题：

- 选项A使用回归模型而非分类模型，不适合预测流失概率
- 选项B同样使用回归模型，且AutoML的解释机制不如随机森林的特征重要性直观
- 选项C使用神经网络，虽然可以生成解释，但这些是事后解释，不如随机森林的内在可解释性强

问题 97

题目

你正在开发一个推荐引擎，用于一家在线服装店。历史客户交易数据存储在BigQuery和Cloud Storage中。你需要执行探索性数据分析(EDA)、预处理和模型训练。你计划在尝试不同类型的算法时重新运行这些EDA、预处理和训练步骤。你希望最小化运行这些步骤时的成本和开发工作。你应该如何配置环境？

You are developing a recommendation engine for an online clothing store. The historical customer transaction data is stored in BigQuery and Cloud Storage. You need to perform exploratory data analysis (EDA), preprocessing and model training. You plan to rerun these EDA, preprocessing, and training steps as you experiment with different types of algorithms. You want to minimize the cost and development effort of running these steps as you experiment. How should you configure the environment?

选项

A. 创建一个使用默认VM实例的Vertex AI Workbench用户管理的笔记本，并使用JupyterLab中的%%bigquery魔术命令查询表格。

Create a Vertex AI Workbench user-managed notebook using the default VM instance, and use the %%bigquery magic commands in Jupyter to query the tables.

B. 创建一个Vertex AI Workbench托管笔记本，直接从JupyterLab界面浏览和查询表格。

Create a Vertex AI Workbench managed notebook to browse and query the tables directly from the JupyterLab interface.

C. 创建一个基于Dataproc Hub的Vertex AI Workbench用户管理的笔记本，并使用JupyterLab中的%%bigquery魔术命令查询表格。

Create a Vertex AI Workbench user-managed notebook on a Dataproc Hub, and use the %%bigquery magic commands in Jupyter to query the tables.

D. 创建一个基于Dataproc集群的Vertex AI Workbench托管笔记本，并使用spark-bigquery-connector访问表格。

Create a Vertex AI Workbench managed notebook on a Dataproc cluster, and use the spark-bigquery-connector to access the tables.

正确答案：B. Create a Vertex AI Workbench managed notebook to browse and query the tables directly from the JupyterLab interface.

解析： 这个问题关注如何为推荐引擎设置最经济高效的开发环境，关键要求是"最小化成本和开发工作"以及"重复运行EDA、预处理和训练步骤"。

选项B是最佳解决方案，原因如下：

1. **托管笔记本的经济性**：

    - Vertex AI Workbench托管笔记本按使用时间收费
    - 开发者不使用时自动关闭，节省成本
    - 不需要管理底层基础设施
    - 适合间歇性实验工作流程

2. **内置数据集成**：

    - JupyterLab界面原生支持BigQuery浏览和查询
    - 无需编写复杂的连接代码或魔术命令
    - 提供友好的数据探索体验
    - 可直接从界面访问Cloud Storage数据

3. **最低的开发工作量**：

    - 预装了常用ML库和依赖
    - 不需要管理环境设置
    - 用户界面直观，减少学习曲线
    - 专注于实验和分析，而非基础设施管理

相比之下，其他选项存在以下问题：

- 选项A需要手动管理笔记本实例的启动和停止，可能导致不必要的成本
- 选项C引入了不必要的Dataproc Hub复杂性，对于初步实验而言过于重量级
- 选项D需要设置和管理Dataproc集群以及spark-bigquery-connector，增加了开发工作量

对于初期的EDA和算法实验阶段，托管笔记本提供了最佳的平衡，既简化了开发工作，又优化了成本结构。

问题 98

题目

你最近将模型部署到Vertex AI端点，并在Vertex AI Feature Store中设置了在线服务。你配置了每日批量摄取作业来更新特征存储。在批量摄取作业期间，你发现特征存储的在线服务节点CPU利用率高，特征检索延迟也高。你需要改善每日批量摄取期间的在线服务性能。你应该怎么做？

You recently deployed a model to a Vertex AI endpoint and set up online serving in Vertex AI Feature Store. You have configured a daily batch ingestion job to update your featurestore. During the batch ingestion jobs, you discover that CPU utilization is high in your featurestore's online serving nodes and that feature retrieval latency is high. You need to improve online serving performance during the daily batch ingestion. What should you do?

选项

A. 在批量摄取作业之前安排增加特征存储中的在线服务节点数量

Schedule an increase in the number of online serving nodes in your featurestore prior to the batch ingestion jobs

B. 为特征存储中的在线服务节点启用自动扩缩

Enable autoscaling of the online serving nodes in your featurestore

C. 为Vertex AI端点中DeployedModel的预测节点启用自动扩缩

Enable autoscaling for the prediction nodes of your DeployedModel in the Vertex AI endpoint

D. 增加批量摄取作业ImportFeatureValues请求中的worker_count

Increase the worker_count in the ImportFeatureValues request of your batch ingestion job

正确答案：B. Enable autoscaling of the online serving nodes in your featurestore

解析： 这个问题关注如何解决在批量摄取作业期间，Vertex AI Feature Store在线服务性能下降的问题。关键指标是高CPU利用率和高特征检索延迟。

选项B是最佳解决方案，原因如下：

1. **自动且动态的资源调整**：
    - 自动扩缩能够根据实际负载情况动态调整服务节点数量
    - 当批量摄取作业增加负载时，系统会自动添加更多节点
    - 当负载减少后，系统会自动缩减资源，优化成本
    - 无需人工干预或预先判断需要的容量
2. **解决根本问题**：
    - 高CPU利用率表明在线服务节点资源不足
    - 自动扩缩直接解决了资源不足的问题
    - 增加更多节点可以分散负载，降低每个节点的CPU利用率
    - 改善了特征检索延迟，提高了在线服务性能
3. **长期维护的简便性**：
    - 一旦配置，自动扩缩会持续工作
    - 即使批量作业模式或负载特征发生变化，也能自适应
    - 减少了持续管理和调整的需求
    - 提供了更健壮的长期解决方案

相比之下，其他选项存在以下问题：

- 选项A需要预先安排节点增加，这需要正确预估所需资源并手动操作，增加了运维复杂性
- 选项C扩展的是模型预测节点而非特征服务节点，没有解决特征检索延迟的问题
- 选项D增加批量作业的worker数量可能会进一步增加对在线服务节点的压力，加剧问题

自动扩缩提供了最灵活、最可维护且最可靠的解决方案，既解决了当前性能问题，又为未来的负载变化提供了自适应能力。

问题 99

题目

你在开发一个基于表格数据的自定义TensorFlow分类模型。你的原始数据存储在BigQuery中，包含数亿行记录，包括分类和数值特征。你需要对某些数值特征使用MaxMin缩放器，并对一些分类特征如SKU名称应用one-hot编码。你的模型将在多个epochs上训练。你希望最小化解决方案的工作量和成本。你应该怎么做？

You are developing a custom TensorFlow classification model based on tabular data. Your raw data is stored in BigQuery. contains hundreds of millions of rows, and includes both categorical and numerical features. You need to use a MaxMin scaler on some numerical features, and apply a one-hot encoding to some categorical features such as SKU names. Your model will be trained over multiple epochs. You want to minimize the effort and cost of your solution. What should you do?

选项

A. 1. 编写SQL查询创建单独的查找表来缩放数值特征。 2. 从Hugging Face部署基于TensorFlow的模型到BigQuery来编码文本特征。 3. 将结果BigQuery视图馈送到Vertex AI训练中。

1. Write a SQL query to create a separate lookup table to scale the numerical features.
2. Deploy a TensorFlow-based model from Hugging Face to BigQuery to encode the text features.
3. Feed the resulting BigQuery view into Vertex AI Training.

B. 1. 使用BigQuery缩放数值特征。 2. 将特征馈送到Vertex AI训练中。 3. 允许TensorFlow执行one-hot文本编码。

1. Use BigQuery to scale the numerical features.
2. Feed the features into Vertex AI Training.
3. Allow TensorFlow to perform the one-hot text encoding.

C. 1. 使用TFX组件和Dataflow编码文本特征并缩放数值特征。 2. 将结果导出到Cloud Storage作为TFRecords。 3. 将数据馈送到Vertex AI训练中。

1. Use TFX components with Dataflow to encode the text features and scale the numerical features.
2. Export results to Cloud Storage as TFRecords.
3. Feed the data into Vertex AI Training.

D. 1. 编写SQL查询创建单独的查找表来缩放数值特征。 2. 在BigQuery中执行one-hot文本编码。 3. 将结果BigQuery视图馈送到Vertex AI训练中。

1. Write a SQL query to create a separate lookup table to scale the numerical features.
2. Perform the one-hot text encoding in BigQuery.
3. Feed the resulting BigQuery view into Vertex AI Training.

正确答案：C. Use TFX components with Dataflow to encode the text features and scale the numerical features. Export results to Cloud Storage as TFRecords. Feed the data into Vertex AI Training.

解析： 这个问题关注处理海量表格数据（数亿行）进行TensorFlow模型训练的最佳方法，尤其需要关注特征工程、多轮训练，以及工作量和成本最小化。

选项C是最佳解决方案，原因如下：

1. **高效的分布式处理**：
    - Dataflow提供了可扩展的分布式处理能力，可以高效处理数亿行数据
    - TFX（TensorFlow Extended）组件专为大规模机器学习预处理设计
    - 这种组合能够处理极大数据量，而不会遇到内存限制或处理瓶颈
2. **一次预处理，多次使用**：

- 预处理结果导出为TFRecords格式，这是一种针对TensorFlow优化的二进制格式
- 在多个训练epochs中只需执行一次预处理，然后重复使用结果
- 避免了每个epoch重新执行one-hot编码和缩放的开销
- 这对于"多个epochs训练"的要求至关重要

3. **成本效益**：

- 虽然初始设置可能需要一些工作，但长期来看节省了计算资源
- 避免了反复从BigQuery读取和处理数据的成本
- TFRecords提供了高效的数据读取，减少了训练期间的I/O开销
- 对于大规模数据和多轮训练，这是最具成本效益的方法

4. **高性能训练**：

- TFRecords格式优化了数据加载和训练性能
- 训练期间的数据访问更高效，减少了瓶颈
- 能够利用TensorFlow的高级数据管道功能

相比之下，其他选项存在以下问题：

- 选项A和D依赖BigQuery进行预处理，对于需要重复访问的多轮训练可能成本较高
- 选项B依赖TensorFlow在训练期间执行one-hot编码，这会导致每个epoch重复相同的预处理工作，计算成本高
- 对于包含SKU名称等高基数分类特征的one-hot编码，在训练期间执行可能导致显著的内存和计算开销

对于数亿行数据和多轮训练的场景，TFX+Dataflow+TFRecords的组合提供了最优的性能和成本平衡。

问题 100

题目

你希望将scikit-learn分类器模型迁移到TensorFlow。你计划使用与训练scikit-learn模型相同的训练集来训练TensorFlow分类器模型，然后使用公共测试集比较性能。你想使用Vertex AI Python SDK手动记录每个模型的评估指标，并基于F1分数和混淆矩阵进行比较。你应该如何记录指标？

You want to migrate a scikit-learn classifier model to TensorFlow. You plan to train the TensorFlow classifier model using the same training set that was used to train the scikit-learn model, and then compare the performances using a common test set. You want to use the Vertex AI Python SDK to manually log the evaluation metrics of each model and compare them based on their F1 scores and confusion matrices. How should you log the metrics?

选项

A. 使用aiplatform.log_classification_metrics函数记录F1分数，使用aiplatform.log_merrics函数记录混淆矩阵。

Use the aiplatform.log_classification_metrics function to log the F1 score, and use the aiplatform.log_merrics function to log the confusion matrix.

B. 使用aiplatform.log_classification_metrics函数记录F1分数和混淆矩阵。

Use the aiplatform.log_classification_metrics function to log the F1 score and the confusion matrix.

C. 使用aiplatform.log_metrics函数记录F1分数和混淆矩阵。

Use the aiplatform.log_metrics function to log the F1 score and the confusion matrix.

D. 使用aiplatform.log_metrics函数记录F1分数，使用aiplatform.log_classification_metrics函数记录混淆矩阵。

Use the aiplatform.log_metrics function to log the F1 score: and use the aiplatform.log_classification_metrics function to log the confusion matrix.

正确答案：B. Use the aiplatform.log_classification_metrics function to log the F1 score and the confusion matrix.

解析： 这个问题询问使用Vertex AI Python SDK记录和比较分类模型指标的最佳方法。

选项B是最佳解决方案，原因如下：

1. **专用分类指标功能**：
    - `aiplatform.log_classification_metrics`是专门为记录分类模型的评估指标设计的
    - 它能够同时处理F1分数和混淆矩阵等所有分类相关指标
    - 该函数内部优化了对分类特定指标的处理和展示
2. **更完整的指标记录**：
    - 使用一个专用函数记录所有相关指标确保了一致性
    - 避免了将相关指标分散在不同函数调用中的风险
    - 保持了逻辑上的连贯性，F1分数和混淆矩阵都是分类评估的组成部分
3. **更好的可视化和比较能力**：
    - Vertex AI的实验UI针对`log_classification_metrics`提供了优化的可视化
    - 便于在实验比较界面中快速查看和对比不同模型的性能
    - 提供了更丰富的模型比较上下文

相比之下，其他选项存在以下问题：

- 选项A中的`log_merrics`函数名拼写错误(应为`log_metrics`)
- 选项C使用通用`log_metrics`函数，没有利用Vertex AI对分类指标的专门支持
- 选项D不必要地将相关指标分散到不同函数中记录，增加了代码复杂性

使用专门设计的`log_classification_metrics`函数是记录和比较分类模型指标的最佳实践，尤其是在需要比较两个不同框架实现的模型时。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 11)

问题 101

题目

你正在为在线服装店开发一个应用程序，帮助用户进行餐饮规划。你想使用机器学习来扫描食谱语料库，提取每种提到的配料（例如胡萝卜、米饭、意大利面）和厨房烹饪器具（例如碗、锅、勺子）。每个食谱都保存在非结构化文本文件中。你应该怎么做？

You work for a company that is developing an application to help users with meal planning. You want to use machine learning to scan a corpus of recipes and extract each ingredient (e.g., carrot, rice, pasta) and each kitchen cookware (e.g., bowl, pot, spoon) mentioned. Each recipe is saved in an unstructured text file. What should you do?

选项

A. 在Vertex AI上创建用于实体提取的文本数据集。创建名为"ingredient"和"cookware"的两个实体，并标注每个实体至少200个示例。训练AutoML实体提取模型来提取这些实体类型的出现。在保留数据集上评估性能。

Create a text dataset on Vertex AI for entity extraction Create two entities called "ingredient" and "cookware", and label at least 200 examples of each entity. Train an AutoML entity extraction model to extract occurrences of these entity types. Evaluate performance on a holdout dataset.

B. 在Vertex AI上创建多标签文本分类数据集。创建测试数据集，并标记与其配料和烹饪器具对应的每个食谱。训练多类分类模型。在保留数据集上评估模型性能。

Create a multi-label text classification dataset on Vertex AI. Create a test dataset, and label each recipe that corresponds to its ingredients and cookware. Train a multi-class classification model. Evaluate the model's performance on a holdout dataset.

C. 使用Natural Language API的实体分析方法从每个食谱中提取配料和烹饪器具。在预标注数据集上评估模型性能。

Use the Entity Analysis method of the Natural Language API to extract the ingredients and cookware from each recipe. Evaluate the model's performance on a prelabeled dataset.

D. 在Vertex AI上创建用于实体提取的文本数据集。为每种不同的配料和烹饪器具创建尽可能多的实体。训练AutoML实体提取模型来提取这些实体。在保留数据集上评估模型性能。

Create a text dataset on Vertex AI for entity extraction. Create as many entities as there are different ingredients and cookware. Train an AutoML entity extraction model to extract those entities. Evaluate the model's performance on a holdout dataset.

正确答案：A. Create a text dataset on Vertex AI for entity extraction Create two entities called "ingredient" and "cookware", and label at least 200 examples of each entity. Train an AutoML entity extraction model to extract occurrences of these entity types. Evaluate performance on a holdout dataset.

解析： 这个问题涉及从非结构化食谱文本中提取特定实体（配料和烹饪器具）的最佳方法。

选项A是最佳解决方案，原因如下：

1. **正确的问题定义**：
    - 从文本中识别和提取特定实体是典型的命名实体识别(NER)任务
    - 实体提取是此类任务的专用解决方案
    - 创建两个一般性实体类别("ingredient"和"cookware")是最合理的方法

2. **标注效率和可扩展性**：
    - 只需要创建两个实体类别，标注工作量合理可控
    - 每类至少200个示例提供了足够的训练数据
    - 模型可以学习识别训练中未见过的新配料和烹饪器具
    - 泛化能力强，无需为每种可能的配料或工具创建单独的实体
3. **AutoML的适用性**：
    - AutoML实体提取专为此类任务设计
    - 无需深入的ML专业知识
    - 提供了平衡易用性和准确性的解决方案

相比之下，其他选项存在以下问题：

- 选项B将问题错误地定义为文本分类任务，这会给整个食谱分配标签，而不是提取其中提到的具体实体
- 选项C使用通用的Natural Language API，可能无法准确区分烹饪领域的特定实体，如配料和烹饪器具
- 选项D建议为每种不同的配料和器具创建单独的实体，这将导致数百甚至数千个实体类别，标注工作量巨大且不可扩展

使用两个通用实体类别的AutoML实体提取提供了最佳的平衡，既满足了技术要求，又保持了实施复杂性的合理水平。

问题 102

题目

你在开发一个模型，预测关键机器部件是否会发生故障。你有一个数据集，由多变量时间序列和指示机器部件是否失效的标签组成。你最近开始在Vertex AI Workbench笔记本中尝试几种不同的预处理和建模方法。你想记录每次运行的数据并跟踪工件。你应该如何设置实验？

You are developing a model to predict whether a failure will occur in a critical machine part. You have a dataset consisting of a multivariate time series and labels indicating whether the machine part failed. You recently started experimenting with a few different preprocessing and modeling approaches in a Vertex AI Workbench notebook. You want to log data and track artifacts from each run. How should you set up your experiments?

选项

A. 1. 使用Vertex AI SDK创建实验并设置Vertex ML Metadata。 2. 使用log_time_series_metrics函数跟踪预处理数据，使用log_merrics函数记录损失值。

1. Use the Vertex AI SDK to create an experiment and set up Vertex ML Metadata.
2. Use the log_time_series_metrics function to track the preprocessed data, and use the log_merrics function to log loss values.

B. 1. 使用Vertex AI SDK创建实验并设置Vertex ML Metadata。 2. 使用log_time_series_metrics函数跟踪预处理数据，使用log_metrics函数记录损失值。

1. Use the Vertex AI SDK to create an experiment and set up Vertex ML Metadata.

2. Use the log_time_series_metrics function to track the preprocessed data, and use the log_metrics function to log loss values.

C. 1. 创建Vertex AI TensorBoard实例，并使用Vertex AI SDK创建实验并关联TensorBoard实例。 2. 使用assign_input_artifact方法跟踪预处理数据，使用log_time_series_metrics函数记录损失值。

1. Create a Vertex AI TensorBoard instance and use the Vertex AI SDK to create an experiment and associate the TensorBoard instance.
2. Use the assign_input_artifact method to track the preprocessed data and use the log_time_series_metrics function to log loss values.

D. 1. 创建Vertex AI TensorBoard实例，并使用Vertex AI SDK创建实验并关联TensorBoard实例。 2. 使用log_time_series_metrics函数跟踪预处理数据，使用log_metrics函数记录损失值。

1. Create a Vertex AI TensorBoard instance, and use the Vertex AI SDK to create an experiment and associate the TensorBoard instance.
2. Use the log_time_series_metrics function to track the preprocessed data, and use the log_metrics function to log loss values.

正确答案：D. Create a Vertex AI TensorBoard instance, and use the Vertex AI SDK to create an experiment and associate the TensorBoard instance. Use the log_time_series_metrics function to track the preprocessed data, and use the log_metrics function to log loss values.

解析： 这个问题关注如何在Vertex AI中为机器故障预测模型设置实验跟踪。关键要素是处理多变量时间序列数据和跟踪各种实验运行的指标与工件。

选项D是最佳解决方案，原因如下：

1. **集成TensorBoard的优势**：
   - TensorBoard专为可视化和比较模型训练运行而设计
   - 特别适合时间序列数据的可视化和分析
   - 提供了丰富的绘图和比较功能
   - 与Vertex AI实验框架无缝集成
2. **适合时间序列数据的专用函数**：
   - `log_time_series_metrics`专为记录时间序列数据而设计
   - 能够有效捕获和展示预处理后的多变量时间序列
   - 可以帮助理解不同预处理方法对数据的影响
3. **通用指标记录的正确使用**：
   - `log_metrics`是记录标量指标(如损失值)的标准函数
   - 功能名称正确拼写，确保了正常功能
   - 适合记录训练和评估过程中的各种性能指标
4. **全面的实验跟踪**：
   - 这种设置提供了最完整的实验跟踪能力
   - 结合了专用时间序列跟踪和通用指标记录
   - 利用TensorBoard的可视化增强了分析能力

    - 便于比较不同预处理和建模方法的效果

相比之下，其他选项存在以下问题：

- 选项A中`log_merrics`函数名拼写错误，且没有利用TensorBoard的可视化能力
- 选项B也缺少TensorBoard集成，对于复杂的时间序列分析和比较能力有限
- 选项C使用了不常见的`assign_input_artifact`方法而非专用的时间序列记录函数

对于涉及时间序列数据的机器故障预测实验，TensorBoard集成和专用记录函数的组合提供了最全面且用户友好的实验跟踪解决方案。

问题 103

题目

你正在帮助你的公司创建更有针对性的在线广告活动。你需要创建一个数据集，用于训练模型。你希望避免在模型中创建或强化不公平偏见。你应该怎么做？（选择两项。）

You are developing a model to help your company create more targeted online advertising campaigns. You need to create a dataset that you will use to train the model. You want to avoid creating or reinforcing unfair bias in the model. What should you do? (Choose two.)

选项

A. 包含全面的人口统计学特征集

Include a comprehensive set of demographic features

B. 仅包括最常与广告交互的人口统计群体

Include only the demographic groups that most frequently interact with advertisements

C. 收集生产流量的随机样本来构建训练数据集

Collect a random sample of production traffic to build the training dataset

D. 收集生产流量的分层样本来构建训练数据集

Collect a stratified sample of production traffic to build the training dataset

E. A在训练模型上针对敏感类别和人口统计学进行公平性测试

Conduct fairness tests across sensitive categories and demographics on the trained model

正确答案：D. Collect a stratified sample of production traffic to build the training dataset E. Conduct fairness tests across sensitive categories and demographics on the trained model

解析： 这个问题关注如何避免在在线广告模型中创建或强化不公平偏见，需要选择两个最佳实践。

选项D和E是最佳组合，原因如下：

1. **选项D：收集分层样本**
    - 分层抽样确保所有相关人口统计群体在训练数据中有充分代表性

- 防止某些群体因在原始流量中比例较小而被忽视
- 提供了更平衡的数据集，使模型能学习服务于各种用户群体
- 这是一种前期预防偏见的积极方法

2. **选项E：进行公平性测试**

- 通过在敏感类别和人口统计学上进行公平性测试，可以直接评估模型中的偏见
- 识别模型可能偏向或不利于某些群体的情况
- 提供了客观的指标来衡量和监控公平性
- 作为后期验证步骤，确保前期预防措施的有效性

这两个选项组合提供了最全面的偏见防控策略：

- 选项D通过数据采集策略在源头预防偏见
- 选项E通过模型测试验证结果公平性
- 结合了预防性和检测性措施，形成完整解决方案

相比之下，其他选项存在以下问题：

- 选项A（包含全面的人口统计学特征集）可能使模型更容易学习和复制现有社会偏见
- 选项B（仅包括最常与广告交互的群体）明确地引入了选择偏差，会强化现有不平等
- 选项C（随机样本）虽然比选项B好，但如果原始数据就存在偏差，随机抽样会保留这些偏差

分层抽样（选项D）加上公平性测试（选项E）提供了最全面的防止模型偏见的策略。

问题 104

题目

你在Vertex AI Workbench笔记本中开发一个ML模型。你希望在使用不同方法进行实验时跟踪工件并比较模型。你需要在迭代模型实现时快速轻松地将成功的实验转化为生产环境。你应该怎么做？

You are developing an ML model in a Vertex AI Workbench notebook. You want to track artifacts and compare models during experimentation using different approaches. You need to rapidly and easily transition successful experiments to production as you iterate on your model implementation. What should you do?

选项

A. 1. 使用实验名称初始化Vertex SDK。记录每个实验的参数和指标，并将数据集和模型工件作为输入和输出附加到每次执行。 2. 在成功实验后创建Vertex AI流水线。

1. Initialize the Vertex SDK with the name of your experiment. Log parameters and metrics for each experiment, and attach dataset and model artifacts as inputs and outputs to each execution.
2. After a successful experiment create a Vertex AI pipeline.

B. 1. 使用实验名称初始化Vertex SDK。记录每个实验的参数和指标，将数据集保存到Cloud Storage桶，并将模型上传到Vertex AI Model Registry。 2. 在成功实验后创建Vertex AI流水线。

1. Initialize the Vertex SDK with the name of your experiment. Log parameters and metrics for each experiment, save your dataset to a Cloud Storage bucket, and upload the models to Vertex AI Model Registry.

2. After a successful experiment, create a Vertex AI pipeline.

C. 1. 创建一个Vertex AI流水线，将你想要跟踪的参数作为PipelineJob的参数。使用Kubeflow Pipelines DSL中的Metrics、Model和Dataset工件类型作为流水线中组件的输入和输出。 2. 提交作业时将流水线与你的实验关联。

1. Create a Vertex AI pipeline with parameters you want to track as arguments to your PipelineJob. Use the Metrics, Model, and Dataset artifact types from the Kubeflow Pipelines DSL as the inputs and outputs of the components in your pipeline.
2. Associate the pipeline with your experiment when you submit the job.

D. 1. 创建一个Vertex AI流水线。使用Kubeflow Pipelines DSL中的Dataset和Model工件类型作为流水线中组件的输入和输出。 2. 在你的训练组件中，使用Vertex AI SDK创建实验运行。配置log_params和log_metrics函数来跟踪实验的参数和指标。

1. Create a Vertex AI pipeline. Use the Dataset and Model artifact types from the Kubeflow Pipelines DSL as the inputs and outputs of the components in your pipeline.
2. In your training component, use the Vertex AI SDK to create an experiment run. Configure the log_params and log_metrics functions to track parameters and metrics of your experiment.

正确答案：A. Initialize the Vertex SDK with the name of your experiment. Log parameters and metrics for each experiment, and attach dataset and model artifacts as inputs and outputs to each execution. After a successful experiment create a Vertex AI pipeline.

解析： 这个问题关注如何在Vertex AI Workbench笔记本中有效管理ML实验，并便于将成功的实验快速转化为生产环境。

选项A是最佳解决方案，原因如下：

1. **直接且自动化的工件管理**：
    - 通过"attach dataset and model artifacts as inputs and outputs"语句，Vertex SDK会自动追踪和管理工件
    - 无需手动指定存储位置或编写额外代码
    - 保持了工件与实验的直接关联
    - 简化了实验迭代过程中的工件管理
2. **简化的工作流程**：
    - 所有操作都在Vertex SDK初始化的实验上下文中完成
    - 无需切换到不同服务或手动管理存储位置
    - 适合在笔记本环境中快速迭代的工作方式
    - 更符合数据科学家的工作习惯
3. **快速实验迭代**：
    - 减少了手动步骤，加快了实验周期
    - 工件自动附加到实验执行，便于回顾和比较
    - 实验、参数、指标和工件保持在统一上下文中
    - 支持"快速轻松地转化为生产环境"的要求

4. **自然过渡到生产**：
    - 成功实验后，可以直接基于已跟踪的工件和参数创建流水线
    - 无需重新组织或迁移实验资产
    - 保持了从实验到生产的一致性

相比之下，其他选项存在以下问题：

- 选项B需要手动管理工件存储，增加了不必要的操作步骤
- 选项C和D从流水线开始而非笔记本实验，不符合题目描述的工作流程
- 这些方法都增加了实验过程中的复杂性，不利于快速迭代开发

选项A通过Vertex SDK的自动化工件管理和简化的工作流程，最好地支持了实验迭代和向生产环境的快速过渡。

问题 105

题目

你在一家运营流媒体音乐服务的组织工作。你有一个基于用户最近收听历史推荐"下一首歌曲"的生产模型。你的模型部署在Vertex AI端点上。你最近使用新数据重新训练了相同的模型。该模型在离线测试中获得了积极的结果。你现在想在生产环境中测试新模型，同时最小化复杂性。你应该怎么做？

You work for an organization that operates a streaming music service. You have a custom production model that is serving a "next song" recommendation based on a user's recent listening history. Your model is deployed on a Vertex AI endpoint. You recently retrained the same model by using fresh data. The model received positive test results offline. You now want to test the new model in production while minimizing complexity. What should you do?

选项

A. 为新模型创建一个新的Vertex AI端点，并将新模型部署到该新端点。构建一个服务，随机将5%的生产流量发送到新端点。监控最终用户指标，如收听时间。如果随着时间推移，模型间的最终用户指标有所改善，则逐步增加发送到新端点的生产流量百分比。

Create a new Vertex AI endpoint for the new model and deploy the new model to that new endpoint. Build a service to randomly send 5% of production traffic to the new endpoint. Monitor end-user metrics such as listening time. If end-user metrics improve between models over time, gradually increase the percentage of production traffic sent to the new endpoint.

B. 在BigQuery中捕获传入的预测请求。在Vertex AI Experiments中创建实验。使用捕获的数据为两个模型运行批量预测。使用用户选择的歌曲来并排比较模型性能。如果新模型的性能指标优于先前的模型，则将新模型部署到生产环境。

Capture incoming prediction requests in BigQuery. Create an experiment in Vertex AI Experiments. Run batch predictions for both models using the captured data. Use the user's selected song to compare the models performance side by side. If the new model's performance metrics are better than the previous model, deploy the new model to production.

C. 将新模型部署到现有的Vertex AI端点。使用流量分割，向新模型发送5%的生产流量。监控最终用户指标，如收听时间。如果随着时间推移，模型间的最终用户指标有所改善，则逐步增加发送到新模型的生产流量百分

比。

Deploy the new model to the existing Vertex AI endpoint. Use traffic splitting to send 5% of production traffic to the new model. Monitor end-user metrics, such as listening time. If end-user metrics improve between models over time, gradually increase the percentage of production traffic sent to the new model.

D. 为现有的Vertex AI端点配置模型监控作业。配置监控作业以检测预测漂移，并设置警报阈值。将端点上的模型从先前模型更新为新模型。如果你收到预测漂移警报，则恢复到先前的模型。

Configure a model monitoring job for the existing Vertex AI endpoint. Configure the monitoring job to detect prediction drift and set a threshold for alerts. Update the model on the endpoint from the previous model to the new model. If you receive an alert of prediction drift, revert to the previous model.

正确答案：C. Deploy the new model to the existing Vertex AI endpoint. Use traffic splitting to send 5% of production traffic to the new model. Monitor end-user metrics, such as listening time. If end-user metrics improve between models over time, gradually increase the percentage of production traffic sent to the new model.

解析： 这个问题关注如何在生产环境中测试新训练的推荐模型，并且要求"最小化复杂性"。

选项C是最佳解决方案，原因如下：

1. **利用现有基础设施**：
    - 在现有端点上部署新模型，而不是创建新端点
    - 避免了设置和管理多个端点的复杂性
    - 保持了简单的部署架构
    - 利用了Vertex AI端点内置的功能
2. **内置流量分割能力**：
    - Vertex AI端点提供原生的流量分割功能
    - 无需开发额外的路由服务或逻辑
    - 提供稳定可靠的流量管理
    - 这是最小化复杂性的关键因素
3. **渐进式部署策略**：
    - 从5%小流量开始，降低风险
    - 基于真实用户指标（如收听时间）进行决策
    - 随着性能验证逐步增加流量
    - 提供安全可控的模型过渡
4. **真实世界性能评估**：
    - 在实际生产环境中测试模型
    - 收集真实用户反馈和行为数据
    - 比离线测试更准确地反映模型效果
    - 确保模型在真实场景中表现良好

相比之下，其他选项存在以下问题：

- 选项A需要创建和管理新的端点，并构建自定义路由服务，增加了不必要的复杂性
- 选项B依赖离线批量测试而非实时生产测试，无法捕获真实用户交互，且引入了额外的数据捕获和存储步骤
- 选项D完全替换模型而不进行A/B测试，风险较高，依赖事后监测而非主动验证

选项C通过使用端点内置的流量分割功能，提供了最简单且最有效的方式在生产环境中测试新模型，同时保持了安全性和可靠性。

问题 106

题目

你创建了一个使用BigQuery ML执行线性回归的模型。你需要在每周收集的累积数据上重新训练模型。你希望最小化开发工作量和调度成本。你应该怎么做？

You created a model that uses BigQuery ML to perform linear regression. You need to retrain the model on the cumulative data collected every week. You want to minimize the development effort and the scheduling cost. What should you do?

选项

A. 使用BigQuery的调度服务定期运行模型重训练查询。

Use BigQuery's scheduling service to run the model retraining query periodically.

B. 在Vertex AI Pipelines中创建一个执行重训练查询的流水线，并使用Cloud Scheduler API每周运行查询。

Create a pipeline in Vertex AI Pipelines that executes the retraining query, and use the Cloud Scheduler API to run the query weekly.

C. 使用Cloud Scheduler触发每周运行查询以重新训练模型的Cloud Function。

Use Cloud Scheduler to trigger a Cloud Function every week that runs the query for retraining the model.

D. 使用BigQuery API连接器和Cloud Scheduler触发Workflows每周重新训练模型。

Use the BigQuery API Connector and Cloud Scheduler to trigger Workflows every week that retrains the model.

正确答案：A. Use BigQuery's scheduling service to run the model retraining query periodically.

解析： 这个问题关注如何以最小的开发工作量和调度成本定期重新训练BigQuery ML模型。

选项A是最佳解决方案，原因如下：

1. **最简化的方法**：
    - BigQuery内置了查询调度功能
    - 不需要额外的服务或组件
    - 设置简单直接，几分钟内完成
    - 无需编写自定义代码
2. **最低的开发工作量**：

    - 使用与创建模型相同的环境进行重训练
    - 利用现有的BigQuery ML模型和查询
    - 仅需设置重复执行的时间表
    - 不需要集成外部服务或工具

3. **成本效益最高**：

    - 不需要额外的调度服务费用
    - 避免了运行和维护单独服务的开销
    - 只需支付查询执行的费用
    - 复用已有的BigQuery基础设施

4. **最少的维护工作**：

    - 一次设置，持续运行
    - 无需维护外部依赖
    - 同一系统中管理模型和调度
    - 减少潜在的故障点

相比之下，其他选项引入了不必要的复杂性：

- 选项B需要设置和维护Vertex AI流水线，增加了设置和维护开销
- 选项C需要创建和维护Cloud Function，增加了开发工作量和潜在故障点
- 选项D引入了最多的组件(BigQuery API连接器、Cloud Scheduler、Workflows)，增加了集成复杂性和维护负担

当模型已经在BigQuery ML中并且需要定期重训练时，BigQuery的内置调度服务提供了最简单、最直接的解决方案，完美符合"最小化开发工作量和调度成本"的要求。

问题 107

题目

你正在构建一个ML模型来检测实时传感器数据中的异常。你将使用Pub/Sub处理传入请求。你希望存储结果以用于分析和可视化。你应该如何配置管道？

You are building an ML model to detect anomalies in real-time sensor data. You will use Pub/Sub to handle incoming requests. You want to store the results for analytics and visualization. How should you configure the pipeline?

选项

A. 1 = Dataflow, 2 = AI Platform, 3 = BigQuery

B. 1 = DataProc, 2 = AutoML, 3 = Cloud Bigtable

C. 1 = BigQuery, 2 = AutoML, 3 = Cloud Functions

D. 1 = BigQuery, 2 = AI Platform, 3 = Cloud Storage

正确答案：A. 1 = Dataflow, 2 = AI Platform, 3 = BigQuery

解析： 这个问题关注如何构建一个实时异常检测管道，处理传感器数据并存储结果以便分析和可视化。

选项A是最佳解决方案，原因如下：

1. **Dataflow作为流处理组件**：
    - Dataflow是Google Cloud上专为流处理设计的服务
    - 可以无缝地从Pub/Sub接收消息并进行实时处理
    - 提供低延迟处理能力，适合实时异常检测
    - 具有内置的窗口、水印和其他流处理功能
2. **AI Platform (现Vertex AI)作为模型服务组件**：
    - 适合部署和托管异常检测ML模型
    - 提供可扩展的预测服务
    - 支持各种自定义异常检测算法
    - 可以集成到Dataflow流水线中进行实时预测
3. **BigQuery作为存储和分析组件**：
    - 专为分析工作负载设计的数据仓库
    - 提供强大的SQL查询功能
    - 支持与各种BI和可视化工具的集成
    - 适合存储异常检测结果以便后续分析和可视化

这三个组件组合形成了一个端到端的管道：

- Dataflow从Pub/Sub接收实时传感器数据并进行预处理
- 处理后的数据发送到AI Platform进行异常检测
- 检测结果存储在BigQuery中用于分析和可视化

相比之下，其他选项存在以下问题：

- 选项B中的DataProc主要用于批处理而非实时流处理；Bigtable虽适合时序数据存储但不如BigQuery便于分析
- 选项C和D中的BigQuery不适合作为实时流处理的初始组件
- 选项C中的Cloud Functions不适合作为分析结果的存储解决方案

选项A提供了处理实时传感器数据、执行异常检测并存储结果以便分析的最佳管道配置。

问题 108

题目

你在一家大型连锁酒店工作，被要求协助营销团队收集预测数据用于有针对性的营销策略。你需要预测用户在未来20天的终身价值(LTV)，以便相应地调整营销活动。客户数据集在BigQuery中，你正在准备表格数据以使用AutoML Tables进行训练。这些数据有一个分布在多个列中的时间信号。你应该如何确保AutoML为你的数据拟合最佳模型？

You work for a large hotel chain and have been asked to assist the marketing team in gathering predictions for a targeted marketing strategy. You need to make predictions about user lifetime value (LTV) over the next 20 days so that marketing can be adjusted accordingly. The customer dataset is in BigQuery, and you are

preparing the tabular data for training with AutoML Tables. This data has a time signal that is spread across multiple columns. How should you ensure that AutoML fits the best model to your data?

选项

A. 手动将所有包含时间信号的列组合成一个数组。允许AutoML适当地解释这个数组。选择训练、验证和测试集的自动数据分割。

Manually combine all columns that contain a time signal into an array. Allow AutoML to interpret this array appropriately. Choose an automatic data split across the training, validation, and testing sets.

B. 提交数据进行训练而不执行任何手动转换。允许AutoML处理适当的转换。选择训练、验证和测试集的自动数据分割。

Submit the data for training without performing any manual transformations. Allow AutoML to handle the appropriate transformations. Choose an automatic data split across the training, validation, and testing sets.

C. 提交数据进行训练而不执行任何手动转换，并指示适当的列作为时间列。允许AutoML根据提供的时间信号拆分你的数据，并保留较新的数据用于验证和测试集。

Submit the data for training without performing any manual transformations, and indicate an appropriate column as the Time column. Allow AutoML to split your data based on the time signal provided, and reserve the more recent data for the validation and testing sets.

D. 提交数据进行训练而不执行任何手动转换。使用具有时间信号的列手动拆分你的数据。确保验证集中的数据来自训练集数据之后30天，测试集中的数据来自验证集之后30天。

Submit the data for training without performing any manual transformations. Use the columns that have a time signal to manually split your data. Ensure that the data in your validation set is from 30 days after the data in your training set and that the data in your testing sets from 30 days after your validation set.

正确答案：C. Submit the data for training without performing any manual transformations, and indicate an appropriate column as the Time column. Allow AutoML to split your data based on the time signal provided, and reserve the more recent data for the validation and testing sets.

解析： 对于预测任务，尤其是涉及未来预测(如未来20天的LTV)，时间顺序至关重要。指定时间列允许AutoML依时间顺序分割数据，而不是随机分割，确保模型训练的方式与实际应用方式一致：使用历史数据预测未来。

保留最新数据作为验证和测试集确保了评估能够反映模型对未来数据的预测能力，模拟了模型在生产环境中的实际使用情况。

AutoML Tables有专门处理时间序列数据的功能，但需要正确指示时间列。这种方法避免了可能引入错误或偏差的手动数据准备步骤。

问题 109

题目

你为一个需要自定义库的Kubeflow Pipeline编写了单元测试。你希望在每次向Cloud Source Repositories的开发分支推送新代码时自动执行单元测试。你应该怎么做？

You have written unit tests for a Kubeflow Pipeline that require custom libraries. You want to automate the execution of unit tests with each new push to your development branch in Cloud Source Repositories. What should you do?

选项

A. 编写一个脚本，依次执行推送到开发分支并在Cloud Run上执行单元测试。

Write a script that sequentially performs the push to your development branch and executes the unit tests on Cloud Run.

B. 使用Cloud Build，设置自动触发器在代码变更推送到开发分支时执行单元测试。

Using Cloud Build, set an automated trigger to execute the unit tests when changes are pushed to your development branch.

C. 设置一个Cloud Logging接收器到Pub/Sub主题，捕获与Cloud Source Repositories的交互。配置Cloud Run的Pub/Sub触发器，并在Cloud Run上执行单元测试。

Set up a Cloud Logging sink to a Pub/Sub topic that captures interactions with Cloud Source Repositories. Configure a Pub/Sub trigger for Cloud Run, and execute the unit tests on Cloud Run.

D. 设置一个Cloud Logging接收器到Pub/Sub主题，捕获与Cloud Source Repositories的交互。使用在消息发送到Pub/Sub主题时触发的Cloud Function执行单元测试。

Set up a Cloud Logging sink to a Pub/Sub topic that captures interactions with Cloud Source Repositories. Execute the unit tests using a Cloud Function that is triggered when messages are sent to the Pub/Sub topic.

正确答案：B. Using Cloud Build, set an automated trigger to execute the unit tests when changes are pushed to your development branch.

解析： Cloud Build是为CI/CD场景专门设计的服务，它原生集成了Cloud Source Repositories，可以直接监听代码仓库的特定分支变更。这是一个直接的集成，无需额外的中间组件或复杂配置。

Cloud Build支持自定义构建步骤，可以轻松安装所需的自定义库，可以通过buildspec文件(cloudbuild.yaml)定义所有必要的依赖和测试命令，还支持使用自定义容器镜像，确保测试环境一致性。

这是Google Cloud推荐的标准CI/CD方法，设置简单，维护成本低，提供完整的执行历史和日志记录。

其他选项都引入了不必要的复杂架构，如手动步骤、Cloud Logging、Pub/Sub等多个组件，增加了维护负担和潜在的故障点。

问题 110

题目

你正在AI Platform上训练一个基于LSTM的模型来总结文本，使用以下作业提交脚本：

```
gcloud ai-platform jobs submit training $JOB_NAME \
--package-path $TRAINER_PACKAGE_PATH \
--module-name $MAIN_TRAINER_MODULE \
--job-dir $JOB_DIR \
```

```
--region $REGION \
--scale-tier basic \
-- \
--epochs 20 \
--batch_size=32 \
--learning_rate=0.001 \
```

你希望确保在不显著影响模型精度的情况下最小化训练时间。你应该怎么做？

You are training an LSTM-based model on AI Platform to summarize text using the following job submission script:

```
gcloud ai-platform jobs submit training $JOB_NAME \
--package-path $TRAINER_PACKAGE_PATH \
--module-name $MAIN_TRAINER_MODULE \
--job-dir $JOB_DIR \
--region $REGION \
--scale-tier basic \
-- \
--epochs 20 \
--batch_size=32 \
--learning_rate=0.001 \
```

You want to ensure that training time is minimized without significantly compromising the accuracy of your model. What should you do?

选项

A. 修改'epochs'参数。

Modify the 'epochs' parameter.

B. 修改'scale-tier'参数。

Modify the 'scale-tier' parameter.

C. 修改'batch size'参数。

Modify the 'batch size' parameter.

D. 修改'learning rate'参数。

Modify the 'learning rate' parameter.

正确答案：B. Modify the 'scale-tier' parameter.

解析： 'scale-tier'参数决定了用于训练的硬件配置。当前设置为'basic'，这是一个基本配置，通常只有CPU资源。升级到更高级别的tier（如BASIC_GPU、STANDARD_1等）会提供更强大的计算资源，对于LSTM这类序列模型，GPU加速可以显著减少训练时间。

更改计算资源不会改变模型的算法、参数或训练过程，训练结果在数学上是相同的，只是计算速度更快，这满足了"不显著影响模型精度"的要求。

其他参数修改可能会影响模型收敛和精度：减少epochs会减少训练时间但可能影响模型性能；增加batch_size可能提高硬件利用率但过大的批量可能降低模型精度；修改learning_rate可能加速收敛但风险高，容易导致模型不稳定。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 12)

问题 111

题目

你在一家大型连锁酒店工作，被要求协助营销团队收集预测数据用于有针对性的营销策略。你需要预测用户在未来20天的终身价值(LTV)，以便相应地调整营销活动。客户数据集在BigQuery中，你正在准备表格数据以使用AutoML Tables进行训练。这些数据有一个分布在多个列中的时间信号。你应该如何确保AutoML为你的数据拟合最佳模型？

You work for a large hotel chain and have been asked to assist the marketing team in gathering predictions for a targeted marketing strategy. You need to make predictions about user lifetime value (LTV) over the next 20 days so that marketing can be adjusted accordingly. The customer dataset is in BigQuery, and you are preparing the tabular data for training with AutoML Tables. This data has a time signal that is spread across multiple columns. How should you ensure that AutoML fits the best model to your data?

选项

A. 手动将所有包含时间信号的列组合成一个数组。允许AutoML适当地解释这个数组。选择训练、验证和测试集的自动数据分割。

Manually combine all columns that contain a time signal into an array. Allow AutoML to interpret this array appropriately. Choose an automatic data split across the training, validation, and testing sets.

B. 提交数据进行训练而不执行任何手动转换。允许AutoML处理适当的转换。选择训练、验证和测试集的自动数据分割。

Submit the data for training without performing any manual transformations. Allow AutoML to handle the appropriate transformations. Choose an automatic data split across the training, validation, and testing sets.

C. 提交数据进行训练而不执行任何手动转换，并指示适当的列作为时间列。允许AutoML根据提供的时间信号拆分你的数据，并保留较新的数据用于验证和测试集。

Submit the data for training without performing any manual transformations, and indicate an appropriate column as the Time column. Allow AutoML to split your data based on the time signal provided, and reserve the more recent data for the validation and testing sets.

D. 提交数据进行训练而不执行任何手动转换。使用具有时间信号的列手动拆分你的数据。确保验证集中的数据来自训练集数据之后30天，测试集中的数据来自验证集之后30天。

Submit the data for training without performing any manual transformations. Use the columns that have a time signal to manually split your data. Ensure that the data in your validation set is from 30 days after the data in your training set and that the data in your testing sets from 30 days after your validation set.

正确答案：C. Submit the data for training without performing any manual transformations, and indicate an appropriate column as the Time column. Allow AutoML to split your data based on the time signal provided, and reserve the more recent data for the validation and testing sets.

解析： 对于预测任务，尤其是涉及未来预测(如未来20天的LTV)，时间顺序至关重要。指定时间列允许AutoML依时间顺序分割数据，而不是随机分割，确保模型训练的方式与实际应用方式一致：使用历史数据预测未来。

保留最新数据作为验证和测试集确保了评估能够反映模型对未来数据的预测能力，模拟了模型在生产环境中的实际使用情况。

AutoML Tables有专门处理时间序列数据的功能，但需要正确指示时间列。这种方法避免了可能引入错误或偏差的手动数据准备步骤。

问题 112

题目

你在AI Platform上部署了多个版本的图像分类模型。你想随着时间推移监控这些模型版本的性能。你应该如何执行这种比较？

You have deployed multiple versions of an image classification model on AI Platform. You want to monitor the performance of the model versions over time. How should you perform this comparison?

选项

A. 在保留数据集上比较每个模型的损失性能。

Compare the loss performance for each model on a held-out dataset.

B. 在验证数据上比较每个模型的损失性能。

Compare the loss performance for each model on the validation data.

C. 使用What-If Tool比较每个模型的接收者操作特征(ROC)曲线。

Compare the receiver operating characteristic (ROC) curve for each model using the What-If Tool.

D. 使用持续评估功能比较模型间的平均精度均值。

Compare the mean average precision across the models using the Continuous Evaluation feature.

正确答案：D. Compare the mean average precision across the models using the Continuous Evaluation feature.

解析： 这个问题涉及AI Platform上模型性能的长期监控策略。关键点是"随着时间推移"监控多个模型版本。

持续评估功能(Continuous Evaluation)是AI Platform的专用功能，专门设计用于持续监控部署模型的性能。它自动收集模型性能随时间变化的数据，提供可视化和报告工具，便于跟踪性能趋势，是唯一一个明确解决"随时间"监控要求的选项。

平均精度均值(Mean Average Precision)是图像分类任务的标准评估指标，对类别不平衡问题具有鲁棒性，可以全面评估模型的整体性能，适合比较不同模型版本的性能差异。

其他选项存在以下问题：

- 选项A和B提到的损失性能比较是一次性评估操作，没有持续监控的机制
- 选项A的"held-out dataset"适合进行最终测试，而非持续监控
- 选项B的验证数据通常用于模型开发阶段，而非生产监控
- 选项C中的What-If Tool主要用于模型可解释性和公平性分析，不是为长期性能监控设计的

在AI Platform上监控已部署模型时，持续评估功能提供了专门的基础设施来跟踪模型性能随时间的变化，自动生成报告和警报，这正是题目所要求的功能。

问题 113

题目

你训练了一个文本分类模型。你有以下SignatureDefs：

```
signature_def['serving_default']:
  The given SavedModel SignatureDef contains the following input(s):
    inputs['text'] tensor_info:
        dtype: DT_STRING
        shape: (-1, 2)
        name: serving_default_text: 0
  The given SavedModel SignatureDef contains the following output(s):
    outputs ['Softmax'] tensor_info:
        dtype: DT_FLOAT
        shape: (-1, 2)
        name: StatefulPartitionedCall:0
  Method name is: tensorflow/serving/predict
```

你启动了一个TensorFlow-serving组件服务器，并尝试使用以下方式发送HTTP请求获取预测：headers = {"content-type": "application/json"} json_response = requests.post('http://localhost:8501/v1/models/text_model:predict', data=data, headers=headers) 正确的预测请求写法是什么？

You trained a text classification model. You have the following SignatureDefs:

```
signature_def['serving_default']:
  The given SavedModel SignatureDef contains the following input(s):
    inputs['text'] tensor_info:
        dtype: DT_STRING
        shape: (-1, 2)
        name: serving_default_text: 0
  The given SavedModel SignatureDef contains the following output(s):
    outputs ['Softmax'] tensor_info:
        dtype: DT_FLOAT
        shape: (-1, 2)
```

```
          name: StatefulPartitionedCall:0
    Method name is: tensorflow/serving/predict
```

You started a TensorFlow-serving component server and tried to send an HTTP request to get a prediction using: headers = {"content-type": "application/json"} json_response = requests.post('http://localhost:8501/v1/models/text_model:predict', data=data, headers=headers) What is the correct way to write the predict request?

选项

A. data = json.dumps({"signature_name" :"seving_default" ,"instances":[['ab', 'bc', 'cd']]})

B. data = json.dumps({"signature_name" :"serving_default" ,"instances":[['a', 'b', 'c', 'd', 'e', 'f']]})

C. data = json.dumps({"signature_name" :"serving_default" ,"instances":[['a', 'b', 'c'], ['d', 'e', 'f']]})

D. data = json.dumps({"signature_name" :"serving_default" ,"instances":[['a', 'b'], ['c', 'd'], ['e', 'f']]})

正确答案：D. data = json.dumps({"signature_name" :"serving_default" ,"instances":[['a', 'b'], ['c', 'd'], ['e', 'f']]})

解析： 这个问题涉及如何正确地向TensorFlow Serving发送预测请求。在使用REST API向TensorFlow Serving模型发送请求时，有几个关键点需要注意：

1. **正确的signature_name**：
    - 必须使用SavedModel中定义的签名名称
    - "serving_default"是SavedModel的标准默认签名名称
    - 选项A中的"seving_default"存在拼写错误，缺少了"r"
2. **正确的实例格式**：
    - SignatureDef显示输入的形状是`shape: (-1, 2)`
    - 这表明模型期望每个实例是一个长度为2的数组
    - 选项D提供了3个实例，每个实例正好是长度为2的数组，符合模型期望的输入形状
3. **JSON格式的请求体**：
    - 使用json.dumps()确保数据被正确序列化为JSON字符串
    - "instances"字段是TensorFlow Serving REST API的标准字段

选项D正确匹配了SignatureDef中指定的输入形状要求。选项B将所有数据放在一个长度为6的数组中，不符合形状要求；选项C提供了2个实例，每个长度为3，也不符合要求。理解并按照SignatureDef中定义的输入规范构造请求对于成功调用TensorFlow Serving模型至关重要。

在TensorFlow Serving中使用REST API时，正确理解模型的输入要求并正确格式化请求参数至关重要。

问题 114

题目

你所在组织的呼叫中心要求你开发一个分析每个电话中客户情绪的模型。呼叫中心每天接收超过一百万个电话，数据存储在Cloud Storage中。收集的数据不得离开呼叫发起的区域，并且不得存储或分析个人身份信息

(PII)。数据科学团队有一个用于可视化和访问的第三方工具，该工具需要SQL ANSI-2011兼容接口。你需要选择数据处理和分析的组件。数据管道应该如何设计？（管道图）

Your organization's call center has asked you to develop a model that analyzes customer sentiments in each call. The call center receives over one million calls daily, and data is stored in Cloud Storage. The data collected must not leave the region in which the call originated, and no Personally Identifiable Information (PII) can be stored or analyzed. The data science team has a third-party tool for visualization and access which requires a SQL ANSI-2011 compliant interface. You need to select components for data processing and for analytics. How should the data pipeline be designed? (Diagram of Pipeline)

选项

A. 1= Dataflow, 2= BigQuery

B. 1 = Pub/Sub, 2= Datastore

C. 1 = Dataflow, 2 = Cloud SQL

D. 1 = Cloud Function, 2= Cloud SQL

正确答案：A. 1= Dataflow, 2= BigQuery

解析： 这个问题涉及设计一个适合高容量呼叫中心数据处理和分析的数据管道，同时满足数据驻留、隐私和技术兼容性要求。

选项A是最佳解决方案，原因如下：

1. **Dataflow作为数据处理组件**：
    - Dataflow是一个完全托管的流和批处理服务，非常适合处理大规模数据（每天超过一百万个电话）
    - 它提供了强大的数据转换能力，可以进行复杂的处理操作（如删除PII）
    - Dataflow支持区域性处理，能够确保数据不离开其来源区域，满足数据驻留要求
    - 它可以无缝地与其他Google Cloud服务集成，特别是Cloud Storage和BigQuery
2. **BigQuery作为分析组件**：
    - BigQuery提供ANSI SQL 2011兼容的接口，满足第三方可视化工具的要求
    - 作为无服务器数据仓库，它能够处理大量的呼叫数据进行分析
    - 它具有强大的安全控制功能，可以确保数据隐私
    - BigQuery支持地理位置策略，帮助满足数据驻留要求

其他选项存在以下问题：

- 选项B中的Pub/Sub适合事件摄取，但不具备Dataflow的强大数据处理能力；Datastore是NoSQL数据库，不提供SQL接口
- 选项C和D中的Cloud SQL可能难以处理这种规模的分析数据，且扩展性不如BigQuery
- 选项D中的Cloud Functions适合较小规模的处理，可能无法高效处理每天一百万个呼叫的数据量

Dataflow和BigQuery的组合是Google Cloud上数据分析管道的标准模式，特别适合需要大规模数据处理、强大分析能力和合规性的场景。

问题 115

题目

你是一家全球鞋店的ML工程师。你负责管理公司网站的ML模型。你被要求构建一个模型，根据用户的购买行为和与其他用户的相似性向用户推荐新产品。你应该怎么做？

You are an ML engineer at a global shoe store. You manage the ML models for the company's website. You are asked to build a model that will recommend new products to the user based on their purchase behavior and similarity with other users. What should you do?

选项

A. 构建一个分类模型

Build a classification model

B. 构建一个基于知识的过滤模型

Build a knowledge-based filtering model

C. 构建一个基于协同过滤的模型

Build a collaborative-based filtering model

D. 构建一个使用特征作为预测因子的回归模型

Build a regression model using the features as predictors

正确答案：C. Build a collaborative-based filtering model

解析： 这个问题关注推荐系统的最佳实践，特别是在零售电子商务环境中。

选项C是最佳解决方案，原因如下：

1. **协同过滤的适用性**：
    - 协同过滤是推荐系统的一种核心方法，特别适合根据用户行为相似性进行推荐
    - 它分析用户之间的行为模式，找到具有相似购买历史的用户群组
    - 这正好满足题目中"基于购买行为和与其他用户的相似性"的要求
2. **协同过滤的工作原理**：
    - 它基于"喜欢相似产品的用户可能也会喜欢其他共同产品"的原则
    - 系统可以识别用户之间的相似性并推荐一个用户喜欢但另一个相似用户尚未购买的产品
    - 这种方法不需要产品的详细特征信息，完全依赖用户行为数据
3. **在电子商务中的应用**：
    - 协同过滤已成为电子商务推荐系统的行业标准
    - 对于如鞋店这样有大量用户和产品的场景尤其有效
    - 可以无缝扩展到大量产品目录和用户群体

其他选项存在以下问题：

- 选项A（分类模型）通常用于将物品或用户分类到预定义的类别，而不是基于相似性生成推荐
- 选项B（基于知识的过滤）主要依赖产品特征和明确的规则，没有利用用户之间的相似性
- 选项D（回归模型）适合预测连续值（如可能的购买金额），而不是生成产品推荐

协同过滤是处理"购买行为和与其他用户的相似性"这一要求的最理想方法，因为它的核心原则正是基于用户之间的相似性模式。

问题 116

题目

你在一家社交媒体公司工作。你需要检测发布的图像是否包含汽车。每个训练示例只属于一个类别。你已经训练了一个物体检测神经网络并将模型版本部署到AI Platform Prediction进行评估。在部署前，你创建了一个评估作业并将其附加到AI Platform Prediction模型版本。你注意到精度低于业务要求允许的水平。你应该如何调整模型最终层的softmax阈值以提高精度？

You work for a social media company. You need to detect whether posted images contain cars. Each training example is a member of exactly one class. You have trained an object detection neural network and deployed the model version to AI Platform Prediction for evaluation. Before deployment, you created an evaluation job and attached it to the AI Platform Prediction model version. You notice that the precision is lower than your business requirements allow. How should you adjust the model's final layer softmax threshold to increase precision?

选项

A. 提高召回率。

Increase the recall.

B. 降低召回率。

Decrease the recall.

C. 增加假阳性的数量。

Increase the number of false positives.

D. 减少假阴性的数量。

Decrease the number of false negatives.

正确答案：B. Decrease the recall.

解析： 这个问题涉及分类模型中精度和召回率之间的权衡，以及如何通过调整决策阈值来优化这些指标。

在分类任务中：

- 精度(Precision) = 真阳性/(真阳性+假阳性) - 衡量的是在所有被预测为阳性的样本中有多少是真正阳性的
- 召回率(Recall) = 真阳性/(真阳性+假阴性) - 衡量的是在所有实际为阳性的样本中有多少被正确预测为阳性的

选项B是正确答案，原因如下：

1. **阈值调整的效果**：
    - 增加softmax阈值（要求更高的置信度才能分类为"包含汽车"）会减少假阳性
    - 这会提高精度，因为我们减少了错误地将不包含汽车的图像归类为包含汽车的情况
    - 然而，这种调整通常会导致模型变得更"保守"，因此会减少召回率
2. **精度-召回率的权衡**：
    - 在大多数分类问题中，精度和召回率之间存在固有的权衡关系
    - 提高一个指标通常会导致另一个指标下降
    - 题目明确要求提高精度，因此我们必须接受召回率的降低
3. **业务角度的考虑**：
    - 在需要高精度的场景中（如不想错误地将无汽车图片标记为有汽车），降低召回率是可接受的代价
    - 这意味着我们可能会漏掉一些实际包含汽车的图片，但我们标记的那些会有更高的准确性

其他选项存在问题：

- 选项A（提高召回率）通常会降低精度，与题目要求相反
- 选项C（增加假阳性）直接降低精度，完全违背了目标
- 选项D（减少假阴性）等同于提高召回率，通常会导致更多假阳性，从而降低精度

理解这些评估指标及其相互关系对于调整和优化机器学习模型至关重要。

问题 117

题目

你负责在各种本地数据集市中构建统一的分析环境。由于使用了大量不连贯的工具和临时解决方案，你的公司在跨服务器集成数据时遇到了数据质量和安全性挑战。你需要一个完全托管的云原生数据集成服务，以降低总工作成本并减少重复工作。你团队中的一些成员更喜欢使用无代码界面来构建提取、转换、加载(ETL)流程。你应该使用哪种服务？

You are responsible for building a unified analytics environment across a variety of on-premises data marts. Your company is experiencing data quality and security challenges when integrating data across the servers, caused by the use of a wide range of disconnected tools and temporary solutions. You need a fully managed, cloud-native data integration service that will lower the total cost of work and reduce repetitive work. Some members on your team prefer a codeless interface for building Extract, Transform, Load (ETL) process. Which service should you use?

选项

A. Dataflow

B. Dataprep

C. Apache Flink

D. Cloud Data Fusion

正确答案：D. Cloud Data Fusion

解析： 这个问题涉及为多种数据源选择适当的数据集成服务，同时考虑了可用性、管理负担和具体业务需求。

选项D是最佳解决方案，原因如下：

1. **Cloud Data Fusion的核心功能**：
    - 这是Google Cloud的完全托管式数据集成服务，专为ETL(提取、转换、加载)工作流设计
    - 提供了一个无代码、可视化的界面，正如题目中团队某些成员所期望的
    - 基于开源CDAP(Cask数据应用平台)框架构建
    - 内置了数百个预配置连接器和转换器
2. **解决特定业务挑战**：
    - 能够连接到本地和云端的各种数据源，解决跨服务器集成的问题
    - 通过标准化流程和数据治理功能提高数据质量
    - 集成了安全控制和数据谱系跟踪机制，解决安全挑战
    - 预建模板和可重用组件减少了重复工作
3. **总拥有成本优势**：
    - 作为完全托管的服务，减少了基础设施维护的负担
    - 通过无代码界面降低了开发成本和专业知识要求
    - 简化了复杂ETL流程的创建和管理
    - 可扩展性设计使其适合处理不断增长的数据需求

其他选项存在以下问题：

- 选项A(Dataflow)是一个强大的数据处理服务，但主要需要通过代码(Java或Python)进行编程，不提供无代码界面
- 选项B(Dataprep)虽然提供无代码界面，但主要设计用于数据准备和探索，而非完整的ETL流程，并正在被Dataplex取代
- 选项C(Apache Flink)是一个开源流处理框架，不是完全托管的Google Cloud服务，需要自己管理基础设施并编写代码

Cloud Data Fusion专为企业级ETL集成需求而设计，能够平衡易用性、功能性和成本效益，是满足题目中所有要求的最佳选择。

问题 118

题目

你是一家受监管保险公司的ML工程师。你被要求开发一个保险审批模型，该模型接受或拒绝潜在客户的保险申请。在构建模型之前，你应该考虑哪些因素？

You are an ML engineer at a regulated insurance company. You are asked to develop an insurance approval model that accepts or rejects insurance applications from potential customers. What factors should you consider before building the model?

选项

A. 涂抹敏感信息、可重现性和可解释性

Redaction, reproducibility, and explainability

B. 可追溯性、可重现性和可解释性

Traceability, reproducibility, and explainability

C. 联邦学习、可重现性和可解释性

Federated learning, reproducibility, and explainability

D. 差分隐私、联邦学习和可解释性

Differential privacy, federated learning, and explainability

正确答案：B. Traceability, reproducibility, and explainability

解析： 这个问题关注在受监管行业（如保险业）构建决策模型时需要考虑的关键因素。

选项B是最佳答案，原因如下：

1. **可追溯性(Traceability)**：
    - 在受监管环境中，必须能够追踪模型的每个决策回溯到其数据来源和模型版本
    - 监管机构可能要求审计决策历史和模型演变过程
    - 这对于满足合规要求和证明公平决策至关重要
    - 保险行业特别需要能够证明决策没有基于受保护的特征（如种族或性别）
2. **可重现性(Reproducibility)**：
    - 确保相同的输入始终产生相同的结果，这对于审计和验证至关重要
    - 允许监管机构验证模型行为的一致性
    - 在法律质疑或投诉情况下，能够重现过去的决策过程
    - 避免随机性导致的不一致审批结果
3. **可解释性(Explainability)**：
    - 理解和解释为什么模型接受或拒绝特定申请的能力
    - 许多金融服务法规要求向被拒绝的申请人提供明确的拒绝原因
    - 帮助识别和减轻潜在的偏见或歧视性决策
    - 增强客户和监管机构对模型决策的信任

这三个因素共同构成了受监管环境中负责任的机器学习实践的基础。

相比之下，其他选项存在以下问题：

- 选项A中的"涂抹敏感信息"虽然对隐私很重要，但不如"可追溯性"全面，后者更能满足监管合规需求
- 选项C和D包含"联邦学习"，这是一种特定的训练技术，虽然有用但不是所有保险模型的基本考虑因素
- 选项D的"差分隐私"是保护个人数据的一种方法，但从合规角度看不如"可追溯性"和"可重现性"基础

在受监管的保险环境中，B选项中的三个因素构成了模型开发的关键考虑因素，能够满足法规要求并建立公平、透明的决策系统。

问题 119

题目

你正在AI Platform上使用TPU训练一个ResNet模型，用于对汽车引擎中的缺陷类型进行视觉分类。你使用Cloud TPU profiler插件捕获训练配置文件，发现它高度受输入限制。你想减少瓶颈并加速模型训练过程。你应该对tf.data数据集做哪些修改？（选择两项。）

You are training a Resnet model on AI Platform using TPUs to visually categorize types of defects in automobile engines. You capture the training profile using the Cloud TPU profiler plugin and observe that it is highly input-bound. You want to reduce the bottleneck and speed up your model training process. Which modifications should you make to the tf.data dataset? (Choose two.)

选项

A. 使用interleave选项读取数据。

Use the interleave option for reading data.

B. 减少repeat参数的值。

Reduce the value of the repeat parameter.

C. 增加shuttle选项的缓冲区大小。

Increase the buffer size for the shuttle option.

D. 设置prefetch选项等于训练批次大小。

Set the prefetch option equal to the training batch size.

E. 减少转换中的批次大小参数。

Decrease the batch size argument in your transformation.

正确答案：A. Use the interleave option for reading data. D. Set the prefetch option equal to the training batch size.

解析： 这个问题涉及如何优化TPU训练过程中的数据管道，特别是在输入受限（input-bound）的情况下。

"输入受限"意味着模型训练速度受到数据输入速度的限制，而不是计算能力的限制。在TPU这样强大的加速器上，数据输入瓶颈尤为常见。选项A和D是解决此问题的最佳方法：

1. **使用interleave选项（选项A）**：
    - `interleave`操作允许并行读取和处理多个文件
    - 当数据从外部源（如GCS）读取时，这可以显著提高吞吐量
    - 它通过并行化I/O操作，减少了等待数据的时间
    - 对于大规模数据集尤其有效
2. **设置prefetch选项（选项D）**：
    - `prefetch`允许tf.data在模型处理当前批次时预取下一批次数据

    - 设置为训练批次大小确保始终有一个完整批次准备好供模型使用
    - 这创建了一个数据处理和模型训练的流水线，减少了批次间的等待时间
    - 有效地将数据准备与模型训练并行化

其他选项不太适合解决输入瓶颈问题：

- 选项B（减少repeat参数）只会减少数据集的重复次数，不会提高每批次的处理速度
- 选项C中提到的"shuttle"可能是对`shuffle`的误称，增加shuffle缓冲区可能会增加内存使用，但不会直接解决输入瓶颈
- 选项E（减少批次大小）可能会降低每批次的等待时间，但会增加批次总数，通常会降低TPU的整体利用率

在处理高性能加速器如TPU的数据输入优化时，并行化数据读取（通过interleave）和预取数据（通过prefetch）是解决输入瓶颈的两个最有效策略。

问题 120

题目

你在一个需要计算成本高昂的预处理操作的数据集上训练了一个模型。你需要在预测时执行相同的预处理。你将模型部署在AI Platform上进行高吞吐量的在线预测。你应该使用哪种架构？

You have trained a model on a dataset that required computationally expensive preprocessing operations. You need to execute the same preprocessing at prediction time. You deployed the model on AI Platform for high-throughput online prediction. Which architecture should you use?

选项

A. 验证你在预处理数据上训练的模型的准确性。创建一个使用原始数据并实时可用的新模型。将新模型部署到AI Platform进行在线预测。

Validate the accuracy of the model that you trained on preprocessed data. Create a new model that uses the raw data and is available in real time. Deploy the new model onto AI Platform for online prediction.

B. 将传入的预测请求发送到Pub/Sub主题。使用Dataflow作业转换传入的数据。使用转换后的数据向AI Platform提交预测请求。将预测结果写入输出Pub/Sub队列。

Send incoming prediction requests to a Pub/Sub topic. Transform the incoming data using a Dataflow job. Submit a prediction request to AI Platform using the transformed data. Write the predictions to an outbound Pub/Sub queue.

C. 将传入的预测请求数据流式传输到Cloud Spanner。创建一个视图来抽象你的预处理逻辑。每秒查询该视图以获取新记录。使用转换后的数据向AI Platform提交预测请求。将预测结果写入输出Pub/Sub队列。

Stream incoming prediction request data into Cloud Spanner. Create a view to abstract your preprocessing logic. Query the view every second for new records. Submit a prediction request to AI Platform using the transformed data. Write the predictions to an outbound Pub/Sub queue.

D. 将传入的预测请求发送到Pub/Sub主题。设置在Pub/Sub主题发布消息时触发的Cloud Function。在Cloud Function中实现你的预处理逻辑。使用转换后的数据向AI Platform提交预测请求。将预测结果写入输出Pub/Sub队列。

Send incoming prediction requests to a Pub/Sub topic. Set up a Cloud Function that is triggered when messages are published to the Pub/Sub topic. Implement your preprocessing logic in the Cloud Function. Submit a prediction request to AI Platform using the transformed data. Write the predictions to an outbound Pub/Sub queue.

正确答案：D. Send incoming prediction requests to a Pub/Sub topic. Set up a Cloud Function that is triggered when messages are published to the Pub/Sub topic. Implement your preprocessing logic in the Cloud Function. Submit a prediction request to AI Platform using the transformed data. Write the predictions to an outbound Pub/Sub queue.

解析： 这个问题关注如何在预测过程中高效处理计算密集型预处理操作，同时保持高吞吐量。

选项D是最佳解决方案，原因如下：

1. **事件驱动架构的优势**：
    - Cloud Functions提供了一个轻量级、可扩展的计算环境，非常适合处理单个预测请求的预处理
    - 事件驱动模型（由Pub/Sub消息触发）提供了天然的扩展机制，能够根据请求量自动扩缩
    - 无需管理基础设施，降低了运维复杂性
    - 处理完成后会自动释放资源，优化成本效益
2. **Pub/Sub的消息缓冲作用**：
    - 输入和输出都使用Pub/Sub，提供了自然的缓冲机制
    - 可以平滑处理预测请求的突发流量
    - 解耦了请求接收、处理和响应阶段，增强系统弹性
    - 支持异步处理模式，适合可能需要一定时间的预处理操作
3. **架构的适当复杂度**：
    - 该设计在复杂性和性能之间取得了良好的平衡
    - 每个组件都专注于其核心功能，便于维护和调试
    - 利用了Google Cloud的托管服务，减少了自定义代码的需求
    - 适合"高吞吐量在线预测"的要求，兼顾了响应性和处理能力

相比之下，其他选项存在以下问题：

- 选项A试图绕过预处理问题，但创建一个直接使用原始数据的新模型可能无法达到原模型的性能，或者根本不可行
- 选项B使用Dataflow，这对于批处理很好，但对于需要实时响应的在线预测可能会引入不必要的延迟和复杂性
- 选项C使用Cloud Spanner，这是一个关系型数据库，不是设计用来处理实时数据流和计算密集型处理的；每秒轮询也不如事件驱动模型高效

Cloud Function的无服务器特性使其特别适合处理变化的负载，同时Pub/Sub提供的消息传递基础设施确保了可靠的请求处理，这种组合是处理计算密集型预处理操作的理想选择。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 13)

问题 121

题目

你的团队训练并测试了一个DNN回归模型，取得了良好的结果。部署六个月后，由于输入数据分布的变化，模型表现不佳。你应该如何解决生产中的输入差异问题？

Your team trained and tested a DNN regression model with good results. Six months after deployment, the model is performing poorly due to a change in the distribution of the input data. How should you address the input differences in production?

选项

A. 创建警报以监控数据偏移，并重新训练模型。

Create alerts to monitor for skew, and retrain the model.

B. 对模型执行特征选择，并使用更少的特征重新训练模型。

Perform feature selection on the model, and retrain the model with fewer features.

C. 重新训练模型，并使用超参数调优服务选择L2正则化参数。

Retrain the model, and select an L2 regularization parameter with a hyperparameter tuning service.

D. 对模型执行特征选择，并按月使用更少的特征重新训练模型。

Perform feature selection on the model, and retrain the model on a monthly basis with fewer features.

正确答案：A. Create alerts to monitor for skew, and retrain the model.

解析： 这个问题关注机器学习模型部署后的常见问题 - 数据分布随时间变化导致的模型性能下降，通常称为"数据漂移"或"概念漂移"。

选项A是最佳解决方案，原因如下：

1. **识别问题的根本原因**：
    - 题目明确指出问题是"输入数据分布的变化"
    - 监控数据偏移(skew)直接解决这一根本问题
    - 偏移监控可以发现训练数据与生产数据之间的分布差异
    - 及早发现问题，可以在模型性能显著下降前采取行动
2. **主动应对方法**：
    - 设置警报系统，当检测到数据分布变化时自动通知
    - 这种持续监控方法适用于生产环境中的长期部署模型
    - 可以检测到季节性变化、市场趋势或用户行为模式的转变
3. **适当的纠正措施**：
    - 一旦发现分布变化，使用新数据重新训练模型
    - 这确保模型适应当前的数据分布

    - 保持模型与实际数据环境的相关性
    - 无需改变模型架构，只需更新其参数以反映新的数据特征

其他选项存在以下问题：

- 选项B(特征选择)不直接解决分布变化的问题，减少特征可能会降低模型捕获数据复杂性的能力
- 选项C(L2正则化)主要是防止过拟合的技术，而不是解决分布变化
- 选项D虽然包含定期重训练的好做法，但其重点是特征减少，而非分布监控，且可能错过月度周期之间的重要变化

在生产环境中，建立监控系统以检测数据分布变化，并在需要时重新训练模型，是解决数据漂移问题的标准最佳实践。

问题 122

题目

你需要使用Compute Engine上的GPU虚拟机训练一个计算机视觉模型，用于预测图像中存在的政府ID类型。你使用以下参数：优化器：SGD，图像形状=224x224，批次大小=64，训练轮数=10，详细度=2。训练过程中你遇到以下错误：ResourceExhaustedError：分配张量时内存不足（OOM）。你应该怎么做？

You need to train a computer vision model that predicts the type of government ID present in a given image using a GPU-powered virtual machine on Compute Engine. You use the following parameters: Optimizer: SGD, Image shape = 224x224, Batch size = 64, Epochs = 10, Verbose = 2. During training you encounter the following error: ResourceExhaustedError: Out Of Memory (OOM) when allocating tensor. What should you do?

选项

A. 更换优化器。

Change the optimizer.

B. 减小批次大小。

Reduce the batch size.

C. 更改学习率。

Change the learning rate.

D. 减小图像形状。

Reduce the image shape.

正确答案：B. Reduce the batch size.

解析： 这个问题涉及深度学习训练过程中常见的GPU内存不足(OOM)错误的解决方法。

选项B是最佳解决方案，原因如下：

1. **批次大小与GPU内存使用的直接关系**：

- 批次大小(Batch size)直接决定了在单次前向和反向传播中需要同时加载到GPU内存的样本数量
- 批次大小越大，需要的GPU内存就越多
- 当前批次大小为64，这对于复杂的计算机视觉模型和较大的图像尺寸来说可能过大
- 减小批次大小（如改为16或32）可以显著降低GPU内存需求

2. **解决OOM错误的最直接方法**：

- 在不改变模型架构和其他训练参数的情况下，减小批次大小是解决OOM错误最简单直接的方法
- 这种调整不会影响模型的最终精度，只会影响训练动态和所需时间
- 批次大小的减小通常可以通过增加训练迭代次数来补偿，保持总体样本学习量

3. **实施成本最低**：

- 相比其他选项，减小批次大小不需要重新设计模型架构或预处理流程
- 只需修改一个训练参数，无需额外的数据处理
- 在面临资源限制时，是最经济有效的解决方案

其他选项存在以下问题：

- 选项A（更换优化器）通常不会显著影响内存使用量；SGD实际上是内存占用较低的优化器
- 选项C（更改学习率）只会影响模型收敛，不会减少内存使用
- 选项D（减小图像形状）虽然也能减少内存使用，但会导致模型输入特征减少，可能影响识别政府ID的关键细节，降低模型性能

批次大小直接影响并行处理的样本数，因此当遇到GPU内存不足错误时，减小批次大小是最常用且最有效的解决方案。

问题 123

题目

你使用AI Platform开发了一个ML模型，并希望将其投入生产。你每秒服务几千个查询，但遇到了延迟问题。传入的请求由负载均衡器分发到运行在Google Kubernetes Engine (GKE)上的多个Kubeflow CPU-only容器中。你的目标是在不改变底层基础设施的情况下改善服务延迟。你应该怎么做？

You developed an ML model with AI Platform, and you want to move it to production. You serve a few thousand queries per second and are experiencing latency issues. Incoming requests are served by a load balancer that distributes them across multiple Kubeflow CPU-only pods running on Google Kubernetes Engine (GKE). Your goal is to improve the serving latency without changing the underlying infrastructure. What should you do?

选项

A. 显著增加TensorFlow Serving的max_batch_size参数。

Significantly increase the max_batch_size TensorFlow Serving parameter.

B. 切换到tensorflow-model-server-universal版本的TensorFlow Serving。

Switch to the tensorflow-model-server-universal version of TensorFlow Serving.

C. 显著增加TensorFlow Serving的max_enqueued_batches参数。

Significantly increase the max_enqueued_batches TensorFlow Serving parameter.

D. 使用源代码重新编译TensorFlow Serving以支持CPU特定优化。指示GKE为服务节点选择适当的基准最小CPU平台。

Recompile TensorFlow Serving using the source to support CPU-specific optimizations. Instruct GKE to choose an appropriate baseline minimum CPU platform for serving nodes.

正确答案：D. Recompile TensorFlow Serving using the source to support CPU-specific optimizations. Instruct GKE to choose an appropriate baseline minimum CPU platform for serving nodes.

解析： 这个问题关注如何在不改变底层基础设施的前提下，提高机器学习模型在Kubernetes环境中的服务延迟。

选项D是最佳解决方案，原因如下：

1. **CPU特定优化的重要性**：
    - 重新编译TensorFlow Serving以支持CPU特定优化可以充分利用底层CPU架构的特定指令集和功能
    - 这些优化包括向量化指令(如AVX、SSE4等)，可以显著提高数值计算性能
    - 对于CPU-only的部署，这些优化尤其重要，因为没有GPU加速
    - 针对特定处理器架构的优化可以减少指令执行时间，直接降低延迟
2. **最小CPU平台选择的影响**：
    - 在GKE中指定基准最小CPU平台确保所有节点都满足特定的处理器功能要求
    - 这保证了优化后的TensorFlow Serving可以在所有节点上高效运行
    - 避免了由于节点间CPU能力差异导致的性能不一致
    - 所有服务实例都能利用相同的CPU优化指令集
3. **符合约束条件**：
    - 这种方法不需要改变底层基础设施（如从CPU切换到GPU或TPU）
    - 不需要更改服务架构或请求分发方式
    - 只是通过软件优化和配置调整来提高性能
    - 最大限度地利用现有硬件资源

其他选项存在以下问题：

- 选项A（增加max_batch_size）可能会提高吞吐量，但实际上会增加单个请求的延迟，因为请求需要等待批次填满
- 选项B（使用universal版本）通常为了兼容性而牺牲特定平台优化，可能无法充分利用特定CPU架构的功能
- 选项C（增加max_enqueued_batches）只会增加可以排队的批次数量，实际上可能会增加平均延迟时间

针对CPU架构进行软件优化是在不改变硬件和基础设施的情况下，提高计算密集型应用性能的最有效方法之一。

问题 124

题目

你有一个生产中的需求预测管道，使用Dataflow在模型训练和预测前预处理原始数据。在预处理过程中，你对存储在BigQuery中的数据进行Z-score标准化，并将其写回BigQuery。每周都会添加新的训练数据。你希望通过最小化计算时间和手动干预来提高流程效率。你应该怎么做？

You have a demand forecasting pipeline in production that uses Dataflow to preprocess raw data prior to model training and prediction. During preprocessing, you employ Z-score normalization on data stored in BigQuery and write it back to BigQuery. New training data is added every week. You want to make the process more efficient by minimizing computation time and manual intervention. What should you do?

选项

A. 使用Google Kubernetes Engine对数据进行标准化。

Normalize the data using Google Kubernetes Engine.

B. 将标准化算法转换为SQL以用于BigQuery。

Translate the normalization algorithm into SQL for use with BigQuery.

C. 使用TensorFlow的Feature Column API中的normalizer_fn参数。

Use the normalizer_fn argument in TensorFlow's Feature Column API.

D. 使用Apache Spark和Dataproc连接器对BigQuery中的数据进行标准化。

Normalize the data with Apache Spark using the Dataproc connector for BigQuery.

正确答案：B. Translate the normalization algorithm into SQL for use with BigQuery.

解析： 这个问题关注如何优化数据处理管道，特别是在处理存储在BigQuery中的数据时，如何提高效率并减少手动干预。

选项B是最佳解决方案，原因如下：

1. **减少数据移动**：
    - 当前管道从BigQuery提取数据，在Dataflow中处理，然后将结果写回BigQuery
    - 这种数据移动增加了处理时间和资源消耗
    - 直接在BigQuery中使用SQL执行标准化消除了数据移动的需要
    - 数据保持在BigQuery内部，大幅减少了处理延迟
2. **利用BigQuery的计算能力**：
    - BigQuery是一个强大的分析引擎，能够高效处理大规模数据
    - Z-score标准化可以使用SQL相对简单地实现：`(value - AVG(value)) / STDDEV(value)`
    - BigQuery的列存储格式和分布式计算架构可以高效地执行这类计算
    - 这种方法利用了已有的基础设施而不是引入新组件
3. **自动化和减少管理开销**：
    - BigQuery可以通过调度查询来自动执行重复性任务
    - 每当新数据添加时，可以自动触发标准化过程
    - 无需管理单独的Dataflow作业和相关资源

    - 简化的架构意味着更少的故障点和更低的维护成本

其他选项存在以下问题：

- 选项A（使用GKE）会引入不必要的复杂性，需要管理Kubernetes集群，与目标"减少手动干预"相矛盾
- 选项C（TensorFlow Feature Column）将标准化移到模型训练环节，这不解决预处理问题，且可能导致训练性能问题
- 选项D（Apache Spark和Dataproc）只是用另一个数据处理框架替换Dataflow，没有从根本上解决数据移动问题，甚至可能增加复杂性

将数据处理逻辑直接集成到数据存储层（在本例中是BigQuery）是数据工程的一个关键最佳实践，特别是当处理需要定期重复的操作时。

问题 125

题目

你需要设计一个Keras自定义深度神经网络，用于基于客户购买历史预测未来购买行为。你想探索多种模型架构，存储训练数据，并能够在同一个仪表板中比较评估指标。你应该怎么做？

You need to design a customized deep neural network in Keras that will predict customer purchases based on their purchase history. You want to explore model performance using multiple model architectures, store training data, and be able to compare the evaluation metrics in the same dashboard. What should you do?

选项

A. 使用AutoML Tables创建多个模型。

Create multiple models using AutoML Tables.

B. 使用Cloud Composer自动化多次训练运行。

Automate multiple training runs using Cloud Composer.

C. 在AI Platform上运行具有相似作业名称的多个训练作业。

Run multiple training jobs on AI Platform with similar job names.

D. 在Kubeflow Pipelines中创建实验来组织多次运行。

Create an experiment in Kubeflow Pipelines to organize multiple runs.

正确答案：D. Create an experiment in Kubeflow Pipelines to organize multiple runs.

解析： 这个问题关注如何有效地组织和比较多个模型架构的训练过程及结果。

选项D是最佳解决方案，原因如下：

1. **实验组织与跟踪**：
    - Kubeflow Pipelines提供了专门的实验功能，可以组织相关的模型训练运行
    - 允许系统化地管理多种模型架构的训练过程
    - 自动跟踪每次运行的参数、配置和结果

- 提供实验版本控制，确保可重现性

2. **统一的指标比较**：

   - Kubeflow集成了强大的可视化工具，包括内置的指标比较仪表板
   - 可以在同一视图中并排比较不同模型架构的性能指标
   - 支持各种可视化方式，如线图、条形图和散点图
   - 可以自定义显示关键性能指标(KPI)，便于决策

3. **端到端ML工作流管理**：

   - 不仅支持模型训练，还支持数据预处理、特征工程和模型部署
   - 可以轻松集成Keras自定义模型代码
   - 提供管道重用和参数化，便于系统化地试验不同架构
   - 支持分布式训练和资源优化

其他选项存在以下问题：

- 选项A(AutoML Tables)不支持使用Keras创建自定义深度神经网络，限制了模型架构的探索
- 选项B(Cloud Composer)虽然可以自动化工作流程，但主要关注调度和依赖管理，缺乏内置的实验跟踪和指标比较功能
- 选项C(相似作业名称)是一种不够系统的方法，没有提供统一的仪表板来比较各种模型的评估指标

Kubeflow Pipelines专为机器学习实验和工作流程设计，提供了组织多次训练运行、跟踪参数和比较性能指标所需的全部功能，是探索多种模型架构性能的理想选择。

问题 126

题目

你正在Google Kubernetes Engine上开发一个Kubeflow管道。管道的第一步是对BigQuery进行查询。你计划将该查询的结果作为输入传递给管道中的下一步。你希望以最简单的方式实现这一点。你应该怎么做？

You are developing a Kubeflow pipeline on Google Kubernetes Engine. The first step in the pipeline is to issue a query against BigQuery. You plan to use the results of that query as the input to the next step in your pipeline. You want to achieve this in the easiest way possible. What should you do?

选项

A. 使用BigQuery控制台执行查询，然后将查询结果保存到一个新的BigQuery表中。

Use the BigQuery console to execute your query, and then save the query results into a new BigQuery table.

B. 编写一个使用BigQuery API执行查询的Python脚本。将此脚本作为Kubeflow管道中的第一步执行。

Write a Python script that uses the BigQuery API to execute queries against BigQuery. Execute this script as the first step in your Kubeflow pipeline.

C. 使用Kubeflow Pipelines的领域特定语言创建一个自定义组件，该组件使用Python BigQuery客户端库执行查询。

Use the Kubeflow Pipelines domain-specific language to create a custom component that uses the Python BigQuery client library to execute queries.

D. 在GitHub上找到Kubeflow Pipelines代码库。找到BigQuery查询组件，复制该组件的URL，并使用它将组件加载到你的管道中。使用该组件对BigQuery执行查询。

Locate the Kubeflow Pipelines repository on GitHub. Find the BigQuery Query Component, copy that component's URL, and use it to load the component into your pipeline. Use the component to execute queries against BigQuery.

正确答案：D. Locate the Kubeflow Pipelines repository on GitHub. Find the BigQuery Query Component, copy that component's URL, and use it to load the component into your pipeline. Use the component to execute queries against BigQuery.

解析： 这个问题关注如何在Kubeflow管道中以最简单的方式集成BigQuery查询功能。

选项D是最佳解决方案，原因如下：

1. **利用现有组件的优势**：
    - Kubeflow Pipelines提供了许多预建组件，包括专门用于BigQuery查询的组件
    - 这些组件已经经过测试和优化，可以直接在管道中使用
    - 无需编写和维护自定义代码来与BigQuery交互
    - 使用现有组件是最快速和最容易的实现方法
2. **组件加载机制的简便性**：
    - Kubeflow Pipelines允许通过URL直接加载远程组件
    - 这意味着只需在管道定义中添加几行代码即可加载和使用组件
    - 不需要将组件代码作为项目的一部分维护
    - 可以利用社区维护的组件获取更新和改进
3. **与Kubeflow生态系统的集成**：
    - 官方组件经过设计，可以与Kubeflow Pipelines运行时环境无缝集成
    - 自动处理身份验证、错误处理和资源管理
    - 确保查询结果以标准格式传递给管道的后续步骤
    - 简化数据在管道步骤之间的流动

其他选项存在以下问题：

- 选项A涉及手动操作，不能集成到自动化管道中，违背了管道自动化的目的
- 选项B需要从头编写和维护Python脚本，增加了不必要的开发工作和潜在的错误点
- 选项C也要求开发自定义组件，虽然可行但比使用现有组件需要更多工作

利用Kubeflow Pipelines生态系统中的现有组件是实现常见功能（如与BigQuery交互）的最佳实践，尤其是在追求简单易用的解决方案时。

问题 127

题目

你正在构建一个预测每日温度的模型。你随机拆分了数据，然后对训练和测试数据集进行了转换。模型训练的温度数据每小时上传一次。在测试过程中，你的模型达到了97%的准确率；然而，部署到生产环境后，模型的准确率下降到66%。如何让你的生产模型更准确？

You are building a model to predict daily temperatures. You split the data randomly and then transformed the training and test datasets. Temperature data for model training is uploaded hourly. During testing, your model performed with 97% accuracy; however, after deploying to production, the model's accuracy dropped to 66%. How can you make your production model more accurate?

选项

A. 将训练和测试数据集的标准化作为两个单独的步骤进行。

Normalize the data for the training, and test datasets as two separate steps.

B. 基于时间而非随机拆分来划分训练和测试数据，以避免数据泄露。

Split the training and test data based on time rather than a random split to avoid leakage.

C. 向测试集添加更多数据，确保测试有公平的分布和样本。

Add more data to your test set to ensure that you have a fair distribution and sample for testing.

D. 在拆分前应用数据转换，并交叉验证以确保转换同时应用于训练和测试集。

Apply data transformations before splitting, and cross-validate to make sure that the transformations are applied to both the training and test sets.

正确答案：B. Split the training and test data based on time rather than a random split to avoid leakage.

解析： 这个问题关注时间序列预测模型中常见的数据拆分问题，以及为什么在生产环境中模型性能会下降。

选项B是最佳解决方案，原因如下：

1. **时间序列数据的特殊性**：
    - 温度数据本质上是时间序列数据，具有时间依赖性和季节性模式
    - 随机拆分时间序列数据会导致训练集包含来自测试集时间段的信息
    - 这种"提前看到未来"的情况会人为地提高测试性能，但在生产中无法实现
    - 基于时间的拆分可以模拟真实的预测场景，更准确地评估模型性能
2. **数据泄露问题**：
    - 数据泄露指测试过程中无意中使用了在实际预测时不可用的信息
    - 在时间序列预测中，随机拆分是数据泄露的主要来源
    - 例如，如果今天的温度受昨天和明天温度的影响，那么随机拆分会将未来信息泄露到训练过程中
    - 性能从97%下降到66%是数据泄露导致测试结果不真实的典型表现
3. **模拟生产环境**：
    - 基于时间的拆分(例如使用前80%的时间数据训练，后20%测试)更准确地模拟生产场景
    - 这确保模型在评估时真正预测"未来"，而不是已经在训练中"看到"的数据点
    - 这种方法会给出更保守但更现实的性能估计

    - 生产环境中的性能下降会减少，因为评估方法与实际使用场景一致

其他选项存在以下问题：

- 选项A（分别标准化）会使问题恶化，因为训练和测试数据将使用不同的统计数据进行转换，增加分布偏移
- 选项C（添加更多测试数据）不解决随机拆分导致的根本问题，只是增加了采样量
- 选项D（先转换后拆分）尽管是正确的数据预处理顺序，但没有解决时间序列数据随机拆分的核心问题

在处理时间序列数据时，基于时间的拆分是一种关键的最佳实践，可以提供更可靠的模型评估并减少部署到生产环境后的性能下降。

问题 128

题目

你正在开发模型来分类客户支持邮件。你已经使用小型数据集在本地系统上用TensorFlow Estimators创建了模型，但现在需要使用大型数据集来训练模型以确保高性能。你将把模型迁移到Google Cloud，并希望最小化代码重构和基础设施开销，使从本地到云端的迁移更容易。你应该怎么做？

You are developing models to classify customer support emails. You created models with TensorFlow Estimators using small datasets on your on premises system, but you now need to train the models using large datasets to ensure high performance. You will port your models to Google Cloud and want to minimize code refactoring and infrastructure overhead for easier migration from on-prem to cloud. What should you do?

选项

A. 使用AI Platform进行分布式训练。

Use AI Platform for distributed training.

B. 在Dataproc上创建集群进行训练。

Create a cluster on Dataproc for training.

C. 创建具有自动扩缩功能的托管实例组。

Create a Managed Instance Group with autoscaling.

D. 使用Kubeflow Pipelines在Google Kubernetes Engine集群上训练。

Use Kubeflow Pipelines to train on a Google Kubernetes Engine cluster.

正确答案：A. Use AI Platform for distributed training.

解析： 这个问题关注如何将本地TensorFlow模型迁移到云端并进行大规模训练，同时最小化代码重构和管理开销。

选项A是最佳解决方案，原因如下：

1. **与TensorFlow的无缝集成**：
    - AI Platform (现称为Vertex AI)原生支持TensorFlow，包括TensorFlow Estimators

    - 它被设计为与TensorFlow工作流程兼容，只需最小的代码更改
    - 允许使用相同的训练脚本，仅需添加一些特定于云的配置
    - 这确保了从本地到云端的平滑过渡，最小化代码重构需求

2. **低基础设施开销**：

    - AI Platform是一个完全托管的服务，无需管理底层基础设施
    - 不需要配置、维护或扩展计算集群
    - 自动处理资源分配和扩展，适应大型数据集训练需求
    - 减少了操作和维护负担，使团队可以专注于模型开发

3. **分布式训练支持**：

    - 提供内置的分布式训练功能，可以有效处理大型数据集
    - 轻松配置多台机器协同训练，无需修改核心模型代码
    - 通过单一命令或简单API调用支持扩展到多个节点
    - 支持同步和异步训练策略

其他选项存在以下问题：

- 选项B(Dataproc)是一个基于Hadoop/Spark的服务，不专为TensorFlow工作负载优化，需要更多的配置和代码重构
- 选项C(托管实例组)需要显著的基础设施管理和配置，增加了操作开销
- 选项D(Kubeflow Pipelines)是一个强大的ML管道工具，但比AI Platform需要更多的初始设置和管理，增加了迁移的复杂性

AI Platform为TensorFlow模型提供了最直接的上云路径，因为它针对TensorFlow工作流程进行了优化，并提供了现成的分布式训练功能，无需大量修改现有代码。

问题 129

题目

你已经在AI Platform上使用TensorFlow训练了一个文本分类模型。你想要对存储在BigQuery中的文本数据使用这个训练好的模型进行批量预测，同时最小化计算开销。你应该怎么做？

You have trained a text classification model in TensorFlow using AI Platform. You want to use the trained model for batch predictions on text data stored in BigQuery while minimizing computational overhead. What should you do?

选项

A. 将模型导出到BigQuery ML。

Export the model to BigQuery ML.

B. 在AI Platform上部署和版本化模型。

Deploy and version the model on AI Platform.

C. 使用Dataflow和SavedModel从BigQuery读取数据。

Use Dataflow with the SavedModel to read the data from BigQuery.

D. 在AI Platform上提交一个指向Cloud Storage中模型位置的批量预测作业。

Submit a batch prediction job on AI Platform that points to the model location in Cloud Storage.

正确答案：A. Export the model to BigQuery ML.

解析： 这个问题涉及如何高效地对存储在BigQuery中的大量文本数据执行预测，同时最小化计算开销。

选项A是最佳解决方案，原因如下：

1. **数据位置和处理效率**：
    - 文本数据已经存储在BigQuery中
    - 将模型导出到BigQuery ML可以实现"将计算移至数据所在位置"的原则
    - 避免了将大量数据从BigQuery移动到其他服务的网络开销和延迟
    - BigQuery的分布式架构能够高效处理大规模数据
2. **最小化计算开销**：
    - BigQuery ML允许直接在SQL查询中使用机器学习模型
    - 不需要为预测设置和管理额外的计算资源
    - 利用BigQuery的按需计算模型，只为实际执行的查询付费
    - 消除了数据移动和专用预测基础架构的开销
3. **TensorFlow与BigQuery ML的集成**：
    - BigQuery ML支持导入训练好的TensorFlow模型
    - 可以使用熟悉的SQL语法对模型进行推理
    - 简化了整体工作流程和维护需求
    - 支持企业级的扩展性和安全性

其他选项存在以下问题：

- 选项B（在AI Platform上部署和版本化）主要适用于在线预测而非批量预测场景，不适合高效处理存储在BigQuery中的大量数据
- 选项C（使用Dataflow）需要设置和管理额外的数据处理管道，增加了基础设施和维护开销
- 选项D（AI Platform批量预测作业）虽然可行，但仍需将数据从BigQuery导出到Cloud Storage，增加了数据移动的成本和复杂性

当数据已经存在于BigQuery中并且需要进行批量预测时，将模型导出到BigQuery ML是最高效的方法，它最大限度地减少了数据移动和计算开销。

问题 130

题目

你与一个数据工程团队合作，该团队已经开发了一个管道来清理数据集并将其保存在Cloud Storage存储桶中。你已经创建了一个ML模型，并希望在新数据可用时立即使用这些数据来刷新你的模型。作为CI/CD工作流的一部分，你希望在Google Kubernetes Engine (GKE)上自动运行Kubeflow Pipelines训练作业。你应该如何设计这个工作流？

You work with a data engineering team that has developed a pipeline to clean your dataset and save it in a Cloud Storage bucket. You have created an ML model and want to use the data to refresh your model as soon as new data is available. As part of your CI/CD workflow, you want to automatically run a Kubeflow Pipelines training job on Google Kubernetes Engine (GKE). How should you architect this workflow?

选项

A. 使用Dataflow配置你的管道，将文件保存在Cloud Storage中。文件保存后，在GKE集群上启动训练作业。

Configure your pipeline with Dataflow, which saves the files in Cloud Storage. After the file is saved, start the training job on a GKE cluster.

B. 使用App Engine创建一个轻量级Python客户端，持续轮询Cloud Storage查找新文件。一旦文件到达，启动训练作业。

Use App Engine to create a lightweight python client that continuously polls Cloud Storage for new files. As soon as a file arrives, initiate the training job.

C. 配置Cloud Storage触发器，在存储桶中有新文件可用时向Pub/Sub主题发送消息。使用由Pub/Sub触发的Cloud Function在GKE集群上启动训练作业。

Configure a Cloud Storage trigger to send a message to a Pub/Sub topic when a new file is available in a storage bucket. Use a Pub/Sub-triggered Cloud Function to start the training job on a GKE cluster.

D. 使用Cloud Scheduler按固定间隔调度作业。作为作业的第一步，检查Cloud Storage存储桶中对象的时间戳。如果自上次运行以来没有新文件，则中止作业。

Use Cloud Scheduler to schedule jobs at a regular interval. For the first step of the job, check the timestamp of objects in your Cloud Storage bucket. If there are no new files since the last run, abort the job.

正确答案：C. Configure a Cloud Storage trigger to send a message to a Pub/Sub topic when a new file is available in a storage bucket. Use a Pub/Sub-triggered Cloud Function to start the training job on a GKE cluster.

解析： 这个问题关注如何设计一个高效的CI/CD工作流，在新数据可用时自动触发机器学习模型的训练。

选项C是最佳解决方案，原因如下：

1. **事件驱动架构的优势**：
    - Cloud Storage触发器提供了一种完全事件驱动的机制，只在实际需要时才执行操作
    - 当新文件上传到存储桶时，会立即触发事件，符合"尽快刷新模型"的要求
    - 这种方法避免了轮询或定时检查，减少了延迟和资源浪费
    - 事件驱动架构比轮询或定时策略更加高效和响应迅速
2. **无服务器组件的优势**：
    - Cloud Functions是一个无服务器计算服务，不需要持续运行资源
    - 只在需要启动训练作业时才消耗资源和成本
    - 自动扩缩以处理多个并发事件，例如多个文件同时上传
    - 维护成本低，无需管理常驻基础设施

3. **Pub/Sub的解耦和可靠性**：
    - Pub/Sub在触发器和Cloud Function之间提供了解耦
    - 即使在高负载下也能可靠传递消息
    - 支持消息重试机制，确保训练作业的可靠启动
    - 允许未来扩展工作流，如将同一事件用于多个下游处理

其他选项存在以下问题：

- 选项A没有明确说明如何检测"文件保存后"，可能需要自定义代码或额外配置来检测文件完成
- 选项B(持续轮询)会不必要地消耗资源，即使在没有新数据的情况下也会运行，不符合按需自动化的要求
- 选项D(定时作业)不能立即响应新数据，需要等待下一个调度间隔，不满足"尽快"的要求，而且即使没有新数据也会定期运行

选项C提供了一个真正事件驱动的无服务器解决方案，确保在新数据可用时立即启动模型训练，同时最小化基础设施管理和资源消耗。这种架构也符合现代云原生设计原则。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 14)

问题 131

题目

你有一个运行中的端到端ML管道，涉及使用AI Platform调整ML模型的超参数，然后使用调优后的最佳参数进行训练。超参数调优的时间比预期长，导致下游流程延迟。你想加快调优作业，同时不显著影响其有效性。你应该采取哪些行动？（选择两项。）

You have a functioning end-to-end ML pipeline that involves tuning the hyperparameters of your ML model using AI Platform, and then using the best-tuned parameters for training. Hypertuning is taking longer than expected and is delaying the downstream processes. You want to speed up the tuning job without significantly compromising its effectiveness. Which actions should you take? (Choose two.)

选项

A. 减少并行试验的数量。

Decrease the number of parallel trials.

B. 减小浮点值的范围。

Decrease the range of floating-point values.

C. 将提前停止参数设置为TRUE。

Set the early stopping parameter to TRUE.

D. 将搜索算法从贝叶斯搜索更改为随机搜索。

Change the search algorithm from Bayesian search to random search.

E. 在后续训练阶段减少最大试验次数。

Decrease the maximum number of trials during subsequent training phases.

正确答案：C. Set the early stopping parameter to TRUE. E. Decrease the maximum number of trials during subsequent training phases.

解析： 这个问题测试如何在不显著降低效果的前提下优化AI Platform上的超参数调优过程。

正确选项的理由：

1. **选项C：将提前停止参数设置为TRUE**
    - 提前停止是一种优化超参数调优时间的有效技术
    - 它会自动终止表现不佳的试验，从而避免资源浪费在不太可能产生最佳结果的配置上
    - 提前停止算法基于统计分析来决定哪些试验可以被终止，而不会显著影响找到最优解的概率
    - 它可以大幅减少总体调优时间，同时保持找到高质量超参数的能力
    - 这是一个"低风险、高回报"的优化策略
2. **选项E：在后续训练阶段减少最大试验次数**
    - 这种策略利用了超参数调优通常有多个阶段的特性
    - 初始阶段可以探索广泛的超参数空间，后续阶段则基于已找到的有希望的区域进行细化
    - 减少后续阶段的试验次数可以节省时间，因为主要的超参数空间已经在初始阶段被探索过
    - 后续阶段的减少不会显著影响发现最优超参数的能力，因为搜索已经被引导到有希望的区域

其他选项存在的问题：

- **选项A（减少并行试验数量）**：这实际上会延长总体调优时间，因为并行试验能够更有效地利用可用资源
- **选项B（减小浮点值的范围）**：虽然这能加快搜索，但可能会显著影响有效性，因为最优值可能被排除在缩小的范围之外
- **选项D（从贝叶斯搜索改为随机搜索）**：贝叶斯搜索通常比随机搜索更高效，因为它会根据先前的结果来指导后续试验。更改为随机搜索可能会导致需要更多试验才能找到好的解决方案

选项C和E提供了在不显著影响调优质量的情况下减少调优时间的最佳方法，使它们成为此场景的理想选择。

问题 132

题目

你的团队正在为一家全球银行构建一个将被数百万客户使用的应用程序。你构建了一个预测模型，可以预测客户账户余额在未来3天的情况。你的团队将在一个新功能中使用这些结果，当用户的账户余额可能降至25美元以下时通知用户。你应该如何提供这些预测？

Your team is building an application for a global bank that will be used by millions of customers. You built a forecasting model that predicts customers' account balances 3 days in the future. Your team will use the results in a new feature that will notify users when their account balance is likely to drop below $25. How should you serve your predictions?

选项

A. 1. 为每个用户创建一个Pub/Sub主题。2. 部署一个Cloud Function，当你的模型预测用户的账户余额将降至25美元阈值以下时发送通知。

1. Create a Pub/Sub topic for each user. 2. Deploy a Cloud Function that sends a notification when your model predicts that a user's account balance will drop below the $25 threshold.

B. 1. 为每个用户创建一个Pub/Sub主题。2. 在App Engine标准环境中部署一个应用程序，当你的模型预测用户的账户余额将降至25美元阈值以下时发送通知。

1. Create a Pub/Sub topic for each user. 2. Deploy an application on the App Engine standard environment that sends a notification when your model predicts that a user's account balance will drop below the $25 threshold.

C. 1. 在Firebase上构建通知系统。2. 在Firebase Cloud Messaging服务器上为每个用户注册一个用户ID，当所有账户余额预测的平均值降至25美元阈值以下时发送通知。

1. Build a notification system on Firebase. 2. Register each user with a user ID on the Firebase Cloud Messaging server, which sends a notification when the average of all account balance predictions drops below the $25 threshold.

D. 1. 在Firebase上构建通知系统。2. 在Firebase Cloud Messaging服务器上为每个用户注册一个用户ID，当你的模型预测用户的账户余额将降至25美元阈值以下时发送通知。

1. Build a notification system on Firebase. 2. Register each user with a user ID on the Firebase Cloud Messaging server, which sends a notification when your model predicts that a user's account balance will drop below the $25 threshold.

正确答案：D. 1. Build a notification system on Firebase. 2. Register each user with a user ID on the Firebase Cloud Messaging server, which sends a notification when your model predicts that a user's account balance will drop below the $25 threshold.

解析： 这个问题测试如何为一个需要向数百万用户提供个性化预测通知的大规模应用程序设计合适的服务架构。

选项D是最佳解决方案，原因如下：

1. **Firebase Cloud Messaging的可扩展性**：
    - Firebase Cloud Messaging (FCM)专门设计用于向移动和网络应用程序的用户发送通知
    - 它能轻松扩展到数百万用户，正如题目中所述的"将被数百万客户使用"
    - FCM处理所有与不同设备平台(iOS、Android、Web)兼容性相关的复杂性
    - 它包含了处理用户在线/离线状态的逻辑，确保消息的可靠传递
2. **直接面向用户的通知系统**：
    - 该选项提供了一个直接的端到端解决方案，从识别需要通知的用户到发送实际通知
    - 它允许针对特定用户发送个性化通知，而不是向所有用户广播
    - 通过用户ID注册，系统可以精确定位需要接收低余额预警的特定用户
    - 这种方法最符合需求："通知用户当他们的账户余额可能降至25美元以下"
3. **高效的资源利用**：

    - 只有当预测表明特定用户的余额将降至阈值以下时，才会触发通知
    - 这种精确定位减少了不必要的处理和通知
    - 避免了为每个用户创建单独资源（如单独的Pub/Sub主题）的开销

其他选项存在的问题：

- 选项A和B都提议"为每个用户创建一个Pub/Sub主题"，这在数百万用户的规模下是不可行的。Pub/Sub主题通常用于更粗粒度的事件类别，而不是单个用户
- 选项C提到"当所有账户余额预测的平均值降至25美元阈值以下时"发送通知，这与需求不符。需求是在个人账户预计降至阈值以下时通知特定用户，而不是基于所有用户的平均值

Firebase Cloud Messaging为此场景提供了理想的基础设施，它支持大规模扩展，同时保持高效的资源利用和准确的用户定位，使选项D成为满足给定需求的最佳选择。

问题 133

题目

你在一家广告公司工作，想要了解公司最新广告活动的效果。你已经将500 MB的活动数据流式传输到BigQuery中。你想查询该表，然后在AI Platform笔记本中使用pandas数据框来处理查询结果。你应该怎么做？

You work for an advertising company and want to understand the effectiveness of your company's latest advertising campaign. You have streamed 500 MB of campaign data into BigQuery. You want to query the table, and then manipulate the results of that query with a pandas dataframe in an AI Platform notebook. What should you do?

选项

A. 使用AI Platform Notebooks的BigQuery单元格魔法命令查询数据，并将结果作为pandas数据框摄取。

Use AI Platform Notebooks' BigQuery cell magic to query the data, and ingest the results as a pandas dataframe.

B. 将表从BigQuery导出为CSV文件到Google Drive，并使用Google Drive API将文件导入到笔记本实例中。

Export your table as a CSV file from BigQuery to Google Drive, and use the Google Drive API to ingest the file into your notebook instance.

C. 从BigQuery将表下载为本地CSV文件，并上传到你的AI Platform笔记本实例。使用pandas.read_csv摄取文件作为pandas数据框。

Download your table from BigQuery as a local CSV file, and upload it to your AI Platform notebook instance. Use pandas.read_csv to ingest he file as a pandas dataframe.

D. 在AI Platform笔记本的bash单元格中，使用bq extract命令将表导出为CSV文件到Cloud Storage，然后使用gsutil cp将数据复制到笔记本中。使用pandas.read_csv将文件摄取为pandas数据框。

From a bash cell in your AI Platform notebook, use the bq extract command to export the table as a CSV file to Cloud Storage, and then use gsutil cp to copy the data into the notebook. Use pandas.read_csv to ingest the file as a pandas dataframe.

正确答案：A. Use AI Platform Notebooks' BigQuery cell magic to query the data, and ingest the results as a pandas dataframe.

解析： 这个问题测试对AI Platform Notebooks（现称为Vertex AI Workbench）与BigQuery集成的理解，以及如何高效地处理分析数据。

选项A是最佳解决方案，原因如下：

1. **直接集成的优势**：
    - AI Platform Notebooks提供了与BigQuery的内置集成，通过"BigQuery魔法命令"(%bigquery)
    - 这允许直接在笔记本单元格中编写SQL查询，并自动将结果转换为pandas数据框
    - 无需中间步骤，如文件导出、下载、上传或格式转换
    - 代码简洁，通常只需一行：`df = %bigquery YOUR_SQL_QUERY_HERE`
2. **数据处理效率**：
    - 该方法消除了将数据移动到临时存储位置的需要
    - 直接查询BigQuery并只检索需要的数据，而不是整个表
    - 对于500 MB的数据集特别高效，因为你可以使用SQL过滤器和聚合来减少传输的数据量
    - 减少了网络传输和存储开销
3. **安全性和便捷性**：
    - 使用BigQuery魔法命令会自动使用笔记本实例的身份验证
    - 不需要额外的API密钥或认证步骤
    - 不需要管理临时文件或清理存储空间
    - 简化了整个工作流程，减少出错的可能性

其他选项存在的问题：

- 选项B、C和D都涉及不必要的中间步骤，如创建和管理CSV文件
- 选项B需要设置和使用额外的Google Drive API
- 选项C需要将数据下载到本地机器，然后再上传到笔记本实例，这既低效又繁琐
- 选项D涉及多个命令行操作，增加了复杂性和潜在的错误点

BigQuery魔法命令是专门为这种场景设计的，提供了最直接、最高效的解决方案，无需额外的数据移动或转换步骤。

问题 134

题目

你是一家全球汽车制造商的ML工程师。你需要构建一个ML模型来预测世界各地不同城市的汽车销量。你应该使用哪些特征或特征交叉来训练城市特定的汽车类型和销量之间的关系？

You are an ML engineer at a global car manufacture. You need to build an ML model to predict car sales in different cities around the world. Which features or feature crosses should you use to train city-specific relationships between car type and number of sales?

选项

A. 三个独立特征：分箱的纬度，分箱的经度，和独热编码的汽车类型。

Thee individual features: binned latitude, binned longitude, and one-hot encoded car type.

B. 一个由纬度、经度和汽车类型之间的元素级乘积获得的特征。

One feature obtained as an element-wise product between latitude, longitude, and car type.

C. 一个由分箱的纬度、分箱的经度和独热编码的汽车类型之间的元素级乘积获得的特征。

One feature obtained as an element-wise product between binned latitude, binned longitude, and one-hot encoded car type.

D. 两个特征交叉作为元素级乘积：第一个是分箱的纬度和独热编码的汽车类型之间的交叉，第二个是分箱的经度和独热编码的汽车类型之间的交叉。

Two feature crosses as an element-wise product: the first between binned latitude and one-hot encoded car type, and the second between binned longitude and one-hot encoded car type.

正确答案：D. Two feature crosses as an element-wise product: the first between binned latitude and one-hot encoded car type, and the second between binned longitude and one-hot encoded car type.

解析： 这个问题测试如何有效地设计特征来捕捉地理位置与产品类型之间的关系，这对于预测不同地区的销售模式至关重要。

选项D是最佳解决方案，原因如下：

1. **有效捕捉地理相关性**：
    - 通过将地理位置分解为纬度和经度两个独立的组件，模型可以分别学习南北方向和东西方向的销售模式
    - 分箱操作将连续的经纬度值转换为离散类别，使模型更容易发现区域模式
    - 这种方法能够有效捕捉如"SUV在北方地区更受欢迎"或"小型车在拥挤的沿海城市更受欢迎"等模式
2. **更精细的交互建模**：
    - 使用两个单独的特征交叉而不是一个三向交叉，允许模型分别学习汽车类型与纬度和经度的关系
    - 这种分解降低了模型需要学习的复杂性，减少了需要的训练数据量
    - 它还降低了特征空间的稀疏性，这在处理高维分类特征(如汽车类型)时特别重要
3. **实际应用的合理性**：
    - 在实际应用中，某些类型的汽车可能在特定纬度带（如寒冷地区的四轮驱动车）或特定经度区域（如欧洲与美洲的不同偏好）表现不同
    - 这种方法允许模型单独捕捉这些模式，而不必同时学习更复杂的三维关系

其他选项存在的问题：

- 选项A使用独立特征，没有捕捉汽车类型与地理位置之间的交互关系
- 选项B使用原始经纬度值，未经过分箱处理的连续地理坐标很难有效捕捉区域模式
- 选项C尝试在单个特征中捕捉所有三个变量之间的交互，这会创建一个过于稀疏和复杂的特征空间，需要更多数据才能有效学习

通过使用两个有针对性的特征交叉，选项D在捕捉复杂的地理销售模式和保持模型可训练性之间取得了最佳平衡。

问题 135

题目

你在一家大型科技公司工作，该公司想要现代化其联络中心。你被要求开发一个解决方案，按产品对传入的电话进行分类，以便更快地将请求路由到正确的支持团队。你已经使用Speech-to-Text API转录了通话内容。你希望最小化数据预处理和开发时间。你应该如何构建这个模型？

You work for a large technology company that wants to modernize their contact center. You have been asked to develop a solution to classify incoming calls by product so that requests can be more quickly routed to the correct support team. You have already transcribed the calls using the Speech-to-Text API. You want to minimize data preprocessing and development time. How should you build the model?

选项

A. 使用AI Platform Training内置算法创建自定义模型。

Use the AI Platform Training built-in algorithms to create a custom model.

B. 使用AutoML Natural Language提取自定义实体进行分类。

Use AutoML Natural Language to extract custom entities for classification.

C. 使用Cloud Natural Language API提取自定义实体进行分类。

Use the Cloud Natural Language API to extract custom entities for classification.

D. 构建一个自定义模型来识别转录通话中的产品关键词，然后通过分类算法运行这些关键词。

Build a custom model to identify the product keywords from the transcribed calls, and then run the keywords through a classification algorithm.

正确答案：B. Use AutoML Natural Language to extract custom entities for classification.

解析： 这个问题测试如何在最小化数据预处理和开发时间的情况下，为联络中心构建有效的通话分类解决方案。

选项B是最佳解决方案，原因如下：

1. **自定义分类的能力**：
    - AutoML Natural Language专门设计用于开发自定义文本分类模型，无需编写代码
    - 它允许你训练模型识别公司特定的产品名称和类别，这对于识别各种产品提及（包括非正式称呼和缩写）非常重要
    - 通过提供带标签的示例，你可以教会模型识别与特定产品相关的各种表达方式
2. **开发时间最小化**：
    - 尽管需要一些初始设置和训练数据，但相比开发完全自定义的模型，AutoML大大简化了流程
    - 它消除了特征工程、模型架构设计和模型训练代码的需要

    - 通过简单的界面，你可以上传数据、添加标签并启动训练过程

3. **与Google Cloud服务的集成**：
    - AutoML Natural Language与其他Google Cloud服务（包括已使用的Speech-to-Text API）无缝集成
    - 训练好的模型可以通过API轻松部署和使用
    - 这种集成简化了从通话转录到分类再到路由的端到端工作流

其他选项存在的问题：

- 选项A（AI Platform Training内置算法）需要更多的数据准备、特征工程和模型训练工作，与最小化开发时间的目标相矛盾
- 选项C（Cloud Natural Language API）虽然提供预构建的实体分析，但只能识别预定义的实体类型（如人物、组织、地点等），不支持识别自定义产品类别
- 选项D要求构建两个自定义模型（一个用于关键词提取，一个用于分类），这大大增加了开发时间和复杂性

AutoML Natural Language为这种场景提供了最佳平衡，它允许创建自定义分类模型来识别特定于产品的实体，同时最小化了开发时间和数据预处理需求。

问题 136

题目

你正在使用TensorFlow训练一个模型，该模型基于存储在多个CSV文件中的1000亿条结构化数据记录。你需要提高输入/输出执行性能。你应该怎么做？

You are training a TensorFlow model on a structured dataset with 100 billion records stored in several CSV files. You need to improve the input/output execution performance. What should you do?

选项

A. 将数据加载到BigQuery中，然后从BigQuery读取数据。

Load the data into BigQuery, and read the data from BigQuery.

B. 将数据加载到Cloud Bigtable中，然后从Bigtable读取数据。

Load the data into Cloud Bigtable, and read the data from Bigtable.

C. 将CSV文件转换为TFRecord分片，并将数据存储在Cloud Storage中。

Convert the CSV files into shards of TFRecords, and store the data in Cloud Storage.

D. 将CSV文件转换为TFRecord分片，并将数据存储在Hadoop分布式文件系统(HDFS)中。

Convert the CSV files into shards of TFRecords, and store the data in the Hadoop Distributed File System (HDFS).

正确答案：C. Convert the CSV files into shards of TFRecords, and store the data in Cloud Storage.

解析： 这个问题测试如何优化TensorFlow训练中的数据输入/输出性能，尤其是处理大规模结构化数据集时。

选项C是最佳解决方案，原因如下：

1. **TFRecord格式的优势**：
    - TFRecord是TensorFlow专用的二进制数据格式，专门设计用于高效的数据输入/输出操作
    - 它支持高效的序列化和反序列化，减少了数据加载期间的CPU开销
    - 与CSV等文本格式相比，二进制格式占用空间更小，读取速度更快
    - TFRecord支持压缩，可以进一步减少存储需求和数据传输时间
2. **数据分片的重要性**：
    - 将1000亿条记录拆分为多个TFRecord分片允许并行读取和处理
    - 分片还使数据集能够更有效地分布在多个训练节点上
    - 对于TensorFlow的`tf.data`API，分片允许更好的数据预取和缓冲策略
    - 分片大小可以针对特定的训练需求进行优化
3. **Cloud Storage的适用性**：
    - Cloud Storage提供高吞吐量的对象存储，非常适合TFRecord文件
    - 它无缝集成了Google Cloud的机器学习服务（如Vertex AI训练）
    - 与其他选项相比，它提供了最简单的设置和管理体验
    - 它允许数据随时可用，不需要额外的数据移动或复制操作

其他选项存在的问题：

- 选项A（BigQuery）虽然是查询和分析的强大工具，但不是为机器学习训练的高吞吐量数据访问模式优化的
- 选项B（Bigtable）是一个NoSQL数据库，适用于键值存储，但不是为TensorFlow训练工作流优化的
- 选项D使用HDFS，这在Google Cloud环境中需要额外设置和管理Hadoop集群，增加了不必要的复杂性

使用Cloud Storage中存储的TFRecord是TensorFlow官方推荐的处理大规模数据集的方法，特别是在Google Cloud环境中。它提供了最佳的性能、可扩展性和易用性组合，尤其是对于1000亿条记录这样的大规模数据集。

问题 137

题目

作为公司的首席ML工程师，你负责构建ML模型来数字化扫描的客户表单。你已经开发了一个TensorFlow模型，可以将扫描图像转换为文本并存储在Cloud Storage中。你需要在每天结束时对收集的聚合数据使用你的ML模型，并且需要最少的人工干预。你应该怎么做？

As the lead ML Engineer for your company, you are responsible for building ML models to digitize scanned customer forms. You have developed a TensorFlow model that converts the scanned images into text and stores them in Cloud Storage. You need to use your ML model on the aggregated data collected at the end of each day with minimal manual intervention. What should you do?

选项

A. 使用AI Platform的批量预测功能。

Use the batch prediction functionality of AI Platform.

B. 在Compute Engine中创建用于预测的服务管道。

Create a serving pipeline in Compute Engine for prediction.

C. 每当新数据点被摄取时，使用Cloud Functions进行预测。

Use Cloud Functions for prediction each time a new data point is ingested.

D. 在AI Platform上部署模型并为在线推理创建一个版本。

Deploy the model on AI Platform and create a version of it for online inference.

正确答案：A. Use the batch prediction functionality of AI Platform.

解析： 这个问题测试如何设计一个自动化的工作流，以最少的人工干预处理定期聚合的数据。

选项A是最佳解决方案，原因如下：

1. **批处理的合适性**：
    - 场景明确指出数据是"在每天结束时"聚合的，这是一个典型的批处理场景
    - AI Platform的批量预测功能专为这种周期性批处理任务设计
    - 它可以处理存储在Cloud Storage中的大量数据，正如题目所述的"扫描图像转换为文本并存储在Cloud Storage中"
    - 批量预测可以被调度为自动运行，符合"最少的人工干预"的要求
2. **操作简便性和可靠性**：
    - 批量预测功能提供了内置的错误处理和重试机制
    - 不需要管理基础设施，减少了维护开销
    - 可以轻松扩展以处理不同大小的批次
    - 提供了监控和日志记录功能，便于故障排除
3. **无缝TensorFlow集成**：
    - AI Platform原生支持TensorFlow模型
    - 题目提到你已经开发了一个TensorFlow模型
    - 你可以直接使用现有模型，无需额外的转换或适配

其他选项存在的问题：

- 选项B（Compute Engine服务管道）需要更多的基础设施设置和维护，与"最少的人工干预"的要求不符
- 选项C（Cloud Functions）更适合实时处理单个数据点，而不是处理聚合的批量数据
- 选项D（在线推理）也是为实时预测而设计的，不适合每天一次的批量处理场景

AI Platform的批量预测功能是处理这种定期聚合数据的理想选择，它提供了自动化、扩展性和最少的运营开销，同时与TensorFlow模型无缝集成。

问题 138

题目

你最近加入了一家拥有数千个数据集的企业级公司。你知道BigQuery中每个表都有准确的描述，你正在寻找适合在AI Platform上构建模型的BigQuery表。你应该如何找到你需要的数据？

You recently joined an enterprise-scale company that has thousands of datasets. You know that there are accurate descriptions for each table in BigQuery, and you are searching for the proper BigQuery table to use for a model you are building on AI Platform. How should you find the data that you need?

选项

A. 使用Data Catalog通过表描述中的关键词搜索BigQuery数据集。

Use Data Catalog to search the BigQuery datasets by using keywords in the table description.

B. 在AI Platform上为每个模型和版本资源添加标签，标明用于训练的BigQuery表名称。

Tag each of your model and version resources on AI Platform with the name of the BigQuery table that was used for training.

C. 在BigQuery中维护一个查找表，映射表描述到表ID。查询此查找表以找到你需要的数据的正确表ID。

Maintain a lookup table in BigQuery that maps the table descriptions to the table ID. Query the lookup table to find the correct table ID for the data that you need.

D. 在BigQuery中执行查询，使用BigQuery原生的INFORMATION_SCHEMA元数据表检索项目中所有现有的表名。使用结果找到你需要的表。

Execute a query in BigQuery to retrieve all the existing table names in your project using the INFORMATION_SCHEMA metadata tables that are native to BigQuery. Use the result to find the table that you need.

正确答案：A. Use Data Catalog to search the BigQuery datasets by using keywords in the table description.

解析： 这个问题测试如何在拥有大量数据的企业环境中高效地发现和检索适当的数据集。

选项A是最佳解决方案，原因如下：

1. **Data Catalog的专用功能**：
   - Data Catalog是Google Cloud的一项元数据管理服务，专门设计用于数据发现和管理
   - 它允许用户搜索、标记和了解组织内的所有数据资产
   - 它提供了强大的搜索功能，可以根据表描述、列名、标签等查找数据资源
   - 对于"数千个数据集"的场景，这是唯一能提供足够搜索能力的解决方案
2. **利用现有表描述的优势**：
   - 题目明确指出"BigQuery中每个表都有准确的描述"
   - Data Catalog能够索引这些描述并使其可搜索
   - 这允许你使用与你的模型相关的领域特定关键词直接查找合适的表
   - 无需额外的设置或维护工作即可利用这些现有的表描述
3. **企业级数据治理**：
   - Data Catalog支持企业级数据治理实践

    - 它与BigQuery无缝集成，自动索引所有数据集和表
    - 它支持详细的访问控制，确保用户只能看到他们有权访问的数据资源
    - 作为一个全托管服务，它为大型企业提供了所需的可扩展性和可靠性

其他选项存在的问题：

- 选项B（添加标签到AI Platform资源）是一种反向方法，它只能帮助你跟踪已经找到并用于训练的表，而不能帮助你找到新的、适合你需求的表
- 选项C（维护查找表）需要创建和维护额外的表，在有数千个数据集的环境中是不可行的，而且容易过时
- 选项D（使用INFORMATION_SCHEMA）只能列出表名，不提供对表描述的搜索能力，在数千个数据集中手动查找合适的表是极其低效的

Data Catalog专为解决大型企业的数据发现问题而设计，它充分利用了现有的表描述，使其成为这种场景下寻找合适数据集的理想选择。

问题 139

题目

你开始处理一个时间序列数据的分类问题，仅仅经过几次实验就在训练数据上获得了99%的ROC曲线下面积（AUC ROC）值。你还没有尝试使用任何复杂的算法或花时间进行超参数调优。你下一步应该怎么做来识别和解决问题？

You started working on a classification problem with time series data and achieved an area under the receiver operating characteristic curve (AUC ROC) value of 99% for training data after just a few experiments. You haven't explored using any sophisticated algorithms or spent any time on hyperparameter tuning. What should your next step be to identify and fix the problem?

选项

A. 通过使用更简单的算法来解决模型过拟合问题。

Address the model overfitting by using a less complex algorithm.

B. 通过在模型训练期间应用嵌套交叉验证来解决数据泄露问题。

Address data leakage by applying nested cross-validation during model training.

C. 通过移除与目标值高度相关的特征来解决数据泄露问题。

Address data leakage by removing features highly correlated with the target value.

D. 通过调整超参数来降低AUC ROC值，从而解决模型过拟合问题。

Address the model overfitting by tuning the hyperparameters to reduce the AUC ROC value.

正确答案：B. Address data leakage by applying nested cross-validation during model training.

解析： 这个问题关注时间序列分类模型中常见的数据泄露问题，尤其是当模型在训练数据上表现异常好时。

选项B是最佳解决方案，原因如下：

1. **嵌套交叉验证的优势**：
    - 嵌套交叉验证包含一个外部循环用于评估模型性能和一个内部循环用于模型选择和超参数调优
    - 它能有效隔离训练数据和验证数据，防止信息泄露
    - 在时间序列数据中尤其重要，因为传统的交叉验证可能导致未来数据泄露到过去的训练中
    - 它提供了一个更严格和可靠的评估框架，能够揭示真实的模型性能
2. **系统性检测数据泄露**：
    - 99%的AUC-ROC值在仅做少量实验的情况下是异常高的，这通常表明存在数据泄露
    - 嵌套交叉验证通过确保每个数据点仅在正确的位置使用一次，有效预防和检测数据泄露
    - 它可以识别模型是否真正学习到了有意义的模式，还是仅仅利用了泄露的信息
    - 如果在嵌套交叉验证下性能显著下降，则明确确认存在数据泄露问题
3. **时间序列数据的正确处理**：
    - 时间序列数据需要特殊的验证方法来维护时间顺序的完整性
    - 嵌套交叉验证可以配置为时间序列分割，确保模型仅使用过去的数据预测未来
    - 这模拟了真实世界的预测场景，提供了更准确的性能评估
    - 它比简单地删除某些特征更系统化，因为它可以发现所有形式的数据泄露，而不仅仅是高相关性特征

其他选项存在的问题：

- 选项A（使用更简单的算法）可能会减少过拟合，但不会直接解决数据泄露问题
- 选项C（移除高相关性特征）虽然在某些情况下有效，但过于简化且可能移除真正有价值的特征，并不能系统地解决所有形式的数据泄露
- 选项D（调整超参数降低AUC）是一种不当做法，人为降低模型性能而不解决实际问题

嵌套交叉验证提供了一个系统的框架来理解和解决时间序列数据中的数据泄露问题，确保模型性能的评估符合实际预测场景，避免了过度乐观的性能估计。

问题 140

题目

你在一家在线旅行社工作，该公司同时向其他公司销售其网站上的广告位。你被要求预测用户下一步应该看到的最相关网页横幅。安全性对于你的公司很重要。模型延迟要求为300ms@p99，库存中有数千个网页横幅，而你的探索性分析表明导航上下文是一个良好的预测因素。你想要实现最简单的解决方案。你应该如何配置预测管道？

You work for an online travel agency that also sells advertising placements on its website to other companies. You have been asked to predict the most relevant web banner that a user should see next. Security is important to your company. The model latency requirements are 300ms@p99, the inventory is thousands of web banners, and your exploratory analysis has shown that navigation context is a good predictor. You want to implement the simplest solution. How should you configure the prediction pipeline?

选项

A. 在网站上嵌入客户端，然后在AI Platform Prediction上部署模型。

Embed the client on the website, and then deploy the model on AI Platform Prediction.

B. 在网站上嵌入客户端，在App Engine上部署网关，然后在AI Platform Prediction上部署模型。

Embed the client on the website, deploy the gateway on App Engine, and then deploy the model on AI Platform Prediction.

C. 在网站上嵌入客户端，在App Engine上部署网关，在Cloud Bigtable上部署数据库用于写入和读取用户的导航上下文，然后在AI Platform Prediction上部署模型。

Embed the client on the website, deploy the gateway on App Engine, deploy the database on Cloud Bigtable for writing and for reading the user's navigation context, and then deploy the model on AI Platform Prediction.

D. 在网站上嵌入客户端，在App Engine上部署网关，在Memorystore上部署数据库用于写入和读取用户的导航上下文，然后在Google Kubernetes Engine上部署模型。

Embed the client on the website, deploy the gateway on App Engine, deploy the database on Memorystore for writing and for reading the user's navigation context, and then deploy the model on Google Kubernetes Engine.

正确答案：B. Embed the client on the website, deploy the gateway on App Engine, and then deploy the model on AI Platform Prediction.

解析： 这个问题测试如何为需要低延迟预测的在线广告系统设计一个简单而有效的架构。

选项B是最佳解决方案，原因如下：

1. **满足延迟要求的简洁架构**：
    - 题目明确要求300ms@p99的延迟，这意味着99%的请求必须在300毫秒内完成
    - 该架构包含三个关键组件：网站上的客户端、App Engine上的网关和AI Platform Prediction上的模型
    - 这种设计保持简单，减少了组件间通信的开销，有助于满足严格的延迟要求
    - App Engine能够自动扩展以处理流量波动，确保在高负载下仍能维持低延迟
2. **安全性考虑**：
    - 题目强调安全性很重要，App Engine网关提供了一个安全层
    - 网关可以处理身份验证、授权和请求验证，保护后端模型服务免受直接暴露
    - 它可以实现速率限制和其他安全控制，防止滥用
    - 这种架构使客户端不直接与预测模型交互，减少了潜在的攻击面
3. **简单性和可维护性**：
    - 题目明确要求"最简单的解决方案"
    - 选项B提供了足够的功能，同时保持了架构的简单性
    - 它避免了不必要的复杂组件，如选项C和D中的额外数据库层
    - 更简单的架构意味着更少的维护开销和更低的故障风险

其他选项存在的问题：

- 选项A过于简化，缺少网关层，这会限制安全控制和灵活性，难以实现导航上下文的处理

- 选项C引入了Cloud Bigtable作为存储导航上下文的数据库，这增加了不必要的复杂性，因为导航上下文可以作为请求的一部分直接从客户端传递
- 选项D不仅添加了Memorystore数据库，还将模型部署在GKE上，这需要更多的基础设施管理，与"最简单解决方案"的要求不符

选项B在满足性能和安全需求的同时保持了简单性，提供了一个易于实现和维护的架构，特别适合题目所述的场景。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 15)

问题 141

题目

你的团队正在从头构建一个基于卷积神经网络（CNN）的架构。在本地CPU环境上运行的初步实验结果令人鼓舞，但收敛速度较慢。你被要求加速模型训练以减少上市时间。你想在Google Cloud上使用虚拟机（VM）来利用更强大的硬件。你的代码不包含任何手动设备放置，也没有使用Estimator模型级抽象进行封装。你应该在哪种环境中训练你的模型？

Your team is building a convolutional neural network (CNN)-based architecture from scratch. The preliminary experiments running on your on premises CPU-only infrastructure were encouraging, but have slow convergence. You have been asked to speed up model training to reduce time-to-market. You want to experiment with virtual machines (VMs) on Google Cloud to leverage more powerful hardware. Your code does not include any manual device placement and has not been wrapped in Estimator model-level abstraction. Which environment should you train your model on?

选项

A. Compute Engine上的AVM，配备1个TPU，并手动安装所有依赖项。

AVM on Compute Engine and 1 TPU with all dependencies installed manually.

B. Compute Engine上的AVM，配备8个GPU，并手动安装所有依赖项。

AVM on Compute Engine and 8 GPUs with all dependencies installed manually.

C. 配备n1-standard-2机器和1个GPU的Deep Learning VM，预装所有库。

A Deep Learning VM with an n1-standard-2 machine and 1 GPU with all libraries pre-installed.

D. 配备更强大CPU的Deep Learning VM（e2-highcpu-16机器），预装所有库。

A Deep Learning VM with more powerful CPU e2-highcpu-16 machines with all libraries pre-installed.

正确答案：C. A Deep Learning VM with an n1-standard-2 machine and 1 GPU with all libraries pre-installed.

解析： 这个问题测试如何为深度学习工作负载选择合适的计算环境，特别是在需要加速CNN训练的情况下。

选项C是最佳解决方案，原因如下：

1. **GPU加速的必要性**：
    - CNN训练通常是计算密集型的，GPU加速可以显著提高训练速度
    - 从CPU环境迁移到GPU环境是加速深度学习训练的最直接方法
    - GPU对卷积操作特别高效，可以并行处理大量矩阵计算
    - 即使单个GPU也能提供比多核CPU快数倍到数十倍的训练速度
2. **Deep Learning VM的便利性**：
    - Deep Learning VM是Google Cloud上预配置的虚拟机镜像，专为机器学习任务设计
    - 它预装了流行的深度学习框架（如TensorFlow、PyTorch）和必要的依赖项
    - 这大大减少了环境设置时间，让你可以快速开始实验
    - 避免了手动安装和配置GPU驱动、CUDA、cuDNN等复杂依赖项的麻烦
3. **初始实验的资源平衡**：
    - n1-standard-2机器（2个vCPU，7.5GB内存）和1个GPU提供了良好的成本效益比
    - 对于初步实验和从CPU迁移到GPU的探索阶段，这是合理的规模
    - 这种配置允许你快速验证GPU加速的效果，然后在需要时扩展到更强大的配置
    - 由于代码是从头开始构建的，可能需要一些调整以充分利用GPU，从单GPU开始更容易调试

其他选项存在的问题：

- 选项A（TPU）虽然强大，但对于未经优化的自定义CNN代码可能过于复杂，并且需要特定的代码调整才能充分利用
- 选项B（8个GPU）对于初始实验而言可能过于昂贵，而且需要额外的并行化代码才能有效利用多GPU
- 选项D只提供了更强的CPU，没有GPU加速，这对于加速CNN训练的效果有限

从未经优化的CPU代码迁移到GPU环境时，Deep Learning VM with 1 GPU提供了最佳的平衡点，结合了易用性、成本效益和显著的性能提升，同时避免了过度复杂的设置。

问题 142

题目

你在一个拥有50多名数据科学家的团队工作，他们都使用AI Platform。你正在设计一个策略，以一种干净且可扩展的方式组织你们的作业、模型和版本。你应该选择哪种策略？

You work on a growing team of more than 50 data scientists who all use AI Platform. You are designing a strategy to organize your jobs, models, and versions in a clean and scalable way. Which strategy should you choose?

选项

A. 在AI Platform笔记本上设置限制性IAM权限，以便只有单个用户或组可以访问给定实例。

Set up restrictive IAM permissions on the AI Platform notebooks so that only a single user or group can access a given instance.

B. 将每个数据科学家的工作分离到不同的项目中，以确保每个数据科学家创建的作业、模型和版本只能被该用户访问。

Separate each data scientist's work into a different project to ensure that the jobs, models, and versions created by each data scientist are accessible only to that user.

C. 使用标签将资源组织成描述性类别。为每个创建的资源应用标签，以便用户在查看或监控资源时可以按标签过滤结果。

Use labels to organize resources into descriptive categories. Apply a label to each created resource so that users can filter the results by label when viewing or monitoring the resources.

D. 为Cloud Logging日志设置一个BigQuery接收器，该接收器经过适当过滤以捕获有关AI Platform资源使用情况的信息。在BigQuery中，创建一个将用户映射到他们正在使用的资源的SQL视图。

Set up a BigQuery sink for Cloud Logging logs that is appropriately filtered to capture information about AI Platform resource usage. In BigQuery, create a SQL view that maps users to the resources they are using.

正确答案：C. Use labels to organize resources into descriptive categories. Apply a label to each created resource so that users can filter the results by label when viewing or monitoring the resources.

解析： 这个问题测试如何为大型数据科学团队设计一个可扩展的AI Platform资源组织策略。

选项C是最佳解决方案，原因如下：

1. **标签的灵活性和可扩展性**：
    - 标签提供了一种灵活且可扩展的方式来组织云资源，无需创建复杂的层次结构
    - 可以应用多个标签来表示不同的分类维度（如项目、团队、环境、目的等）
    - 随着团队和资源的增长，标签系统可以轻松扩展以适应新的组织需求
    - 标签不影响资源的功能，仅用于组织和过滤目的
2. **资源可见性和协作**：
    - 使用标签允许团队成员查看和过滤所有资源，促进知识共享和协作
    - 数据科学家可以轻松找到与特定项目、模型类型或业务领域相关的资源
    - 这种方法支持跨团队协作和资源共享，避免创建信息孤岛
    - 管理者可以获得团队工作的全局视图，同时仍能按需过滤特定类别
3. **运营效率**：
    - 标签可以与Google Cloud的监控、日志记录和计费系统集成
    - 这使团队能够按项目、团队或其他维度跟踪资源使用情况和成本
    - 可以设置基于标签的提醒和仪表板，以监控特定类别的资源性能
    - 对于大型团队，这显著简化了资源管理和成本归因

其他选项存在的问题：

- 选项A（限制性IAM权限）主要关注访问控制而非资源组织，不解决资源分类和可发现性问题
- 选项B（分离到不同项目）会创建管理开销和孤岛，阻碍协作和资源共享，不是一个可扩展的长期解决方案
- 选项D（BigQuery日志分析）是一个监控解决方案，不是组织资源的主要策略；它可能作为补充但不能替代直接的资源组织方法

在大型数据科学团队中，使用标签提供了组织性和灵活性的最佳平衡，使团队成员能够有效管理和发现资源，同时促进协作和知识共享。

问题 143

题目

你正在训练一个用于语义图像分割的深度学习模型，希望减少训练时间。在使用Deep Learning VM镜像时，你收到以下错误：资源'projects/deeplearning-platform/zones/europe-west4-c/acceleratorTypes/nvidia-tesla-k80'未找到。你应该怎么做？

You are training a deep learning model for semantic image segmentation with reduced training time. While using a Deep Learning VM Image, you receive the following error: The resource 'projects/deeplearning-platform/zones/europe-west4-c/acceleratorTypes/nvidia-tesla-k80' was not found. What should you do?

选项

A. 确保你在所选区域中有GPU配额。

Ensure that you have GPU quota in the selected region.

B. 确保所需的GPU在所选区域中可用。

Ensure that the required GPU is available in the selected region.

C. 确保你在所选区域中有抢占式GPU配额。

Ensure that you have preemptible GPU quota in the selected region.

D. 确保所选GPU有足够的GPU内存用于工作负载。

Ensure that the selected GPU has enough GPU memory for the workload.

正确答案：B. Ensure that the required GPU is available in the selected region.

解析： 这个问题测试如何诊断和解决Google Cloud中与GPU可用性相关的错误。

选项B是最佳解决方案，原因如下：

1. **错误消息的明确指示**：
    - 错误消息直接表明特定资源（nvidia-tesla-k80加速器类型）在特定区域（europe-west4-c）未找到
    - 这通常表示所请求的GPU类型在该特定区域不可用
    - 资源路径中提到的是区域特定资源，指向了可用性问题而非配额问题
    - 不同的GPU型号在Google Cloud的不同区域有不同的可用性
2. **解决方案的针对性**：
    - 选择在提供nvidia-tesla-k80 GPU的区域创建VM是解决此错误的直接方法
    - 或者，可以选择在当前区域使用不同的GPU类型（如nvidia-tesla-p100或nvidia-tesla-v100）
    - 这需要检查哪些GPU类型在特定区域可用，并相应地调整请求

3. **区域限制的理解**：
    - Google Cloud的硬件资源在不同区域有不同的可用性
    - 一些较旧的GPU型号（如K80）可能不在所有区域提供
    - 理解这些区域限制对于成功部署云资源至关重要
    - 在创建具有特定加速器类型的VM之前，需要验证该加速器在目标区域是否可用

其他选项存在的问题：

- 选项A（确保GPU配额）虽然配额是必要的，但错误消息明确指示的是资源不存在问题，而非配额限制
- 选项C（确保抢占式GPU配额）与错误消息无关，因为消息没有提到抢占式实例
- 选项D（确保足够的GPU内存）假设GPU已经存在但内存不足，而错误消息清楚地表明整个资源（GPU类型）不存在

此类错误的解决方案是检查特定GPU型号在哪些区域可用，然后相应地调整部署策略。这种区域特定的资源可用性是云计算中的常见考虑因素。

问题 144

题目

你的团队正在研究一个NLP研究项目，目的是根据作者撰写的文章预测其政治倾向。你有一个结构如下的大型训练数据集：（数据集示例）。你遵循了标准的80%-10%-10%数据分布，分别用于训练、测试和评估子集。在保持80-10-10比例的同时，你应该如何将训练样本分布到训练-测试-评估子集中？

Your team is working on an NLP research project to predict political affiliation of authors based on articles they have written. You have a large training dataset that is structured like this: (Dataset example) You followed the standard 80%-10%-10% data distribution across the training, testing, and evaluation subsets. How should you distribute the training examples across the train-test-eval subsets while maintaining the 80-10-10 proportion?

选项

A. 将文本随机分布到训练-测试-评估子集中：训练集：[TextA1, TextB2, ...] 测试集：[TextA2, TextC1, TextD2, ...] 评估集：[TextB1, TextC2, TextD1, ...]

Distribute texts randomly across the train-test-eval subsets: Train set: [TextA1, TextB2, ...] Test set: [TextA2, TextC1, TextD2, ...] Eval set: [TextB1, TextC2, TextD1, ...]

B. 将作者随机分布到训练-测试-评估子集中：(*) 训练集：[TextA1, TextA2, TextD1, TextD2, ...] 测试集：[TextB1, TextB2, ...] 评估集：[TexC1,TextC2 ...]

Distribute authors randomly across the train-test-eval subsets: (*) Train set: [TextA1, TextA2, TextD1, TextD2, ...] Test set: [TextB1, TextB2, ...] Eval set: [TexC1,TextC2 ...]

C. 将句子随机分布到训练-测试-评估子集中：训练集：[SentenceA11, SentenceA21, SentenceB11, SentenceB21, SentenceC11, SentenceD21 ...] 测试集：[SentenceA12, SentenceA22, SentenceB12, SentenceC22, SentenceC12, SentenceD22 ...] 评估集：[SentenceA13, SentenceA23, SentenceB13, SentenceC23, SentenceC13, SentenceD31 ...]

Distribute sentences randomly across the train-test-eval subsets: Train set: [SentenceA11, SentenceA21, SentenceB11, SentenceB21, SentenceC11, SentenceD21 ...] Test set: [SentenceA12, SentenceA22, SentenceB12, SentenceC22, SentenceC12, SentenceD22 ...] Eval set: [SentenceA13, SentenceA23, SentenceB13, SentenceC23, SentenceC13, SentenceD31 ...]

D. 将文本段落（即连续句子的块）分布到训练-测试-评估子集中：训练集：[SentenceA11, SentenceA12, SentenceD11, SentenceD12 ...] 测试集：[SentenceA13, SentenceB13, SentenceB21, SentenceD23, SentenceC12, SentenceD13 ...] 评估集：[SentenceA11, SentenceA22, SentenceB13, SentenceD22, SentenceC23, SentenceD11 ...]

Distribute paragraphs of texts (i.e., chunks of consecutive sentences) across the train-test-eval subsets: Train set: [SentenceA11, SentenceA12, SentenceD11, SentenceD12 ...] Test set: [SentenceA13, SentenceB13, SentenceB21, SentenceD23, SentenceC12, SentenceD13 ...] Eval set: [SentenceA11, SentenceA22, SentenceB13, SentenceD22, SentenceC23, SentenceD11 ...]

正确答案：B. Distribute authors randomly across the train-test-eval subsets: (*) Train set: [TextA1, TextA2, TextD1, TextD2, ...] Test set: [TextB1, TextB2, ...] Eval set: [TexC1,TextC2 ...]

解析： 这个问题测试如何正确分割NLP数据集，以确保模型评估的有效性，特别是在预测作者属性的任务中。

选项B是最佳解决方案，原因如下：

1. **防止数据泄露**：
    - 将相同作者的所有文本保持在同一子集（训练、测试或评估）中至关重要
    - 如果同一作者的文本出现在训练集和测试/评估集中，会造成数据泄露
    - 模型可能会学习到特定作者的写作风格特征，而不是真正学习政治倾向的通用特征
    - 这种数据泄露会导致过于乐观的性能估计，无法反映模型在新作者上的真实表现
2. **保持泛化能力评估的完整性**：
    - 预测政治倾向的目标是能够准确分析从未见过的作者
    - 通过作者级别划分数据，测试和评估集包含训练期间完全未见过的作者
    - 这能真实评估模型对新作者的泛化能力，符合实际应用场景
    - 若测试集包含训练集中出现过的作者，模型性能可能被高估
3. **避免特征关联问题**：
    - 作者往往在不同文章中保持一致的政治立场和写作风格
    - 同一作者的文章可能包含相似的词汇选择、论证结构和观点表达
    - 通过作者分割，确保模型不会因为记住特定作者的特征而获得不当优势
    - 这种方法鼓励模型学习更通用的政治倾向指标，而非作者特定特征

其他选项存在的问题：

- 选项A（随机分布文本）可能导致同一作者的不同文章分布在不同子集中，创建数据泄露
- 选项C（随机分布句子）会导致严重的数据泄露，因为同一篇文章的句子可能同时出现在训练和测试集中
- 选项D（分布段落）同样导致数据泄露，因为来自同一文章和同一作者的不同段落会出现在不同的数据子集中

在预测与作者相关的属性（如政治倾向、人口统计特征等）的NLP任务中，按作者划分数据集是最佳实践，确保模型评估的有效性和结果的可靠性。

问题 145

题目

你的团队被要求在Google Cloud上创建一个ML解决方案，用于分类平台的支持请求。你分析了需求并决定使用TensorFlow构建分类器，以便对模型的代码、服务和部署有完全控制权。你将使用Kubeflow管道作为ML平台。为了节省时间，你想基于现有资源构建并使用托管服务，而不是构建全新的模型。你应该如何构建这个分类器？

Your team has been tasked with creating an ML solution in Google Cloud to classify support requests for one of your platforms. You analyzed the requirements and decided to use TensorFlow to build the classifier so that you have full control of the model's code, serving, and deployment. You will use Kubeflow pipelines for the ML platform. To save time, you want to build on existing resources and use managed services instead of building a completely new model. How should you build the classifier?

选项

A. 使用Natural Language API来分类支持请求。

Use the Natural Language API to classify support requests.

B. 使用AutoML Natural Language构建支持请求分类器。

Use AutoML Natural Language to build the support requests classifier.

C. 使用AI Platform上的已建立文本分类模型执行迁移学习。

Use an established text classification model on AI Platform to perform transfer learning.

D. 按原样使用AI Platform上的已建立文本分类模型来分类支持请求。

Use an established text classification model on AI Platform as-is to classify support requests.

正确答案：C. Use an established text classification model on AI Platform to perform transfer learning.

解析： 这个问题测试如何在需要控制和开发速度之间找到平衡，为支持请求分类构建ML解决方案。

选项C是最佳解决方案，原因如下：

1. **满足控制需求与时间效率的平衡**：
    - 题目明确指出需要"对模型的代码、服务和部署有完全控制权"
    - 通过迁移学习，你可以基于已有模型构建，同时保持对模型代码的控制
    - 这种方法既满足了定制化需求，又避免了从零开始训练的时间成本
    - 使用已建立的模型作为起点符合"基于现有资源构建"的要求
2. **与TensorFlow和Kubeflow集成**：
    - 迁移学习可以在TensorFlow框架内完成，符合技术选择需求
    - 你可以将模型训练和部署过程集成到Kubeflow管道中

- 这保留了对整个流程的灵活性和可定制性
- AI Platform支持TensorFlow模型，并可以与Kubeflow集成

3. **利用现有资源的优势**：

- 迁移学习利用预训练模型中已经学到的特征
- 这显著减少了所需的训练数据量和计算资源
- 特别适合支持请求分类这类文本分类任务
- 已建立的模型可能已经学习了通用的语言特征，只需要在特定领域进行微调

其他选项存在的问题：

- 选项A（使用Natural Language API）是完全托管的服务，不提供对模型代码和部署的控制
- 选项B（使用AutoML Natural Language）虽然允许自定义模型，但同样不提供对模型内部工作的控制
- 选项D（按原样使用已建立模型）没有任何自定义，无法针对特定的支持请求类型进行优化

迁移学习提供了最佳折衷方案，让你可以利用预训练模型的优势，同时保持对模型代码、训练过程和部署的完全控制，符合题目中的所有关键需求。

问题 146

题目

你最近加入了一个即将发布新项目的机器学习团队。作为项目负责人，你被要求确定ML组件的生产就绪程度。团队已经测试了特征和数据、模型开发以及基础设施。你应该向团队推荐哪项额外的就绪性检查？

You recently joined a machine learning team that will soon release a new project. As a lead on the project, you are asked to determine the production readiness of the ML components. The team has already tested features and data, model development, and infrastructure. Which additional readiness check should you recommend to the team?

选项

A. 确保训练是可重现的。

Ensure that training is reproducible.

B. 确保所有超参数都已调优。

Ensure that all hyperparameters are tuned.

C. 确保对模型性能进行监控。

Ensure that model performance is monitored.

D. 确保在架构中捕获特征期望。

Ensure that feature expectations are captured in the schema.

正确答案：C. Ensure that model performance is monitored.

解析： 这个问题测试ML工程师如何确保机器学习系统在生产环境中的可靠性和可维护性。

选项C是最佳解决方案，原因如下：

1. **生产环境中的持续表现**：
    - 在生产环境中监控模型性能是确保ML系统长期成功的关键
    - 与其他已测试的方面不同，监控涉及模型部署后的持续观察，而不仅仅是部署前的一次性测试
    - 实时监控可以检测数据漂移、模型性能下降或生产环境中出现的任何其他问题
    - 这是一个前瞻性的措施，确保系统在实际使用中持续提供价值
2. **完整的ML生命周期覆盖**：
    - 题目提到团队已经测试了特征、数据、模型开发和基础设施
    - 这些主要是部署前的考虑因素，而监控是部署后的关键组成部分
    - 监控完成了ML系统生命周期的覆盖，从开发到部署再到持续运营
    - 它是连接开发环境和生产环境之间差距的桥梁
3. **响应变化的能力**：
    - 通过监控模型性能，团队可以设置警报并制定预案来应对性能变化
    - 没有适当的监控，模型可能会在生产中静默降级，而团队却毫不知情
    - 监控使团队能够主动而非被动地管理其ML资产
    - 这对于及时重新训练模型或进行必要的干预至关重要

其他选项存在的问题：

- 选项A（训练可重现性）虽然重要，但通常是模型开发阶段的一部分，题目已说明已测试过
- 选项B（超参数调优）是模型开发的子集，题目明确表示已经测试过模型开发
- 选项D（特征期望捕获）与数据测试密切相关，题目表明特征和数据已经测试过

监控是唯一真正在部署后开始的测试类型，确保模型在实际条件下正常运行，并能够及时发现和解决问题。这是ML系统生产就绪性的关键方面。

问题 147

题目

你在一家信用卡公司工作，被要求使用AutoML Tables基于历史数据创建一个自定义欺诈检测模型。你需要优先检测欺诈交易，同时最小化误报。训练模型时你应该使用哪种优化目标？

You work for a credit card company and have been asked to create a custom fraud detection model based on historical data using AutoML Tables. You need to prioritize detection of fraudulent transactions while minimizing false positives. Which optimization objective should you use when training the model?

选项

A. 使用最小化对数损失的优化目标。

An optimization objective that minimizes Log loss.

B. 使用在召回率为0.50时最大化精确率的优化目标。

An optimization objective that maximizes the Precision at a Recall value of 0.50.

C. 使用最大化精确率-召回率曲线下面积(AUC PR)值的优化目标。

An optimization objective that maximizes the area under the precision-recall curve (AUC PR) value.

D. 使用最大化接收者操作特征曲线下面积(AUC ROC)值的优化目标。

An optimization objective that maximizes the area under the receiver operating characteristic curve (AUC ROC) value.

正确答案：C. An optimization objective that maximizes the area under the precision-recall curve (AUC PR) value.

解析： 这个问题测试如何为欺诈检测等高度不平衡分类问题选择合适的评估指标和优化目标。

选项C是最佳解决方案，原因如下：

1. **精确率-召回率权衡的重要性**：
    - 欺诈检测需要同时关注两个关键方面：检测尽可能多的欺诈案例（高召回率）和避免误报（高精确率）
    - 题目明确说明需要"优先检测欺诈交易，同时最小化误报"，这正是精确率和召回率之间的权衡
    - 精确率-召回率曲线(PR曲线)直接展示了这两个指标在不同分类阈值下的权衡关系
    - 通过最大化PR曲线下面积，模型会在这两个目标之间寻找最佳平衡点
2. **适用于不平衡数据集**：
    - 欺诈检测是一个典型的不平衡问题，欺诈案例通常只占所有交易的极小部分
    - 对于不平衡数据集，PR曲线比ROC曲线更能敏感地反映模型性能
    - 当负类（正常交易）数量远大于正类（欺诈交易）时，即使有大量误报，ROC曲线也可能显示良好结果
    - 而PR曲线会明确反映出精确率下降的情况，更适合评估此类不平衡问题
3. **全面的性能度量**：
    - AUC PR提供了在所有可能阈值下的综合性能度量
    - 它不要求选择单一固定的阈值，而是评估模型在不同操作点的表现
    - 这为后续根据业务需求灵活调整决策阈值提供了基础
    - 在实际部署中，可以根据成本-效益分析设定最终阈值

其他选项存在的问题：

- 选项A（最小化对数损失）是一个通用的分类损失函数，没有特别关注欺诈检测问题中的精确率-召回率权衡
- 选项B（在召回率为0.50时最大化精确率）过于特定，只关注单一操作点，忽略了其他可能的阈值选择
- 选项D（最大化AUC ROC）虽然普遍使用，但在高度不平衡的数据集中可能过于乐观，对误报不够敏感

对于信用卡欺诈检测这样的不平衡分类问题，最大化AUC PR能够最好地满足既要检测欺诈又要减少误报的双重要求。

问题 148

题目

你的公司管理着一个视频分享网站，用户可以观看和上传视频。你需要创建一个ML模型来预测哪些新上传的视频会最受欢迎，以便在公司网站上优先展示这些视频。你应该使用哪个结果来确定模型是否成功？

Your company manages a video sharing website where users can watch and upload videos. You need to create an ML model to predict which newly uploaded videos will be the most popular so that those videos can be prioritized on your company's website. Which result should you use to determine whether the model is successful?

选项

A. 如果上传视频的用户获得了超过10,000个赞，模型就会将视频预测为受欢迎。

The model predicts videos as popular if the user who uploads them has over 10,000 likes.

B. 模型根据点击次数预测了97.5%的最受欢迎的点击诱饵视频。

The model predicts 97.5% of the most popular clickbait videos measured by number of clicks.

C. 模型预测了95%的最受欢迎视频，这些视频是按上传后30天内的观看时长衡量的。

The model predicts 95% of the most popular videos measured by watch time within 30 days of being uploaded.

D. 上传后7天和30天的观看次数（经过对数转换）之间的皮尔逊相关系数等于0。

The Pearson correlation coefficient between the log-transformed number of views after 7 days and 30 days after publication is equal to 0.

正确答案：C. The model predicts 95% of the most popular videos measured by watch time within 30 days of being uploaded.

解析： 这个问题测试如何为预测视频流行度的ML模型选择合适的评估指标。

选项C是最佳解决方案，原因如下：

1. **观看时长作为衡量视频质量的关键指标**：
    - 观看时长（watch time）被视频平台广泛认为是衡量视频吸引力和质量的最佳指标
    - 与简单的点击次数或观看次数相比，观看时长能更好地反映用户真正的兴趣和参与度
    - 长观看时长表明用户发现内容有价值，而不仅仅是被点击诱饵吸引
    - 优先推荐高观看时长的视频通常会提高整体用户体验和平台参与度
2. **30天时间窗口的合理性**：
    - 30天提供了足够长的时间来收集足够的用户数据，但又不会过长导致推荐系统反应迟缓
    - 这个时间窗口能捕捉视频的持久吸引力，而不仅仅是短期流行
    - 在视频发布后的30天内评估观看时长，平台可以及时做出决策优先推荐真正受欢迎的内容
    - 许多视频平台分析表明，30天数据与视频长期表现有较强的相关性
3. **95%的预测准确率**：
    - 95%是一个合理高的准确率目标，表明模型能够可靠地识别大多数热门内容
    - 这个准确率水平既有雄心又现实可行，适合作为评估模型成功的标准

    - 该指标与业务目标直接相关：确保受欢迎的视频被识别并优先展示

其他选项存在的问题：

- 选项A仅基于上传者的受欢迎程度，而不是视频本身的质量或吸引力，这忽略了新创作者可能制作的高质量内容
- 选项B专注于点击诱饵视频和点击次数，这可能会降低用户体验，因为高点击率不一定意味着高质量内容
- 选项D描述的是一个相关系数值为0，表明早期观看量与后期观看量之间没有相关性，这实际上表明模型没有预测价值

使用"30天内的观看时长"作为成功指标，使模型专注于识别能够长期吸引用户注意力的高质量内容，这与视频分享平台的核心业务目标高度一致。

问题 149

题目

你正在处理一个基于神经网络的项目。提供给你的数据集包含不同范围的列。在准备数据进行模型训练时，你发现梯度优化在将权重移动到良好解决方案方面遇到困难。你应该怎么做？

You are working on a Neural Network-based project. The dataset provided to you has columns with different ranges. While preparing the data for model training, you discover that gradient optimization is having difficulty moving weights to a good solution. What should you do?

选项

A. 使用特征构建来组合最强的特征。

Use feature construction to combine the strongest features.

B. 使用表示转换（规范化）技术。

Use the representation transformation (normalization) technique.

C. 通过删除具有缺失值的特征来改进数据清洗步骤。

Improve the data cleaning step by removing features with missing values.

D. 更改分区步骤以减少测试集的维度并拥有更大的训练集。

Change the partitioning step to reduce the dimension of the test set and have a larger training set.

正确答案：B. Use the representation transformation (normalization) technique.

解析： 这个问题测试如何解决神经网络训练中因特征范围不同而导致的梯度优化问题。

选项B是最佳解决方案，原因如下：

1. **规范化解决特征不平衡问题**：
    - 当特征具有不同的数值范围时，梯度优化会偏向于范围较大的特征
    - 这导致模型训练过程不稳定，收敛慢或难以找到全局最优解
    - 规范化（如Z-score标准化、Min-Max缩放）将所有特征调整到相似的数值范围

- 这确保每个特征对模型的贡献基于其信息内容，而不是其数值大小

2. **优化神经网络训练过程**：
   - 规范化后的特征可以加速训练收敛，因为梯度更新更加平衡
   - 这有助于避免在训练过程中出现的梯度爆炸或消失问题
   - 对于使用梯度下降的算法（如大多数神经网络训练）尤其重要
   - 许多神经网络架构中，规范化已成为标准预处理步骤
3. **实际应用价值**：
   - 规范化是一种简单但强大的转换，不会丢失原始特征中的信息
   - 它可以与各种神经网络架构和训练算法兼容
   - 在生产环境中，可以轻松将相同的规范化参数应用于新数据

其他选项存在的问题：

- 选项A（特征构建）可能有用，但不直接解决不同范围导致的梯度问题
- 选项C（删除缺失值特征）处理的是数据完整性问题，而非范围差异问题
- 选项D（改变分区步骤）改变的是训练/测试集大小，不会影响特征范围差异问题

使用规范化是机器学习特别是深度学习中的最佳实践，尤其当数据集包含不同尺度的特征时。这是解决题目中描述的梯度优化问题的直接且有效的方法。

问题 150

题目

你的数据科学团队需要快速尝试各种特征、模型架构和超参数。他们需要跟踪各种实验的准确度指标，并使用API随时查询这些指标。他们应该使用什么来跟踪和报告实验，同时最小化手动工作量？

Your data science team needs to rapidly experiment with various features, model architectures, and hyperparameters. They need to track the accuracy metrics for various experiments and use an API to query the metrics over time. What should they use to track and report their experiments while minimizing manual effort?

选项

A. 使用Kubeflow管道执行实验。导出指标文件，并使用Kubeflow管道API查询结果。

Use Kubeflow Pipelines to execute the experiments. Export the metrics file, and query the results using the Kubeflow Pipelines API.

B. 使用AI Platform Training执行实验。将准确度指标写入BigQuery，并使用BigQuery API查询结果。

Use AI Platform Training to execute the experiments. Write the accuracy metrics to BigQuery, and query the results using the BigQuery API.

C. 使用AI Platform Training执行实验。将准确度指标写入Cloud Monitoring，并使用Monitoring API查询结果。

Use AI Platform Training to execute the experiments. Write the accuracy metrics to Cloud Monitoring, and query the results using the Monitoring API.

D. 使用AI Platform Notebooks执行实验。在共享的Google Sheets文件中收集结果，并使用Google Sheets API查询结果。

Use AI Platform Notebooks to execute the experiments. Collect the results in a shared Google Sheets file, and query the results using the Google Sheets API.

正确答案：A. Use Kubeflow Pipelines to execute the experiments. Export the metrics file, and query the results using the Kubeflow Pipelines API.

解析： 这个问题测试如何为数据科学团队实现高效的实验跟踪和指标查询系统。

选项A是最佳解决方案，原因如下：

1. **Kubeflow管道的实验管理能力**：
    - Kubeflow管道专为机器学习工作流程编排和实验管理而设计
    - 它内置了实验跟踪功能，可以自动记录每次运行的参数、指标和结果
    - 这种端到端的解决方案减少了集成多个系统的复杂性
    - 它提供了结构化的方式来组织、比较和复现实验
2. **自动化和可重复性**：
    - Kubeflow管道支持将整个ML流程（从数据预处理到评估）定义为可重复的工作流
    - 这种自动化显著减少了手动工作量，满足了题目中的关键要求
    - 管道可以参数化，便于快速尝试不同的特征、模型架构和超参数
    - 以代码方式定义的管道确保了实验的可重复性和一致性
3. **综合的API支持**：
    - Kubeflow管道提供了丰富的API，可以以编程方式查询和分析实验结果
    - 这些API允许团队构建自定义仪表板或报告系统
    - 支持按时间、参数或性能指标过滤和比较实验
    - 实验元数据和结果自动存储，便于后续分析

其他选项存在的问题：

- 选项B（AI Platform Training + BigQuery）需要额外的工作来设置和维护数据流，并将实验元数据与结果相关联
- 选项C（AI Platform Training + Cloud Monitoring）虽然对时间序列指标有好处，但不提供全面的实验跟踪功能
- 选项D（AI Platform Notebooks + Google Sheets）需要大量手动工作来维护，容易出错，且不足以支持团队规模的实验跟踪

Kubeflow管道提供了一个集成的平台，用于执行、跟踪和分析ML实验，同时通过自动化和结构化工作流最大限度地减少手动工作。这使其成为要求快速实验和最小化手动工作量的数据科学团队的理想选择。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 16)

问题 151

题目

你在一家银行工作，正在构建一个随机森林模型用于欺诈检测。你的数据集包含交易记录，其中1%被标识为欺诈。哪种数据转换策略可能会提高你的分类器性能？

You work for a bank and are building a random forest model for fraud detection. You have a dataset that includes transactions, of which 1% are identified as fraudulent. Which data transformation strategy would likely improve the performance of your classifier?

选项

A. 将数据写入TFRecords格式。

Write your data in TFRecords.

B. 对所有数值特征进行Z标准化。

Z-normalize all the numeric features.

C. 将欺诈交易过采样10倍。

Oversample the fraudulent transaction 10 times.

D. 对所有分类特征使用独热编码。

Use one-hot encoding on all categorical features.

正确答案：C. Oversample the fraudulent transaction 10 times.

解析： 这个问题测试如何处理高度不平衡的分类问题，特别是在欺诈检测这类少数类别极少的情况下。

选项C是最佳解决方案，原因如下：

1. **解决类别不平衡问题**：
    - 在数据集中只有1%的交易是欺诈的，这是一个严重的类别不平衡问题
    - 在不平衡数据上训练的模型往往偏向于占多数的类别（此例中为非欺诈交易）
    - 过采样少数类（欺诈交易）可以增加它们在训练数据中的表示
    - 这有助于模型更好地学习识别欺诈交易的模式，而不仅仅是预测所有交易都是非欺诈的
2. **随机森林与过采样的适配性**：
    - 随机森林对过采样策略反应良好，特别是在处理不平衡数据时
    - 通过增加少数类样本，树模型在分裂时有更多机会考虑这些案例
    - 由于随机森林构建多棵树并综合它们的预测，过采样有助于确保少数类在不同树的构建过程中得到足够重视
    - 这种方法比简单地调整类别权重更直接，因为它实际上增加了模型可以学习的少数类模式
3. **改善关键指标**：
    - 在欺诈检测中，准确识别欺诈案例（召回率）通常比整体准确率更重要
    - 过采样可以提高模型对欺诈案例的敏感性，提高召回率

    - 同时，与完全平衡数据集相比，10倍的过采样仍保留了一定程度的类别不平衡，有助于保持合理的精确率
    - 这种平衡对于实际的欺诈检测系统至关重要，可以减少误报同时捕获更多真实欺诈

其他选项存在的问题：

- 选项A（TFRecords格式）只是一种文件格式，不直接解决类别不平衡问题；它主要用于优化TensorFlow模型的数据输入流程，与提高分类器性能的关系不大
- 选项B（Z标准化）虽然是有用的预处理步骤，但主要解决特征尺度问题，对严重不平衡的类别分布没有直接作用；随机森林对特征缩放不敏感，这使得此选项的价值进一步降低
- 选项D（独热编码）是处理分类特征的标准方法，但它不解决类别不平衡问题；虽然它对随机森林有用，但与解决1%欺诈交易的检测挑战无关

在欺诈检测等高度不平衡的分类任务中，适当地处理类别不平衡问题比标准的特征工程技术更能显著提高模型性能。过采样是一种简单有效的策略，特别适用于决策树系列算法如随机森林。

问题 152

题目

你正在使用迁移学习基于预训练的EfficientNet模型训练一个图像分类器。你的训练数据集有20,000张图像。你计划每天重新训练一次模型。你需要最小化基础设施成本。你应该使用什么平台组件和配置环境？

You are using transfer learning to train an image classifier based on a pre-trained EfficientNet model. Your training dataset has 20,000 images. You plan to retrain the model once per day. You need to minimize the cost of infrastructure. What platform components and configuration environment should you use?

选项

A. 配备4个V100 GPU和本地存储的Deep Learning VM。

A Deep Learning VM with 4 V100 GPUs and local storage.

B. 配备4个V100 GPU和云存储的Deep Learning VM。

A Deep Learning VM with 4 V100 GPUs and Cloud Storage.

C. 配备V100 GPU节点池和NFS服务器的Google Kubernetes Engine集群。

A Google Kubernetes Engine cluster with a V100 GPU Node Pool and an NFS Server.

D. 使用自定义规模层级、4个V100 GPU和云存储的AI Platform Training作业。

An AI Platform Training job using a custom scale tier with 4 V100 GPUs and Cloud Storage.

正确答案：D. An AI Platform Training job using a custom scale tier with 4 V100 GPUs and Cloud Storage.

解析： 这个问题测试如何为定期执行的机器学习工作负载选择最具成本效益的基础设施。

选项D是最佳解决方案，原因如下：

1. **按需计算资源**：

- AI Platform Training作业是无服务器的，只在实际训练时使用和计费
- 由于模型只需每天重新训练一次，使用随时可用的服务可以避免保持资源常驻带来的成本
- 这种方法避免了支付未使用资源的费用，对于每天只运行一次的工作负载特别有利
- 当作业完成后，所有计算资源都会自动释放，无需手动干预

2. **基础设施管理开销最小化**：

- AI Platform Training自动处理资源的预配和解除预配
- 无需管理底层基础设施，如集群、VM或GPU驱动程序的更新和维护
- 这减少了运营开销和相关的人力成本
- 团队可以专注于模型开发而非基础设施管理

3. **高效的数据和模型管理**：

- 云存储提供了一个持久且可扩展的位置来存储训练数据和模型
- 每次训练运行可以轻松访问最新数据，并将更新后的模型保存回云存储
- 这种设置支持自动化的持续训练工作流程
- 云存储的成本效益优于维护专用的NFS服务器

其他选项存在的问题：

- 选项A（Deep Learning VM with 本地存储）需要持续运行VM，即使在不训练时也会产生费用；本地存储意味着数据持久性问题
- 选项B（Deep Learning VM with 云存储）解决了存储问题，但VM仍需持续运行，浪费大量资源
- 选项C（GKE集群）引入了过多的复杂性，需要管理Kubernetes集群和NFS服务器，对于简单的每日作业来说过于复杂且成本高

虽然定制的AI Platform Training作业可能仍然使用4个V100 GPU（这对于20,000张图像的迁移学习任务可能有些过度），但在给定的选项中，它提供了最佳的成本效益平衡，因为你只在需要时才为这些资源付费。

问题 153

题目

在对数据集进行探索性分析时，你发现分类特征A具有很强的预测能力，但有时会缺失。你应该怎么做？

While conducting an exploratory analysis of a dataset, you discover that categorical feature A has substantial predictive power, but it is sometimes missing. What should you do?

选项

A. 如果缺失值超过15%，则删除特征A。否则，按原样使用特征A。

Drop feature A if more than 15% of values are missing. Otherwise, use feature A as-is.

B. 计算特征A的众数，然后用它替换特征A中的缺失值。

Compute the mode of feature A and then use it to replace the missing values in feature A.

C. 用与特征A具有最高皮尔逊相关性的特征的值替换缺失值。

Replace the missing values with the values of the feature with the highest Pearson correlation with feature A.

D. 为缺失值向分类特征A添加一个额外的类别。创建一个新的二元特征，指示特征A是否缺失。

Add an additional class to categorical feature A for missing values. Create a new binary feature that indicates whether feature A is missing.

正确答案：D. Add an additional class to categorical feature A for missing values. Create a new binary feature that indicates whether feature A is missing.

解析： 这个问题测试如何处理具有高预测能力但存在缺失值的分类特征。

选项D是最佳解决方案，原因如下：

1. **保留最大信息量**：
    - 将缺失值作为一个单独的类别，保留了原始特征的所有可用信息
    - 创建缺失指示器特征，捕获了缺失模式本身可能包含的信息
    - 这种双重方法确保了模型可以利用与特征A相关的所有可能的信号
    - 不会像其他方法那样丢弃或替换潜在有价值的信息
2. **缺失值可能有意义**：
    - 在许多实际场景中，值的缺失本身可能是有预测意义的
    - 例如，某些人口统计特征的缺失可能与某些行为或结果相关
    - 通过创建缺失指示器，模型可以学习这些潜在关系
    - 同时，将缺失作为额外类别允许模型区分真实类别和缺失情况
3. **方法的灵活性**：
    - 这种方法适用于各种模型类型，包括树模型和神经网络
    - 它不对缺失值的分布做出假设
    - 它允许模型自行学习缺失值的最佳处理方式
    - 与其他方法相比，这种方法引入的偏差最小

其他选项存在的问题：

- 选项A（基于阈值删除特征）会完全浪费一个具有"很强预测能力"的特征，这通常是不可取的
- 选项B（众数填充）假设缺失值与最常见值相似，这可能不准确且会引入偏差
- 选项C（基于相关性填充）对分类变量使用皮尔逊相关性是不恰当的；此外，这种方法可能会引入噪声并掩盖真实的缺失模式

处理缺失值时，保留最大信息量并允许模型学习缺失模式通常是最佳策略，特别是当相关特征具有很强的预测能力时。

问题 154

题目

你在一家大型零售商工作，被要求根据顾客的购买习惯对他们进行细分。所有顾客的购买历史记录已上传到BigQuery。你怀疑可能存在几个不同的顾客群体，但你不确定有多少个，也不了解他们行为中的共同点。你希望找到最高效的解决方案。你应该怎么做？

You work for a large retailer and have been asked to segment your customers by their purchasing habits. The purchase history of all customers has been uploaded to BigQuery. You suspect that there may be several distinct customer segments, however you are unsure of how many, and you don't yet understand the commonalities in their behavior. You want to find the most efficient solution. What should you do?

选项

A. 使用BigQuery ML创建k-means聚类模型。让BigQuery自动优化集群数量。

Create a k-means clustering model using BigQuery ML. Allow BigQuery to automatically optimize the number of clusters.

B. 在Dataprep中创建一个引用你的BigQuery表的新数据集。使用Dataprep识别每列内的相似性。

Create a new dataset in Dataprep that references your BigQuery table. Use Dataprep to identify similarities within each column.

C. 使用Data Labeling Service标记BigQuery中的每条客户记录。使用AutoML Tables在标记的数据上训练模型。查看评估指标以了解数据中是否存在潜在模式。

Use the Data Labeling Service to label each customer record in BigQuery. Train a model on your labeled data using AutoML Tables. Review the evaluation metrics to understand whether there is an underlying pattern in the data.

D. 从公司的营销团队获取客户细分列表。使用Data Labeling Service根据该列表标记BigQuery中的每条客户记录。使用Data Studio分析数据集中标签的分布。

Get a list of the customer segments from your company's Marketing team. Use the Data Labeling Service to label each customer record in BigQuery according to the list. Analyze the distribution of labels in your dataset using Data Studio.

正确答案：A. Create a k-means clustering model using BigQuery ML. Allow BigQuery to automatically optimize the number of clusters.

解析： 这个问题测试如何选择合适的方法来发现和分析客户购买行为中的自然分组。

选项A是最佳解决方案，原因如下：

1. **无监督学习的适用性**：
    - 问题陈述明确指出你不确定客户群体的数量，也不了解它们的共同点
    - 这正是无监督学习的典型应用场景，其中k-means聚类是最常用的算法之一
    - 聚类可以发现数据中的自然分组，而不需要预先定义类别或标签
    - 这允许数据自己"说话"，揭示可能无法通过人工分析轻易发现的模式
2. **BigQuery ML的效率**：
    - 使用BigQuery ML直接在存储数据的地方进行分析，无需移动大量数据
    - 这显著提高了处理效率并减少了复杂性
    - BigQuery的内置功能可以自动优化聚类数量，解决了你不确定有多少客户群体的问题
    - 这种方法避免了手动尝试不同聚类数量的迭代过程

3. **数据驱动的决策**：
    - k-means聚类将基于购买历史中的实际模式生成客户细分
    - 这些数据驱动的细分可能揭示营销团队未曾考虑过的新的客户群体
    - 聚类结果可以直接用于个性化营销和产品推荐
    - 得到的细分将反映客户的真实行为，而不是预先定义的假设

其他选项存在的问题：

- 选项B（使用Dataprep）主要是数据准备工具，虽然可以帮助探索数据，但不提供先进的聚类功能
- 选项C（Data Labeling Service + AutoML）要求你已经有标签或需要人工创建标签，这与问题的场景矛盾
- 选项D（从营销团队获取细分）依赖于现有的知识，而不是发现新的数据驱动的细分，这与题目的假设矛盾

在这种情况下，使用BigQuery ML进行k-means聚类是最有效的方法，因为它直接在原数据上操作，自动发现模式，不需要预先知道分组数量，且能高效地处理大规模客户购买历史数据。

问题 155

题目

你最近设计并构建了一个使用特定于组织框架的关键依赖项的自定义神经网络。你需要使用Google Cloud上的托管训练服务来训练这个模型。然而，这些ML框架和相关依赖项不受AI Platform Training支持。此外，你的模型和数据都太大，无法在单台机器上加载。你选择的ML框架使用调度器、工作器和服务器的分布式结构。你应该怎么做？

You recently designed and built a custom neural network that uses critical dependencies specific to your organization's framework. You need to train the model using a managed training service on Google Cloud. However, the ML framework and related dependencies are not supported by AI Platform Training. Also, both your model and your data are too large to fit in memory on a single machine. Your ML framework of choice uses the scheduler, workers, and servers distribution structure. What should you do?

选项

A. 使用AI Platform Training上可用的内置模型。

Use a built-in model available on AI Platform Training.

B. 构建自定义容器，在AI Platform Training上运行作业。

Build your custom container to run jobs on AI Platform Training.

C. 构建自定义容器，在AI Platform Training上运行分布式训练作业。

Build your custom containers to run distributed training jobs on AI Platform Training.

D. 将你的代码重新配置为使用AI Platform Training支持的依赖项的ML框架。

Reconfigure your code to a ML framework with dependencies that are supported by AI Platform Training.

正确答案：C. Build your custom containers to run distributed training jobs on AI Platform Training.

解析： 这个问题测试如何在自定义依赖项和分布式训练需求的情况下选择合适的训练基础设施。

选项C是最佳解决方案，原因如下：

1. **保留自定义依赖项的能力**：
    - 题目强调了这些依赖项是"特定于组织框架的关键依赖项"
    - 自定义容器允许你打包和使用任何所需的依赖项，无论它们是否被AI Platform Training原生支持
    - 这种方法保留了组织特定的ML框架和工具，而不需要重写代码
    - 它允许你在云环境中复制本地开发环境
2. **分布式训练支持**：
    - 题目明确指出模型和数据太大，无法在单台机器上加载，这表明需要分布式训练
    - 你的框架已经使用了"调度器、工作器和服务器"的分布式结构
    - AI Platform Training支持通过自定义容器进行分布式训练，可以处理这种架构
    - 这允许你横向扩展到多台机器，解决内存限制问题
3. **托管服务的好处**：
    - 使用AI Platform Training作为托管服务，你可以获得资源管理、扩展和监控等好处
    - 自定义容器与这些托管服务功能无缝集成
    - 你可以利用Google Cloud的计算能力，同时保持对软件环境的控制
    - 这种方法平衡了自定义需求和托管服务的便利性

其他选项存在的问题：

- 选项A（使用内置模型）要求放弃自定义神经网络，这与需求不符
- 选项B（使用单个容器）忽略了分布式训练的需求，无法解决模型和数据太大的问题
- 选项D（重新配置代码）要求重写或调整模型以使用支持的框架，这可能是不必要的工作量，并可能削弱关键功能

通过构建自定义容器并将其配置为分布式训练，你可以保留组织特定的ML框架和依赖项，同时解决规模问题，这是在这种情况下的最佳平衡。

问题 156

题目

在监控模型训练的GPU利用率时，你发现你的输入管道有一个原生同步实现。训练数据被分割到多个文件中。你想减少输入管道的执行时间。你应该怎么做？

While monitoring your model training's GPU utilization, you discover that you have a native synchronous implementation. The training data is split into multiple files. You want to reduce the execution time of your input pipeline. What should you do?

选项

A. 增加CPU负载。

Increase the CPU load.

B. 为管道添加缓存。

Add caching to the pipeline.

C. 增加网络带宽。

Increase the network bandwidth.

D. 为管道添加并行交错。

Add parallel interleave to the pipeline.

正确答案：D. Add parallel interleave to the pipeline.

解析： 这个问题测试如何优化输入数据管道，特别是在处理分散在多个文件中的训练数据时。

选项D是最佳解决方案，原因如下：

1. **解决同步处理瓶颈**：
    - 问题明确指出你有一个"原生同步实现"，这意味着数据处理是按顺序进行的
    - 同步处理是一个主要瓶颈，特别是当处理多个文件时，因为系统必须等待一个文件处理完成后才能开始下一个
    - 并行交错允许系统同时从多个文件读取和处理数据
    - 这种并行化可以显著减少输入管道的整体延迟
2. **与分布式数据结构的匹配**：
    - 问题指出"训练数据被分割到多个文件中"，这正是并行交错设计要解决的场景
    - 并行交错专门用于从多个源并行读取数据，非常适合这种分布式数据情况
    - 它允许系统在一个文件读取操作等待（例如由于I/O延迟）时处理其他文件
    - 这种方法充分利用了现代存储系统的并行访问能力
3. **GPU利用率的优化**：
    - 题目开头提到了"GPU利用率"，这暗示了一个关键问题：GPU可能处于等待数据的状态
    - 当输入管道不能足够快地提供数据时，GPU利用率会下降
    - 通过并行化数据加载和预处理，可以确保GPU始终有数据可处理
    - 这将提高GPU利用率，进一步减少总体训练时间

其他选项存在的问题：

- 选项A（增加CPU负载）是一个模糊的解决方案，没有明确如何组织增加的处理能力；仅仅增加CPU使用率而不改变流程不太可能解决同步处理问题
- 选项B（添加缓存）对重复访问的数据有用，但不解决初始加载和处理的同步瓶颈
- 选项C（增加网络带宽）假设瓶颈是网络相关的，但问题描述没有暗示这一点；即使网络更快，同步处理仍会限制整体性能

在处理分布在多个文件中的训练数据时，并行交错通过允许并行数据加载和预处理，直接解决了同步实现的限制，是提高输入管道性能的最有效方法。

问题 157

题目

你的数据科学团队正在基于预训练的RestNet模型训练一个用于图像分类的PyTorch模型。你需要执行超参数调优来优化多个参数。你应该怎么做？

Your data science team is training a PyTorch model for image classification based on a pre-trained RestNet model. You need to perform hyperparameter tuning to optimize for several parameters. What should you do?

选项

A. 将模型转换为Keras模型，并运行Keras Tuner作业。

Convert the model to a Keras model, and run a Keras Tuner job.

B. 使用自定义容器在AI Platform上运行超参数调优作业。

Run a hyperparameter tuning job on AI Platform using custom containers.

C. 创建Kubeflow Pipelines实例，并在Katib上运行超参数调优作业。

Create a Kuberflow Pipelines instance, and run a hyperparameter tuning job on Katib.

D. 将模型转换为TensorFlow模型，并在AI Platform上运行超参数调优作业。

Convert the model to a TensorFlow model, and run a hyperparameter tuning job on AI Platform.

正确答案：B. Run a hyperparameter tuning job on AI Platform using custom containers.

解析： 这个问题测试如何为PyTorch模型选择适当的超参数调优方法。

选项B是最佳解决方案，原因如下：

1. **保持原始框架的完整性**：
    - 题目明确指出团队使用的是PyTorch模型，将其转换为其他框架（如选项A和D所建议的）会引入不必要的复杂性和潜在问题
    - 自定义容器允许你使用原生PyTorch环境，保持模型和训练脚本的完整性
    - 这避免了因框架转换可能导致的细微差异和兼容性问题
    - 团队可以继续使用他们已经熟悉的PyTorch工具和生态系统
2. **AI Platform的超参数调优能力**：
    - AI Platform提供了强大的超参数调优服务，支持并行化运行多个训练作业
    - 它可以自动尝试不同的超参数组合，追踪结果，并帮助识别最佳配置
    - 通过自定义容器，可以将这些能力扩展到任何ML框架，包括PyTorch
    - 这提供了一个托管服务的便利性，同时保持完全的框架灵活性
3. **操作简单性和可扩展性**：
    - 与建立和维护完整的Kubeflow基础设施（选项C）相比，使用AI Platform的自定义容器通常更简单
    - 自定义容器可以打包所有必要的依赖项，确保一致的执行环境
    - AI Platform处理调度、资源分配和结果跟踪，减轻了团队的运营负担
    - 它还提供了良好的可扩展性，可以根据需要并行运行多个训练试验

其他选项存在的问题：

- 选项A（转换为Keras并使用Keras Tuner）要求从PyTorch转换到完全不同的框架，这是不必要的工作并可能引入错误
- 选项C（Kubeflow和Katib）虽然技术上可行，但需要设置和维护Kubeflow基础设施，比AI Platform复杂
- 选项D（转换为TensorFlow）与选项A类似，需要不必要的模型转换，增加了复杂性和潜在的问题

在需要为PyTorch模型执行超参数调优时，使用支持自定义容器的AI Platform是平衡灵活性、易用性和可扩展性的最佳选择。

问题 158

题目

你有一大量的书面支持案例，可以分为3个独立的类别：技术支持、账单支持或其他问题。你需要快速构建、测试和部署一个服务，可以自动将未来的书面请求分类到这些类别之一。你应该如何配置这个流水线？

You have a large corpus of written support cases that can be classified into 3 separate categories: Technical Support, Billing Support, or Other Issues. You need to quickly build, test, and deploy a service that will automatically classify future written requests into one of the categories. How should you configure the pipeline?

选项

A. 使用Cloud Natural Language API获取元数据来分类传入的案例。

Use the Cloud Natural Language API to obtain metadata to classify the incoming cases.

B. 使用AutoML Natural Language构建和测试分类器。将模型部署为REST API。

Use AutoML Natural Language to build and test a classifier. Deploy the model as a REST API.

C. 使用BigQuery ML构建和测试逻辑回归模型来分类传入请求。使用BigQuery ML执行推理。

Use BigQuery ML to build and test a logistic regression model to classify incoming requests. Use BigQuery ML to perform inference.

D. 使用Google的BERT预训练模型创建TensorFlow模型。构建和测试分类器，并使用Vertex AI部署模型。

Create a TensorFlow model using Google's BERT pre-trained model. Build and test a classifier, and deploy the model using Vertex AI.

正确答案：B. Use AutoML Natural Language to build and test a classifier. Deploy the model as a REST API.

解析： 这个问题测试如何为文本分类任务选择最合适的技术解决方案，特别强调了快速开发和部署的需求。

选项B是最佳解决方案，原因如下：

1. **快速开发和部署**：
    - AutoML Natural Language提供了一个无代码/低代码解决方案，可以快速训练文本分类模型
    - 它不需要机器学习专业知识或复杂的特征工程，大大缩短了开发时间
    - 题目特别强调需要"快速构建、测试和部署"，AutoML是实现这一目标的理想选择

    - 自动将模型部署为REST API进一步简化了集成过程

2. **专为文本分类设计**：

    - AutoML Natural Language专门针对文本分类等NLP任务进行了优化
    - 它已经预先配置了适当的模型架构和训练参数，这些都经过了谷歌团队的广泛测试
    - 对于分类特定类别的支持案例这样的直接文本分类任务，它提供了极高的准确性
    - 无需手动设计和实现复杂的深度学习架构

3. **易用性和实用性平衡**：

    - AutoML提供了自定义和灵活性（比使用预构建API更多），但不需要复杂的ML工程工作
    - 它允许你利用自己的标记数据（支持案例语料库），比使用通用API更有针对性
    - 模型训练完成后，可以轻松部署到生产环境，作为可扩展的REST端点
    - 这个解决方案提供了强大的ML能力，同时最小化了实施复杂性

其他选项存在的问题：

- 选项A（Cloud Natural Language API）虽然最快，但缺乏为特定业务领域定制的能力；它无法直接分类为这三个特定类别，除非进行额外的开发工作
- 选项C（BigQuery ML）对于简单的文本分类不是最优选择；它主要适用于结构化数据，而不是非结构化文本
- 选项D（TensorFlow + BERT + Vertex AI）在技术上可行，但对于"快速构建"的要求来说过于复杂；它需要深度学习专业知识和大量的手动工程工作

考虑到需要快速构建和部署一个能处理文本分类任务的解决方案，AutoML Natural Language提供了开发速度、准确性和部署简易性的最佳平衡。

问题 159

题目

你需要快速构建和训练一个模型，用于预测带有自定义类别的客户评论情感，且不需要编写代码。你没有足够的数据从头训练模型。生成的模型应具有高预测性能。你应该使用哪项服务？

You need to quickly build and train a model to predict the sentiment of customer reviews with custom categories without writing code. You do not have enough data to train a model from scratch. The resulting model should have high predictive performance. Which service should you use?

选项

A. AutoML Natural Language

AutoML Natural Language

B. Cloud Natural Language API

Cloud Natural Language API

C. AI Hub预制Jupyter Notebooks

AI Hub pre-made Jupyter Notebooks

D. AI Platform Training内置算法

AI Platform Training built-in algorithms

正确答案：A. AutoML Natural Language

解析： 这个问题测试如何为情感分析任务选择合适的Google Cloud服务，尤其是在有特定约束条件的情况下。

选项A是最佳解决方案，原因如下：

1. **自定义类别的支持**：
   - 题目要求模型能够预测"带有自定义类别的客户评论情感"
   - AutoML Natural Language允许你定义自己的类别，超越了简单的正面/负面/中性分类
   - 你可以根据业务需求创建特定的情感类别（如"非常满意"、"略有不满"、"非常失望"等）
   - 这种灵活性使其能够适应各种业务场景和细粒度情感分析需求
2. **无需编码的要求**：
   - 题目明确指出需要"不需要编写代码"的解决方案
   - AutoML Natural Language提供了完全可视化的界面，从数据上传到模型训练和评估
   - 它使用简单的拖放和点击界面，使非技术用户也能创建复杂的NLP模型
   - 这显著降低了实施障碍，加快了开发时间
3. **数据效率**：
   - 题目提到"没有足够的数据从头训练模型"
   - AutoML Natural Language利用迁移学习，在预训练的大型语言模型基础上进行微调
   - 这种方法大大减少了所需的训练数据量，通常只需几百个样本即可获得良好的结果
   - 这使其特别适合数据有限的情况，仍能提供强大的预测性能
4. **预测性能**：
   - 题目要求"生成的模型应具有高预测性能"
   - AutoML Natural Language使用谷歌最先进的NLP技术，经过优化以提供高准确性
   - 它会自动选择和调整最适合你的数据的模型架构
   - 即使使用有限的训练数据，它通常也能提供优于手动构建模型的结果

其他选项存在的问题：

- 选项B（Cloud Natural Language API）是预训练的API，不支持自定义类别；它只提供标准的情感分析（正面/负面/中性）
- 选项C（AI Hub预制Jupyter Notebooks）需要编写代码来修改和使用，违反了无需编码的要求
- 选项D（AI Platform Training内置算法）仍然需要编码技能来准备数据和配置模型，不是完全的无代码解决方案

在需要快速构建具有自定义类别的情感分析模型，且数据有限和无需编码的情况下，AutoML Natural Language是最适合的选择，它平衡了易用性、灵活性和高性能。

问题 160

题目

你需要为一个社交媒体应用构建一个ML模型，用于预测用户提交的个人资料照片是否符合要求。该应用将通知用户照片是否符合要求。你应该如何构建模型以确保应用不会错误地接受不合规的照片？

You need to build an ML model for a social media application to predict whether a user's submitted profile photo meets the requirements. The application will inform the user if the picture meets the requirements. How should you build a model to ensure that the application does not falsely accept a non-compliant picture?

选项

A. 使用AutoML优化模型的召回率，以最小化假阴性。

Use AutoML to optimize the model's recall in order to minimize false negatives.

B. 使用AutoML优化模型的F1分数，以平衡假阳性和假阴性的准确性。

Use AutoML to optimize the model's F1 score in order to balance the accuracy of false positives and false negatives.

C. 使用Vertex AI Workbench用户管理的笔记本构建一个自定义模型，该模型有三倍于符合个人资料照片要求的图片示例。

Use Vertex AI Workbench user-managed notebooks to build a custom model that has three times as many examples of pictures that meet the profile photo requirements.

D. 使用Vertex AI Workbench用户管理的笔记本构建一个自定义模型，该模型有三倍于不符合个人资料照片要求的图片示例。

Use Vertex AI Workbench user-managed notebooks to build a custom model that has three times as many examples of pictures that do not meet the profile photo requirements.

正确答案：D. Use Vertex AI Workbench user-managed notebooks to build a custom model that has three times as many examples of pictures that do not meet the profile photo requirements.

解析： 这个问题测试如何构建一个图像分类模型，特别关注如何最小化特定类型的错误（在此案例中为假阳性）。

选项D是最佳解决方案，原因如下：

1. **专注于减少假阳性错误**：
    - 题目明确指出关键需求是"不会错误地接受不合规的照片"，这本质上是要最小化假阳性（错误地将不合规照片分类为合规）
    - 通过提供更多不合规照片的例子，模型能够更好地学习识别各种不合规情况的特征
    - 这种不平衡的训练数据集故意偏向于识别不合规照片，从而减少误接受的可能性
    - 对社交媒体平台来说，误接受不合规照片的成本通常远高于误拒绝合规照片的成本
2. **自定义模型的控制能力**：
    - Vertex AI Workbench提供了构建和训练自定义模型所需的灵活性
    - 用户管理的笔记本允许数据科学家精确控制数据准备、模型架构和训练过程
    - 这种自定义方法使团队能够实现特定的业务目标（在这种情况下，最小化假阳性）
    - 与自动化解决方案相比，这种方法允许更细粒度地调整类别权重和损失函数

3. **处理不平衡分类问题的有效策略**：
    - 三倍于不合规照片的例子创造了一个有目的的不平衡数据集
    - 这是处理具有不对称错误成本的分类问题的公认策略
    - 由于模型会偏向于更频繁看到的类别，增加不合规照片的例子会使模型更倾向于预测"不合规"
    - 即使准确率略有下降，这种方法也能确保对业务最关键的错误类型（假阳性）得到最小化

其他选项存在的问题：

- 选项A（优化召回率）会最小化假阴性而非假阳性，这与需求相反；更高的召回率可能导致更多不合规照片被错误接受
- 选项B（优化F1分数）同样重视假阳性和假阴性，而题目明确要求优先考虑减少假阳性
- 选项C（三倍合规照片的例子）实际上会产生相反的结果，使模型更可能接受不合规照片，增加假阳性风险

通过增加不合规照片的训练样本，并使用Vertex AI Workbench的自定义控制能力，选项D提供了最有效的策略来确保社交媒体应用不会错误地接受不合规照片。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 17)

问题 161

题目

你在一家大型国际企业领导数据科学团队。你的团队训练的大多数模型都是使用高级TensorFlow API在AI Platform上利用GPU的大规模模型。你的团队通常需要几周或几个月来迭代一个模型的新版本。你最近被要求审查团队的支出。你应该如何降低Google Cloud计算成本而不影响模型性能？

You lead a data science team at a large international corporation. Most of the models your team trains are large-scale models using high-level TensorFlow APIs on AI Platform with GPUs. Your team usually takes a few weeks or months to iterate on a new version of a model. You were recently asked to review your team's spending. How should you reduce your Google Cloud compute costs without impacting the model's performance?

选项

A. 使用AI Platform运行带检查点的分布式训练作业。

Use AI Platform to run distributed training jobs with checkpoints.

B. 使用AI Platform运行不带检查点的分布式训练作业。

Use AI Platform to run distributed training jobs without checkpoints.

C. 迁移到Google Kubernetes Engine上的Kubeflow进行训练，并使用带检查点的抢占式虚拟机。

Migrate to training with Kubeflow on Google Kubernetes Engine, and use preemptible VMs with checkpoints.

D. 迁移到Google Kubernetes Engine上的Kubeflow进行训练，并使用不带检查点的抢占式虚拟机。

Migrate to training with Kubeflow on Google Kubernetes Engine, and use preemptible VMs without checkpoints.

正确答案：C. Migrate to training with Kubeflow on Google Kubernetes Engine, and use preemptible VMs with checkpoints.

解析： 这个问题测试如何优化大规模机器学习工作负载的计算成本，同时保持模型性能。

选项C是最佳解决方案，原因如下：

1. **抢占式VM的成本优势**：
    - 抢占式VM的价格通常比标准VM低得多，可以节省50-80%的计算成本
    - 对于需要几周或几个月才能完成的长期训练工作，这种成本节约会累积成显著的金额
    - 这类VM非常适合长时间运行的批处理作业，如机器学习模型训练
    - 使用抢占式VM是降低Google Cloud计算成本的最有效策略之一
2. **检查点的必要性**：
    - 抢占式VM可能随时被终止（最多运行24小时），若没有检查点，训练进度会全部丢失
    - 通过定期保存检查点，训练可以从上次保存点恢复，而不是从头开始
    - 这对于长期运行的训练作业尤其重要，可以防止大量计算资源被浪费
    - 检查点是使用抢占式VM进行ML训练的最佳实践，确保成本优化不会导致效率下降
3. **Kubeflow on GKE的灵活性和控制**：
    - 从AI Platform迁移到Kubeflow on GKE提供了更多的灵活性和对基础设施的控制
    - Kubeflow提供了完整的ML工作流编排能力，支持高级训练策略
    - GKE允许精细控制资源分配、自动扩展和调度策略
    - 这种组合允许更好地优化基础设施使用，进一步降低成本

其他选项存在的问题：

- 选项A（AI Platform带检查点）缺少使用抢占式VM的成本节约，抢占式VM是问题中的关键成本降低因素
- 选项B（AI Platform不带检查点）不仅缺少抢占式VM的成本优势，还增加了因作业失败导致计算资源浪费的风险
- 选项D（Kubeflow抢占式VM不带检查点）虽然利用了抢占式VM的成本优势，但由于缺少检查点，频繁的抢占会导致大量工作丢失，实际上会增加总体成本和训练时间

通过将Kubeflow on GKE的灵活性与抢占式VM的成本优势和检查点的可靠性相结合，选项C提供了降低计算成本同时不牺牲模型训练可靠性和性能的最佳方法。

问题 162

题目

你需要基于存储在BigQuery中包含50,000条记录的数据集训练一个回归模型。该数据包括共20个分类和数值特征，目标变量可能包含负值。你需要在最大化模型性能的同时最小化工作量和训练时间。你应该采取什么方法来训练这个回归模型？

You need to train a regression model based on a dataset containing 50,000 records that is stored in BigQuery. The data includes a total of 20 categorical and numerical features with a target variable that can

include negative values. You need to minimize effort and training time while maximizing model performance. What approach should you take to train this regression model?

选项

A. 创建自定义TensorFlow DNN模型。

Create a custom TensorFlow DNN model.

B. 使用BQML XGBoost回归训练模型。

Use BQML XGBoost regression to train the model.

C. 使用AutoML Tables训练模型，不设置提前停止。

Use AutoML Tables to train the model without early stopping.

D. 使用AutoML Tables训练模型，将RMSE作为优化目标。

Use AutoML Tables to train the model with RMSE as the optimization objective.

正确答案：B. Use BQML XGBoost regression to train the model.

解析： 这个问题测试如何选择合适的机器学习方法来平衡开发工作量、训练时间和模型性能。

选项B是最佳解决方案，原因如下：

1. **数据本地性和处理效率**：
    - 数据已经存储在BigQuery中，使用BigQuery ML意味着无需将数据移出其存储位置
    - 这消除了数据提取、转换和加载(ETL)的开销，显著减少了准备时间
    - 在数据所在位置直接训练模型避免了数据传输带来的延迟和成本
    - 对于50,000条记录的数据集，这种就地处理方法特别高效
2. **XGBoost算法的优势**：
    - XGBoost是一种强大的梯度提升树算法，通常在各种机器学习竞赛中表现出色
    - 它能有效处理混合数据类型（问题中提到有分类和数值特征）
    - 对于中等规模的表格数据集（如50,000条记录），XGBoost提供了良好的性能和训练速度平衡
    - 它原生支持负值目标变量，不需要特殊的数据转换
3. **开发工作量最小化**：
    - BQML提供了简化的SQL接口来训练和部署模型，无需复杂的代码开发
    - 与创建自定义DNN模型相比，这大大减少了所需的专业知识和编码工作
    - 基本的特征工程可以直接在SQL查询中完成
    - 部署和预测也可以直接在BigQuery环境中进行，简化了整个工作流程

其他选项存在的问题：

- 选项A（自定义TensorFlow DNN）需要大量的工作来设计网络架构、实现特征工程和调整超参数，不符合最小化工作量的要求

- 选项C（AutoML Tables不设提前停止）可能会导致不必要的长训练时间，而且需要将数据从BigQuery导出
- 选项D（AutoML Tables with RMSE）虽然为回归问题选择了合适的优化指标，但仍然需要额外的数据迁移步骤，且训练过程可能比XGBoost需要更多资源

BigQuery ML的XGBoost回归提供了工作量、训练时间和模型性能之间的最佳平衡，特别是对于已经存储在BigQuery中的中等规模表格数据。

问题 163

题目

你正在构建一个拥有超过100个输入特征的线性模型，所有特征的值都在-1到1之间。你怀疑许多特征是无信息的。你想从模型中移除无信息特征，同时保持有信息特征的原始形式。你应该使用哪种技术？

You are building a linear model with over 100 input features, all with values between −1 and 1. You suspect that many features are non informative. You want to remove the non-informative features from your model while keeping the informative ones in their original form. Which technique should you use?

选项

A. 使用主成分分析(PCA)消除最不具信息量的特征。

Use principal component analysis (PCA) to eliminate the least informative features.

B. 使用L1正则化将无信息特征的系数降为0。

Use L1 regularization to reduce the coefficients of uninformative features to 0.

C. 在构建模型后，使用Shapley值确定哪些特征最具信息量。

After building your model, use Shapley values to determine which features are the most informative.

D. 使用迭代式特征剔除技术，识别移除后不会降低模型性能的特征。

Use an iterative dropout technique to identify which features do not degrade the model when removed.

正确答案：B. Use L1 regularization to reduce the coefficients of uninformative features to 0.

解析： 这个问题测试如何选择合适的特征选择方法，特别是在处理具有大量潜在无信息特征的线性模型时。

选项B是最佳解决方案，原因如下：

1. **L1正则化的特征选择特性**：
    - L1正则化（也称为Lasso）通过在训练过程中对模型系数的绝对值施加惩罚，促使无信息特征的系数正好降为零
    - 这种特性使得L1正则化成为自动特征选择的有效方法，因为系数为零的特征实际上被排除在模型之外
    - 这种方法不需要单独的预处理步骤，而是将特征选择集成到模型训练中
    - 特别适合处理特征数量大于样本数量的情况，防止过拟合
2. **保持原始特征形式**：

- 与转换整个特征空间的方法不同，L1正则化保留了具有信息价值的原始特征
- 这满足了问题中"保持有信息特征的原始形式"的要求
- 有信息的特征保持其解释性和原始尺度，便于模型解释
- 这种方法不改变特征的本质特性，只简单地从模型中排除不相关的特征

3. **适用于线性模型**：

- L1正则化特别适合线性模型，完美对应问题的背景
- 它可以集成到许多线性算法中，如线性回归、逻辑回归和支持向量机
- 正则化强度可通过超参数调整，允许控制特征选择的严格程度
- 这种方法在计算上高效，适合处理大量特征

其他选项存在的问题：

- 选项A（PCA）将特征转换为主成分，改变了特征的原始形式，不符合保持特征原始形式的要求
- 选项C（Shapley值）是一种后处理方法，帮助解释而非执行特征选择；需要先建立完整模型，然后才能进行特征重要性分析
- 选项D（迭代特征剔除）虽然有效，但计算成本高昂且可能不稳定，尤其是对于100多个特征；此外，这种方法也不如L1正则化与线性模型的集成度高

对于具有潜在大量无信息特征的线性模型，L1正则化在保持有信息特征的原始形式的同时，提供了一种简洁高效的自动特征选择方法。

问题 164

题目

你在一家全球鞋类零售商工作，需要根据历史库存数据预测商品何时会缺货。客户行为高度动态，因为鞋类需求受多种不同因素影响。你希望部署的模型是在所有可用数据上训练的，但在推向生产环境前，想要在特定数据子集上跟踪性能。什么是执行这种验证最精简且可靠的方式？

You work for a global footwear retailer and need to predict when an item will be out of stock based on historical inventory data. Customer behavior is highly dynamic since footwear demand is influenced by many different factors. You want to serve models that are trained on all available data, but track your performance on specific subsets of data before pushing to production. What is the most streamlined and reliable way to perform this validation?

选项

A. 使用TFX ModelValidator工具指定生产就绪性的性能指标。

Use then TFX ModelValidator tools to specify performance metrics for production readiness.

B. 使用k折交叉验证作为验证策略，确保模型已准备好进入生产环境。

Use k-fold cross-validation as a validation strategy to ensure that your model is ready for production.

C. 使用最近相关的一周数据作为验证集，确保模型在当前数据上表现准确。

Use the last relevant week of data as a validation set to ensure that your model is performing accurately on current data.

D. 使用整个数据集，并将接收者操作特征曲线下面积(AUC ROC)作为主要指标。

Use the entire dataset and treat the area under the receiver operating characteristics curve (AUC ROC) as the main metric.

正确答案：A. Use then TFX ModelValidator tools to specify performance metrics for production readiness.

解析： 这个问题测试如何为具有时间依赖性和动态消费者行为的预测模型选择合适的验证策略。

选项A是最佳解决方案，原因如下：

1. **生产就绪性评估的专业工具**：
    - TFX ModelValidator专门设计用于评估模型是否符合生产部署的标准
    - 它允许明确定义性能指标和阈值，确保模型在推向生产前满足质量标准
    - 这些工具支持在特定数据子集上评估模型性能，正如题目所要求的
    - ModelValidator可以自动化验证过程，减少手动工作并提高可靠性
2. **结构化的验证流程**：
    - TFX ModelValidator提供了一个完整的框架来定义验证过程
    - 它允许指定多个性能指标，可以同时在不同数据子集上跟踪这些指标
    - 这种结构化方法确保验证过程的一致性和可重复性
    - 它可以无缝集成到更大的TFX流水线中，支持持续集成和部署
3. **与题目要求的精确匹配**：
    - 题目明确表示需要"在所有可用数据上训练"模型，同时"在特定数据子集上跟踪性能"
    - TFX ModelValidator允许在整个数据集上训练模型，然后在定义的子集上验证性能
    - 它支持创建各种数据切片，可以按时间、地区或产品类别等维度评估模型
    - 这种方法提供了最精简和可靠的方式来满足题目中描述的验证需求

其他选项存在的问题：

- 选项B（k折交叉验证）需要重新训练模型多次，这与在"所有可用数据上训练"的要求不符；此外，它通常不考虑数据的时间性质
- 选项C（使用最后一周数据作为验证集）虽然是一种有效方法，但相比TFX ModelValidator提供的结构化框架，它缺乏灵活性和自动化
- 选项D（整个数据集与AUC ROC）不允许在特定子集上跟踪性能，与题目要求不符；此外，AUC ROC可能不是库存预测最合适的指标

TFX ModelValidator工具提供了最精简和可靠的方式来验证模型在生产环境中的性能，同时保持在所有可用数据上训练模型的能力，这与问题中描述的零售预测场景完美匹配。

问题 165

题目

你已经在Vertex AI上部署了一个模型用于实时推理。在一次在线预测请求过程中，你收到了"内存不足"错误。你应该怎么做？

You have deployed a model on Vertex AI for real-time inference. During an online prediction request, you get an "Out of Memory" error. What should you do?

选项

A. 使用批量预测模式代替在线模式。

Use batch prediction mode instead of online mode.

B. 使用更小批次的实例重新发送请求。

Send the request again with a smaller batch of instances.

C. 在用于预测前使用base64编码数据。

Use base64 to encode your data before using it for prediction.

D. 申请增加预测请求数量的配额。

Apply for a quota increase for the number of prediction requests.

正确答案：B. Send the request again with a smaller batch of instances.

解析： 这个问题测试如何解决Vertex AI中在线预测时的内存不足错误。

选项B是最佳解决方案，原因如下：

1. **直接解决内存问题**：
    - "内存不足"错误明确表明当前请求需要的内存超过了分配给预测服务的内存
    - 减少每个批次中的实例数量会直接降低单个请求所需的内存
    - 这是一个立即可行的解决方案，不需要对部署策略或基础设施进行重大更改
    - 通过减小批量大小，可以在不牺牲在线响应能力的情况下继续使用服务
2. **保持在线预测的优势**：
    - 在线预测对于需要实时响应的应用程序至关重要，通过减小批量大小，你可以继续使用在线模式
    - 这种方法不需要重新设计应用程序的架构或改变与预测服务的交互方式
    - 它保留了在线预测的低延迟特性，这在许多实时应用中是必不可少的
    - 与完全切换到批量预测模式相比，这是一个更简单、影响更小的更改
3. **常见的解决方案**：
    - 批量大小的调整是解决推理时内存问题的标准做法
    - 这种方法不需要额外的配额申请或基础设施更改
    - 它是一种快速实施的解决方案，可以在不增加成本的情况下立即应用
    - 通过实验不同的批量大小，你可以找到平衡内存使用和吞吐量的最佳配置

其他选项存在的问题：

- 选项A（切换到批量预测）改变了预测的本质，从实时响应变为异步处理，这可能不适合需要即时结果的应用

- 选项C（base64编码）实际上会略微增加数据大小，不会解决内存不足问题；此外，数据编码通常与内存使用无关
- 选项D（增加请求配额）解决的是请求数量限制问题，而不是单个请求的内存限制；增加请求配额不会增加每个预测实例的可用内存

在处理Vertex AI上的内存不足错误时，减小预测请求的批量大小是最直接有效的解决方案，它能够在保持在线预测功能的同时降低内存需求。

问题 166

题目

你在一家基于订阅的公司工作。你已训练了一个树和神经网络的集成模型来预测客户流失，即客户不再续订年度订阅的可能性。平均预测流失率为15%，但对于一个特定客户，模型预测他们有70%的可能性流失。该客户的产品使用率为30%，位于纽约市，成为客户的时间是1997年。你需要解释实际预测（70%流失率）与平均预测之间的差异。你想使用Vertex Explainable AI。你应该怎么做？

You work at a subscription-based company. You have trained an ensemble of trees and neural networks to predict customer churn, which is the likelihood that customers will not renew their yearly subscription. The average prediction is a 15% churn rate, but for a particular customer the model predicts that they are 70% likely to churn. The customer has a product usage history of 30%, is located in New York City, and became a customer in 1997. You need to explain the difference between the actual prediction, a 70% churn rate, and the average prediction. You want to use Vertex Explainable AI. What should you do?

选项

A. 训练本地代理模型来解释个体预测。

Train local surrogate models to explain individual predictions.

B. 在Vertex Explainable AI上配置采样Shapley解释。

Configure sampled Shapley explanations on Vertex Explainable AI.

C. 在Vertex Explainable AI上配置集成梯度解释。

Configure integrated gradients explanations on Vertex Explainable AI.

D. 测量每个特征的影响，计算方式为特征权重乘以特征值。

Measure the effect of each feature as the weight of the feature multiplied by the feature value.

正确答案：B. Configure sampled Shapley explanations on Vertex Explainable AI.

解析： 这个问题测试如何选择适当的方法来解释模型预测，特别是在使用Vertex Explainable AI解释集成模型的预测差异时。

选项B是最佳解决方案，原因如下：

1. **Shapley值的适用性**：
    - Shapley值是一种源自博弈论的方法，非常适合解释单个预测与基准（如平均预测）之间的差异
    - 它为每个特征分配一个贡献值，表示该特征对最终预测的影响程度

    - 这正好满足需求：解释为什么这个特定客户的预测流失率（70%）远高于平均流失率（15%）
    - Shapley值提供了公平的特征贡献度量，考虑了特征间的相互作用

2. **集成模型的兼容性**：

    - 题目明确指出使用了"树和神经网络的集成模型"
    - Shapley值是模型无关的，可以应用于任何模型类型，包括集成模型
    - 与一些仅适用于特定模型类型的解释方法不同，Shapley值可以一致地解释集成模型的预测
    - 这使其成为解释由不同算法组合的复杂模型的理想选择

3. **Vertex Explainable AI的实现**：

    - Vertex Explainable AI原生支持采样Shapley解释
    - 采样方法通过近似计算提高了Shapley值的计算效率，使其在实际应用中更可行
    - 这种实现提供了易于理解的可视化和解释，可以直观地展示每个特征对预测的贡献
    - 这使业务人员能够理解为什么特定客户（如纽约市的低使用率长期客户）可能有更高的流失风险

其他选项存在的问题：

- 选项A（本地代理模型）通常指LIME等方法，这些方法虽然有用，但不如Shapley值适合比较与基准的差异
- 选项C（集成梯度）主要设计用于深度学习模型，不适合解释树模型部分，而题目使用的是树和神经网络的集成
- 选项D（权重乘以特征值）过于简化，不能捕捉特征间的相互作用，在集成模型中也难以定义明确的"权重"

采样Shapley值为解释集成模型的预测提供了最全面、最公平的方法，特别适合解释个体预测与平均预测的差异，这与问题中描述的场景完全一致。

问题 167

题目

你需要对BigQuery表中的1亿条记录执行批量预测，使用自定义TensorFlow DNN回归模型，然后将预测结果存储在BigQuery表中。你想最小化构建这个推理流水线所需的工作量。你应该怎么做？

You need to execute a batch prediction on 100 million records in a BigQuery table with a custom TensorFlow DNN regressor model, and then store the predicted results in a BigQuery table. You want to minimize the effort required to build this inference pipeline. What should you do?

选项

A. 使用BigQuery ML导入TensorFlow模型，并运行ml.predict函数。

Import the TensorFlow model with BigQuery ML, and run the ml.predict function.

B. 使用TensorFlow BigQuery读取器加载数据，并使用BigQuery API将结果写入BigQuery。

Use the TensorFlow BigQuery reader to load the data, and use the BigQuery API to write the results to BigQuery.

C. 创建Dataflow流水线将BigQuery中的数据转换为TFRecords。在Vertex AI Prediction上运行批量推理，并将结果写入BigQuery。

Create a Dataflow pipeline to convert the data in BigQuery to TFRecords. Run a batch inference on Vertex AI Prediction, and write the results to BigQuery.

D. 在Dataflow流水线中加载TensorFlow SavedModel。使用带有自定义函数的BigQuery I/O连接器在流水线内执行推理，并将结果写入BigQuery。

Load the TensorFlow SavedModel in a Dataflow pipeline. Use the BigQuery I/O connector with a custom function to perform the inference within the pipeline, and write the results to BigQuery.

正确答案：A. Import the TensorFlow model with BigQuery ML, and run the ml.predict function.

解析： 这个问题测试如何为大规模批量预测任务设计最高效的流水线，同时最小化开发工作量。

选项A是最佳解决方案，原因如下：

1. **数据位置不变的优势**：
    - 通过将TensorFlow模型导入BigQuery ML，数据可以保持在其原始位置（BigQuery）
    - 这消除了需要移动1亿条记录的数据传输开销，这在大规模数据处理中是一个重要考虑因素
    - 避免数据移动不仅提高了效率，还降低了网络带宽成本和潜在的安全风险
    - 这种"将计算带到数据"的方法对于大规模批处理非常理想
2. **最小化开发工作量**：
    - BigQuery ML提供了简单的SQL接口来导入外部模型并运行预测
    - 使用ml.predict函数只需几行SQL代码，无需构建和维护复杂的数据处理流水线
    - 不需要配置和管理额外的服务或资源（如Dataflow或Vertex AI）
    - 这显著降低了实现和维护成本，符合"最小化工作量"的要求
3. **BigQuery的可扩展性**：
    - BigQuery设计用于处理数十亿条记录，能够高效地处理1亿条记录的批量预测
    - 它自动处理计算资源的分配和扩展，无需手动配置
    - 预测结果直接写入BigQuery表，简化了端到端流程
    - 整个过程可以通过SQL查询调度和自动化，便于集成到现有工作流中

其他选项存在的问题：

- 选项B（TensorFlow BigQuery reader）需要将大量数据从BigQuery移出，这对于1亿条记录来说效率低下且复杂
- 选项C（Dataflow+TFRecords+Vertex AI）引入了多个服务和数据转换步骤，显著增加了复杂性和工作量
- 选项D（Dataflow with SavedModel）虽然是一个可行的解决方案，但需要构建和维护自定义Dataflow流水线，远比使用BigQuery ML复杂

对于需要在BigQuery中对大量数据执行批量预测的情况，将模型导入BigQuery ML并使用内置的预测功能提供了最简单、最高效的解决方案，最大限度地减少了工作量同时保持了处理大规模数据的能力。

问题 168

题目

你正在使用包含分类输入值的数据集创建深度神经网络分类模型。某些列的基数超过10,000个唯一值。你应该如何将这些分类值编码为模型的输入？

You are creating a deep neural network classification model using a dataset with categorical input values. Certain columns have a cardinality greater than 10,000 unique values. How should you encode these categorical values as input into the model?

选项

A. 将每个分类值转换为整数值。

Convert each categorical value into an integer value.

B. 将分类字符串数据转换为一热哈希桶。

Convert the categorical string data to one-hot hash buckets.

C. 将分类变量映射为布尔值向量。

Map the categorical variables into a vector of boolean values.

D. 将每个分类值转换为行程长度编码的字符串。

Convert each categorical value into a run-length encoded string.

正确答案：B. Convert the categorical string data to one-hot hash buckets.

解析： 这个问题测试如何处理高基数分类特征作为深度神经网络的输入。

选项B是最佳解决方案，原因如下：

1. **哈希技术处理高基数的有效性**：
    - 当面对超过10,000个唯一值的高基数分类特征时，传统的one-hot编码会产生极其稀疏的超高维度特征向量
    - 哈希技术通过将大量可能的分类值映射到固定数量的桶中，显著减少了特征向量的维度
    - 这种方法在保留分类信息的同时避免了维度爆炸，是处理高基数分类特征的标准方法
    - 对于深度神经网络尤其有效，因为它提供了合理的特征表示而不会显著增加模型复杂度
2. **计算效率和内存优势**：
    - one-hot哈希桶允许你控制特征表示的维度，不论原始特征有多少个唯一值
    - 与完整的one-hot编码相比，这显著减少了内存使用和计算复杂度
    - 对于基数超过10,000的特征，这种效率增益尤为显著
    - 它允许更快的训练时间和更高效的模型推理
3. **适合神经网络架构**：
    - 神经网络特别适合处理哈希后的one-hot编码，因为它们可以学习相似哈希桶中分类的共同特性
    - 这种编码保留了分类变量的非序数性质，避免了不当的数值关系

    - 即使发生哈希冲突（不同类别哈希到同一个桶），神经网络通常仍能通过其他特征学习区分这些类别
    - TensorFlow等流行的深度学习框架为这种编码方法提供了内置支持

其他选项存在的问题：

- 选项A（整数编码）在分类之间引入了错误的序数关系，暗示相邻整数表示的类别在某种程度上相似
- 选项C（布尔值向量）基本上是标准的one-hot编码，对于10,000+唯一值的特征来说，它会创建过大且稀疏的向量
- 选项D（行程长度编码）是一种数据压缩技术，不适合作为神经网络的特征表示；它不提供神经网络可以有效学习的数值表示

对于具有高基数分类特征的深度神经网络模型，one-hot哈希桶提供了最佳的平衡：它保留了分类变量的非序数性质，同时通过控制哈希桶的数量来管理维度，这使其成为处理超过10,000个唯一值的分类特征的理想选择。

问题 169

题目

你需要训练一个自然语言模型，对包含数百万个示例和10万个唯一词的产品描述进行文本分类。你想要对单词进行预处理，以便它们可以被输入到循环神经网络中。你应该怎么做？

You need to train a natural language model to perform text classification on product descriptions that contain millions of examples and 100,000 unique words. You want to preprocess the words individually so that they can be fed into a recurrent neural network. What should you do?

选项

A. 创建单词的热编码，并将编码输入到模型中。

Create a hot-encoding of words, and feed the encodings into your model.

B. 从预训练模型中识别词嵌入，并在模型中使用这些嵌入。

Identify word embeddings from a pre-trained model, and use the embeddings in your model.

C. 按单词出现频率排序，并使用这些频率作为模型中的编码。

Sort the words by frequency of occurrence, and use the frequencies as the encodings in your model.

D. 为每个单词分配从1到100,000的数值，并将这些值作为输入提供给模型。

Assign a numerical value to each word from 1 to 100,000 and feed the values as inputs in your model.

正确答案：B. Identify word embeddings from a pre-trained model, and use the embeddings in your model.

解析：这个问题测试如何为大规模文本分类任务选择合适的单词表示方法，特别是在使用循环神经网络（RNN）的情况下。

选项B是最佳解决方案，原因如下：

1. **预训练词嵌入的语义优势**：

    - 预训练词嵌入（如Word2Vec、GloVe或FastText）将单词映射到低维密集向量空间，其中语义相似的单词在向量空间中彼此接近
    - 这些嵌入已经在大型语料库上训练，捕获了丰富的语义和句法关系
    - 使用预训练嵌入可以将外部知识转移到你的模型中，即使你自己的训练数据有限
    - 对于包含100,000个唯一词的大型词汇表，预训练嵌入提供了一种高效的方式来表示单词的含义

2. **维度和计算效率**：

    - 预训练词嵌入通常将单词表示为低维向量（如100-300维），而one-hot编码对于100,000个单词将产生100,000维稀疏向量
    - 这种降维显著减少了模型的参数数量，加快了训练和推理速度
    - 对于循环神经网络特别重要，因为它们在处理长序列的高维输入时计算成本很高
    - 密集的词嵌入向量在现代GPU上处理效率更高，与稀疏表示相比

3. **与循环神经网络的兼容性**：

    - 循环神经网络特别适合处理密集的词嵌入向量
    - 预训练嵌入提供了更丰富的起点，使RNN能够更有效地学习序列中的模式
    - 它们允许模型更好地泛化到训练数据中未见过的词汇组合
    - 现代NLP实践中，将预训练词嵌入与RNN结合是处理文本分类任务的标准方法

其他选项存在的问题：

- 选项A（热编码，即one-hot编码）为每个单词创建一个100,000维的稀疏向量，这对于RNN来说非常低效且计算密集
- 选项C（频率编码）丢失了词义信息，简单地用频率表示单词过度简化了语言的复杂性
- 选项D（整数编码）在单词之间引入了人为的序数关系，这可能误导模型认为数值接近的单词在语义上也接近

在处理具有大型词汇表的文本分类任务时，使用预训练词嵌入是既高效又有效的策略，它为循环神经网络提供了丰富的语义表示，同时避免了维度灾难和计算低效的问题。

问题 170

题目

你在一家在线旅行社工作，该公司还在其网站上向其他公司销售广告位。你被要求预测用户接下来应该看到的最相关网页横幅广告。安全性对你的公司很重要。模型延迟要求是300毫秒@p99，库存中有数千个网页横幅，你的探索性分析表明导航上下文是个很好的预测因素。你想要实现最简单的解决方案。你应该如何配置预测流水线？

You work for an online travel agency that also sells advertising placements on its website to other companies. You have been asked to predict the most relevant web banner that a user should see next. Security is important to your company. The model latency requirements are 300ms@p99, the inventory is thousands of web banners, and your exploratory analysis has shown that navigation context is a good predictor. You want to Implement the simplest solution. How should you configure the prediction pipeline?

选项

A. 在网站上嵌入客户端，然后在AI Platform Prediction上部署模型。

Embed the client on the website, and then deploy the model on AI Platform Prediction.

B. 在网站上嵌入客户端，在App Engine上部署网关，在Firestore上部署数据库用于写入和读取用户的导航上下文，然后在AI Platform Prediction上部署模型。

Embed the client on the website, deploy the gateway on App Engine, deploy the database on Firestore for writing and for reading the user's navigation context, and then deploy the model on AI Platform Prediction.

C. 在网站上嵌入客户端，在App Engine上部署网关，在Cloud Bigtable上部署数据库用于写入和读取用户的导航上下文，然后在AI Platform Prediction上部署模型。

Embed the client on the website, deploy the gateway on App Engine, deploy the database on Cloud Bigtable for writing and for reading the user's navigation context, and then deploy the model on AI Platform Prediction.

D. 在网站上嵌入客户端，在App Engine上部署网关，在Memorystore上部署数据库用于写入和读取用户的导航上下文，然后在Google Kubernetes Engine上部署模型。

Embed the client on the website, deploy the gateway on App Engine, deploy the database on Memorystore for writing and for reading the user's navigation context, and then deploy the model on Google Kubernetes Engine.

正确答案：B. Embed the client on the website, deploy the gateway on App Engine, deploy the database on Firestore for writing and for reading the user's navigation context, and then deploy the model on AI Platform Prediction.

解析： 这个问题测试如何为实时推荐系统设计符合延迟和安全性要求的最简单架构。

选项B是最佳解决方案，原因如下：

1. **简单性与托管服务的优势**：
    - 题目强调要实现"最简单的解决方案"，这是选择标准中的关键因素
    - 组合使用App Engine、Firestore和AI Platform Prediction都是完全托管的服务，最大限度地减少了基础设施管理
    - 不需要管理容器、集群或自定义扩展策略，大大简化了架构
    - 这种完全托管的服务组合提供了最低的运营开销和最简单的实现路径
2. **Firestore的优势**：
    - Firestore是一个无服务器的文档数据库，无需配置或预置，即开即用
    - 它提供自动扩展、高可用性和强一致性，非常适合存储和检索用户导航上下文
    - 对于数千个网页横幅的库存规模，Firestore的性能完全足够
    - 其实时数据同步能力使得前端可以轻松获取最新的用户导航上下文
3. **AI Platform Prediction的适用性**：
    - AI Platform Prediction是一个完全托管的预测服务，无需管理基础设施
    - 它能够轻松处理预测请求，并能自动扩展以满足需求
    - 对于中等复杂度的模型和数千个广告选项的规模，它可以满足300ms@p99的延迟要求
    - 它提供内置的安全功能，如加密、IAM和审计日志，满足安全性要求
4. **整体架构的协同效应**：

    - App Engine网关提供了安全的API层，处理身份验证和授权
    - Firestore存储用户导航上下文，提供可靠的数据持久性
    - AI Platform Prediction处理模型推理，返回最相关的广告
    - 这三个组件协同工作，创建了一个简单、安全且高效的端到端流程

其他选项存在的问题：

- 选项A（仅有客户端和AI Platform）缺少存储用户导航上下文的数据库，不能利用这个重要的预测因素
- 选项C（Cloud Bigtable）引入了不必要的复杂性，Bigtable主要设计用于高吞吐量工作负载，对于此用例而言过于复杂
- 选项D（Memorystore和GKE）需要更多的手动配置和管理，包括容器化模型和管理Kubernetes集群，违背了"最简单解决方案"的要求

考虑到题目强调的简单性需求，并权衡安全性和延迟要求，基于完全托管服务的架构（App Engine、Firestore和AI Platform Prediction）提供了最简单、最低维护的解决方案，适合快速实施并满足指定的要求。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 18)

问题 171

题目

你的数据科学团队要求一个支持定期模型重训练、Docker容器，以及支持自动扩展和监控在线预测请求的服务的系统。你应该为这个系统选择哪些平台组件？

Your data science team has requested a system that supports scheduled model retraining, Docker containers, and a service that supports autoscaling and monitoring for online prediction requests. Which platform components should you choose for this system?

选项

A. Vertex AI Pipelines和App Engine。

Vertex AI Pipelines and App Engine

B. Vertex AI Pipelines、Vertex AI Prediction和Vertex AI Model Monitoring。

Vertex AI Pipelines, Vertex AI Prediction, and Vertex AI Model Monitoring

C. Cloud Composer、BigQuery ML和Vertex AI Prediction。

Cloud Composer, BigQuery ML, and Vertex AI Prediction

D. Cloud Composer、Vertex AI Training with custom containers和App Engine。

Cloud Composer, Vertex AI Training with custom containers, and App Engine

正确答案：B. Vertex AI Pipelines, Vertex AI Prediction, and Vertex AI Model Monitoring

解析： 这个问题测试如何选择合适的Google Cloud组件来构建端到端的ML系统，满足特定的功能需求。

选项B是最佳解决方案，原因如下：

1. **支持定期模型重训练的需求**：
    - Vertex AI Pipelines是一个用于创建和编排ML工作流的托管服务
    - 它允许创建可重复、可调度的ML管道，完美支持定期模型重训练的需求
    - 这些管道可以被调度为按固定时间间隔运行，确保模型定期使用最新数据进行更新
    - Pipelines支持复杂的训练工作流，包括数据预处理、特征工程、模型训练和评估
2. **Docker容器支持**：
    - Vertex AI Pipelines原生支持Docker容器
    - 管道中的每个组件都可以使用自定义Docker镜像来定义其环境和依赖项
    - 这提供了极大的灵活性，允许数据科学家使用他们偏好的库和工具
    - 容器环境确保了训练和部署环境的一致性，减少了"在我的电脑上可以运行"的问题
3. **自动扩展和监控在线预测**：
    - Vertex AI Prediction提供了一个完全托管的服务，用于部署ML模型以进行在线预测
    - 它支持自动扩展，可以根据传入请求的流量自动调整资源
    - Vertex AI Model Monitoring提供对模型性能和预测请求的持续监控
    - 它可以检测数据偏移和异常，并在模型性能下降时发出警报
4. **组件间的集成**：
    - 这三个服务是完全集成的，提供了无缝的端到端体验
    - 通过Vertex AI Pipelines训练的模型可以直接部署到Vertex AI Prediction
    - Vertex AI Model Monitoring可以直接附加到部署在Vertex AI Prediction上的模型
    - 这种集成最大限度地减少了在不同服务之间移动数据和模型的复杂性

其他选项存在的问题：

- 选项A（Vertex AI Pipelines和App Engine）缺少监控功能，且App Engine虽然可以托管预测服务，但不提供专门的ML模型部署和自动扩展功能
- 选项C（Cloud Composer、BigQuery ML和Vertex AI Prediction）虽然可以支持工作流调度，但BigQuery ML限制了可使用的ML框架和模型类型，可能不满足团队对Docker容器的需求
- 选项D（Cloud Composer、Vertex AI Training with custom containers和App Engine）缺少专门的模型监控功能，且同样存在App Engine不是专为ML预测设计的问题

Vertex AI Pipelines、Vertex AI Prediction和Vertex AI Model Monitoring的组合提供了一个全面、集成的解决方案，满足了定期重训练、容器支持和自动扩展监控在线预测的所有要求。这是构建现代ML系统最简单和最有效的方法。

问题 172

题目

你需要设计一个架构，提供异步预测以确定特定任务关键型机器部件是否会发生故障。你的系统从机器的多个传感器收集数据。你希望构建一个模型，根据过去12小时每个传感器数据的平均值，预测未来N分钟内是否会发生故障。你应该如何设计这个架构？

You need to design an architecture that serves asynchronous predictions to determine whether a particular mission-critical machine part will fail. Your system collects data from multiple sensors from the machine. You want to build a model that will predict a failure in the next N minutes, given the average of each sensor's data from the past 12 hours. How should you design the architecture?

选项

A. 1. 传感器通过HTTP请求发送数据到部署为微服务并暴露REST API进行预测的ML模型。2. 你的应用程序查询你部署模型的Vertex AI端点。3. 调用应用程序在模型产生预测后立即接收响应。

1. HTTP requests are sent by the sensors to your ML model, which is deployed as a microservice and exposes a REST API for prediction 2. Your application queries a Vertex AI endpoint where you deployed your model. 3. Responses are received by the caller application as soon as the model produces the prediction.

B. 1. 传感器将事件发送到Pub/Sub，实时消费并由Dataflow流处理管道处理。2. 管道调用模型进行预测并将预测结果发送到另一个Pub/Sub主题。3. 下游系统消费包含预测结果的Pub/Sub消息进行监控。

1. Events are sent by the sensors to Pub/Sub, consumed in real time, and processed by a Dataflow stream processing pipeline. 2. The pipeline invokes the model for prediction and sends the predictions to another Pub/Sub topic. 3. Pub/Sub messages containing predictions are then consumed by a downstream system for monitoring.

C. 1. 使用Dataflow将数据导出到Cloud Storage。2. 提交使用Cloud Storage中训练好的模型对预处理数据进行评分的Vertex AI批量预测作业。3. 从Cloud Storage导出批量预测作业输出并导入到Cloud SQL。

1. Export your data to Cloud Storage using Dataflow. 2. Submit a Vertex AI batch prediction job that uses your trained model in Cloud Storage to perform scoring on the preprocessed data. 3. Export the batch prediction job outputs from Cloud Storage and import them into Cloud SQL.

D. 1. 使用BigQuery命令行工具将数据导出到Cloud Storage。2. 提交使用Cloud Storage中训练好的模型对预处理数据进行评分的Vertex AI批量预测作业。3. 从Cloud Storage导出批量预测作业输出并导入到BigQuery。

1. Export the data to Cloud Storage using the BigQuery command-line tool 2. Submit a Vertex AI batch prediction job that uses your trained model in Cloud Storage to perform scoring on the preprocessed data. 3. Export the batch prediction job outputs from Cloud Storage and import them into BigQuery.

正确答案：B. 1. Events are sent by the sensors to Pub/Sub, consumed in real time, and processed by a Dataflow stream processing pipeline. 2. The pipeline invokes the model for prediction and sends the predictions to another Pub/Sub topic. 3. Pub/Sub messages containing predictions are then consumed by a downstream system for monitoring.

解析： 这个问题测试如何设计一个适合工业预测性维护场景的ML架构，需要处理传感器数据流并提供异步预测。

选项B是最佳解决方案，原因如下：

1. **适合异步预测的流处理架构**：
    - 问题明确要求"异步预测"，这意味着预测不需要立即返回给调用者
    - Pub/Sub提供了可靠的异步消息传递系统，非常适合传感器数据的收集

- Dataflow流处理允许连续处理传入的传感器数据，并计算12小时的滚动平均值
- 这种架构通过将预测结果发布到另一个Pub/Sub主题，实现了完全解耦的异步工作流

2. **传感器数据处理的优势**：

- 工业物联网(IIoT)传感器通常生成连续的数据流，Pub/Sub是处理这种数据的理想选择
- Dataflow的窗口操作可以轻松计算过去12小时的滚动平均值，这是预测所需的
- 流处理管道可以实时进行特征工程和预处理，为模型准备适当的输入
- 这种方法可以处理可能的传感器数据传输延迟或间歇性连接问题

3. **可扩展性和容错性**：

- Pub/Sub和Dataflow都是完全托管的服务，可以自动扩展以处理传感器数据量的变化
- 这种架构具有内置的容错功能，可确保即使在组件临时失败的情况下，数据也不会丢失
- 通过将预测结果发送到另一个Pub/Sub主题，可以支持多个下游消费者（如监控系统、警报系统等）
- 这种解耦的消息传递架构使系统更加健壮，各个组件可以独立失败和恢复

其他选项存在的问题：

- 选项A描述的是同步REST API架构，不符合"异步预测"的要求；此外，如果模型预测时间较长，可能会导致HTTP请求超时
- 选项C使用批处理而非流处理方法，可能无法及时处理传感器数据并提供足够及时的预测；将数据移动到Cloud SQL增加了不必要的复杂性
- 选项D与选项C类似，但使用BigQuery，同样不适合需要近乎实时处理的连续传感器数据流

对于需要从多个传感器收集数据并提供异步故障预测的场景，基于Pub/Sub和Dataflow的流处理架构（选项B）提供了最适合的解决方案，它既满足了技术要求，又提供了可扩展性和容错性。

问题 173

题目

你的公司管理一个从多个不同在线来源聚合新闻文章并发送给用户的应用程序。你需要构建一个推荐模型，向读者推荐与他们当前正在阅读的文章相似的文章。你应该使用哪种方法？

Your company manages an application that aggregates news articles from many different online sources and sends them to users. You need to build a recommendation model that will suggest articles to readers that are similar to the articles they are currently reading. Which approach should you use?

选项

A. 创建一个协同过滤系统，基于用户的过去行为向用户推荐文章。

Create a collaborative filtering system that recommends articles to a user based on the user's past behavior.

B. 使用word2vec将所有文章编码为向量，并构建一个基于向量相似性返回文章的模型。

Encode all articles into vectors using word2vec, and build a model that returns articles based on vector similarity.

C. 为每个用户构建一个逻辑回归模型，预测是否应该向用户推荐某篇文章。

Build a logistic regression model for each user that predicts whether an article should be recommended to a user.

D. 手动标记几百篇文章，然后基于这些手动分类的文章训练一个SVM分类器，将额外的文章分类到各自的类别中。

Manually label a few hundred articles, and then train an SVM classifier based on the manually classified articles that categorizes additional articles into their respective categories.

正确答案：B. Encode all articles into vectors using word2vec, and build a model that returns articles based on vector similarity.

解析： 这个问题测试如何选择合适的推荐系统方法来满足特定的内容推荐需求。

选项B是最佳解决方案，原因如下：

1. **基于内容的推荐方法适合性**：
    - 问题明确要求推荐"与他们当前正在阅读的文章相似的文章"，这明确指向基于内容的推荐方法
    - Word2vec是一种将文本转换为数值向量表示的技术，能够捕捉词语的语义关系
    - 通过这种方法，语义相似的文章在向量空间中会彼此靠近
    - 计算文章向量间的相似度（如余弦相似度）可以有效找出与当前阅读内容最相似的文章
2. **不依赖用户历史数据的优势**：
    - 这种方法不需要用户的历史阅读数据就能工作，可以立即为新用户提供推荐
    - 它解决了"冷启动"问题，即使是首次使用应用的用户也能获得相关推荐
    - 对于新发布的文章，也可以立即集成到推荐系统中，无需等待用户交互数据积累
    - 这种方法专注于文章内容本身，而不是用户行为模式，更符合题目要求
3. **实现的可行性和效率**：
    - Word2vec等模型已经有成熟的预训练版本，可以快速应用于新闻文本处理
    - 向量相似性计算计算效率高，适合实时推荐场景
    - 这种方法可以轻松扩展到大量文章，处理新闻聚合应用中常见的大规模内容库
    - 相似性搜索可以通过近似最近邻算法进一步优化，确保快速响应

其他选项存在的问题：

- 选项A（协同过滤）基于用户的过去行为模式而非当前阅读内容，不符合题目要求；它需要大量用户交互数据才能有效工作
- 选项C（每用户逻辑回归模型）为每个用户创建单独模型过于复杂，且同样需要大量历史数据；不适合基于当前阅读内容的即时推荐需求
- 选项D（基于SVM的分类）更适合文章分类而非相似性推荐；手动标记数百篇文章的方法难以扩展，且分类方法难以捕捉细粒度的内容相似性

基于word2vec的向量相似性方法能够直接分析文章内容，找出语义相似的文章，这正是题目所要求的"推荐与他们当前正在阅读的文章相似的文章"的最直接实现方式。

问题 174

题目

你在一家大型社交网络服务提供商工作，用户在平台上发布文章并讨论新闻。每天有数百万条评论发布，超过200名人类审核员不断审查评论并标记不当内容。你的团队正在构建一个ML模型来帮助人类审核员检查平台上的内容。该模型会对每条评论进行评分，并将可疑评论标记给人类审核。你应该使用哪些指标来监控模型的性能？

You work for a large social network service provider whose users post articles and discuss news. Millions of comments are posted online each day, and more than 200 human moderators constantly review comments and flag those that are inappropriate. Your team is building an ML model to help human moderators check content on the platform. The model scores each comment and flags suspicious comments to be reviewed by a human. Which metric(s) should you use to monitor the model's performance?

选项

A. 模型每分钟标记的消息数量。

Number of messages flagged by the model per minute

B. 模型每分钟标记并被人类确认为不当的消息数量。

Number of messages flagged by the model per minute confirmed as being inappropriate by humans.

C. 基于每分钟发送给人类审核的0.1%原始消息随机样本的精确率和召回率估计。

Precision and recall estimates based on a random sample of 0.1% of raw messages each minute sent to a human for review

D. 基于每分钟被模型标记为潜在不当内容的消息样本的精确率和召回率估计。

Precision and recall estimates based on a sample of messages flagged by the model as potentially inappropriate each minute

正确答案：C. Precision and recall estimates based on a random sample of 0.1% of raw messages each minute sent to a human for review

解析： 这个问题测试如何为内容审核模型选择合适的评估指标，特别是在高容量内容平台上。

选项C是最佳解决方案，原因如下：

1. **无偏见的性能评估**：
    - 随机抽样0.1%的原始消息提供了一个无偏见的样本，代表了整个消息流
    - 这种方法可以评估模型在各种内容上的表现，而不仅仅是它已经标记的内容
    - 随机样本可以捕捉模型可能系统性地忽略的边缘案例或内容类型
    - 无偏见的样本是准确计算真正的召回率和精确率所必需的
2. **全面的性能指标**：
    - 精确率衡量模型标记的消息中有多少确实是不当的（减少误报）
    - 召回率衡量模型成功识别出所有实际不当消息的比例（减少漏报）
    - 两个指标的结合为模型性能提供了全面的视图
    - 这种方法可以帮助平衡模型在内容审核中的严格程度
3. **持续监控和评估**：

    - 每分钟发送样本进行人工审核，提供了持续的模型监控
    - 这允许快速发现模型性能的任何变化或退化
    - 持续评估可以检测对新出现的不当内容模式的响应
    - 这种方法与大规模社交媒体平台的运营现实相符

其他选项存在的问题：

- 选项A（每分钟标记的消息数量）只是一个吞吐量指标，不能反映标记的准确性；模型可能标记了很多消息，但都是误报
- 选项B（被确认为不当的标记消息数量）有选择性偏差，因为它只考虑模型已标记的内容，无法评估模型漏掉的不当内容（假阴性）
- 选项D（基于被标记消息的样本）同样存在选择性偏差，无法提供关于模型整体性能的真实画面，特别是关于召回率

在高容量内容平台上，使用随机抽样的原始消息计算精确率和召回率估计是监控内容审核模型性能的最佳方法，因为它提供了无偏见、全面和持续的评估。

问题 175

题目

你是一家零售公司的主要ML工程师。你想以集中化的方式跟踪和管理ML元数据，使你的团队能够通过生成工件来获得可重现的实验。你应该向你的团队推荐哪种管理解决方案？

You are a lead ML engineer at a retail company. You want to track and manage ML metadata in a centralized way so that your team can have reproducible experiments by generating artifacts. Which management solution should you recommend to your team?

选项

A. 在BigQuery中存储你的tf.logging数据。

Store your tf.logging data in BigQuery.

B. 在Hive Metastore中管理所有关系实体。

Manage all relational entities in the Hive Metastore.

C. 在Google Cloud的运维套件中存储所有ML元数据。

Store all ML metadata in Google Cloud's operations suite.

D. 使用Vertex ML Metadata管理你的ML工作流程。

Manage your ML workflows with Vertex ML Metadata.

正确答案：D. Manage your ML workflows with Vertex ML Metadata.

解析： 这个问题测试如何为ML团队选择合适的元数据管理解决方案，以支持实验可重现性和工件跟踪。

选项D是最佳解决方案，原因如下：

1. **专为ML元数据管理设计**：

- Vertex ML Metadata是Google Cloud的专用服务，专门为机器学习开发生命周期设计
- 它提供了跟踪执行、数据集、模型和指标等ML工件的能力
- 该服务支持元数据的结构化存储，包括参数、指标、数据集和模型等
- 这完全符合题目中"跟踪和管理ML元数据"的需求

2. **支持实验可重现性**：

- Vertex ML Metadata记录了生成ML工件的完整谱系（lineage）
- 这使团队能够跟踪哪些数据集、参数和代码版本生成了特定模型
- 可以重现过去的实验，通过查看相同的参数和数据集
- 这直接解决了题目中"可重现实验"的关键需求

3. **集中化和团队协作**：

- Vertex ML Metadata提供了一个集中式存储库来存储所有ML项目的元数据
- 团队成员可以共享、查询和重用彼此的实验和模型
- 这促进了知识共享和协作，使团队不会重复工作
- 满足了题目中"集中化方式"的需求

4. **与Google Cloud ML生态系统的集成**：

- Vertex ML Metadata与其他Vertex AI服务无缝集成
- 它可以自动捕获Vertex AI训练作业、管道和预测的元数据
- 这种集成简化了元数据管理，减少了手动记录的需要
- 作为零售公司，这种集成对于生产级ML系统特别重要

其他选项存在的问题：

- 选项A（BigQuery中的tf.logging数据）过于局限于TensorFlow日志数据，不提供实验可重现性所需的完整元数据管理
- 选项B（Hive Metastore）主要用于数据仓库元数据管理，而非ML工作流管理；它不是专为ML实验跟踪设计的
- 选项C（Google Cloud的运维套件）过于宽泛，不是为ML元数据和实验可重现性设计的专用解决方案

对于需要以集中方式跟踪ML元数据并实现实验可重现性的零售公司ML团队，Vertex ML Metadata提供了最全面、最专业的解决方案，使团队能够有效地生成、跟踪和重现ML工件。

问题 176

题目

你获得了一个包含基于公司营销活动的销售预测数据集。数据结构化存储在BigQuery中，由一个数据分析师团队精心管理。你需要准备一份报告，提供关于数据预测能力的见解。你被要求使用不同复杂程度的ML模型进行多次实验，包括简单模型和多层神经网络。你只有几个小时来收集实验结果。你应该使用哪些Google Cloud工具以最高效和自助方式完成这项任务？

You have been given a dataset with sales predictions based on your company's marketing activities. The data is structured and stored in BigQuery, and has been carefully managed by a team of data analysts. You need to prepare a report providing insights into the predictive capabilities of the data. You were asked to run several ML models with different levels of sophistication, including simple models and multilayered neural

networks. You only have a few hours to gather the results of your experiments. Which Google Cloud tools should you use to complete this task in the most efficient and self-serviced way?

选项

A. 使用BigQuery ML运行多个回归模型，并分析它们的性能。

Use BigQuery ML to run several regression models, and analyze their performance.

B. 使用Dataproc从BigQuery读取数据，并使用SparkML运行多个模型。

Read the data from BigQuery using Dataproc, and run several models using SparkML.

C. 使用Vertex AI Workbench用户管理的笔记本，通过scikit-learn代码运行各种ML算法和性能指标。

Use Vertex AI Workbench user-managed notebooks with scikit-learn code for a variety of ML algorithms and performance metrics.

D. 使用Vertex AI训练自定义TensorFlow模型，从BigQuery读取数据，并实现各种ML算法。

Train a custom TensorFlow model with Vertex AI, reading the data from BigQuery featuring a variety of ML algorithms.

正确答案：A. Use BigQuery ML to run several regression models, and analyze their performance.

解析： 这个问题测试如何在时间紧迫的情况下选择最有效的工具来分析数据并构建多种复杂度的ML模型。

选项A是最佳解决方案，原因如下：

1. **利用数据所在位置的优势**：
    - 数据已经存储在BigQuery中，使用BigQuery ML可以直接在数据所在位置训练模型
    - 这消除了数据移动的需要，显著减少了准备时间
    - 当时间紧迫时（"只有几个小时"），避免数据传输是关键的效率因素
    - 在数据源上直接处理避免了复制和移动大型数据集的开销
2. **自助服务能力**：
    - BigQuery ML提供了简单的SQL接口来训练和评估模型，无需复杂的设置
    - 它允许通过熟悉的SQL语言快速迭代不同的模型，非常适合时间有限的探索
    - 用户可以立即开始建模，无需配置额外的基础设施或环境
    - 这种自助方法完美符合题目要求的"最高效和自助方式"
3. **支持不同复杂度的模型**：
    - BigQuery ML支持多种模型类型，从简单的线性回归到复杂的深度神经网络
    - 它可以处理"不同复杂程度的ML模型...包括简单模型和多层神经网络"的要求
    - 用户可以快速实验不同类型的模型，并比较它们的性能
    - 内置的评估和解释功能使准备所需的"见解报告"变得更加容易
4. **快速实验迭代**：
    - 使用SQL训练和评估模型允许快速迭代，非常适合有限的时间窗口

    - 内置的模型评估函数可以快速生成性能指标
    - 可以轻松比较不同模型的结果，为报告提供全面视角
    - 这些因素结合在一起，使BigQuery ML成为在几小时内获得结果的理想选择

其他选项存在的问题：

- 选项B（Dataproc和SparkML）需要设置Spark集群并将数据从BigQuery移动到Dataproc，这在时间有限的情况下会增加不必要的复杂性和延迟
- 选项C（Vertex AI Workbench和scikit-learn）虽然灵活，但需要将数据从BigQuery导出，并设置笔记本环境，增加了前期工作
- 选项D（Vertex AI自定义TensorFlow模型）在所有选项中设置时间最长，需要创建自定义TensorFlow代码、配置训练作业并管理模型部署

当数据已经在BigQuery中，且需要在几个小时内快速实验多种模型时，BigQuery ML是最高效的自助式解决方案，它最大限度地减少了设置时间，并允许专注于模型构建和分析。

问题 177

题目

你是一家银行的ML工程师。你使用AutoML Tables开发了一个二元分类模型，用于预测客户是否会按时偿还贷款。该输出用于批准或拒绝贷款申请。一位客户的贷款申请被你的模型拒绝，银行的风险部门正要求你提供导致模型做出这一决定的原因。你应该怎么做？

You are an ML engineer at a bank. You have developed a binary classification model using AutoML Tables to predict whether a customer will make loan payments on time. The output is used to approve or reject loan requests. One customer's loan request has been rejected by your model, and the bank's risks department is asking you to provide the reasons that contributed to the model's decision. What should you do?

选项

A. 使用预测的局部特征重要性。

Use local feature importance from the predictions.

B. 使用数据摘要页面中与目标值的相关性。

Use the correlation with target values in the data summary page.

C. 使用模型评估页面中的特征重要性百分比。

Use the feature importance percentages in the model evaluation page.

D. 独立变化特征以识别每个特征改变分类的阈值。

Vary features independently to identify the threshold per feature that changes the classification.

正确答案：A. Use local feature importance from the predictions.

解析： 这个问题测试如何为特定预测提供可解释性，特别是在使用AutoML Tables等自动化ML服务构建的模型中。

选项A是最佳解决方案，原因如下：

1. **个体预测的解释需求**：
    - 问题明确指出需要解释"一位客户的贷款申请被拒绝"的具体原因
    - 局部特征重要性专门设计用于解释单个实例的预测结果
    - 它显示每个特征对该特定预测的贡献程度
    - 这正是风险部门询问的"导致模型做出这一决定的原因"
2. **AutoML Tables的内置功能**：
    - AutoML Tables提供局部特征重要性作为其可解释性功能的一部分
    - 这些解释对于每个预测都是唯一的，反映了特定客户数据的影响
    - 用户可以直接从预测结果中获取这些解释，无需额外的计算
    - 这些局部解释通常以可视化形式呈现，便于与非技术利益相关者（如风险部门）沟通
3. **符合银行和金融服务的监管需求**：
    - 在金融服务领域，解释为何拒绝贷款申请通常是监管合规的要求
    - 局部特征重要性提供了具体的、单一实例级别的解释
    - 这些解释可用于向客户和监管机构证明决策是基于相关因素而非歧视性特征
    - 这种透明度对于银行业尤为重要，尤其是在涉及信贷决策时
4. **实用性和即时可用性**：
    - 局部特征重要性可以立即从已完成的预测中提取
    - 无需重新训练模型或执行额外的分析
    - 这些解释是为该特定预测量身定制的，而非一般性观察
    - 这使风险部门能够直接了解拒绝该特定客户贷款申请的原因

其他选项存在的问题：

- 选项B（与目标值的相关性）只提供数据集中的一般统计关系，无法解释特定预测
- 选项C（特征重要性百分比）是全局解释而非局部解释，显示对整体模型性能的影响，而非单个预测
- 选项D（独立变化特征）是一种需要额外计算的敏感性分析方法，在AutoML Tables中不是现成可用的功能，且计算成本高

对于需要解释特定客户贷款申请被拒绝原因的银行ML工程师来说，使用预测的局部特征重要性是最直接、最相关且最符合监管要求的方法。

问题 178

题目

你在一家杂志发行商工作，需要构建一个模型来预测哪些客户将在来年续订他们的订阅。使用公司的历史数据作为训练集，你创建了一个TensorFlow模型并将其部署到AI Platform。你需要确定对模型提供的每个预测而言，哪个客户属性具有最强的预测能力。你应该怎么做？

You work for a magazine distributor and need to build a model that predicts which customers will renew their subscriptions for the upcoming year. Using your company's historical data as your training set, you created a TensorFlow model and deployed it to AI Platform. You need to determine which customer attribute has the most predictive power for each prediction served by the model. What should you do?

选项

A. 使用AI Platform笔记本对模型执行Lasso回归分析，这将消除不提供强信号的特征。

Use AI Platform notebooks to perform a Lasso regression analysis on your model, which will eliminate features that do not provide a strong signal.

B. 将预测结果流式传输到BigQuery。使用BigQuery的CORR(X1, X2)函数计算每个特征与目标变量之间的皮尔逊相关系数。

Stream prediction results to BigQuery. Use BigQuery's CORR(X1, X2) function to calculate the Pearson correlation coefficient between each feature and the target variable.

C. 在AI Platform上使用AI Explanations功能。提交每个预测请求时使用'explain'关键字，以使用采样Shapley方法检索特征归因。

Use the AI Explanations feature on AI Platform. Submit each prediction request with the 'explain' keyword to retrieve feature attributions using the sampled Shapley method.

D. 使用Google Cloud中的What-If工具来确定在排除单个特征时模型的表现。按照从模型中删除时导致性能下降最显著的顺序对特征重要性进行排序。

Use the What-If tool in Google Cloud to determine how your model will perform when individual features are excluded. Rank the feature importance in order of those that caused the most significant performance drop when removed from the model.

正确答案：C. Use the AI Explanations feature on AI Platform. Submit each prediction request with the 'explain' keyword to retrieve feature attributions using the sampled Shapley method.

解析： 这个问题测试如何确定模型中各个特征对特定预测的重要性，特别是在已部署到AI Platform的模型情境中。

选项C是最佳解决方案，原因如下：

1. **针对个体预测的特征归因**：
    - 问题要求确定"对模型提供的每个预测而言"哪个客户属性最重要
    - AI Explanations使用采样Shapley方法为每个单独的预测提供特征归因
    - 这种方法计算每个特征对特定预测结果的贡献
    - 这正好满足了需要了解个体预测层面特征重要性的要求
2. **与部署模型的集成**：
    - 模型已经部署在AI Platform上，AI Explanations是该平台的内置功能
    - 通过在预测请求中简单地添加'explain'关键字即可获取解释
    - 无需修改已部署的模型或创建新的分析流程
    - 这提供了一种无缝集成且低摩擦的解决方案
3. **Shapley值的理论基础**：
    - 采样Shapley方法基于合作博弈论中的Shapley值
    - 它提供了一种公平的方式来分配特征对预测的贡献

    - 这种方法考虑了特征之间的交互作用
    - 它是目前解释复杂模型个体预测的最先进方法之一

4. **实用性和效率**：

    - 采样Shapley方法通过采样近似来提高计算效率
    - 它可以应用于任何类型的模型，包括复杂的TensorFlow模型
    - 结果易于解释，通常以图形方式呈现，显示每个特征的相对重要性
    - 这种方法的结果可以直接用于业务决策和沟通

其他选项存在的问题：

- 选项A（Lasso回归分析）是一种特征选择技术，用于确定全局重要性而非每个预测的特征重要性；它需要创建一个新的简化模型
- 选项B（BigQuery相关系数）仅测量线性关系，不能捕捉复杂的非线性特征交互；它也只提供全局特征重要性，而非每个预测的
- 选项D（What-If工具）通过特征消融来评估全局特征重要性，而非每个预测的特征归因；此外，它需要重新运行模型多次，效率较低

对于需要确定TensorFlow模型每个预测的最重要客户属性的杂志发行商来说，使用AI Platform的AI Explanations功能提供了最直接、最精确且最易于实施的解决方案。

问题 179

题目

你正在开发一个二元分类ML算法，用于检测机密扫描文档的图像中是否包含公司标志。在数据集中，96%的样本没有标志，因此数据集非常倾斜。哪些指标能给你的模型提供最大的信心？

You are working on a binary classification ML algorithm that detects whether an image of a classified scanned document contains a company's logo. In the dataset, 96% of examples don't have the logo, so the dataset is very skewed. Which metrics would give you the most confidence in your model?

选项

A. F-score，其中召回率的权重大于精确率。

F-score where recall is weighed more than precision

B. RMSE

RMSE

C. F1 score

F1 score

D. F-score，其中精确率的权重大于召回率。

F-score where precision is weighed more than recall

正确答案：A. F-score where recall is weighed more than precision

解析： 这个问题测试如何为高度不平衡的分类数据集选择合适的评估指标。

选项A是最佳解决方案，原因如下：

1. **处理数据不平衡的合适指标**：
   - 当数据集极度不平衡（96%的样本属于一个类别）时，准确率这样的标准指标会产生误导
   - 简单地预测"无标志"对所有样本，模型就能轻松达到96%的准确率，但这完全没有实用价值
   - F-score结合了精确率和召回率，是处理不平衡数据的良好选择
   - 在安全关键应用中，调整F-score中的权重以强调召回率（即使用Fβ，β>1）是合适的

2. **召回率优先的安全理由**：
   - 在机密文档处理中，漏报（未能识别出含有公司标志的文档）可能带来严重的安全或合规风险
   - 给定这是"机密扫描文档"，确保捕获所有可能包含敏感信息的文档至关重要
   - 即使代价是产生一些误报需要额外的人工审核，这也比漏掉可能存在安全风险的文档要好
   - 强调召回率的F-score能更好地优化模型，确保尽可能多地捕获实际包含标志的文档

3. **比较其他指标的不足**：
   - RMSE（均方根误差）主要用于回归问题，不适用于二元分类任务
   - F1 score虽然也结合了精确率和召回率，但对两者给予相同权重，无法突出召回率在安全应用中的重要性
   - 精确率权重高于召回率的F-score在安全关键应用中不是最佳选择，因为它可能导致危险的漏检

4. **安全和合规视角**：
   - 在安全相关应用中，漏检（假阴性）通常比误报（假阳性）具有更严重的后果
   - 误报仅导致额外的人工审核成本，而漏报可能导致安全漏洞或违规
   - 由于我们处理的是"机密"文档，保守的方法是优先考虑安全而不是效率
   - 在这种情况下，即使导致更多人工审核的工作量，也应确保不会漏掉任何实际包含标志的文档

当处理涉及机密文档的高度不平衡的二元分类问题时，安全考虑通常优先于效率，使用召回率权重大于精确率的F-score（Fβ，β>1）提供了最适合的性能评估指标，能够在保障安全的前提下给予模型表现最大的信心。

问题 180

题目

你在一家跨国饮料公司的数据科学团队工作。你需要开发一个ML模型，预测公司在不同地区推出新系列天然风味瓶装水的盈利能力。你获得了包含所有地区的产品类型、产品销售量、费用和利润的历史数据。你应该使用什么作为模型的输入和输出？

You work on the data science team for a multinational beverage company. You need to develop an ML model to predict the company's profitability for a new line of naturally flavored bottled waters in different locations. You are provided with historical data that includes product types, product sales volumes, expenses, and profits for all regions. What should you use as the input and output for your model?

选项

A. 使用纬度、经度和产品类型作为特征。使用利润作为模型输出。

Use latitude, longitude, and product type as features. Use profit as model output.

B. 使用纬度、经度和产品类型作为特征。使用收入和支出作为模型输出。

Use latitude, longitude, and product type as features. Use revenue and expenses as model outputs.

C. 使用产品类型以及纬度与经度的交叉特征，然后进行分箱，作为特征。使用利润作为模型输出。

Use product type and the feature cross of latitude with longitude, followed by binning, as features. Use profit as model output.

D. 使用产品类型以及纬度与经度的交叉特征，然后进行分箱，作为特征。使用收入和支出作为模型输出。

Use product type and the feature cross of latitude with longitude, followed by binning, as features. Use revenue and expenses as model outputs.

正确答案：C. Use product type and the feature cross of latitude with longitude, followed by binning, as features. Use profit as model output.

解析： 这个问题测试如何为预测业务盈利能力设计适当的特征工程和模型输出结构。

选项C是最佳解决方案，原因如下：

1. **高级特征工程的优势**：
    - 仅使用原始的纬度和经度作为单独特征可能无法捕捉地理位置的完整模式
    - 创建纬度和经度的交叉特征可以捕捉特定地理区域的独特特性
    - 对这些交叉特征进行分箱处理可以创建有意义的地理区域，使模型能够学习区域层面的模式
    - 这种方法比简单使用原始坐标创建了更具预测力的特征
2. **恰当的模型输出选择**：
    - 题目明确要求预测"盈利能力"，利润是衡量盈利能力的直接指标
    - 使用单一的利润输出简化了模型，使其更容易优化和解释
    - 与预测收入和支出然后间接计算利润相比，直接预测利润可以减少累积误差
    - 利润作为单一目标使模型训练更加专注，而不是在多个目标间分散注意力
3. **特征与业务问题的匹配**：
    - 产品类型是关键特征，因为不同类型的饮料可能有不同的盈利模式
    - 地理位置（通过交叉特征和分箱处理）捕捉了市场差异，如消费偏好、定价弹性和竞争格局
    - 这些特征恰好匹配了题目中的业务问题：预测"不同地区"的新产品线盈利能力
    - 这种方法能够捕捉区域与产品类型之间可能存在的重要交互作用
4. **可扩展性和通用性**：
    - 纬度和经度的交叉特征加分箱可以应用于任何地理位置，包括公司尚未开展业务的新区域
    - 预测利润的模型可以直接用于商业决策，如市场进入策略和产品组合优化
    - 这种方法不需要预先收集新区域的收入和支出数据，只需要地理坐标和类似产品类型
    - 它为扩展到新市场提供了可扩展的分析框架

其他选项存在的问题：

- 选项A缺乏高级特征工程，简单使用原始纬度和经度无法充分捕捉地理区域的复杂性
- 选项B不仅缺乏高级特征工程，还使用了多输出模型，增加了复杂性且不直接解决盈利能力预测问题
- 选项D虽然使用了高级特征工程，但与选项B一样，使用双重输出（收入和支出）增加了模型复杂性，且需要额外步骤计算最终关注的利润

通过结合适当的特征工程（产品类型和地理交叉特征加分箱）和直接相关的目标输出（利润），选项C提供了一个既强大又简洁的解决方案，最适合预测不同地区新产品线的盈利能力。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 19)

问题 181

题目

你是一家社交媒体公司的ML工程师，你正在开发一个用户头像照片的视觉滤镜。这需要你训练一个ML模型来检测人脸周围的边界框。你想在公司的iOS移动应用程序中使用这个滤镜。你希望最小化代码开发工作量，并希望模型针对移动手机推理进行优化。你应该怎么做？

You work as an ML engineer at a social media company, and you are developing a visual filter for users' profile photos. This requires you to train an ML model to detect bounding boxes around human faces. You want to use this filter in your company's iOS-based mobile phone application. You want to minimize code development and want the model to be optimized for inference on mobile phones. What should you do?

选项

A. 使用AutoML Vision训练模型，并使用"导出为Core ML"选项。

Train a model using AutoML Vision and use the "export for Core ML" option.

B. 使用AutoML Vision训练模型，并使用"导出为Coral"选项。

Train a model using AutoML Vision and use the "export for Coral" option.

C. 使用AutoML Vision训练模型，并使用"导出为TensorFlow.js"选项。

Train a model using AutoML Vision and use the "export for TensorFlow.js" option.

D. 训练自定义TensorFlow模型，并将其转换为TensorFlow Lite（TFLite）。

Train a custom TensorFlow model and convert it to TensorFlow Lite (TFLite).

正确答案：A. Train a model using AutoML Vision and use the "export for Core ML" option.

解析： 这个问题测试如何为iOS移动应用程序选择合适的ML模型训练和导出方法。

选项A是最佳解决方案，原因如下：

1. **针对iOS平台优化**：
    - Core ML是Apple专为iOS设备开发的机器学习框架

- 它专门针对iOS设备进行了优化，可以充分利用设备的硬件加速功能（如Neural Engine）
- 使用Core ML格式的模型在iOS设备上运行时效率更高，能耗更低
- 这完全符合题目中"希望模型针对移动手机推理进行优化"的要求

2. **自动化程度和代码开发最小化**：

- AutoML Vision是一个无需编写大量代码就能训练高质量视觉模型的托管服务
- "导出为Core ML"选项可以直接生成可在iOS应用中使用的模型文件
- 这极大减少了从模型训练到部署的开发工作
- 这满足了题目中"最小化代码开发工作量"的要求

3. **面部检测任务的适用性**：

- AutoML Vision具有检测对象（包括人脸）周围边界框的能力
- 它可以通过标记数据集轻松训练用于人脸检测的模型
- 这种方法非常适合题目中描述的"检测人脸周围的边界框"任务
- 对于视觉滤镜这类应用，面部检测是关键的第一步

4. **集成便捷性**：

- Core ML模型可以直接集成到iOS应用中，使用Swift或Objective-C
- Apple提供了全面的API和工具，使Core ML模型的集成变得简单
- 开发者不需要处理复杂的模型转换或优化过程
- 整体工作流程更简单，更符合"最小化代码开发"的目标

其他选项存在的问题：

- 选项B（导出为Coral）适用于Google的Edge TPU设备，而不是iOS设备；Coral是为Google自己的边缘计算硬件设计的
- 选项C（导出为TensorFlow.js）主要用于在Web浏览器中运行模型，不是为iOS原生应用设计的；在移动设备上可能会有性能问题
- 选项D（自定义TensorFlow模型并转换为TFLite）虽然TFLite可以在iOS上运行，但需要更多的代码开发工作，不符合"最小化代码开发"的要求

对于在iOS应用中实现人脸检测滤镜的需求，使用AutoML Vision训练模型并导出为Core ML格式是最简单、最优化且最符合要求的方法。

问题 182

题目

你被要求使用存储在中等大小（约10 GB）的BigQuery表中的数据集构建一个模型。你需要快速确定这些数据是否适合模型开发。你想创建一份一次性报告，其中包含数据分布的信息可视化和更复杂的统计分析，以便与团队中的其他ML工程师分享。你需要最大的灵活性来创建报告。你应该怎么做？

You have been asked to build a model using a dataset that is stored in a medium-sized (~10 GB) BigQuery table. You need to quickly determine whether this data is suitable for model development. You want to create a one-time report that includes both informative visualizations of data distributions and more sophisticated statistical analyses to share with other ML engineers on your team. You require maximum flexibility to create your report. What should you do?

选项

A. 使用Vertex AI Workbench用户管理的笔记本生成报告。

Use Vertex AI Workbench user-managed notebooks to generate the report.

B. 使用Google Data Studio创建报告。

Use the Google Data Studio to create the report.

C. 使用Dataflow上的TensorFlow Data Validation输出生成报告。

Use the output from TensorFlow Data Validation on Dataflow to generate the report.

D. 使用Dataprep创建报告。

Use Dataprep to create the report.

正确答案：A. Use Vertex AI Workbench user-managed notebooks to generate the report.

解析： 这个问题测试如何选择合适的工具来分析数据集并创建灵活的报告。

选项A是最佳解决方案，原因如下：

1. **最大的灵活性**：
    - Vertex AI Workbench用户管理的笔记本提供了完整的Jupyter笔记本环境
    - 这允许使用Python、R或其他语言编写自定义代码来执行任何类型的分析
    - 你可以使用任何开源或自定义库进行数据可视化和统计分析
    - 这完全满足题目中"最大的灵活性"的要求
2. **BigQuery数据访问和处理**：
    - Vertex AI Workbench可以直接连接到BigQuery并查询数据
    - 对于10GB大小的数据集，笔记本可以高效处理，无论是直接查询还是下载子集
    - 它支持使用BigQuery存储API或使用`%%bigquery`魔术命令轻松查询数据
    - 这种连接使得处理存储在BigQuery中的数据变得简单高效
3. **高级可视化和统计分析**：
    - 使用matplotlib、seaborn、plotly等库可以创建各种高级数据可视化
    - 可以使用scipy、statsmodels、scikit-learn等库进行复杂的统计分析
    - 支持交互式可视化，使数据探索更加直观
    - 这满足了题目中"包含数据分布的信息可视化和更复杂的统计分析"的要求
4. **共享和协作**：
    - 笔记本可以导出为多种格式（HTML、PDF等）以便分享
    - 其他团队成员可以查看或复制笔记本来重现分析
    - 代码和结果并排显示，使报告更容易理解
    - 这满足了题目中"与团队中的其他ML工程师分享"的需求

其他选项存在的问题：

- 选项B（Google Data Studio）提供了良好的可视化功能，但在执行复杂统计分析方面灵活性有限；它更适合创建仪表板而非深入的数据分析
- 选项C（TensorFlow Data Validation）专注于数据验证和模式检查，而非一般的数据探索和可视化；它的功能范围太窄，不满足"最大灵活性"的要求
- 选项D（Dataprep）是一个数据准备和转换工具，虽然有一些可视化功能，但在执行高级统计分析方面的灵活性不足；它更适合数据清洗和转换，而非复杂的探索性数据分析

对于需要灵活性来执行各种数据分析和创建包含高级可视化和统计分析的报告，Vertex AI Workbench用户管理的笔记本是最合适的选择，它提供了所需的灵活性和功能，同时能够高效处理存储在BigQuery中的数据。

问题 183

题目

你在一家国际公司的运维团队工作，该公司管理着分布在世界各地数据中心的大量本地服务器。你的团队收集服务器的监控数据，包括CPU/内存消耗情况。当服务器发生故障时，你的团队负责修复。目前，故障数据尚未被正确标记。你的管理团队希望你建立一个预测性维护解决方案，使用虚拟机的监控数据来检测潜在故障并向服务台团队发出警报。你应该首先做什么？

You work on an operations team at an international company that manages a large fleet of on-premises servers located in few data centers around the world. Your team collects monitoring data from the servers, including CPU/memory consumption. When an incident occurs on a server, your team is responsible for fixing it. Incident data has not been properly labeled yet. Your management team wants you to build a predictive maintenance solution that uses monitoring data from the VMs to detect potential failures and then alerts the service desk team. What should you do first?

选项

A. 训练一个时间序列模型来预测机器的性能值。配置一个警报，当机器的实际性能值与预测的性能值显著不同时触发。

Train a time-series model to predict the machines' performance values. Configure an alert if a machine's actual performance values significantly differ from the predicted performance values.

B. 实现一个简单的启发式方法（例如，基于z-score）来标记机器的历史性能数据。训练一个模型，基于这个标记的数据集来预测异常。

Implement a simple heuristic (e.g., based on z-score) to label the machines' historical performance data. Train a model to predict anomalies based on this labeled dataset.

C. 开发一个简单的启发式方法（例如，基于z-score）来标记机器的历史性能数据。在生产环境中测试这个启发式方法。

Develop a simple heuristic (e.g., based on z-score) to label the machines' historical performance data. Test this heuristic in a production environment.

D. 雇佣一个合格的分析师团队来审查和标记机器的历史性能数据。基于这个手动标记的数据集训练一个模型。

Hire a team of qualified analysts to review and label the machines' historical performance data. Train a model based on this manually labeled dataset.

正确答案：B. Implement a simple heuristic (e.g., based on z-score) to label the machines' historical performance data. Train a model to predict anomalies based on this labeled dataset.

解析： 这个问题测试如何在缺乏标记数据的情况下开始构建预测性维护解决方案。

选项B是最佳解决方案，原因如下：

1. **解决标记数据缺失的问题**：
    - 题目明确指出"故障数据尚未被正确标记"，这是构建监督学习模型的首要障碍
    - 使用简单的启发式方法（如z-score）可以快速有效地识别历史数据中的异常情况
    - 这种方法可以自动为历史性能数据创建标签，识别哪些模式可能代表故障或异常
    - 这解决了缺乏标记数据的主要挑战，为后续的模型训练奠定基础
2. **完整的解决方案路径**：
    - 此选项不仅包括数据标记策略，还包括基于标记数据训练预测模型的完整流程
    - 它提供了一个端到端的解决方案：从无标记数据到标记数据，再到预测模型
    - 这种方法最终可以实现预测性维护的目标：检测潜在故障并发出警报
    - 它满足了管理团队的需求，提供了一个可行的路径来构建所需的解决方案
3. **平衡速度和质量**：
    - 启发式方法可以快速实施，无需等待长时间的人工标记过程
    - 虽然不如人工标记精确，但对于初始模型训练来说已经足够
    - 这种方法可以让团队快速开始构建解决方案，而不是在前期工作上花费过多时间
    - 随着时间推移，模型和标记方法都可以进一步优化和改进
4. **资源高效性**：
    - 不需要额外雇佣人员或分配大量资源进行手动标记
    - 可以使用现有的数据和计算资源实施
    - 这种方法在计算和人力资源方面都具有成本效益
    - 适合作为预测性维护项目的起点，没有过高的初始投入

其他选项存在的问题：

- 选项A跳过了数据标记步骤，直接训练时间序列模型；在没有标记数据的情况下，很难评估模型的性能和有效性
- 选项C只实施了启发式标记方法但没有继续训练预测模型，停留在半途而未完成整个解决方案
- 选项D需要大量的人力资源和时间投入，实施成本高，不适合作为第一步；虽然人工标记的质量可能更高，但不是一个高效的起点

在构建预测性维护解决方案时，使用简单启发式方法标记历史数据并基于此训练预测模型是一个平衡效率和效果的最佳第一步，特别是在面临标记数据缺失的情况下。

问题 184

题目

你正在开发一个ML模型，该模型使用视频流中的切片帧并在特定对象周围创建边界框。你想要自动化训练管道中的以下步骤：在Cloud Storage中摄取和预处理数据，然后使用Vertex AI作业进行对象模型的训练和超参数调

优，最后将模型部署到一个端点。你希望以最少的集群管理来编排整个管道。你应该使用什么方法？

You are developing an ML model that uses sliced frames from video feed and creates bounding boxes around specific objects. You want to automate the following steps in your training pipeline: ingestion and preprocessing of data in Cloud Storage, followed by training and hyperparameter tuning of the object model using Vertex AI jobs, and finally deploying the model to an endpoint. You want to orchestrate the entire pipeline with minimal cluster management. What approach should you use?

选项

A. 在Google Kubernetes Engine上使用Kubeflow管道。

Use Kubeflow Pipelines on Google Kubernetes Engine.

B. 使用Vertex AI管道和TensorFlow Extended (TFX) SDK。

Use Vertex AI Pipelines with TensorFlow Extended (TFX) SDK.

C. 使用Vertex AI管道和Kubeflow管道SDK。

Use Vertex AI Pipelines with Kubeflow Pipelines SDK.

D. 使用Cloud Composer进行编排。

Use Cloud Composer for the orchestration.

正确答案：C. Use Vertex AI Pipelines with Kubeflow Pipelines SDK.

解析： 这个问题测试如何为ML训练管道选择适当的编排解决方案，特别是在需要最小化集群管理的情况下。

选项C是最佳解决方案，原因如下：

1. **最小化集群管理**：
    - Vertex AI管道是一个完全托管的服务，不需要用户管理任何底层基础设施
    - 用户无需配置、扩展或维护集群资源
    - 这满足了题目中"最少的集群管理"的关键要求
    - 与需要管理Kubernetes集群或Airflow环境的解决方案相比，这大大减少了运维负担
2. **框架无关的灵活性**：
    - Kubeflow管道SDK是框架无关的，支持各种ML框架（TensorFlow、PyTorch、scikit-learn等）
    - 题目中没有指定使用特定的框架，因此选择一个通用SDK提供了更大的灵活性
    - 这使团队可以根据具体任务需求选择最合适的工具和库
    - 对于视频处理和对象检测，可能需要使用多种框架和工具的组合
3. **完整的管道支持**：
    - Kubeflow管道SDK提供了构建端到端ML工作流所需的所有组件
    - 它支持数据摄取、预处理、模型训练、超参数调优和模型部署
    - 这些组件完美匹配题目中描述的所有管道步骤
    - SDK允许定义可重用、可组合的管道组件

4. **与Vertex AI的集成**：
    - Vertex AI管道原生支持Kubeflow管道SDK
    - 各个步骤之间的数据无缝流动，减少了手动干预的需要
    - 管道可以被调度为定期运行，支持模型的持续训练和改进
    - 这种集成简化了从开发到生产的整个ML生命周期

其他选项存在的问题：

- 选项A（Kubeflow管道on GKE）需要管理Kubernetes集群，不符合"最少的集群管理"要求；虽然功能强大，但增加了运维复杂性
- 选项B（Vertex AI管道with TFX SDK）假设使用TensorFlow框架，但题目没有指定使用任何特定框架；这限制了在选择最适合任务的框架方面的灵活性
- 选项D（Cloud Composer）是基于Apache Airflow的通用工作流工具，不是专为ML工作流优化的；它要求设置和管理Airflow环境，这增加了一定的管理负担

对于需要自动化ML训练管道并希望最小化集群管理的场景，特别是在没有指定特定ML框架的情况下，使用Vertex AI管道和Kubeflow管道SDK的组合提供了既灵活又无需管理基础设施的理想解决方案。

问题 185

题目

你正在使用一个包含300万张X光图像的数据集训练对象检测机器学习模型，每张图像大约2 GB。你使用Vertex AI Training在一个配置了32核CPU、128 GB RAM和1个NVIDIA P100 GPU的Compute Engine实例上运行自定义训练应用程序。你注意到模型训练花费了非常长的时间。你想在不牺牲模型性能的情况下减少训练时间。你应该怎么做？

You are training an object detection machine learning model on a dataset that consists of three million X-ray images, each roughly 2 GB in size. You are using Vertex AI Training to run a custom training application on a Compute Engine instance with 32-cores, 128 GB of RAM, and 1 NVIDIA P100 GPU. You notice that model training is taking a very long time. You want to decrease training time without sacrificing model performance. What should you do?

选项

A. 将实例内存增加到512 GB并增加批处理大小。

Increase the instance memory to 512 GB and increase the batch size.

B. 在训练作业中将NVIDIA P100 GPU替换为v3-32 TPU。

Replace the NVIDIA P100 GPU with a v3-32 TPU in the training job.

C. 在Vertex AI Training作业中启用早停。

Enable early stopping in your Vertex AI Training job.

D. 使用tf.distribute.Strategy API并运行分布式训练作业。

Use the tf.distribute.Strategy API and run a distributed training job.

正确答案：B. Replace the NVIDIA P100 GPU with a v3-32 TPU in the training job.

解析： 这个问题测试如何优化大规模数据集上的模型训练时间，同时保持模型性能。

选项B是最佳解决方案，原因如下：

1. **TPU的卓越计算能力**：
    - v3-32 TPU相比单个NVIDIA P100 GPU提供了显著更高的计算能力
    - TPU专为机器学习工作负载优化，特别是对象检测等计算密集型任务
    - 单个v3-32 TPU包含32个TPU核心，可提供超过420 TFLOPS的计算性能，远超P100 GPU
    - 这种巨大的计算能力提升可以显著减少300万张X光图像的训练时间
2. **保持模型性能**：
    - 将GPU替换为TPU不会改变模型的基本结构或学习算法
    - 它只是提供了更强大的硬件加速器来执行相同的计算
    - 这满足了题目中"不牺牲模型性能"的要求
    - TPU训练通常能够保持或甚至提高模型的精度和性能
3. **针对大规模视觉数据的优化**：
    - TPU针对大规模数据集和深度学习模型进行了优化
    - 对于对象检测这类视觉任务，TPU的矩阵计算单元特别高效
    - TPU的高内存带宽能够更好地处理大型X光图像（每张2GB）
    - 这种专业化的计算架构特别适合数据密集型的计算机视觉任务
4. **实施简便性**：
    - 在Vertex AI Training中，将GPU替换为TPU是一个简单的配置更改
    - 不需要重写整个训练基础架构或重新设计数据处理流程
    - 这种方法比设置分布式训练系统更直接、更容易实施
    - 作为单一优化步骤，它提供了最佳的"投入产出比"

其他选项存在的问题：

- 选项A（增加内存和批处理大小）虽然可能加快训练速度，但内存不是主要瓶颈，单独增加批处理大小可能会影响模型收敛和最终性能
- 选项C（启用早停）会通过在验证性能不再提高时提前结束训练来减少训练时间，但这实际上可能导致模型欠拟合，从而牺牲模型性能
- 选项D（使用分布式训练）虽然有效，但设置更复杂，需要重构代码和数据流程，作为第一步可能过于复杂

对于处理300万张大型X光图像的对象检测模型训练，将NVIDIA P100 GPU替换为v3-32 TPU是减少训练时间同时维持模型性能的最直接、最有效的方法。TPU的专业设计正是为了加速这类大规模机器学习任务，使其成为这种情况下的理想选择。

问题 186

题目

你是一家工业设备制造公司的数据科学家。你正在开发一个回归模型，根据从所有工厂收集的传感器数据来估计公司制造工厂的能源消耗。传感器每天收集数千万条记录。你需要为你的模型安排日常训练运行，使用截至当前日期收集的所有数据。你希望你的模型能够平稳扩展并且需要最少的开发工作。你应该怎么做？

You are a data scientist at an industrial equipment manufacturing company. You are developing a regression model to estimate the power consumption in the company's manufacturing plants based on sensor data collected from all of the plants. The sensors collect tens of millions of records every day. You need to schedule daily training runs for your model that use all the data collected up to the current date. You want your model to scale smoothly and require minimal development work. What should you do?

选项

A. 使用AutoML Tables训练回归模型。

Train a regression model using AutoML Tables.

B. 开发自定义TensorFlow回归模型，并使用Vertex AI Training进行优化。

Develop a custom TensorFlow regression model, and optimize it using Vertex AI Training.

C. 开发自定义scikit-learn回归模型，并使用Vertex AI Training进行优化。

Develop a custom scikit-learn regression model, and optimize it using Vertex AI Training.

D. 使用BigQuery ML开发回归模型。

Develop a regression model using BigQuery ML.

正确答案：D. Develop a regression model using BigQuery ML.

解析： 这个问题测试如何为需要处理大量工业传感器数据的回归模型选择适当的开发和训练方法。

选项D是最佳解决方案，原因如下：

1. **处理大规模数据的能力**：
    - BigQuery是专为处理大规模数据设计的，可以轻松处理"每天数千万条记录"的数据量
    - BigQuery ML允许直接在数据所在位置训练模型，无需数据移动
    - 这种方法对于持续增长的时间序列数据特别有效
    - 随着数据量增加，BigQuery ML会自动扩展，无需额外配置
2. **最少的开发工作**：
    - BigQuery ML使用SQL语法来定义和训练模型，无需编写复杂的Python代码
    - 对于熟悉SQL的数据科学家来说，学习曲线较低
    - 不需要设置和管理单独的ML基础设施
    - 这满足了题目中"需要最少的开发工作"的要求
3. **简化的日常训练调度**：
    - BigQuery作业可以通过Cloud Scheduler轻松调度
    - 可以设置每日自动运行的SQL查询来训练模型
    - 增量数据可以自动纳入训练过程

    - 这使得满足"日常训练运行"的要求变得简单

4. **平稳扩展能力**：

    - BigQuery的底层架构设计用于处理PB级数据
    - 它使用分布式查询执行，自动处理资源分配
    - 无需担心随着数据增长而手动调整计算资源
    - 这满足了题目中"平稳扩展"的要求

其他选项存在的问题：

- 选项A（AutoML Tables）虽然也需要最少的开发工作，但可能需要从原始存储位置导出数据，且对于需要每日重新训练的用例，可能不如BigQuery ML方便
- 选项B（自定义TensorFlow模型）需要大量开发工作来构建、优化和部署模型，不符合"最少的开发工作"的要求
- 选项C（自定义scikit-learn模型）同样需要大量开发工作，而且scikit-learn可能在处理非常大的数据集时面临扩展挑战

对于工业环境中需要每日处理大量传感器数据并重新训练的回归模型，BigQuery ML提供了最佳的平衡点，它结合了处理大规模数据的能力、最少的开发工作和平稳的扩展性。

问题 187

题目

你使用scikit-learn构建了一个自定义ML模型。训练时间比预期要长。你决定将模型迁移到Vertex AI Training，并希望改进模型的训练时间。你应该首先尝试什么？

You built a custom ML model using scikit-learn. Training time is taking longer than expected. You decide to migrate your model to Vertex AI Training, and you want to improve the model's training time. What should you try out first?

选项

A. 将模型迁移到TensorFlow，并使用Vertex AI Training进行训练。

Migrate your model to TensorFlow, and train it using Vertex AI Training.

B. 使用多个Compute Engine虚拟机以分布式模式训练模型。

Train your model in a distributed mode using multiple Compute Engine VMs.

C. 在Vertex AI上使用DLVM镜像训练模型，并确保代码尽可能利用NumPy和SciPy内部方法。

Train your model with DLVM images on Vertex AI, and ensure that your code utilizes NumPy and SciPy internal methods whenever possible.

D. 使用带GPU的Vertex AI Training训练模型。

Train your model using Vertex AI Training with GPUs.

正确答案：D. Train your model using Vertex AI Training with GPUs.

解析：这个问题测试如何为scikit-learn模型选择适当的加速方法，特别是在迁移到Vertex AI Training时。

选项D是最佳解决方案，原因如下：

1. **GPU加速的直接性能提升**：
    - GPU可以显著加速机器学习模型的训练，包括scikit-learn模型中的许多算法
    - 某些scikit-learn算法（如基于梯度的方法）可以从GPU加速中获益
    - 这是一个相对简单的变更，不需要重写模型或算法
    - 作为"首先尝试"的步骤，这是最直接、最低风险的选项
2. **Vertex AI Training的GPU支持**：
    - Vertex AI Training提供了多种GPU选项，可直接在训练作业配置中指定
    - 无需对代码进行大量修改，只需配置训练环境以包含GPU
    - 这种方法保留了原始scikit-learn模型的所有功能和特性
    - Vertex AI自动处理GPU的配置和管理，简化了实施过程
3. **与其他选项相比的实施简便性**：
    - 相比完全重写为TensorFlow模型或设置分布式训练，使用GPU是一个更快速的改进
    - 这可以作为一个初始步骤，评估性能提升后再考虑更复杂的优化
    - 题目特别询问"首先尝试什么"，强调了解决方案的实施顺序
    - GPU加速提供了良好的性能提升与实施复杂性的平衡
4. **与scikit-learn的兼容性**：
    - 虽然scikit-learn本身的大多数算法不直接使用GPU，但底层操作（如通过NumPy）可以受益
    - 有一些scikit-learn兼容的库（如RAPIDS）可以提供GPU加速版本的算法
    - 使用带GPU的Vertex AI环境为这些优化提供了基础
    - 这保持了与现有scikit-learn代码的兼容性，同时提供性能改进

其他选项存在的问题：

- 选项A（迁移到TensorFlow）需要完全重写模型，这是一个大型工程，不适合作为首要尝试的步骤
- 选项B（分布式训练）对于scikit-learn来说实施复杂，许多scikit-learn算法不容易并行化，作为首要步骤风险较高
- 选项C（DLVM镜像和优化NumPy/SciPy方法）虽然有帮助，但效果可能有限，且优化代码需要深入了解底层库

当考虑优化scikit-learn模型的训练时间时，使用Vertex AI Training的GPU是一个平衡了实施简易性和性能提升的最佳首要步骤。如果这种方法的改进不足，可以进一步考虑其他更复杂的优化。

问题 188

题目

你是一家旅游公司的ML工程师。多年来，你一直在研究客户的旅行行为，并部署了预测客户度假模式的模型。你观察到客户的度假目的地会基于季节性和假期而变化；然而，这些季节性变化在不同年份之间很相似。你想要快速且轻松地存储和比较不同年份的模型版本和性能统计数据。你应该怎么做？

You are an ML engineer at a travel company. You have been researching customers' travel behavior for many years, and you have deployed models that predict customers' vacation patterns. You have observed that customers' vacation destinations vary based on seasonality and holidays; however, these seasonal variations are similar across years. You want to quickly and easily store and compare the model versions and performance statistics across years. What should you do?

选项

A. 在Cloud SQL中存储性能统计数据。查询该数据库以比较各模型版本的性能统计数据。

Store the performance statistics in Cloud SQL. Query that database to compare the performance statistics across the model versions.

B. 在Vertex AI中为每年的每个季节创建模型版本。在Vertex AI UI的Evaluate选项卡中比较各模型的性能统计数据。

Create versions of your models for each season per year in Vertex AI. Compare the performance statistics across the models in the Evaluate tab of the Vertex AI UI.

C. 在Kubeflow中将每个季节每年的管道运行性能统计数据存储为一个实验。在Kubeflow UI中比较各实验的结果。

Store the performance statistics of each pipeline run in Kubeflow under an experiment for each season per year. Compare the results across the experiments in the Kubeflow UI.

D. 使用Vertex ML Metadata存储每个模型版本的性能统计数据，将季节和年份作为事件。比较各切片之间的结果。

Store the performance statistics of each version of your models using seasons and years as events in Vertex ML Metadata. Compare the results across the slices.

正确答案：D. Store the performance statistics of each version of your models using seasons and years as events in Vertex ML Metadata. Compare the results across the slices.

解析： 这个问题测试如何为随时间变化的模型性能数据选择合适的存储和比较方法。

选项D是最佳解决方案，原因如下：

1. **专为ML元数据管理设计**：
    - Vertex ML Metadata是专门为存储和分析ML工作流程元数据而设计的
    - 它可以捕获模型版本、参数、指标和其他相关元数据
    - 这个服务专门针对ML工作流程优化，比通用数据库更适合此任务
    - 它提供了专门的功能来比较不同实验和模型版本
2. **时间序列数据的结构化表示**：
    - 将"季节和年份作为事件"存储允许创建一个结构化的时间序列视图
    - 这种方法完美契合题目中"客户的度假目的地会基于季节性和假期而变化"的观察
    - 它创建了一个直观的方式来组织不同时间段的模型性能
    - 这种结构使得跨年份的季节性比较变得简单直观

3. **切片比较功能**：
    - Vertex ML Metadata允许创建和比较数据切片
    - 这些切片可以基于季节、年份或其他相关维度
    - 切片比较功能使得识别跨年份的季节性模式变得容易
    - 这满足了题目中"快速且轻松地...比较"的需求
4. **扩展性和集成**：
    - Vertex ML Metadata与其他Google Cloud ML服务无缝集成
    - 随着更多数据和模型版本的添加，该系统可以轻松扩展
    - 它提供了API，允许以编程方式存储和检索元数据
    - 这使得建立自动化流程来分析长期趋势变得可能

其他选项存在的问题：

- 选项A（Cloud SQL）虽然可行，但需要设计自定义表结构和查询，不如专为ML元数据设计的解决方案高效
- 选项B（Vertex AI模型版本）主要关注模型部署和版本控制，而非详细的时间序列性能分析；Evaluate选项卡的比较功能相对有限
- 选项C（Kubeflow实验）需要设置和维护Kubeflow环境，增加了复杂性；它更适合管道开发而非长期性能历史跟踪

对于需要长期跟踪ML模型性能并识别季节性模式的旅游公司来说，使用Vertex ML Metadata存储性能统计数据，并将季节和年份作为事件，提供了最佳的解决方案，既实现了结构化存储，又提供了强大的比较分析能力。

问题 189

题目

你正在开发一个ML模型，用于分类X光图像是否表明骨折风险。你已经在Vertex AI上使用TPU作为加速器训练了一个ResNet架构，但对训练时间和内存使用不满意。你想快速迭代你的训练代码，但对代码的修改要最小化。你还希望最小化对模型准确性的影响。你应该怎么做？

You are developing an ML model intended to classify whether X-ray images indicate bone fracture risk. You have trained a ResNet architecture on Vertex AI using a TPU as an accelerator, however you are unsatisfied with the training time and memory usage. You want to quickly iterate your training code but make minimal changes to the code. You also want to minimize impact on the model's accuracy. What should you do?

选项

A. 减少模型架构中的层数。

Reduce the number of layers in the model architecture.

B. 将全局批处理大小从1024减少到256。

Reduce the global batch size from 1024 to 256.

C. 减少模型中使用的图像尺寸。

Reduce the dimensions of the images used in the model.

D. 配置模型使用bfloat16而不是float32。

Configure your model to use bfloat16 instead of float32.

正确答案：D. Configure your model to use bfloat16 instead of float32.

解析： 这个问题测试如何优化TPU上运行的深度学习模型的训练性能，同时保持模型准确性。

选项D是最佳解决方案，原因如下：

1. **TPU优化的数值格式**：
    - bfloat16（脑浮点16位）是专为神经网络设计的数值格式，特别适合TPU
    - 与标准float32相比，bfloat16将内存使用量减少一半
    - TPU硬件专门针对bfloat16操作进行了优化，可以显著加速计算
    - 这正好解决了题目中提到的"训练时间和内存使用"问题
2. **代码变更最小化**：
    - 将数值精度从float32更改为bfloat16通常只需要修改一两行代码
    - 在大多数深度学习框架中，这只是设置一个参数或标志的问题
    - 不需要重构模型架构或数据处理管道
    - 这满足了题目中"对代码的修改要最小化"的要求
3. **对模型准确性影响最小**：
    - bfloat16保留了float32的指数位，只减少了尾数位
    - 这种设计使其能够表示与训练深度学习模型相关的广泛数值范围
    - 对于大多数神经网络应用，bfloat16和float32之间的准确性差异可以忽略不计
    - 这满足了题目中"最小化对模型准确性的影响"的要求
4. **特别适合医学图像分类**：
    - 医学图像分类（如骨折风险评估）对准确性要求很高
    - bfloat16提供了性能和准确性之间的最佳平衡
    - 在TPU上，bfloat16专门设计用于维持模型质量同时提高性能
    - 这使其成为这类医疗应用的理想选择

其他选项存在的问题：

- 选项A（减少层数）是对模型架构的重大更改，可能显著影响准确性，不符合"最小化对模型准确性的影响"的要求
- 选项B（减少批处理大小）可能实际上会增加总训练时间，因为每轮会处理更少的样本，且可能影响收敛性
- 选项C（减少图像尺寸）需要更改数据预处理管道，且可能导致丢失对于骨折检测至关重要的细节信息

对于在TPU上训练的ResNet模型，使用bfloat16替代float32是优化训练时间和内存使用的最佳方法，它只需要最小的代码更改，同时对模型准确性的影响最小。

问题 190

题目

你已经成功地将一个训练在表格数据上的大型复杂TensorFlow模型部署到生产环境中。你想要预测存储在名为my-fortune500-company-project项目中的subscription.subscriptionPurchase BigQuery表中每个订阅的生命周期价值（LTV）字段。你已经将所有训练代码组织到一个TensorFlow Extended (TFX) 管道中，从BigQuery表中预处理数据到将验证过的模型部署到Vertex AI端点。你希望防止预测漂移，即生产环境中的特征数据分布随时间显著变化的情况。你应该怎么做？

You have successfully deployed to production a large and complex TensorFlow model trained on tabular data. You want to predict the lifetime value (LTV) field for each subscription stored in the BigQuery table named subscription.subscriptionPurchase in the project named my fortune500-company-project. You have organized all your training code, from preprocessing data from the BigQuery table up to deploying the validated model to the Vertex AI endpoint, into a TensorFlow Extended (TFX) pipeline. You want to prevent prediction drift, i.e., a situation when a feature data distribution in production changes significantly over time. What should you do?

选项

A. 使用Vertex AI Pipelines实现模型的每日持续再训练。

Implement continuous retraining of the model daily using Vertex AI Pipelines.

B. 添加一个模型监控作业，每24小时对10%的传入预测进行采样。

Add a model monitoring job where 10% of incoming predictions are sampled 24 hours.

C. 添加一个模型监控作业，每24小时对90%的传入预测进行采样。

Add a model monitoring job where 90% of incoming predictions are sampled 24 hours.

D. 添加一个模型监控作业，每小时对10%的传入预测进行采样。

Add a model monitoring job where 10% of incoming predictions are sampled every hour.

正确答案：B. Add a model monitoring job where 10% of incoming predictions are sampled 24 hours.

解析： 这个问题测试如何检测和防止生产环境中的模型漂移问题，特别是特征分布变化导致的预测漂移。

选项B是最佳解决方案，原因如下：

1. **资源与检测能力的平衡**：
    - 每24小时采样一次提供了资源使用与漂移检测能力之间的最佳平衡
    - 10%的采样率足以获取有统计意义的数据样本，而不会对系统性能造成过大负担
    - 对于预测客户终身价值(LTV)这类长期指标，每日级别的监控通常足够及时
    - 这种方法为大型企业系统提供了可持续的监控框架
2. **更稳定的统计基础**：
    - 24小时周期可以减少短期波动和噪声的影响，提供更稳定的分布变化检测
    - 在相同采样率下，24小时收集的总样本量比1小时大得多，提供更可靠的统计显著性
    - 更大的样本集可以更准确地反映整体数据分布的变化
    - 这种方法减少了误报的可能性，提高了漂移检测的准确性

3. **适合LTV预测的特性**：
    - 生命周期价值(LTV)是一个长期指标，不太可能在小时级别发生显著变化
    - 客户订阅行为和价值模式通常以天、周、月为单位变化，而非小时
    - 每日监控与此类业务指标的性质相符
    - 这提供了及时的洞察，同时避免了过度监控
4. **成本效益最优化**：
    - 每24小时监控一次比每小时监控节省了显著的计算资源和成本
    - 在大型企业环境("my-fortune500-company-project")中，资源优化是重要考量
    - 成本节约不会显著影响漂移检测的有效性
    - 这种平衡使得长期持续监控在经济上更为可行

其他选项存在的问题：

- 选项A（每日持续再训练）是应对漂移的策略而不是检测机制；在确认存在漂移之前就进行再训练可能会浪费资源
- 选项C（24小时90%采样）采样率过高，会消耗过多资源并增加系统负担，而不会提供显著的额外检测益处
- 选项D（每小时10%采样）监控频率过高，对于LTV这类长期指标来说过于频繁，会导致资源浪费并可能捕获无意义的短期波动

对于需要监控表格数据模型预测客户终身价值的生产系统，每24小时对10%的传入预测进行采样提供了最佳的资源效率、统计可靠性和及时检测能力的平衡。

Google Cloud Professional Machine Learning Engineer 考试题目集 (Part 20)

问题 191

题目

你最近使用Keras开发了一个深度学习模型，现在你正在尝试不同的训练策略。首先，你使用单个GPU训练模型，但训练过程太慢。接下来，你使用tf.distribute.MirroredStrategy将训练分布到4个GPU上（没有其他更改），但你没有观察到训练时间的减少。你应该怎么做？

You recently developed a deep learning model using Keras, and now you are experimenting with different training strategies. First, you trained the model using a single GPU, but the training process was too slow. Next, you distributed the training across 4 GPUs using tf.distribute.MirroredStrategy (with no other changes), but you did not observe a decrease in training time. What should you do?

选项

A. 使用tf.distribute.Strategy.experimental_distribute_dataset分布数据集。

Distribute the dataset with tf.distribute.Strategy.experimental_distribute_dataset

B. 创建自定义训练循环。

Create a custom training loop.

C. 使用TPU和tf.distribute.TPUStrategy。

Use a TPU with tf.distribute.TPUStrategy.

D. 增加批处理大小。

Increase the batch size.

正确答案：A. Distribute the dataset with tf.distribute.Strategy.experimental_distribute_dataset

解析： 这个问题测试如何正确优化分布式深度学习训练，特别是在使用tf.distribute.MirroredStrategy时。

选项A是最佳解决方案，原因如下：

1. **数据分发的关键瓶颈**：
    - 当使用tf.distribute.MirroredStrategy时，如果没有正确地分发数据集，可能会导致严重的性能瓶颈
    - 默认情况下，数据集可能没有被优化为多GPU环境
    - tf.distribute.Strategy.experimental_distribute_dataset专门设计用来优化数据在设备间的分发
    - 这可以减少设备间的等待时间和数据传输开销
2. **解决数据管道瓶颈**：
    - 在分布式训练中，常见的瓶颈是数据加载和预处理
    - 未优化的数据集可能导致GPU等待数据，造成计算资源浪费
    - experimental_distribute_dataset方法可以并行处理数据加载和预处理
    - 这确保每个GPU都能及时获取数据，最大化计算资源的利用
3. **自动分片和预取**：
    - 这个API可以自动处理数据的分片（sharding）
    - 它还可以实现高效的数据预取（prefetching）
    - 这些优化对于多GPU环境至关重要
    - 原始代码可能没有这些优化，导致无法获得分布式训练的好处
4. **最小代码更改的有效解决方案**：
    - 实现这个解决方案只需要几行代码
    - 无需修改模型架构或训练循环的核心逻辑
    - 这是一个针对性强的更改，专门解决分布式训练的数据瓶颈
    - 它是优化tf.distribute.MirroredStrategy性能的关键步骤

其他选项存在的问题：

- 选项B（自定义训练循环）是一个过于复杂的解决方案，需要大量代码重写，而问题可能只是数据分发
- 选项C（使用TPU）是改变整个硬件架构，而不是解决当前设置中的性能问题
- 选项D（增加批处理大小）虽然可能有帮助，但如果数据分发是瓶颈，仅增加批大小可能无法解决根本问题，甚至可能加剧数据传输瓶颈

当在多GPU环境中使用tf.distribute.MirroredStrategy但没有看到预期的性能提升时，首先应该确保数据集通过experimental_distribute_dataset正确优化，这是解决分布式训练性能问题的关键步骤。

问题 192

题目

你在一家拥有全球数百万用户的游戏公司工作。所有游戏都提供了聊天功能，允许玩家实时交流。消息可以用20多种语言输入，并使用Cloud Translation API进行实时翻译。你被要求构建一个ML系统来实时审核聊天内容，同时确保各种语言之间的性能一致，且不改变现有的服务基础设施。你使用内部开发的word2vec模型对Cloud Translation API翻译的聊天消息进行嵌入，训练了第一个模型。然而，该模型在不同语言间的性能存在显著差异。你应该如何改进它？

You work for a gaming company that has millions of customers around the world. All games offer a chat feature that allows players to communicate with each other in real time. Messages can be typed in more than 20 languages and are translated in real time using the Cloud Translation API. You have been asked to build an ML system to moderate the chat in real time while assuring that the performance is uniform across the various languages and without changing the serving infrastructure. You trained your first model using an in-house word2vec model for embedding the chat messages translated by the Cloud Translation API. However, the model has significant differences in performance across the different languages. How should you improve it?

选项

A. 在损失函数中添加一个正则化项，如Min-Diff算法。

Add a regularization term such as the Min-Diff algorithm to the loss function.

B. 使用原始语言的聊天消息训练分类器。

Train a classifier using the chat messages in their original language.

C. 用GPT-3或T5替换内部的word2vec。

Replace the in-house word2vec with GPT-3 or T5.

D. 移除对误报率过高的语言的审核。

Remove moderation for languages for which the false positive rate is too high.

正确答案：C. Replace the in-house word2vec with GPT-3 or T5.

解析： 这个问题测试如何改进多语言聊天审核系统，特别是在不同语言间实现一致的性能。

选项C是最佳解决方案，原因如下：

1. **先进的多语言表示能力**：
    - GPT-3和T5等大型语言模型在多语言理解方面表现出色
    - 这些模型经过大量多语言数据的预训练，能够捕捉不同语言的细微差别
    - 与简单的word2vec相比，它们能够生成更丰富、更有语义意义的表示
    - 这些高质量的表示可以帮助模型在不同语言间保持一致的性能
2. **上下文理解能力**：
    - word2vec只能提供单词级别的嵌入，缺乏上下文理解

- GPT-3和T5能够理解完整句子和对话的上下文
- 这对于审核系统特别重要，因为有害内容往往依赖于上下文
- 这种理解能力可以显著提高所有语言的准确性

3. **迁移学习优势**：

- 这些大型模型已经习得了多语言的共性和差异
- 可以利用迁移学习来适应特定的审核任务
- 即使某些语言的训练数据较少，也能获得不错的性能
- 这有助于解决当前系统中不同语言性能不一致的问题

4. **符合不改变基础设施的要求**：

- 只需替换嵌入模型，不需要改变整体审核流程
- 仍然可以使用Cloud Translation API进行实时翻译
- 保持了系统的实时处理能力
- 这种方法是对现有管道的增强，而不是完全重构

其他选项存在的问题：

- 选项A（添加Min-Diff正则化）虽然可以帮助减少不同组间的性能差异，但它只是治标不治本，不解决表示质量的基本问题
- 选项B（使用原始语言训练）虽然有潜力，但需要为每种语言收集大量标记数据，这在20多种语言的情况下可能不可行
- 选项D（移除高误报率语言的审核）是回避问题而非解决问题，会导致用户体验不一致和安全隐患

通过用GPT-3或T5等先进的预训练语言模型替换内部开发的word2vec，可以显著提高多语言表示的质量和一致性，这是改进当前系统中语言间性能差异的最有效方法。

问题 193

题目

你在一家开发大型多人在线（MMO）游戏的游戏公司工作。你构建了一个TensorFlow模型，用于预测玩家在未来两周内是否会进行超过10美元的应用内购买。该模型的预测结果将用于调整每个用户的游戏体验。用户数据存储在BigQuery中。你应该如何部署模型，同时优化成本、用户体验和管理便捷性？

You work for a gaming company that develops massively multiplayer online (MMO) games. You built a TensorFlow model that predicts whether players will make in-app purchases of more than $10 in the next two weeks. The model's predictions will be used to adapt each user's game experience. User data is stored in BigQuery. How should you serve your model while optimizing cost, user experience, and ease of management?

选项

A. 将模型导入BigQuery ML。使用批量读取BigQuery中的数据进行预测，并将数据推送到Cloud SQL。

Import the model into BigQuery ML. Make predictions using batch reading data from BigQuery, and push the data to Cloud SQL

B. 将模型部署到Vertex AI Prediction。使用批量读取Cloud Bigtable中的数据进行预测，并将数据推送到Cloud SQL。

Deploy the model to Vertex AI Prediction. Make predictions using batch reading data from Cloud Bigtable, and push the data to Cloud SQL.

C. 将模型嵌入到移动应用程序中。在每次应用内购买事件通过Pub/Sub发布后进行预测，并将数据推送到Cloud SQL。

Embed the model in the mobile application. Make predictions after every in-app purchase event is published in Pub/Sub, and push the data to Cloud SQL.

D. 将模型部署到Vertex AI Prediction。使用批量读取BigQuery中的数据进行预测，并将预测结果存储在BigQuery中。

Deploy the model to Vertex AI Prediction. Make predictions using batch reading data from BigQuery, and store the predictions in BigQuery.

正确答案：D. Deploy the model to Vertex AI Prediction. Make predictions using batch reading data from BigQuery, and store the predictions in BigQuery.

解析： 这个问题测试如何为游戏环境中的预测模型选择最佳的部署和服务策略，同时优化成本、用户体验和管理便捷性。

选项D是最佳解决方案，原因如下：

1. **数据一致性和简化数据流**：
    - 用户数据已经存储在BigQuery中，直接从BigQuery读取数据进行批量预测是最直接的方法
    - 将预测结果存回BigQuery创建了一个统一的数据存储位置
    - 这种方法避免了在多个数据存储服务（如BigQuery、Cloud SQL和Bigtable）之间移动数据
    - 简化的数据流程大大降低了管理复杂性和潜在的错误
2. **成本效益**：
    - Vertex AI Prediction提供按需扩展能力，只在需要时使用资源
    - 批量预测模式比实时预测更具成本效益，特别是对于不需要立即结果的用例
    - BigQuery的存储和查询价格对于这种预测场景（预测玩家两周内的行为）是经济的
    - 避免了维护额外数据库（如Cloud SQL）的成本
3. **用户体验优化**：
    - 批量预测可以提前完成，为游戏体验调整提供充分准备时间
    - 不需要在移动设备上运行模型，避免了对设备性能和电池的影响
    - Vertex AI提供了稳定的预测性能，确保所有用户获得一致的游戏体验
    - 集中式预测允许更容易地更新模型，无需客户端更新
4. **管理便捷性**：
    - Vertex AI提供了用户友好的界面来管理和监控模型
    - 模型版本控制、监控和日志记录功能便于排查问题
    - 与BigQuery的原生集成简化了数据流管理

    - 不需要在多个服务之间编排复杂的数据转移

其他选项存在的问题：

- 选项A（BigQuery ML）虽然可行，但可能限制了一些TensorFlow模型的高级功能，且将结果推送到Cloud SQL增加了不必要的复杂性
- 选项B（使用Cloud Bigtable）引入了不必要的数据迁移步骤，因为用户数据已经在BigQuery中
- 选项C（嵌入模型到移动应用）会增加应用大小，影响性能，且依赖购买事件触发预测不符合预测未来两周行为的需求

对于需要预测玩家未来两周内购买行为的MMO游戏场景，将模型部署到Vertex AI Prediction并使用BigQuery作为数据源和预测结果存储，提供了最佳的成本、用户体验和管理便捷性平衡。

问题 194

题目

你正在使用BigQuery ML构建线性回归模型，以预测客户购买公司产品的可能性。你的模型使用城市名称变量作为关键预测因素。为了训练和提供模型服务，数据必须以列的形式组织。你希望使用最少的代码准备数据，同时保持可预测的变量。你应该怎么做？

You are building a linear regression model on BigQuery ML to predict a customer's likelihood of purchasing your company's products. Your model uses a city name variable as a key predictive component. In order to train and serve the model, your data must be organized in columns. You want to prepare your data using the least amount of coding while maintaining the predictable variables. What should you do?

选项

A. 使用TensorFlow创建一个带有词汇表的分类变量。创建词汇表文件，并将其作为模型的一部分上传到BigQuery ML。

Use TensorFlow to create a categorical variable with a vocabulary list. Create the vocabulary file, and upload it as part of your model to BigQuery ML.

B. 创建一个不包含城市信息列的新BigQuery视图。

Create a new view with BigQuery that does not include a column with city information

C. 使用Cloud Data Fusion将每个城市分配到标记为1、2、3、4或5的区域，然后在模型中使用该数字表示城市。

Use Cloud Data Fusion to assign each city to a region labeled as 1, 2, 3, 4, or 5, and then use that number to represent the city in the model.

D. 使用Dataprep通过一次性编码方法转换状态列，使每个城市成为具有二进制值的列。

Use Dataprep to transform the state column using a one-hot encoding method, and make each city a column with binary values.

正确答案：A. Use TensorFlow to create a categorical variable with a vocabulary list. Create the vocabulary file, and upload it as part of your model to BigQuery ML.

解析： 这个问题测试如何在BigQuery ML中为包含城市名称这种分类变量的线性回归模型准备数据。

选项A是最佳解决方案，原因如下：

1. **适合BigQuery ML的分类特征处理：**
    - BigQuery ML支持使用词汇表（vocabulary list）处理分类变量
    - 这是处理高基数（有许多不同值）分类变量（如城市名称）的推荐方法
    - 预定义的词汇表确保训练和预测时使用相同的编码映射
    - 这种方法避免了数据泄漏和不一致性问题
2. **最少的代码量要求：**
    - 使用TensorFlow创建词汇表是一个简单的过程，只需几行代码
    - 一旦创建了词汇表，BigQuery ML会自动处理编码过程
    - 这种方法不需要编写复杂的SQL转换或数据处理管道
    - 满足了题目中"使用最少的代码准备数据"的要求
3. **保持可预测变量的能力：**
    - 词汇表方法保留了城市名称的预测能力
    - 它创建了一个有意义的表示，而不是简单地删除或过度简化这一重要特征
    - 这种表示方法可以捕捉城市之间的关系和相似性
    - 满足了题目中"保持可预测的变量"的要求
4. **与BigQuery ML的集成：**
    - BigQuery ML原生支持将词汇表作为模型的一部分上传
    - 这种方法简化了部署和服务流程
    - 词汇表可以与模型一起版本化和管理
    - 这提供了端到端的解决方案，符合BigQuery ML的最佳实践

其他选项存在的问题：

- 选项B（创建不包含城市信息的视图）完全移除了一个关键预测变量，题目明确指出城市名称是"关键预测因素"
- 选项C（将城市映射到5个区域）过度简化了数据，可能丢失了大量信息，且需要额外的Cloud Data Fusion流程
- 选项D（使用一次性编码创建二进制列）对于城市这种基数很高的变量可能会创建太多列，导致模型复杂度增加并可能引起过拟合

对于在BigQuery ML中处理城市名称这种分类变量，使用TensorFlow创建词汇表并将其作为模型的一部分上传是最佳方法，它平衡了代码简洁性和保持变量预测能力的需求。